模式识别

刘文黎

liu_wenli@hust.edu.cn

土木与水利工程学院

第2章 基于贝叶斯决策理论的分类器

本章主要内容

2.1 引言: 一个简单的例子
2.2 贝叶斯决策理论
2.3 判别函数和决策面
2.4 正态分布的贝叶斯分类
2.5 未知概率密度函数的估计
2.6 最近邻准则
2.7 贝叶斯网络

2.1 引言：一个简单的例子

- 分类可以看成一种决策
- 给一个硬币x，没有任何信息，猜是1角(ω_1)还是5角(ω_2)
  - 错误率（类别决策错误的概率）

$$\mathrm{P}(\text{error}) = 1 - \mathrm{P}(\omega_1) = \mathrm{P}(\omega_2) \quad (\text{如果决策 } x \in \omega_1)$$

  - 决策规则（最小错误率准则）：没有考虑两类概率相同的情况

$$x \begin{cases} \in \omega_1 & \mathrm{P}(\omega_1) > \mathrm{P}(\omega_2) \\ \in \omega_2 & \mathrm{P}(\omega_1) < \mathrm{P}(\omega_2) \end{cases}$$

  - 先验概率 (Priori probability)：$\mathrm{P}(\omega_i)$

- 给一个硬币，已知重量x，猜是1角还是5角
  - 后验概率 (posterior probability)

$$P(\omega_i|\mathrm{x})$$

  - 决策规则

$$x\begin{cases}\in\ \omega_1 & P(\omega_1|x)\ > P(\omega_2|\mathrm{x}) \\ \in\ \omega_2 & P(\omega_1|\mathrm{x})\ < P(\omega_2|\mathrm{x})\end{cases}$$

  - 错误率

$$\mathrm{P}(\mathrm{error}|x) = 1 - \mathrm{P}(\omega_1|x) = \mathrm{P}(\omega_2|x) \quad (\text{如果决策 } x \in\ \omega_1)$$

  - 贝叶斯公式 (Bayes formula)

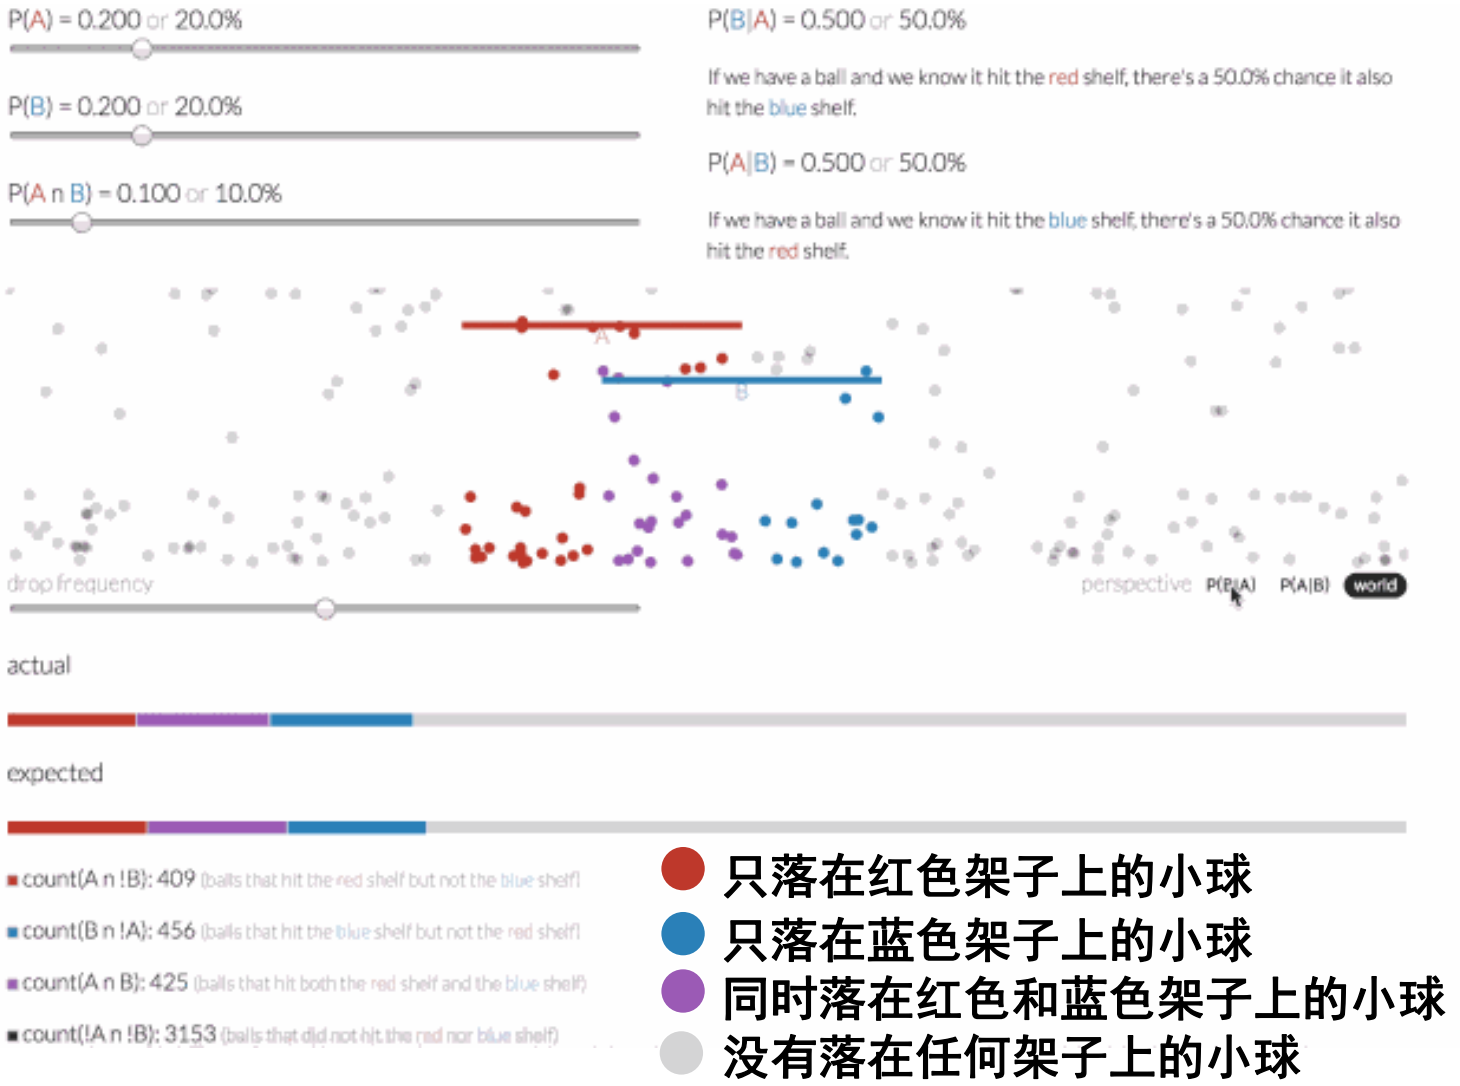
$$P(\omega_i|\mathrm{x}) = \frac{P(\omega_i,\mathrm{x})}{P(\mathrm{x})} = \frac{P(\mathrm{x}|\omega_i)P(\omega_i)}{P(\mathrm{x})}$$

$P(\mathrm{x})$为两类硬币重量的概率密度，$P(\mathrm{x}|\omega_i)$为第i类硬币重量的概率密度，称为类条件密度

• 条件概率

条件概率是指一个事件在另外一个事件已经发生条件下的发生概率。一个落下来的球可能落在红色的架子上(称之为A事件)，或者落在蓝色架子上(称之为B事件)，或者两者兼而有之。

那么给定一个球，它击中了红色架子（A事件），而后击中蓝色架子（B事件）的概率会是多少呢？可以通过给定A的条件概率，即P（B | A）来回答这个问题。



只落在红色架子上的小球
只落在蓝色架子上的小球
同时落在红色和蓝色架子上的小球
没有落在任何架子上的小球

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{\bullet}{\bullet + \bullet}$$

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{\bullet}{\bullet + \bullet}$$

$$\Rightarrow \quad P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

2.2 贝叶斯决策理论

贝叶斯决策（统计决策理论）

是统计模式识别的基本方法和基础，是“最优分类器”：使平均错误率最小

条件：

类别数一定，ω_1，i=1,⋯,c（决策论中把类别称作状态）

已知类先验概率和类条件概率密度

$$P(\omega_i)，\ P(\mathrm{x}|\omega_i)，\ i=1,\cdots,c$$

目标：根据特征x判定类别ω ⟷ 计算后验概率$P(\omega_i|\mathrm{x})$

统计决策公式：

基于两类问题，在样本x上错误概率：$p(e|x)=\begin{cases}P(\omega_2|x), x \in \omega_1\\ P(\omega_1|x), x \in \omega_2\end{cases}$

错误率（错误概率的期望）：$P(e)=\int p(e|x)p(x)\,dx$

对特征x的取值空间做积分

2.2.1 最小化分类错误概率

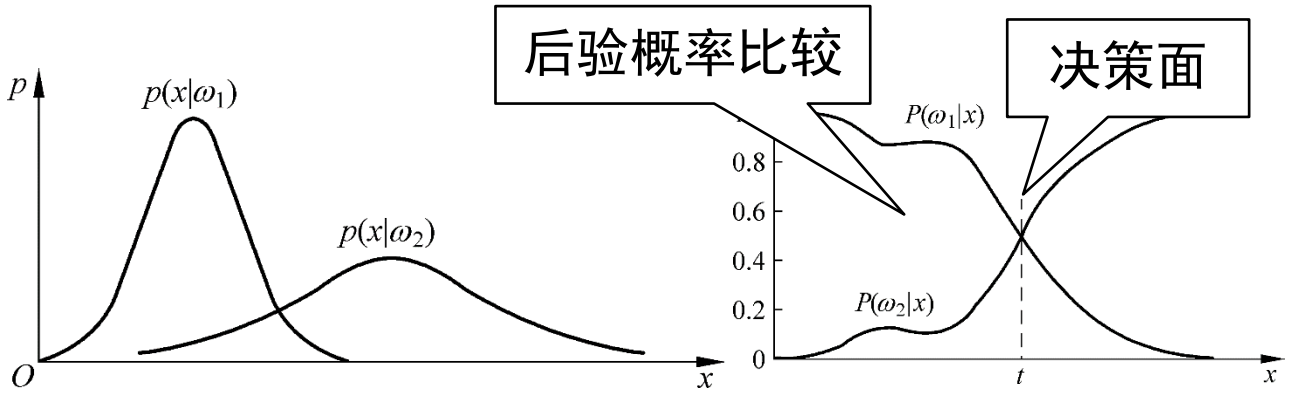
$$\min \mathrm{P}(\mathrm{error}) = \min \int \mathrm{P}(\mathrm{error}|x)\mathrm{P}(x)dx \Rightarrow \min \mathrm{P}(\mathrm{error}|x) \ \ \forall x$$

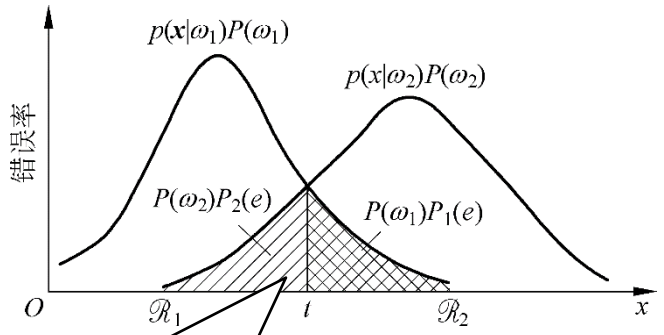
$$\mathrm{P}(\mathrm{error}|x) = 1 - \mathrm{P}(\omega_1|x) = \mathrm{P}(\omega_2|x) \quad (\text{如果决策 } x \in \omega_1)$$

似然比

$$\text{若 } l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \leqslant \lambda = \frac{P(\omega_2)}{P(\omega_1)}, \quad \text{则 } x \in \begin{cases} \omega_2 \\ \omega_1 \end{cases}$$

$p(x|\omega_1)$反映了在ω_1类中观察到特征值x的相对可能性





判断错误区域为阴影面积之和

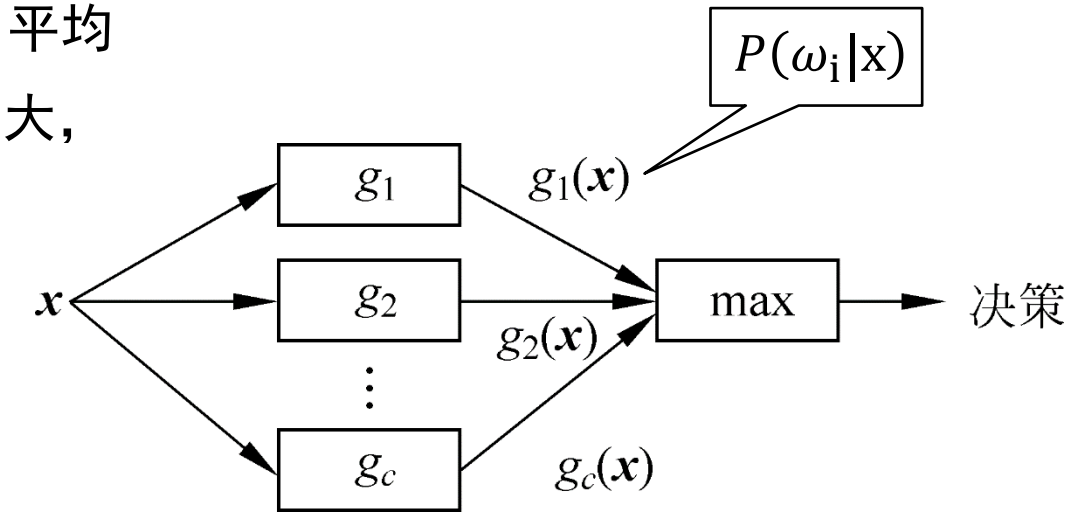
最小错误率准则 **等价于** 后验概率最大（决策面）

- 多类判别决策
  - $P(\omega_i|x) = \max_{j=1,\cdots,c} P(\omega_j|x) \Rightarrow x\epsilon\omega_i$
  - $P(x|\omega_i)P(\omega_i) = \max_{j=1,\cdots,c} P(x|\omega_j)P(\omega_j) \Rightarrow x\epsilon\omega_i$

可以把每类后验概率$P(\omega_i|x)$或$P(x|\omega_i)P(\omega_i)$看做判别函数$g_i(x)$,决策过程为寻找判别函数的最值

多决策过程，将特征空间分割成c个区域，平均错误概率$P(e)$将由c(c-1)组成，计算量非常大，可以通过计算平均正确率来计算错误率

$P(e) = 1 - P(c)$



例：

假设在某个局部地区细胞识别中，正常（ ω_1 ）和异常（ ω_2 ）两类的先验概率分别为正常状态$P(\omega_1)$ =0.9，异常状态$P(\omega_2)$ =0.1，现有一待识别细胞，其观察值为*x*,从类条件概率密度曲线上分别查得$p(x|\omega_1)$=0.2, $p(x|\omega_2)$=0.4，试对该细胞*x*进行分类。

利用贝叶斯公式，分别计算出ω_1 和ω_2 的后验概率

$$P(\omega_1|x) = \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^{2} p(x|\omega_j)P(\omega_j)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$

$$P(\omega_2|x) = 1 - P(\omega_1|x) = 0.182$$

根据贝叶斯决策规则， $\mathrm{P}(\omega_1|\mathrm{x}) > \mathrm{P}(\omega_2|\mathrm{x})$，所以合理的决策是*x*为正常状态

也可以通过求解似然比及其阈值来分析

似然比： $l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} = \frac{0.2}{0.4} = 0.5$　　似然比阈值：$\lambda = \frac{p(\omega_2)}{p(\omega_1)} = \frac{0.1}{0.9} \approx 0.1$

$l(x) > \lambda$，因此决策为第一类，即正常状态

2.2.2 最小化平均风险

- 最小错误率

$$\mathrm{P}(\mathrm{error}|x)=\begin{cases}\mathrm{P}(\omega_2|x) & (\text{如果决策 } x\in\omega_1)\\ \mathrm{P}(\omega_1|x) & (\text{如果决策 } x\in\omega_2)\end{cases}$$

只考虑了错误，下面考虑不同错误带来的损失

$$\min \mathrm{P}(\mathrm{error})=\min\int \mathrm{P}(\mathrm{error}|x)\mathrm{P}(x)dx$$

- 风险 $R(\alpha_i|x)=\sum_{j=1}^{c}\lambda(\alpha_i,\omega_j)P(\omega_j|x),\quad i=1,\cdots,k$（对于X采取决策$\alpha_i$ 带来的损失）

（R=P C）

损失函数

- 最小风险（决策规则）

$$R(\alpha_i|x)=\begin{cases}\lambda(\alpha_1,\omega_2)\cdot\mathrm{P}(\omega_2|x) & (\text{如果决策 } x\in\omega_1)\\ \lambda(\alpha_2,\omega_1)\cdot\mathrm{P}(\omega_1|x) & (\text{如果决策 } x\in\omega_2)\end{cases}$$

$$\min \mathrm{R}(\alpha)=\min\int R(\alpha(x)|x)\mathrm{P}(x)dx$$

平均期望风险最小化

- 最小风险贝叶斯决策

$$\alpha = \arg\min_{i=1,\cdots,k} R(\alpha_i|x)$$

在实际是两类且决策也是两类的情况下（没有拒绝），最小风险贝叶斯决策为

若 $\lambda_{11}\mathrm{P}(\omega_1|x) + \lambda_{12}\mathrm{P}(\omega_2|x) \leqslant \lambda_{21}\mathrm{P}(\omega_1|x) + \lambda_{22}\mathrm{P}(\omega_2|x)$， 则 $x \in \begin{cases}\omega_1\\ \omega_2\end{cases}$

其中$\lambda_{12} = (\alpha_1，\ \omega_2)$是把属于第2类的样本分为第1类时的损失， $\lambda_{21} = (\alpha_2，\ \omega_1)$是把属于第1类的样本分为第2类时的损失， $\lambda_{11} = (\alpha_1，\ \omega_1)$、 $\lambda_{22} = (\alpha_2，\ \omega_2)$是决策正确时的损失。

通常， $\lambda_{11} = \lambda_{22}$=0。

损失函数
决策表

状态 / 损失 / 决策	自然状态					
	ω_1	ω_2	…	ω_j	…	ω_c
α_1	$\lambda(\alpha_1,\omega_1)$	$\lambda(\alpha_1,\omega_2)$	…	$\lambda(\alpha_1,\omega_j)$	…	$\lambda(\alpha_1,\omega_c)$
α_2	$\lambda(\alpha_2,\omega_1)$	$\lambda(\alpha_2,\omega_2)$	…	$\lambda(\alpha_2,\omega_j)$	…	$\lambda(\alpha_2,\omega_c)$
⋮	⋮	⋮	⋮	⋮	⋮	⋮
α_i	$\lambda(\alpha_i,\omega_1)$	$\lambda(\alpha_i,\omega_2)$	…	$\lambda(\alpha_i,\omega_j)$	…	$\lambda(\alpha_i,\omega_c)$
⋮	⋮	⋮	⋮	⋮	⋮	⋮
α_a	$\lambda(\alpha_a,\omega_1)$	$\lambda(\alpha_a,\omega_2)$	…	$\lambda(\alpha_a,\omega_j)$	…	$\lambda(\alpha_a,\omega_c)$

例2

假设在某个局部地区细胞识别中，正常（ ω_1 ）和异常（ ω_2 ）两类的先验概率分别为正常状态$P(\omega_1)$ =0.9，异常状态$P(\omega_2)$ =0.1，现有一待识别细胞，其观察值为x,从类条件概率密度曲线上分别查得$p(x|\omega_1)$=0.2, $p(x|\omega_2)$=0.4,此题，我们给定$\lambda = (\lambda_{11}, \lambda_{12}, \lambda_{21}, \lambda_{22}) = (0,6,1,0)$,试利用最小风险贝叶斯决策对该细胞$x$进行分类。

通过例1，得出ω_1 和ω_2 的后验概率$\mathrm{P}(\omega_1|\mathrm{x}) = 0.818$，$\mathrm{P}(\omega_2|\mathrm{x}) = 0.182$

计算条件风险：

$\mathrm{R}(\alpha_1|\mathrm{x}) = \sum_{\mathrm{j}=1}^{2} \lambda_{1\mathrm{j}} \mathrm{P}(\omega_\mathrm{j}|\mathrm{x}) = \lambda_{12}\mathrm{P}(\omega_2|\mathrm{x}) = 1.092$

$\mathrm{R}(\alpha_2|\mathrm{x}) = \lambda_{21}\mathrm{P}(\omega_1|\mathrm{x})$ =0.818

由于$\mathrm{R}(\alpha_1|\mathrm{x}) > \mathrm{R}(\alpha_2|\mathrm{x})$，即决策2风险小，因此被判定为异常细胞



决策表的制定

- 最小风险贝叶斯决策中的损失函数$\lambda(\alpha_i, \omega_j)$决策表是需要人为确定的，决策表不同会导致决策结果的不同
- 在实际应用中，需要认真分析所研究问题的内在特点和分类的目的
- 与应用领域的专家共同设计出适当的损失函数决策表



2.2.3 两类错误率、Neyman-Pearson决策与ROC曲线

- 两类错误率及评价指标：分类错误的损失不同
  - 两类：阳性 (positive)、阴性 (negative)
  - 第一类错误率 (假阳性Type-I error rate) $\alpha = \frac{FP}{FP+TN}$
  - 第二类错误率 (假阴性Type-II error rate) $\beta = \frac{FN}{FN+TP}$
  - 灵敏度 (sensitivity) $S_n = \frac{TP}{TP+FN}$
  - 特异度 (specificity) $S_p = \frac{TN}{TN+FP}$

虚警

决策 \ 状态	阳性	阴性
阳性	真阳性 (TP)	假阳性 (FP)
阴性	假阴性 (FN)	真阴性 (TN)

漏检

- 其他常用评价指标
  - 正确率 (accuracy)　　$\mathrm{Acc} = \frac{\mathrm{TP}+TN}{\mathrm{TP}+TN+FP+FN}$（所有样本被正确分类的比例）
  - 召回率 (recall)　　$\mathrm{Rec} = \frac{TP}{TP+FN}$（阳性样本中被正确分类为阳性的比例，即灵敏度）
  - 正确率 (precision)　　$\mathrm{Pre} = \frac{TP}{TP+FP}$（分类器判定为阳性的样本中正确判断的比例）
  - F度量 (F-measure)　　$F = \frac{2Rec \cdot Pre}{Rec+\mathrm{Pre}}$（召回率和正确率的调和平均，综合评价）

状态 / 决策	阳性	阴性
阳性	真阳性 (TP)	假阳性 (FP)
阴性	假阴性 (FN)	真阴性 (TN)

Neyman-Pearson决策

- Neyman-Pearson决策规则：要求一类错误率控制在很小，在此前提下使另一类错误率尽可能小

$$\min P_1(e) \qquad s.t.\ P_2(e) = \varepsilon_0 \ \ (\varepsilon_0 > 0)$$

- 拉格朗日 (Lagrange) 乘子法

拉格朗日乘子

$$\min \gamma = \min P_1(e) + \lambda\,(\,P_2(e) - \varepsilon_0)$$

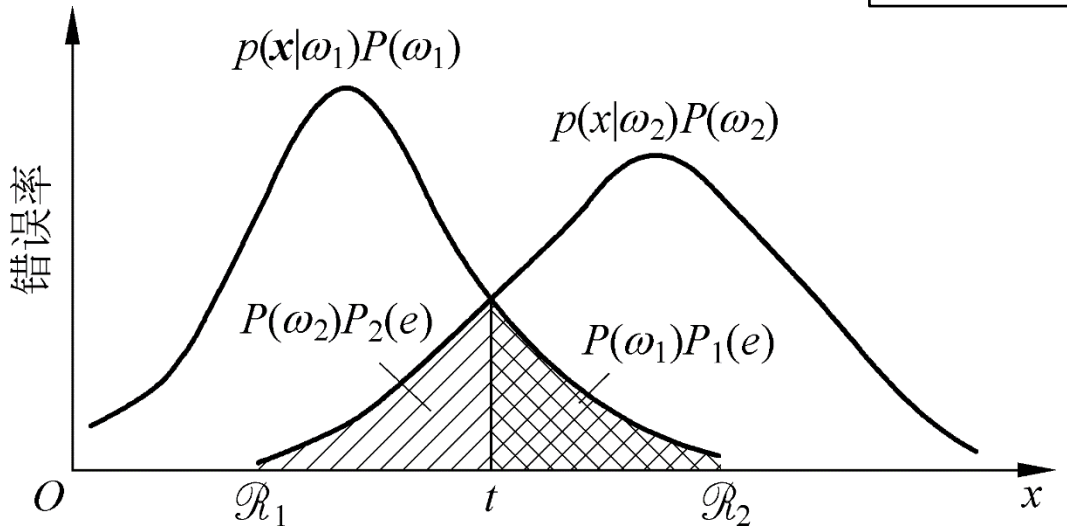
- 决策准则：

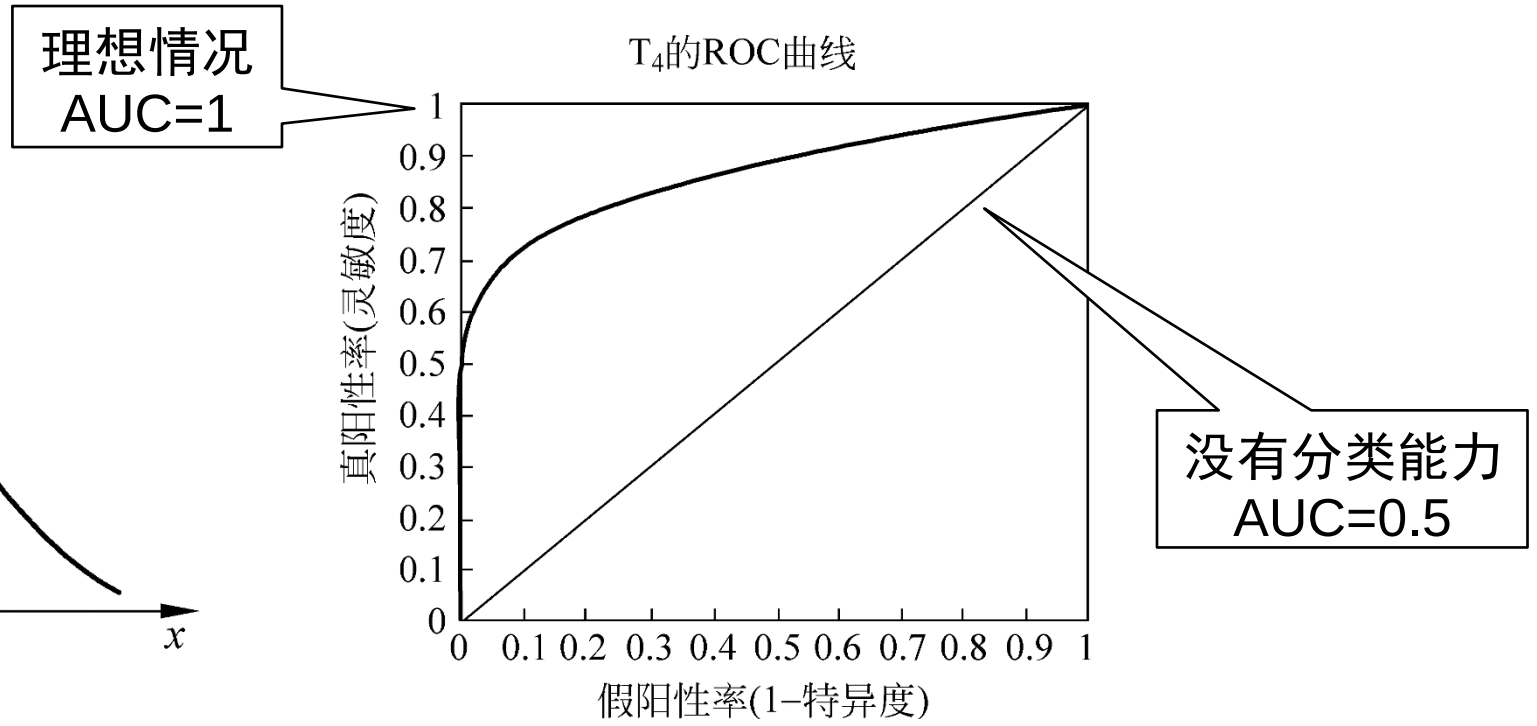
$$l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \begin{matrix} > \\ < \end{matrix} \lambda, \quad \text{则} \quad x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

λ可根据$P_2(e) = 1 - \int_0^{\lambda} p(l|\omega_2)dl = \varepsilon_0$用数值方法求解，或根据ROC曲线决定

ROC曲线

- ROC (Receiver Operating Characteristic) 曲线
- AUC (Area Under ROC curves) 曲线下面积（面积越大，分类效果越好）





应用：医学数字成像诊断试验检查瓣膜的断裂情况

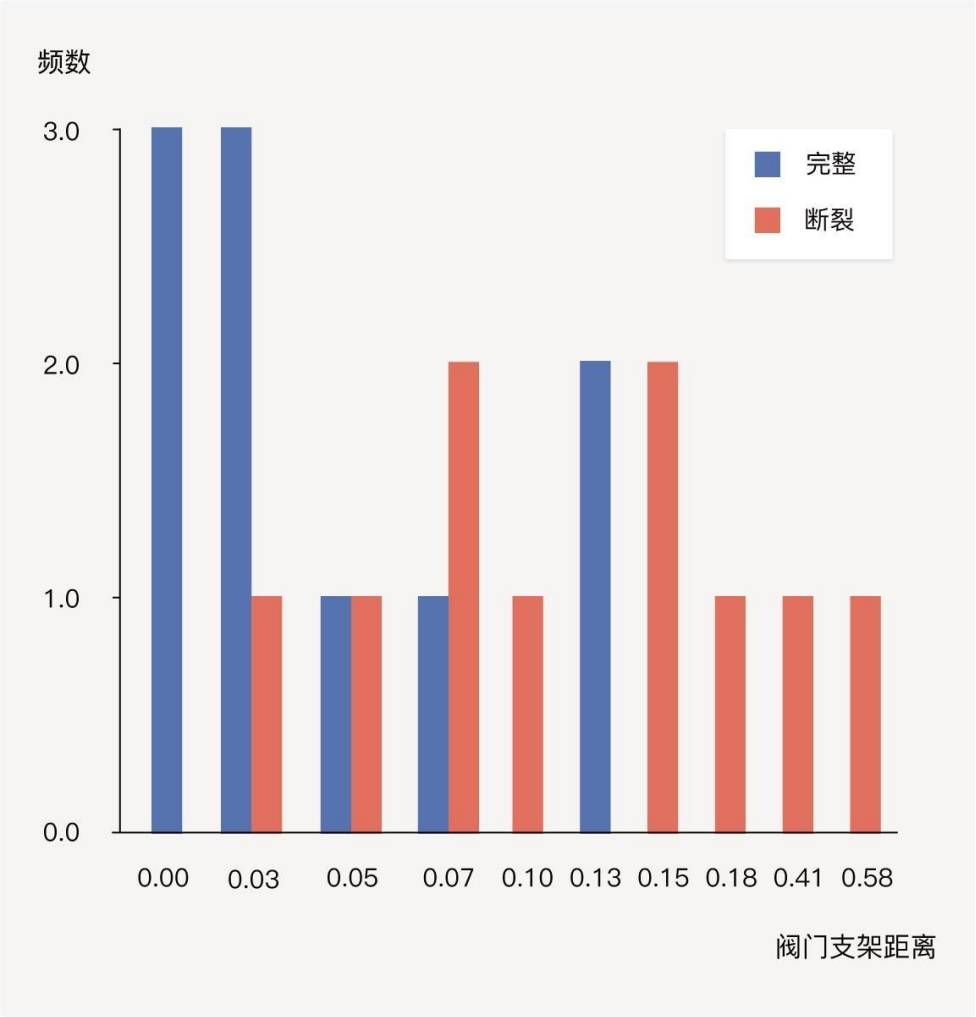


图1. 受试者心脏瓣膜情况和阀门支架距离之间的关系

有20位受试者体内含有植入式人工心脏瓣膜，现拟采用数字成像诊断试验检查瓣膜的断裂情况。常用的检查方法是测量**阀门支架之间的距离，距离越大，瓣膜断裂的可能性越大**。经手术发现，这20位受试者的瓣膜断裂情况和阀门支架距离的关系如图。

瓣膜断裂受试者的阀门支架距离在0.03到0.58之间，瓣膜完好受试者的阀门支架距离在0.0到0.13之间。

应用：医学数字成像诊断试验检查瓣膜的断裂情况

表1. 心脏瓣膜诊断试验的灵敏度和特意度分布情况

截点设置	灵敏度	特异度	假阴性率	假阳性率
> 0.58	0.0	1.0	1.0	0.0
> 0.13	0.5	1.0	0.5	0.0
> 0.07	0.6	0.8	0.4	0.2
> 0.05	0.8	0.7	0.2	0.3
> 0.03	0.9	0.6	0.1	0.4
> 0.0	1.0	0.3	0.0	0.7
≥ 0.0	1.0	0.0	0.0	1.0

为了评价该数字成像诊断试验的灵敏度和特异度，我们设置**诊断截点为0.05**，即认为阀门支架距离大于0.05的受试者是瓣膜断裂阳性，小于或等于0.05的受试者是瓣膜断裂阴性。从而计算出**该诊断试验的灵敏度为0.80，特异度为0.70**。

当然，我们知道如果我们**选择其他截点**，该诊断试验的**灵敏度**和**特异度**都会**发生相应变化**。如果我们选择比较大的阀门支架距离为诊断截点，如0.13，那么灵敏度就会下降到0.50，而特异度会增加到1.0。如果我们选择比较小的阀门支架距离为诊断截点，如0.03，那么灵敏度会增加到0.90，而特异度会降低到0.60。这个例子说明，在**同一诊断试验中，灵敏度和特异度之间存在内在联系，即一个增加，另一个就会减低。**在这项诊断试验中，设置不同截点时灵敏度和特异度的变化情况如表。

医咖会

应用：医学数字成像诊断试验检查瓣膜的断裂情况

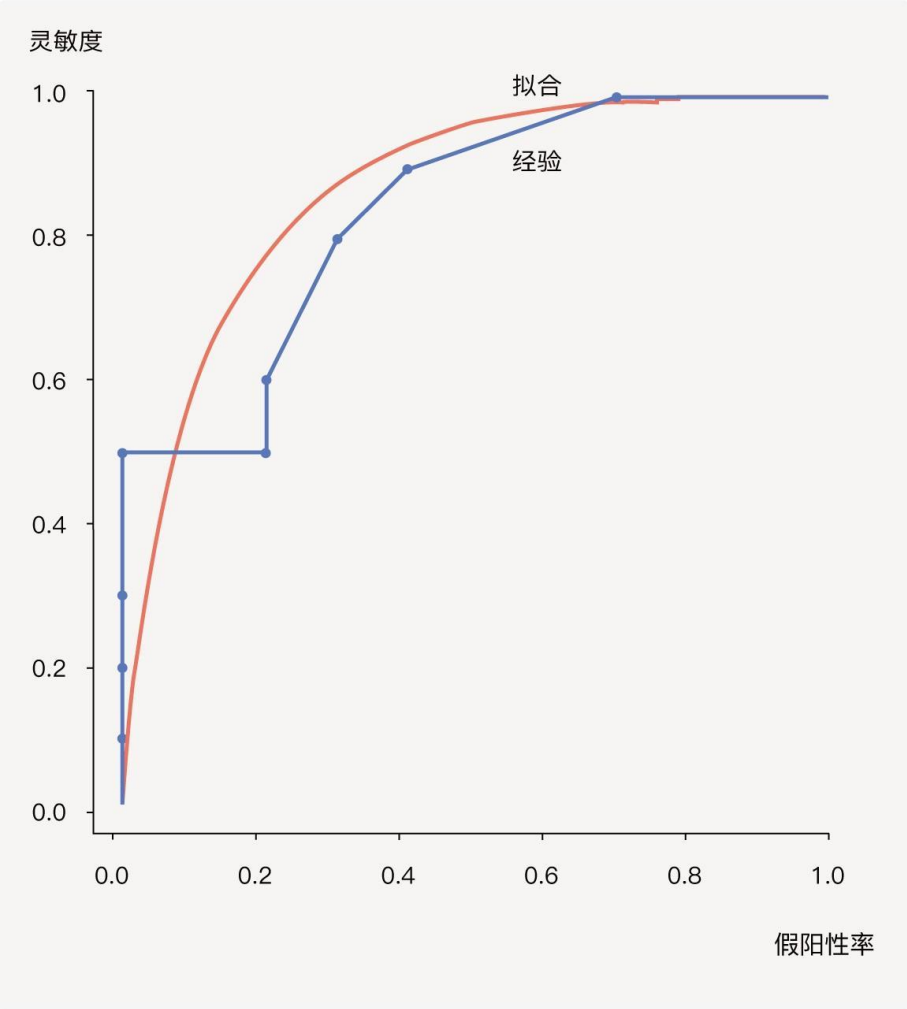


图2. 瓣膜断裂诊断试验的经验和拟合ROC曲线图

医咖会

接下来，我们就可以根据该诊断试验中**灵敏度(y)**和**假阳性率(x)**（1-特异度）相应的数值来绘制ROC曲线了。

例如，当截点为0.07时，该诊断试验的灵敏度为0.6，假阳性率为0.2，即我们可以在坐标上取点（0.2，0.6）。以此类推，我们可以得到很多这样的坐标点，并将他们连接起来，绘制出经验ROC曲线。但同时，我们也可以根据这些坐标点绘制出**拟合ROC曲线**，如图。

应用：用于诊断COVID-19肺炎的研究案例

IEEE TRANSACTIONS ON MEDICAL IMAGING, VOL. 39, NO. 8, AUGUST 2020 2595

Dual-Sampling Attention Network for Diagnosis of COVID-19 From Community Acquired Pneumonia

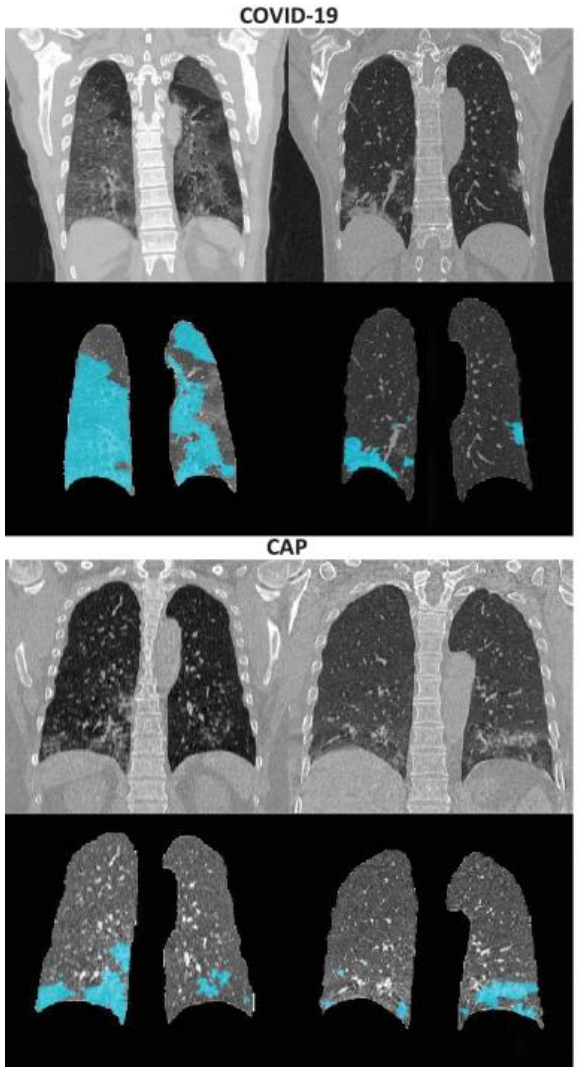
Xi Ouyang, Jiayu Huo, Liming Xia, Fei Shan, Jun Liu, Zhanhao Mo, Fuhua Yan, Zhongxiang Ding, Qi Yang, Bin Song, Feng Shi, Huan Yuan, Ying Wei, Xiaohuan Cao, Yaozong Gao, Dijia Wu, Qian Wang, and Dinggang Shen

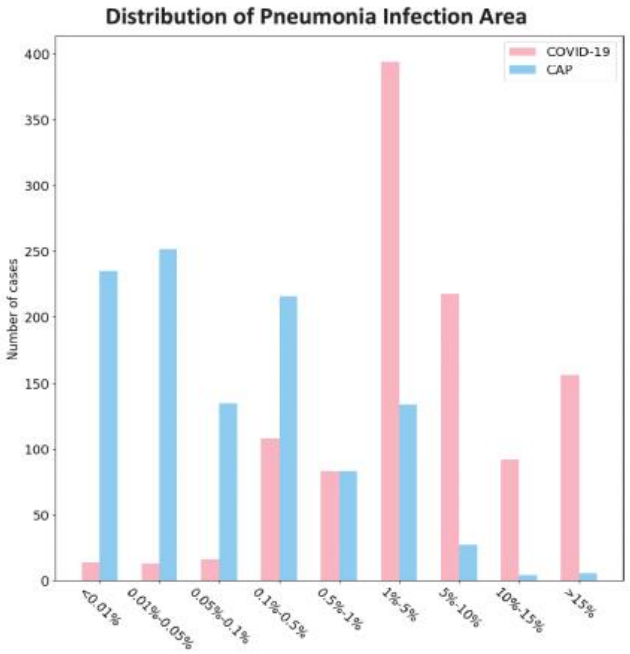
Title: 社区获得性肺炎COVID-19诊断双采样注意力网络

Abstract:

在早期检测冠状病毒COVID-19，以提供适切医疗服务和保护未感染人群，具有极其重要的意义。**为此，我们创造了一个双抽样注意力网络，用于自动分析社区采集的胸部计算机断层扫描（CT），以诊断COVID-19引发的肺炎**。我们引入了一种新型的在线注意力模块，结合了三维卷积网络（CNN），以在诊断过程中聚焦于肺部感染区域。值得注意的是，COVID-19和CAP的感染区域存在不均衡的分布，部分原因是COVID-19病情的快速进展。因此，我们采用了双抽样策略，以解决这一学习不均衡的问题。我们的方法基于来自8家顶尖医院的COVID-19多中心CT数据进行了评估（据我们了解）。在训练-验证阶段，我们收集了1588名患者的2186张CT扫描图，进行了5倍交叉验证。在测试阶段，我们使用了另一个独立的大规模测试数据集，其中包含2057名患者的2796张CT扫描。研究结果显示，我们的算法能够有效辨别COVID-19图像，其接受者操作**特征曲线下的面积（AUC）值达到0.944，准确率为87.5%，敏感性为86.9%，特异性为90.1%，F1分数为82.0%**。鉴于这一出色表现，我们的算法有望在CAP诊断COVID-19方面为放射科医生提供支持，尤其是在COVID-19爆发的早期阶段。

应用：用于诊断COVID-19肺炎的研究案例





1.自动分割肺部和肺炎感染区域

两个COVID-19患者（左上）和两个CAP患者（左下）的CT图像和**感染分割**的例子，以及我们训练-验证集中COVID-19和CAP**感染区域的大小分布**（右）。肺部和感染区域的分割结果来自一个成熟的VB-Net工具包。感染区域的大小由分割的感染区域和整个肺部的体积比来表示。与CAP相比，COVID-19病例在感染区域大小方面往往有更严重的感染。

应用：用于诊断COVID-19肺炎的研究案例

Results		TV set	Test set
AUC	RN34 + US	0.984	0.934±0.011
	Attention RN34 + US	0.986	**0.948±0.003**
	Attention RN34 + SS	0.987	0.938±0.002
	Attention RN34 + DS	**0.988**	0.944±0.003
准确度 Accuracy	RN34 + US	0.945	0.859±0.013
	Attention RN34 + US	0.947	**0.879±0.012**
	Attention RN34 + SS	0.951	0.869±0.008
	Attention RN34 + DS	**0.954**	0.875±0.009
灵敏度 Sensitivity	RN34 + US	0.931	0.856±0.029
	Attention RN34 + US	0.941	**0.872±0.018**
	Attention RN34 + SS	0.953	0.868±0.020
	Attention RN34 + DS	**0.954**	0.869±0.016
特异性 Specificity	RN34 + US	**0.959**	0.870±0.071
	Attention RN34 + US	0.953	**0.907±0.029**
	Attention RN34 + SS	0.948	0.876±0.048
	Attention RN34 + DS	0.954	0.901±0.025
F度量 F1-score	RN34 + US	0.945	0.798±0.011
	Attention RN34 + US	0.947	**0.825±0.013**
	Attention RN34 + SS	0.951	0.811±0.004
	Attention RN34 + DS	**0.954**	0.820±0.008

2.数据集测试结果

验证数据集(TV set)和测试数据集(Test set)上不同模型分类结果的比较。

RN34：3D ResNet34;

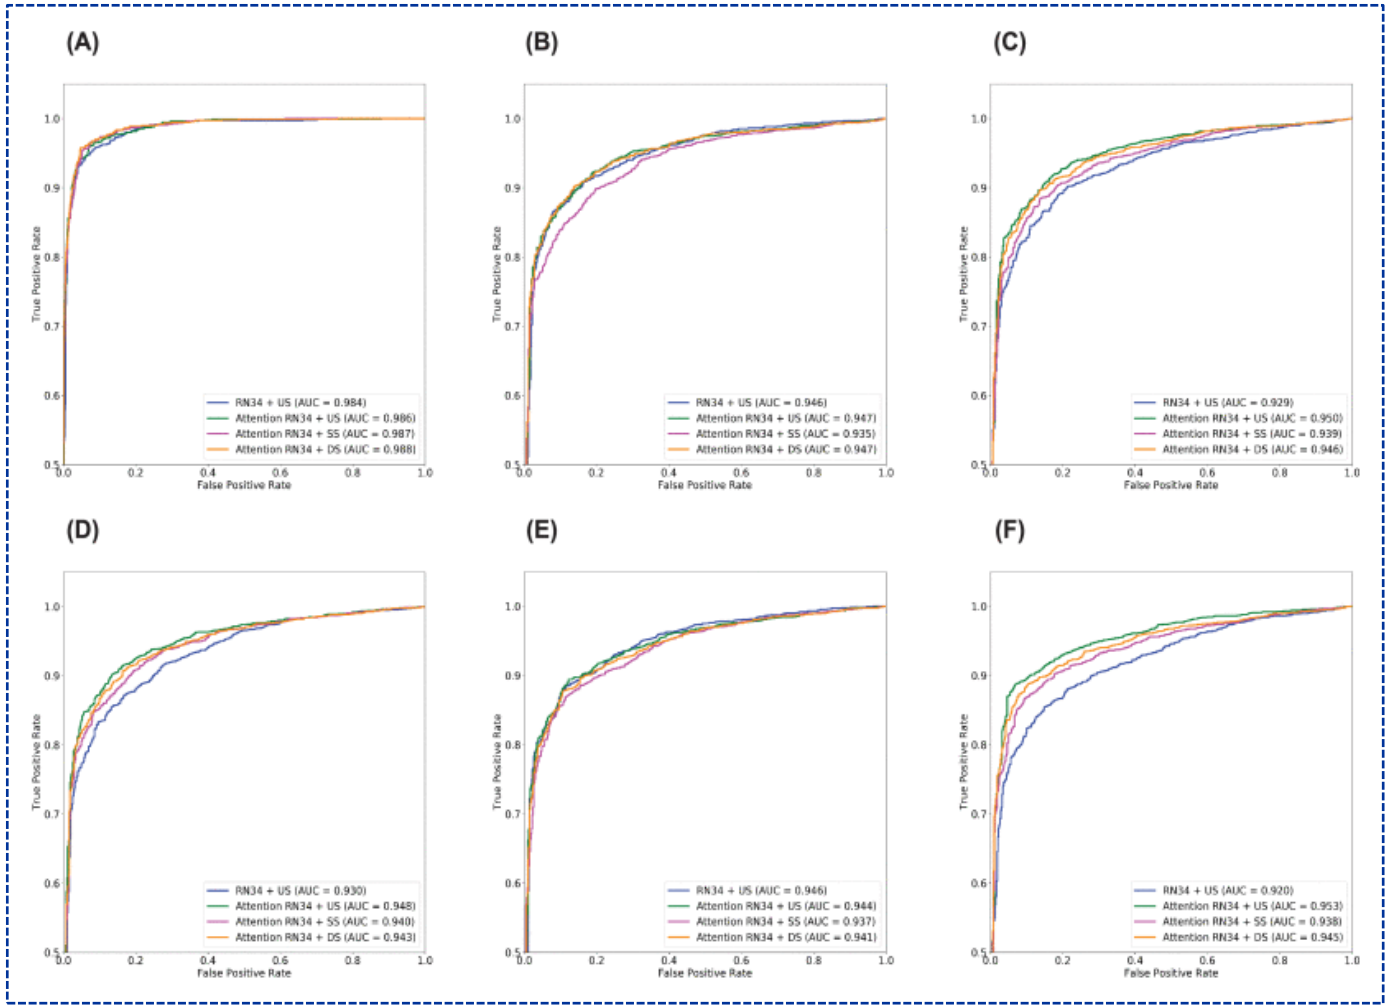
US：统一抽样;

SS：大小平衡采样;

DS：双采样

AUC、**准确度**、**灵敏度**、**特异性**和 **F1 评分**的结果见此表。TV set上的结果是 5 个验证集的综合结果。对于Test set的结果，我们显示了每个训练验证折叠的五个训练模型的平均±标准差）分数

应用：用于诊断COVID-19肺炎的研究案例



3.ROC曲线反映诊断精度

验证数据集(TV set)和测试数据集(Test set)的 ROC 曲线。

（A） TV set的ROC曲线为5倍。

（B）使用TV set fold1的模型测试数据集的ROC曲线。

（C）使用TV set fold2的模型测试数据集的ROC曲线。

（D）使用TV set fold3的模型测试数据集的ROC曲线。

（E）使用TV set fold4的模型测试数据集的ROC曲线。

（F）使用TV set fold5的模型测试数据集的ROC曲线。

2.3 判别函数和决策面

- 判别函数
  - 概率密度函数 $\mathrm{p}(\boldsymbol{x}|\omega_i)=\frac{1}{(2\pi)^{d/2}|\boldsymbol{\Sigma}_i|^{1/2}}exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i{}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)\right\}$
  - 判别函数（对数形式）

$$\mathrm{g_i}(\boldsymbol{x})=\ln\big(\mathrm{p}(\boldsymbol{x}|\omega_i)\mathrm{p}(\omega_i)\big)=-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i{}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)+\ln\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_i|^{\frac{1}{2}}}+\ln\mathrm{p}(\omega_i)$$

- 决策面方程

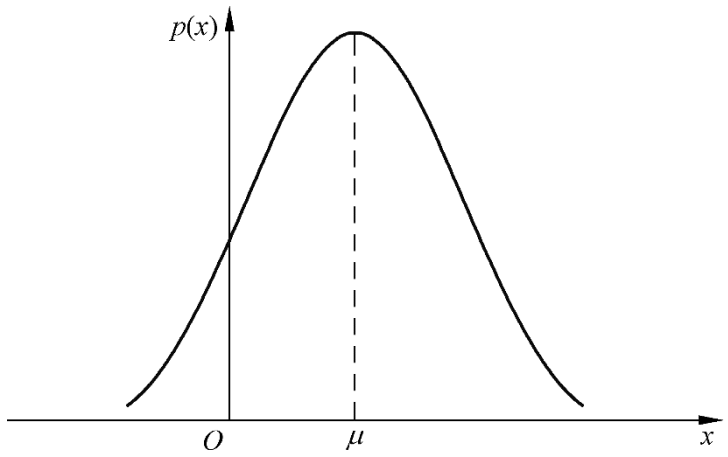
$$\mathrm{g_i}(\boldsymbol{x})=\mathrm{g_j}(\boldsymbol{x})\Rightarrow-\frac{1}{2}\Big[(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i{}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)-\big(\boldsymbol{x}-\boldsymbol{\mu}_j\big)^T\boldsymbol{\Sigma}_j{}^{-1}\big(\boldsymbol{x}-\boldsymbol{\mu}_j\big)\Big]-\frac{1}{2}\ln\frac{|\boldsymbol{\Sigma}_i|}{|\boldsymbol{\Sigma}_j|}+\ln\frac{\mathrm{p}(\omega_i)}{\mathrm{p}\big(\omega_j\big)}=0$$

2.4 正态分布时的贝叶斯决策

- 单变量正态分布 $\mathrm{N}(\mu,\sigma^2)$

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}$$

$$\mu=E\{x\}=\int_{-\infty}^{\infty}xp(x)dx \qquad \sigma^2=\int_{-\infty}^{\infty}(x-\mu)^2p(x)dx$$



- 多元正态分布 $\mathrm{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$

$$p(\boldsymbol{x})=\frac{1}{(2\pi)^{d/2}|\boldsymbol{\Sigma}|^{1/2}}exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right\}$$

$\boldsymbol{x}$是$\boldsymbol{d}$维列向量，

$\mu=E\{\boldsymbol{x}\}$ $\boldsymbol{\Sigma}=E\{(\boldsymbol{x}-\boldsymbol{\mu})(\boldsymbol{x}-\boldsymbol{\mu})^T\}$

称X服从d维正态分布，记X~$N_d(\mu,\Sigma)$,参数μ，$\sum$分别为X的均值和协方差

正态分布的性质 (1)

- 多元正态分布由均值$\boldsymbol{\mu}$和协方差$\boldsymbol{\Sigma}$完全确定

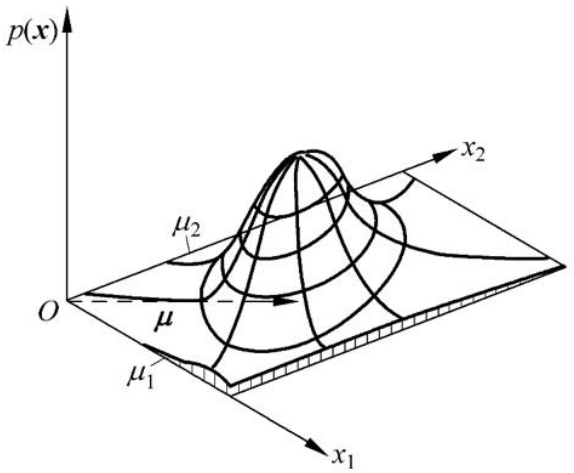
  多元正态分布概率密度函数记为$p(x)\sim N(\mu,\boldsymbol{\Sigma})$

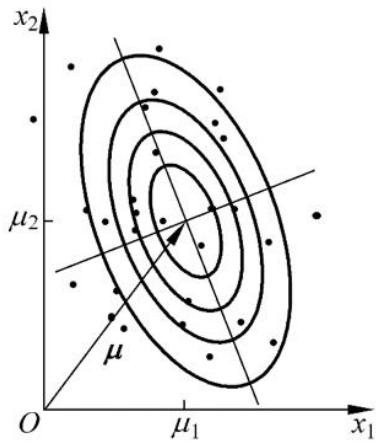
- 等密度点形成超椭球面

  形成条件：密度$p(x)$值不变，即

  $(\boldsymbol{x}-\boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})$=常数

- 不相关性等价于独立性
  - 若分量x_i和分量x_j不相关 → x_i和x_j相互独立
  - 若协方差矩阵$\boldsymbol{\Sigma}$为对角阵→ 各分量相互独立





正态分布的性质 (2)

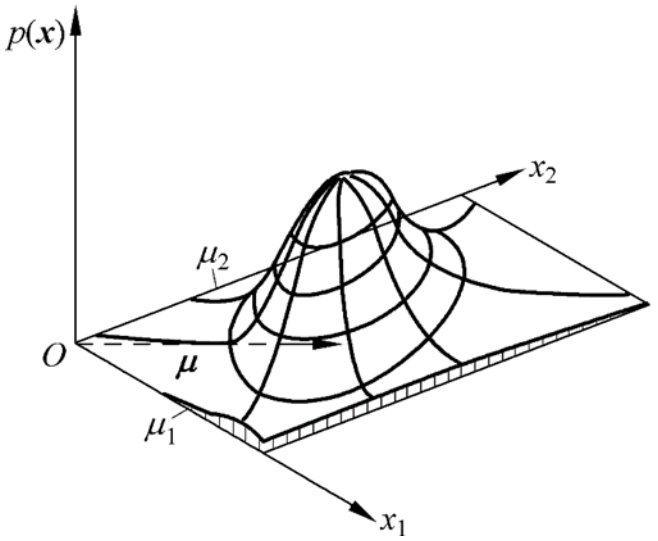
- 多元正态分布的边缘分布是正态分布

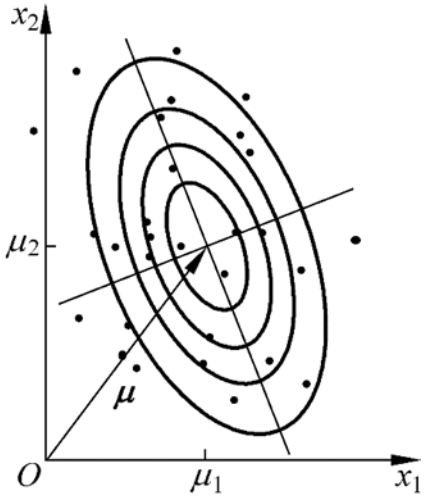
$$p(x_i) \sim N(\mu_i, \sigma_{ii}^2)$$

- 多元正态分布的条件分布是正态分布
- 多元正态随机向量的线性变换仍为多元正态分布

$$\begin{cases} \mathrm{p}(\boldsymbol{x}) \sim \mathrm{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ \boldsymbol{y} = A\boldsymbol{x} \end{cases} \Rightarrow \quad p(\boldsymbol{y}) \sim \mathrm{N}\left(A\boldsymbol{\mu}, A\boldsymbol{\Sigma}A^T\right)$$

  - 多元正态随机向量的线性组合为一维正态随机变量





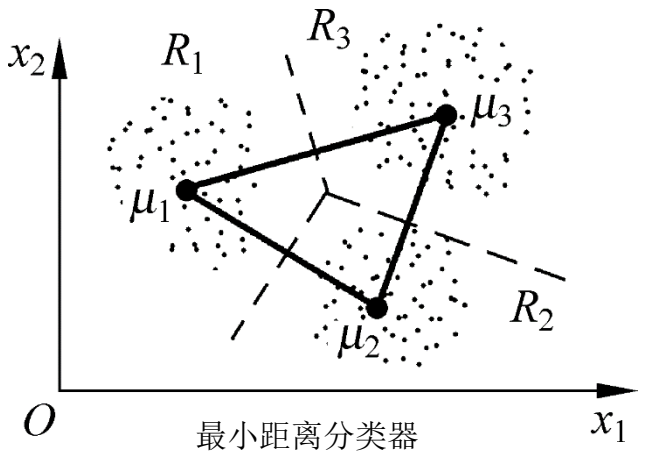
特殊情况下的正态分布的贝叶斯决策（1）

$$\mathrm{g_i}(\boldsymbol{x}) = \ln\big(\mathrm{p}(\boldsymbol{x}|\omega_i)\mathrm{p}(\omega_i)\big) = -\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i{}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i) + \ln\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} + \ln\mathrm{p}(\omega_i)$$

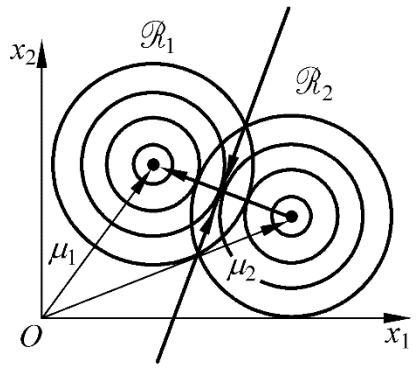
- 各类协方差阵相等、且各特征独立、方差相等 $\boldsymbol{\Sigma}_i = \sigma^2\mathrm{I}$
  - 各类先验概率相等 $\mathrm{p}(\omega_i) = \mathrm{p}(\omega_j),\ i,j = 1,2,\cdots c$，则有

$$\mathrm{g_i}(\boldsymbol{x}) \triangleq -\frac{1}{2\sigma^2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T(\boldsymbol{x}-\boldsymbol{\mu}_i) = -\frac{1}{2\sigma^2}||\boldsymbol{x}-\boldsymbol{\mu}_i||^2$$

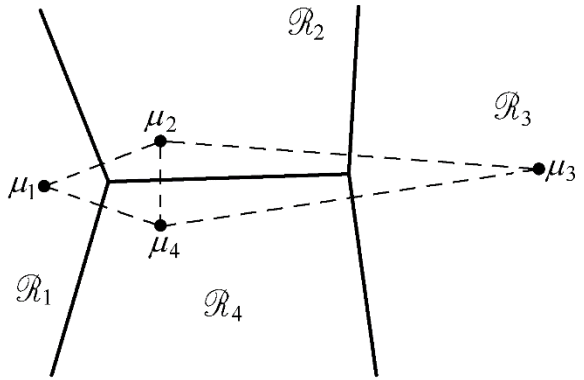
  - 球状分布，分类只取决于样本到各类中心的距离



最小距离分类器



(a) 两类情况



(b) 多类情况

特殊情况下的正态分布的贝叶斯决策（2）

$$g_i(\boldsymbol{x}) = \ln\big(p(\boldsymbol{x}|\omega_i)p(\omega_i)\big) = -\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i) + \ln\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} + \ln p(\omega_i)$$

- 各类协方差阵相等、且各特征独立、方差相等 $\boldsymbol{\Sigma}_i = \sigma^2 \mathrm{I}$
  - 各类先验概率不相等，则有

$$g_i(\boldsymbol{x}) \triangleq -\frac{1}{2\sigma^2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T(\boldsymbol{x}-\boldsymbol{\mu}_i) + \ln p(\omega_i) = -\frac{1}{2\sigma^2}||\boldsymbol{x}-\boldsymbol{\mu}_i||^2 + \ln p(\omega_i)$$

$$g_i(\boldsymbol{x}) = \frac{\boldsymbol{\mu}_i^T}{\sigma^2}\boldsymbol{x} - \frac{1}{2\sigma^2}\boldsymbol{\mu}_i^T\boldsymbol{\mu}_i + \ln p(\omega_i)$$

  - 决策面与先验概率相等时的决策面平行，只是向先验概率小的方向偏移
    - 先验概率大的一类要占据更大的决策空间

特殊情况下的正态分布的贝叶斯决策（3）

$$g_i(\boldsymbol{x}) = \ln\big(p(\boldsymbol{x}|\omega_i)p(\omega_i)\big) = -\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i) + \ln\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} + \ln p(\omega_i)$$

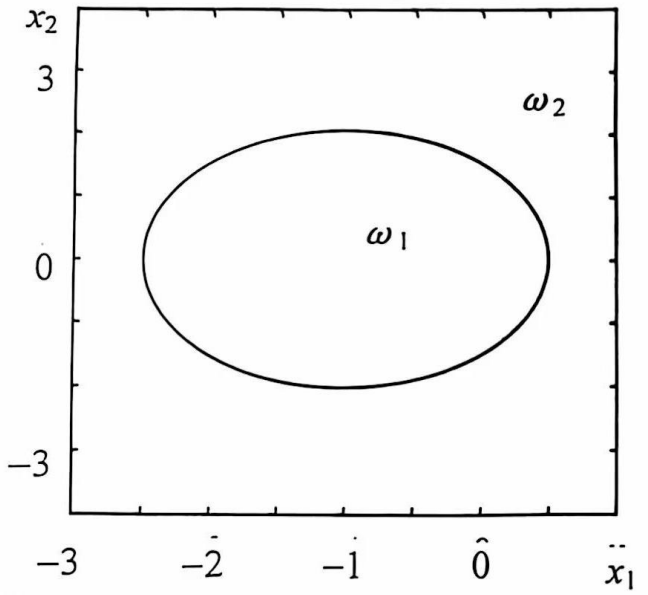
- 各类协方差矩阵都相等 $\boldsymbol{\Sigma}_i = \boldsymbol{\Sigma}$
  - 各类样本集中于以该类均值$\boldsymbol{\mu}_i$为中心的同样大小和形状的超椭球内

$$g_i(\boldsymbol{x}) \triangleq \ln\big(p(\boldsymbol{x}|\omega_i)p(\omega_i)\big) = -\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i) + \ln p(\omega_i)$$

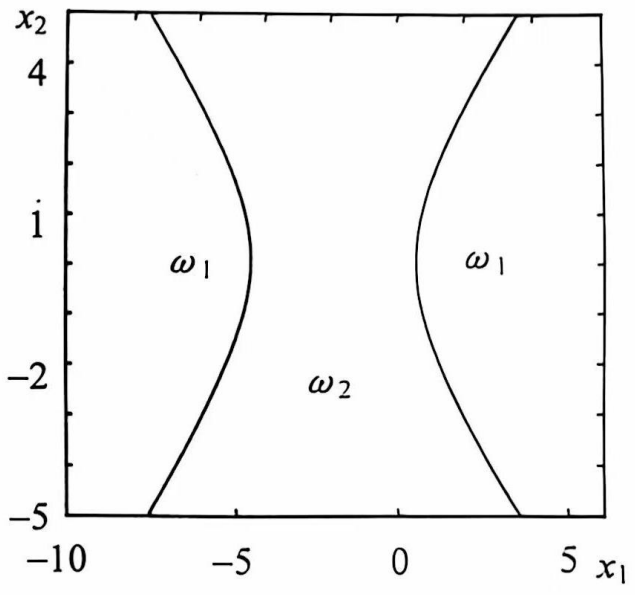
Mahalanobis 距离（马氏距离的平方），记为γ^2

  - 若各类的先验概率相等，决策面通过$\boldsymbol{\mu}_i$和$\boldsymbol{\mu}_j$连线中点
  - 若各类的先验概率不相等，决策面向先验概率小的均值点偏移

其他情况下的贝叶斯决策面形式



(a)



(b)

$$\boldsymbol{\Sigma}_{\mathrm{a}} = \begin{bmatrix} 0.3 & 0.0 \\ 0.0 & 0.35 \end{bmatrix}$$

$$\boldsymbol{\Sigma}_{\boldsymbol{b}} = \begin{bmatrix} 1.2 & 0.0 \\ 0.0 & 1.85 \end{bmatrix}$$

二次决策曲线的例子。改变高斯函数的协方差矩阵可以得到不同的决策曲线，如椭圆、抛物线、双曲线和直线对

错误率

- 错误率反映了分类问题固有复杂性的程度

在分类过程中，任何一种决策都有其相对应的错误率，采取指定的决策规则进行分类时，错误率是固定的

- 在分类器设计出来后, 通常是以错误率大小来衡量其性能优劣
- 通常是以错误率大小作为比较方案的标准

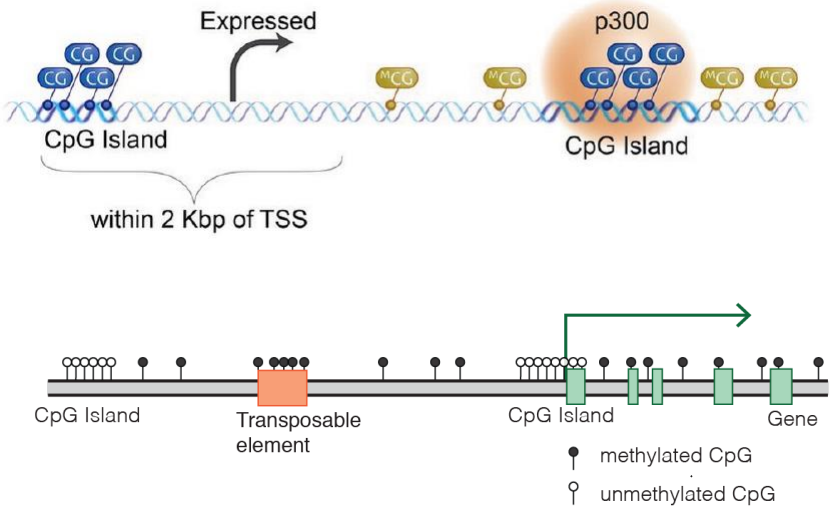
$$\mathrm{P}(e) = P(\omega_1)\int P(\boldsymbol{x}|\omega_1)d\boldsymbol{x} + P(\omega_2)\int P(\boldsymbol{x}|\omega_2)d\boldsymbol{x} = P(\omega_1)P_1(e) + P(\omega_2)P_2(e)$$

- 实际中，按理论公式计算错误率很困难

拓展：离散时间序列样本的统计决策

基本思想：求取后验概率进行决策

- 例：基因组上CpG岛 (CpG Island)的识别问题
  - 由于生物化学机制的作用，DNA链上出现相连的C和G核苷酸相连的概率比随机情况小很多，把相连的C和G叫作一个CpG双核苷酸
  - CpG在基因组上分布不均匀，会相对集中，富集区称为CpG岛
  - CpG岛识别问题为二分类问题，分为CpG岛和非CpG岛



- 马尔可夫模型下的贝叶斯决策

  - 把DNA序列看做时间序列，每一时刻取值$x_i = \{A, T, G, C\}$，且第i时刻的取值依赖第i-1时刻的取值
  - 一阶马尔可夫模型$P(x_i|x_{i-1}, x_{i-2}, \cdots, x_1) = P(x_i|x_{i-1})$

    转移概率 $a_{st} = P(x_i = t|x_{i-1} = s)$

    对一个长L的序列，观察这个序列的概率为

$$P(x) \triangleq P(x_1, x_2, \cdots, x_i) = P(x_1) \prod_{i=2}^{L} a_{x_{i-1}} a_{x_i}$$

– 马尔可夫模型状态转移矩阵和状态转移图举例

- 状态转移矩阵

对DNA序列来说，每一位置取值为四种，转移概率为4×4，称为转移概率矩阵或状态转移矩阵

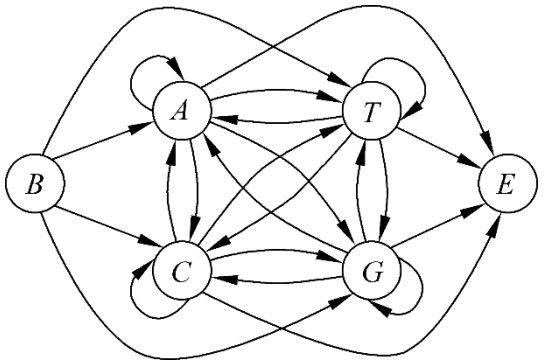
其中，行表示前一时刻的取值，列表示当前时刻的取值，例（2,3）位置的0.078表示$P(x_i = G|x_{i-1} = C) = 0.078$

-	A	C	G	T
A	0.300	0.205	0.285	0.210
C	0.322	0.298	0.078	0.302
G	0.248	0.246	0.298	0.208
T	0.177	0.239	0.292	0.292

- 状态转移图

开始（B）和结束（E）状态设置为空，内部根据指向线段表示状态转移概率

每种状态都可能在序列最后的位置上，每个状态指向终极状态E的连线表示该概率



- CpG岛与非CpG岛转移概率矩阵的估计

– 连续变量的贝叶斯决策，用类条件概率密度来描述各类样本特征分布，利用类条件概率密度计算似然比$l(x)=\frac{p(x|\omega_1)}{p(x|\omega_2)}$和相关阈值$\lambda$比值进行判别

– 同样思想适用离散变量，将CpG岛记为“+”，非CpG岛记为“-”，用$a_{st}^{+}=\frac{c_{st}^{+}}{\sum_{t'}c_{st'}^{+}}$和$a_{st}^{-}=\frac{c_{st}^{-}}{\sum_{t'}c_{st'}^{-}}$分别估计两类的状态转移概率

– 考虑长序列处理问题，采取对数似然比进行判别

$$S(x)=\log\frac{P(x|+)}{P(x|-)}=\sum_{i=1}^{L}\log\frac{a_{x_{i-1}x_i}^{+}}{a_{x_{i-1}x_i}^{-}}=\sum_{i=1}^{L}\beta_{x_{i-1}x_i}$$

CpG岛与非CpG岛转移概率矩阵举例

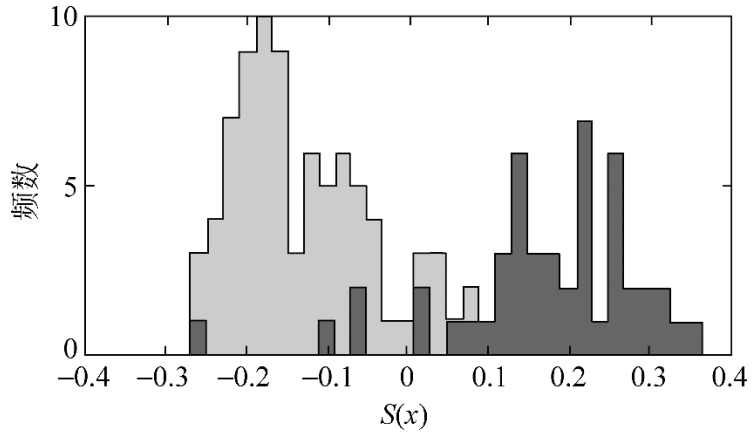
- 某个数据集上估计的CpG岛和非CpG岛状态转移矩阵

+	A	C	G	T
A	0.180	0.274	0.426	0.120
C	0.171	0.368	0.274	0.188
G	0.161	0.339	0.375	0.125
T	0.079	0.355	0.384	0.182

-	A	C	G	T
A	0.300	0.205	0.285	0.210
C	0.322	0.298	0.078	0.302
G	0.248	0.246	0.298	0.208
T	0.177	0.239	0.292	0.292

- 利用公式$S(x) = \log\frac{P(x|+)}{P(x|-)} = \sum_{i=1}^{L}\log\frac{a^{+}_{x_{i-1}x_i}}{a^{-}_{x_{i-1}x_i}} = \sum_{i=1}^{L}\beta_{x_{i-1}x_i}$某计算对数似然矩阵（以2为底）

beta	A	C	G	T
A	-.740	0.419	0.580	-.803
C	-.913	0.302	1.812	-.685
G	-.624	0.461	0.331	-.730
T	-1.169	0.573	0.393	-.679



马尔可夫链

- 在状态空间中有两种状态（A和B），共有4种可能的转换：从A到A、从A到B、从B到A、从B到B。每种转换的概率均为0.5
- 与绘制马尔可夫链图相比，建模者通常使用“转移矩阵”来计算转移概率。矩阵中的行和列分别代表状态，而单元格则表示从一个状态转移到另一个状态的概率，功能等同于图中的箭头



	A	B
A	P(A|A): 0.50	P(B|A): 0.50
B	P(A|B): 0.50	P(B|B): 0.50

如果状态空间增加一个状态，就会在转移矩阵中增加一行和一列，导致单元格数量呈二次方增长，这也凸显了转移矩阵的重要性（否则，马尔可夫链的图像会变得极为复杂）

马尔可夫链

– 马尔可夫链的一个作用是用计算机模拟现实世界中的现象。例如，可以用来检测一个新建的水坝溢流的频率（取决于连续下雨的天数）。为建立这个模型，可以从下面的雨天（R）和晴天（S）开始：

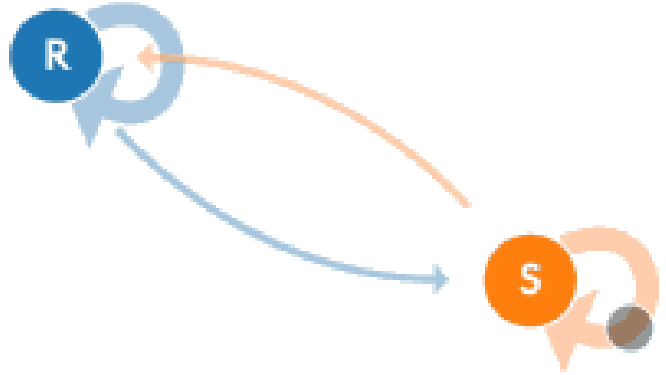
R S S S R R R R R R R R S S S S S R R R R R R R R R R R R R R

– 表述这种模拟天气的方法就是：“有一半的天数是下雨天。所以模拟中的每一天都有50%的概率是下雨的。”这个规则在模拟中所产生的序列如下：

R S R S S S R S R R S R S S S R S S S R R S R S S S S R R S S S

– 你注意到上面的序列和原来的不太一样了吗?第二个序列似乎具有跳跃性，而第一个(真实数据)似乎具有“粘性”。在真实的数据中，如果某一天是晴天，那么第二天也很可能是晴天。
– 可以通过两个状态的马尔可夫链来消除这种“粘性”。当马尔可夫链处于状态“R”时，它保持在该状态的概率是0.9，状态改变的概率是0.1。同样，“S”状态保持不变的概率是0.9，过渡到“R”状态的概率是0.1。

S S S R R R S R R R R R R S S S



– 在许多需要对大规模的现象做研究的工作人员手中，马尔可夫链的作用可以变得非常强大。例如，谷歌用于确定搜索结果顺序的算法，称为PageRank，就是一种马尔可夫链。

讨论

- 贝叶斯决策
  - 最小错误率→最大后验概率决策
  - 最小风险决策
  - 先验概率、类条件概率密度、后验概率
- 基于模型的模式识别/机器学习方法
  - 先估计模型（概率密度函数）
  - 再决策

2.5 未知概率密度函数的估计

- 基于样本的两步贝叶斯
  - 根据训练样本估计概率密度函数，记为$\hat{p}\left(\boldsymbol{x}|\omega_i\right)$和$\hat{P}\left(\omega_i\right)$
  - 根据估计的概率密度函数设计分类器
- 希望$N \to \infty$时基于样本的估计收敛于理论结果

$$\hat{p}\left(\boldsymbol{x}|\omega_i\right) \to p(\boldsymbol{x}|\omega_i), when\ N \to \infty$$

$$\hat{P}\left(\omega_i\right) \to P(\omega_i), when\ N \to \infty$$

- 概率密度函数估计的方法
  - 参数估计与非参数估计

基本概念

- 参数估计
  - 已知概率密度函数形式，估计未知或部分未知参数
- 非参数估计
  - 概率密度函数形式未知，直接用已知类型学习样本估计参数
- 几个名词
  - 统计量，样本的某种函数
  - 参数空间，概率密度函数形式已知的前提下，未知参数全部可容许值组成的集合
  - 点估计，估计量和估计值，点估计问题为构造一个统计量d（$x_1,\cdots,x_N$）作为参数θ的估计$\hat{\theta}$，在统计学中称$\hat{\theta}$为θ的估计量
  - 区间估计，在置信区间（d_1，d_2）作为θ的范围的估计

2.5.1 最大似然参数估计

- 基本假设
  - 待估计参数θ未知但确定（多个参数时是向量）
  - 每一类的样本独立同分布
  - 每一类条件概率密度函数$p(\boldsymbol{x}|\omega_i)$函数形式确定，只是参数未知
  - 不同类别的参数独立，可分别处理
- 基于以上假设，考虑一类N个样本

$$x = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N\}$$ 独立从$p(\boldsymbol{x};\theta)$中抽取

则联合概率密度函数：

$$p(\boldsymbol{X};\theta) \equiv p(\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N;\theta) = \prod_{k=1}^{N} p(\boldsymbol{x}_k;\theta)$$

θ关于$\boldsymbol{X}$的似然函数

用最大似然估计(Maximum Likelihood,ML)θ计算似然函数的最大值：

$$\hat{\theta}_{ML} = \arg\max_{\theta} \prod_{k=1}^{N} p(\boldsymbol{x}_k; \theta)$$

要得到最大值，$\hat{\theta}_{ML}$ 必须满足的条件是，似然函数关于θ的梯度为零，由于对函数的单调性。我们定义似然函数为：

$$L(\theta) = \ln \prod_{k=1}^{N} p(\boldsymbol{x}_k; \theta)$$

最大似然估计的特点：

- 最大似然估计是渐进无偏的，均值定义为

$$\lim_{N\to\infty} E[\hat{\theta}_{ML}] = \theta_0$$

也可以说估计值的均值收敛于真值

- 最大似然估计是渐进一致的，即它满足

$$\lim_{N\to\infty} \text{prob}\left\{\left\|\hat{\theta}_{ML} - \theta_0\right\| \le \epsilon\right\} = 1$$

当N足够大时，最大似然估计的方差趋近于零。对于估计值来说，一致性非常重要，因为他可以是无偏的，但会导致估计值出现大的方差。在这种情况下，对来自单个集合$\boldsymbol{X}$的结果不能保证其准确性。

- 最大似然估计是渐进有效的，即它达到了Cramer Rao下限。这是所有估计能够达到的最小方差值。

- 当$N \to \infty$时，最大似然估计的概率密度函数接近均值为θ_0的高斯分布。该性质是中心极限定理及最大似然估计与随机变量之和相关的结果。

2.5.2 最大后验概率估计

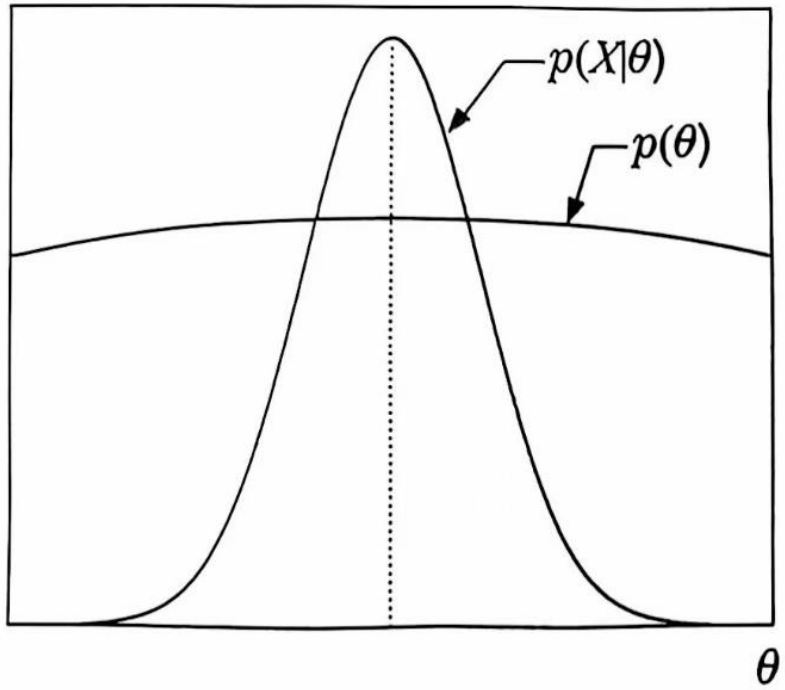
推导最大似然估计时，我们认为θ是未知参数。在本节讨论中，我们认为它是一个随机向量，并在样本$\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots$，$\boldsymbol{x}_N$存在的条件下估计它的值。由贝叶斯定理有

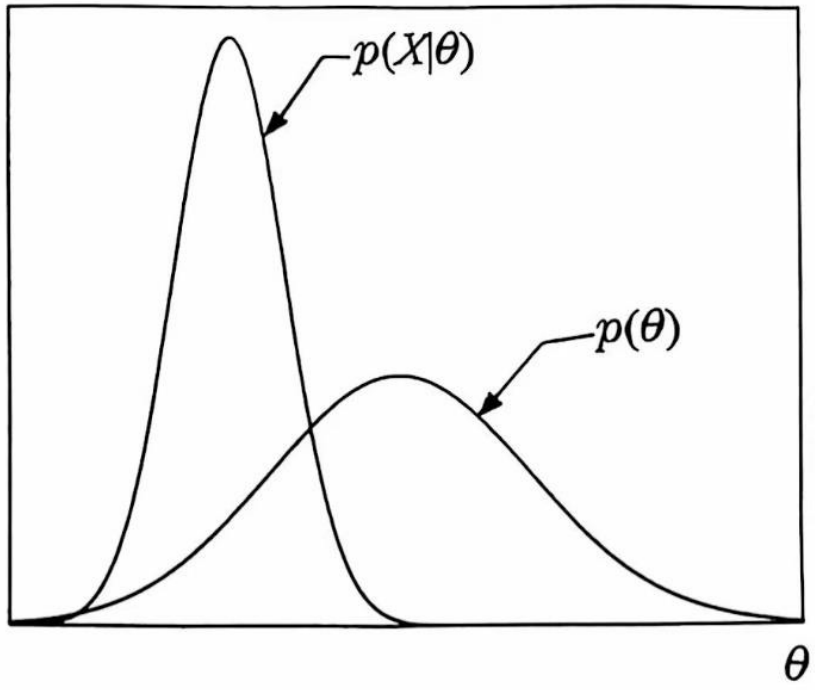
$$p(\boldsymbol{\theta})p(\boldsymbol{X}|\boldsymbol{\theta}) = p(\boldsymbol{X})p(\boldsymbol{\theta}|\boldsymbol{X}) \text{ 或 } p(\boldsymbol{\theta}|\boldsymbol{X}) = \frac{p(\boldsymbol{\theta})p(\boldsymbol{X}|\boldsymbol{\theta})}{p(\boldsymbol{X})}$$

最大后验概率(Maximum a Posteriori, MAP)估计值$\hat{\theta}_{MAP}$定义为$p(\boldsymbol{\theta}|\boldsymbol{X})$取值最大的那个点，

$$\hat{\theta}_{MAP} = \frac{\partial}{\partial \boldsymbol{\theta}} p(\boldsymbol{\theta}|\boldsymbol{X})=0, \frac{\partial}{\partial \boldsymbol{\theta}} (p(\boldsymbol{X})p(\boldsymbol{\theta}|\boldsymbol{X}))=0$$

最大似然估计和最大后验概率估计的不同是后者包含$p(\theta)$。假设服从均匀分布，即对所有θ它是一个常量，那么这两个估计得到的相同的结果。 $p(\theta)$的方差较小时，这也基本正确，在普通情况下，这两个估计会得到不同的结果。





2.5.3 贝叶斯推论

- 基本思想
  - 把参数估计看成贝叶斯决策问题
  - 待估计参数看成具有先验分布$p(\theta)$的随机变量
  - 其取值和样本集有关 $\chi = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N\}$
  - 最有条件是最小错误率或者最小风险，损失函数为$\lambda(\widehat{\boldsymbol{\theta}}, \theta)$

最大似然估计将待估参数当作未知但固定的量

- 用$\widehat{\boldsymbol{\theta}}$来估计时的总期望风险为
  - 样本取值空间E^d,参数取值空间为Θ

$$R = \int_{E^d} \int_{\Theta} \lambda\left(\widehat{\boldsymbol{\theta}}, \theta\right)\ p(\theta|\boldsymbol{x})\, p(\boldsymbol{x}) d\theta d\boldsymbol{x}$$

- 用$\widehat{\boldsymbol{\theta}}$来估计时的总期望风险为
  - 样本取值空间E^d,参数取值空间为Θ

$$R = \int_{E^d} \int_{\Theta} \lambda\left(\widehat{\boldsymbol{\theta}}, \theta\right)\ p(\theta|\boldsymbol{x})\, p(\boldsymbol{x}) d\theta d\boldsymbol{x}$$

  - 定义在样本$\boldsymbol{x}$下的条件风险为

$$R\left(\widehat{\boldsymbol{\theta}}\middle|\boldsymbol{x}\right) = \int_{\Theta} \lambda\left(\widehat{\boldsymbol{\theta}}, \theta\right)\ p(\theta|\boldsymbol{x}) d\theta$$

  - 总期望风险为

$$R = \int_{E^d} \int_{\Theta} R\left(\widehat{\boldsymbol{\theta}}\middle|\boldsymbol{x}\right) p(\boldsymbol{x}) d\theta d\boldsymbol{x}$$

- 对经验风险求最小，记为θ^*
- 事先制定损失决策表，常用平方损失函数 $\lambda\left(\widehat{\boldsymbol{\theta}}, \theta\right) = \left(\theta - \hat{\theta}\right)^2$

定义损失函数

- 可以证明：若采用平方误差损失函数，则贝叶斯估计量为条件期望

$$\theta^* = E(\theta|x) = \int_\Theta \theta p(\theta|\boldsymbol{x})\, d\theta$$

$$\theta^* = E(\theta|\chi) = \int_\Theta \theta p(\theta|\chi)\, d\theta$$

- 平方误差下贝叶斯估计的步骤
  - 确定θ的先验分布密度$p(\theta)$
  - 求出样本集的联合分布

$$p(\chi|\theta) = \prod_{i=1}^{N} p(\boldsymbol{x}_i|\theta)$$

  - 利用贝叶斯公式求出参数后验概率

$$p(\theta|\chi) = \frac{p(\chi|\theta)p(\theta)}{\int_\Theta p(\chi|\theta)p(\theta)d\theta}$$

  - 求出贝叶斯估计量θ^*

- 考虑更一般的情况，反映样本数目

$$\chi^N = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_N\}$$

$$\theta^* = \int_\Theta \theta p(\theta|\chi^N)\, d\theta$$

$$p(\theta|\chi^N) = \frac{p(\chi^N|\theta)p(\theta)}{\int_\Theta p(\chi^N|\theta)p(\theta)d\theta}$$

- 当N大于1时

$$p(\chi^N|\theta) = p(\boldsymbol{x_N}|\theta)\; p(\chi^{N-1}|\theta)$$

  – 可得如下递推公式

$$p(\theta|\chi^N) = \frac{p(\boldsymbol{x_N}|\theta)\; p(\theta|\chi^{N-1})}{\int_\Theta p(\boldsymbol{x_N}|\theta)\; p(\theta|\chi^{N-1})d\theta}$$

  – 样本无穷多时 $p(\theta|\chi^{N\to\infty}) = p(\theta)$

- 正态分布下的贝叶斯估计
  - 假定均值的先验分布也是正态分布，对均值估计

$$p(\theta|\mu) = \frac{p(\chi|\mu)p(\mu)}{\int_{\Theta} p(\chi|\mu)p(\mu)d\mu}$$

  - 估计结果为

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} \mu_0$$

$$\sigma_N^2 = \frac{\sigma^2\sigma_0^2}{N\sigma_0^2 + \sigma^2}$$

- 贝叶斯估计和贝叶斯学习的优势——应对参数不确定性

无人驾驶，其环境和系统就存在很多未知的随机因素

◆Uncertainty in Data/Environment: Ubiquitous, sometimes Adversarial!



Road conditions



Traffics



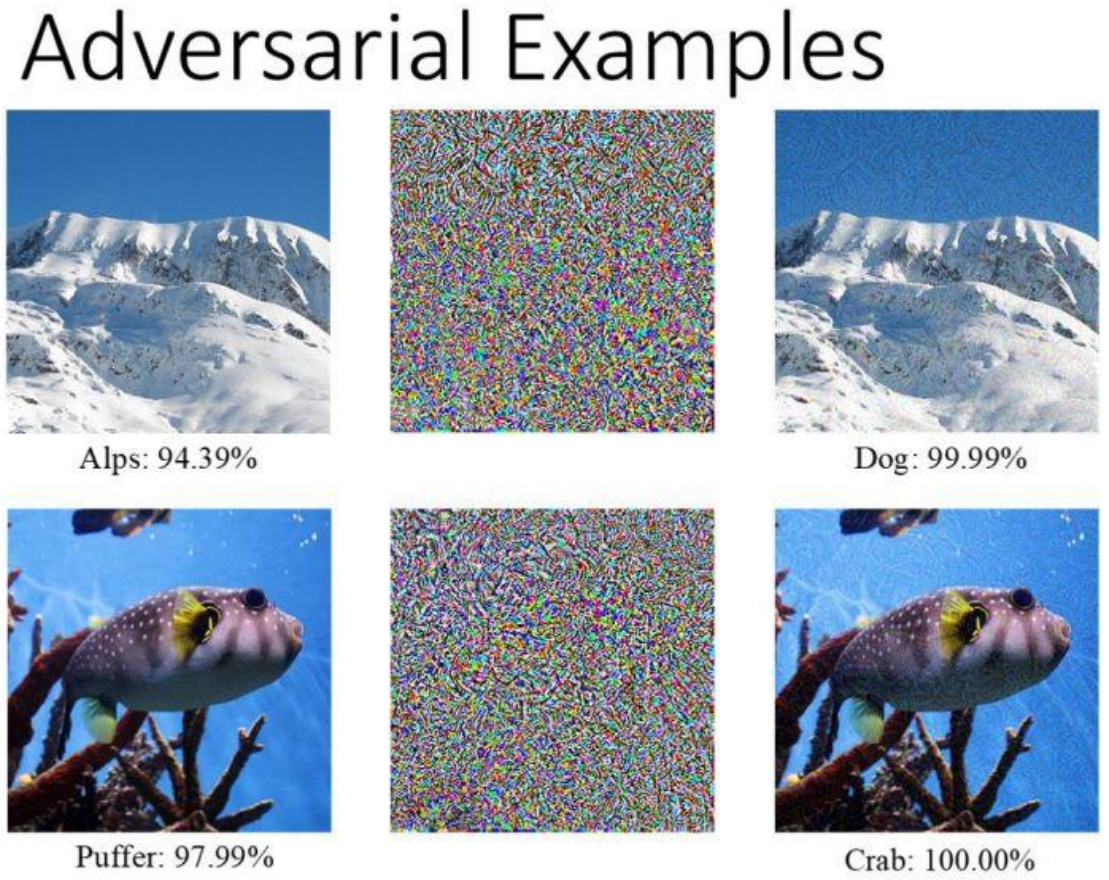
Pedestrian behaviors





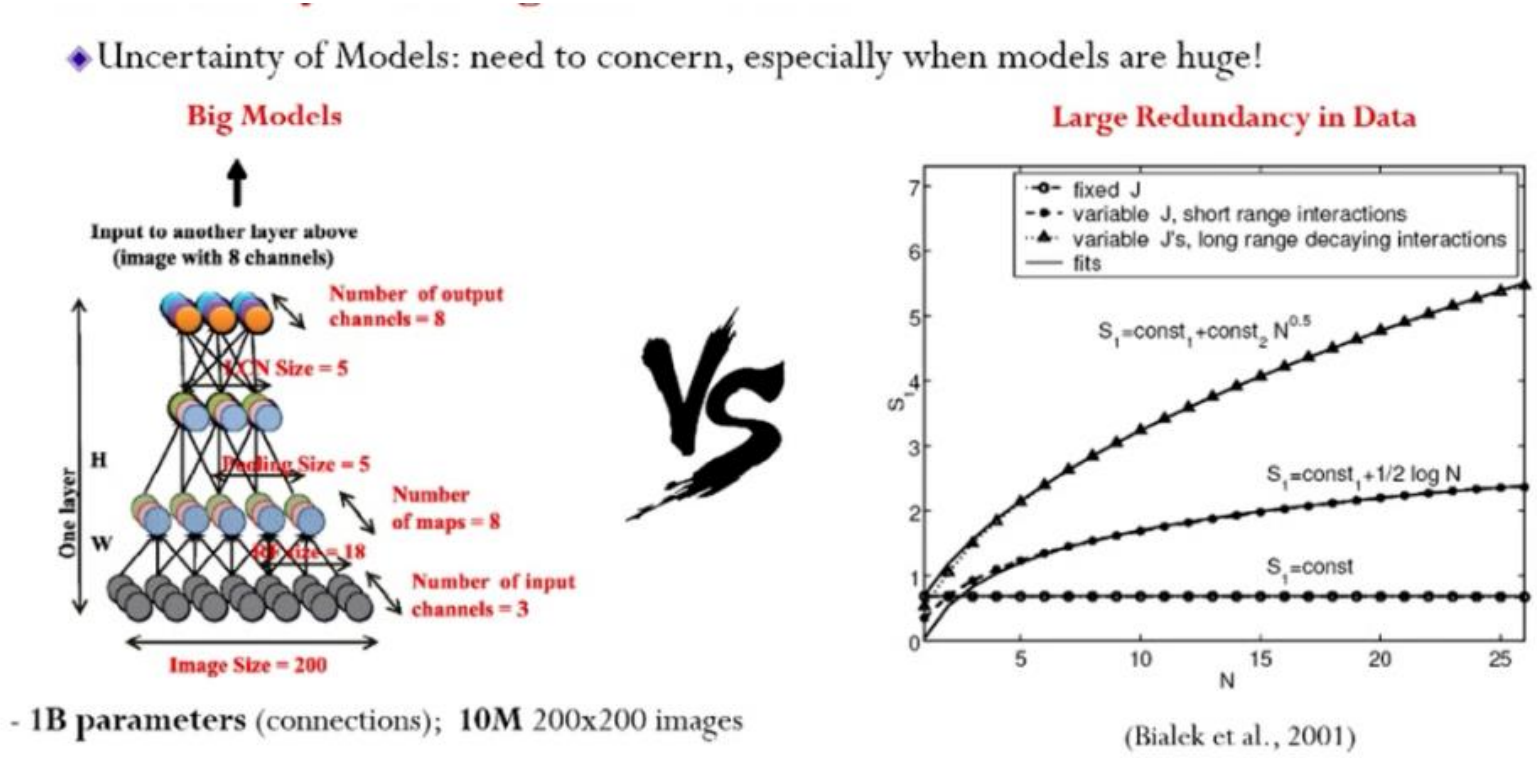
- 贝叶斯估计和贝叶斯学习的优势——应对参数不确定性

对抗样本研究（恶意干扰产生的不确定性），如果在一张图片中加上少量的噪音，虽然展示效果对人眼没有影响，而足以让人工神经网络产生误判



- 贝叶斯估计和贝叶斯学习的优势——应对参数不确定性

模型“体量”越来越大，一个经典的模型甚至达到了十亿规模的参数，而最近，包含上千亿参数的模型也已经出现



2.5.4 最大熵估计

熵的概念源于香农信息论。它是关于事件的不确定性的度量，或是系统输出信息的随机性度量，若$p(\boldsymbol{x})$是一个概念密度函数，则相关的熵H定义为

$$H = -\int_{\boldsymbol{x}} p(\boldsymbol{x}) \ln p(\boldsymbol{x})\, dx$$

现在假设$p(\boldsymbol{x})$未知，但已知一些相关的约束(均值、方差等)。未知概率密度函数的最大熵估计是给定约束下的最大熵。根据Jaynes陈述的最大熵原理，在约束下，这样的估计对应于具有最大可能随机性的分布。

符合测得这些值的随机量的概率分布可有多种、以至无穷多种，通常，其中有一种分布的熵最大。选用这种具有最大熵的分布作为该随机变量的分布，是一种有效的处理方法和准则

2.5.5 混合模型

通过密度函数的线性组合来得到未知$p(\boldsymbol{x})$的模型（假设J个分布对$p(\boldsymbol{x})$ 的形成有贡献），该模型能够任意接近任何连续密度函数，前提是混合了足够数量的J和适当的模型参数，形式如下：

$$p(\boldsymbol{x}) = \sum_{\mathrm{j}=1}^{J} p(\boldsymbol{x}|j)\, P_j$$

式中，$\sum_{\mathrm{j}=1}^{J} P_j=1$ $\int_{\boldsymbol{x}} p(\boldsymbol{x}|j)\, dx = 1$

假设每个样本 x 都可以从J个模型之一中抽取出来，并用参数化的密度函数$p(x|j;\theta)$表示。为了估计未知参数θ和模型权重P_j 的最优值，需要最大化样本的似然函数。然而，由于缺乏关于样本类别的标注信息，直接进行这种最大化计算在数学上会变得复杂

期望值最大算法（EM）

这个算法在过去几年里备受关注，并且广泛用于具有不完整数据集的任务

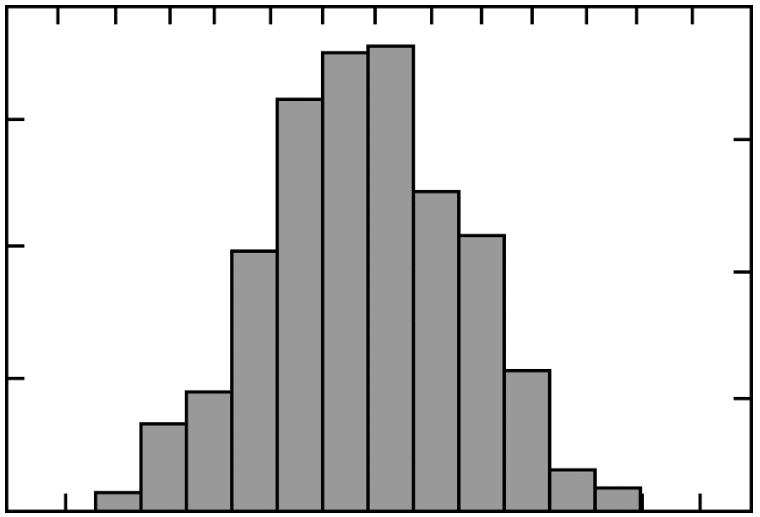
2.5.6 非参数估计

- 基本思想
  - 样本的密度函数形式未知
  - 有些情况样本的分布很难用函数形式描述
  - 直接用样本估计整个函数
  - 可以看作从所有可能的函数中进行选择

无法利用概率密度函数估计参数

非参数估计的基本原理与直方图方法

- 直方图
  - 把样本$\boldsymbol{x}$的每个分量分成k个等间隔小窗，若$\boldsymbol{x}$是d维向量，则分割得到k^d个小舱或小体积，每个小舱的体积记为V
  - 统计落入小舱内的样本数目q_i
  - 把小舱内的概率密度看作常数， 估计值$\frac{q_i}{NV}$



- 基本原理

问题：已知样本集$x = \{x_1, \cdots, x_N\}$中的样本是服从密度函数$p(\boldsymbol{x})$的总体中独立抽取出来的，求$p(\boldsymbol{x})$的估计$\hat{p}(\boldsymbol{x})$

– 随机向量落入小区域范围的估计为

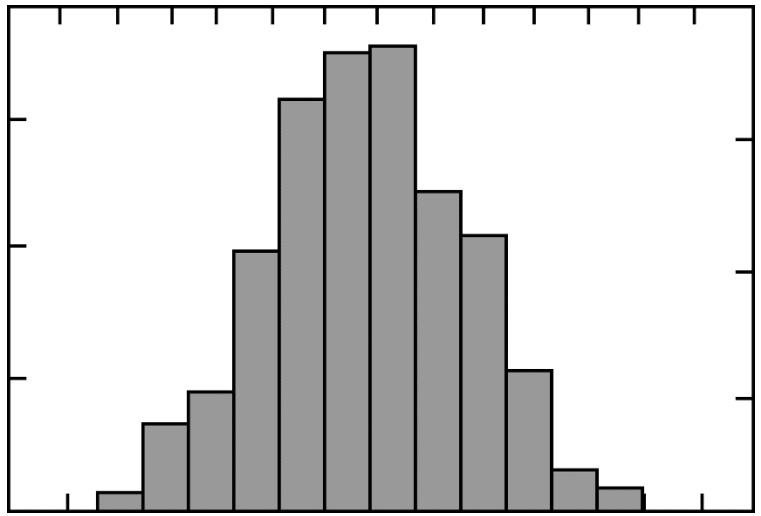
$$P_R = \int_R p(\boldsymbol{x})d\boldsymbol{x} = p(\boldsymbol{x})V$$

– 小区域中落入k个样本时P_R的估计为

$$\hat{P}_R = \frac{k}{N}$$

– 直方图小舱内的概率密度估计为

$$\hat{p}(\boldsymbol{x}) = \frac{k}{NV}$$



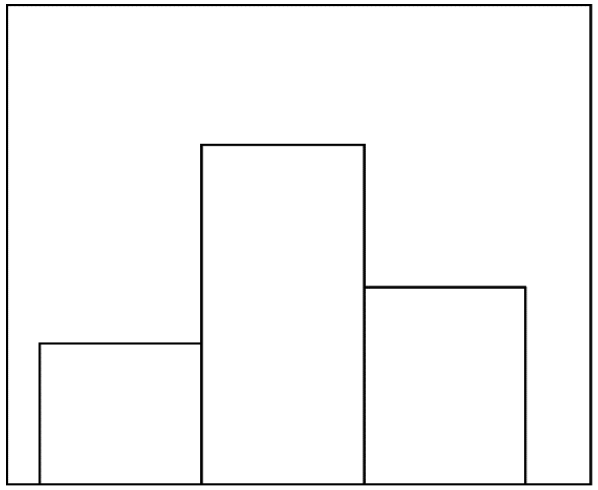
对应直方图使用的对小舱内概率密度的估计

- 小舱选择

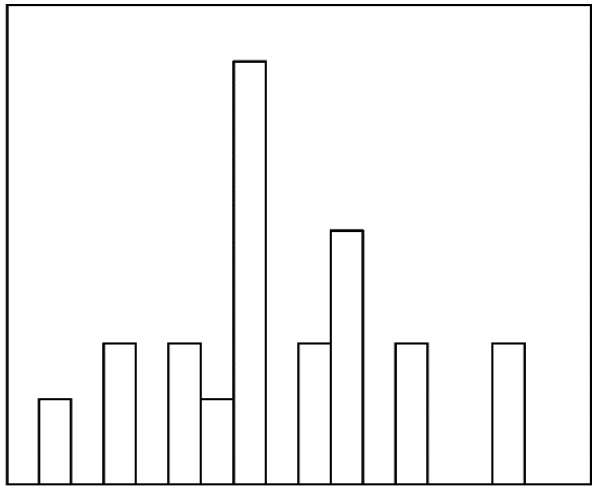
问题：采用将特征空间在样本取值范围等分，小舱的选择与估计效果紧密相关

  - 过大，则估计的密度函数粗糙
  - 过小，则估计结果不连续

小舱的选择应与样本总数相适应



(a) 小窗过宽



(b) 小窗过窄

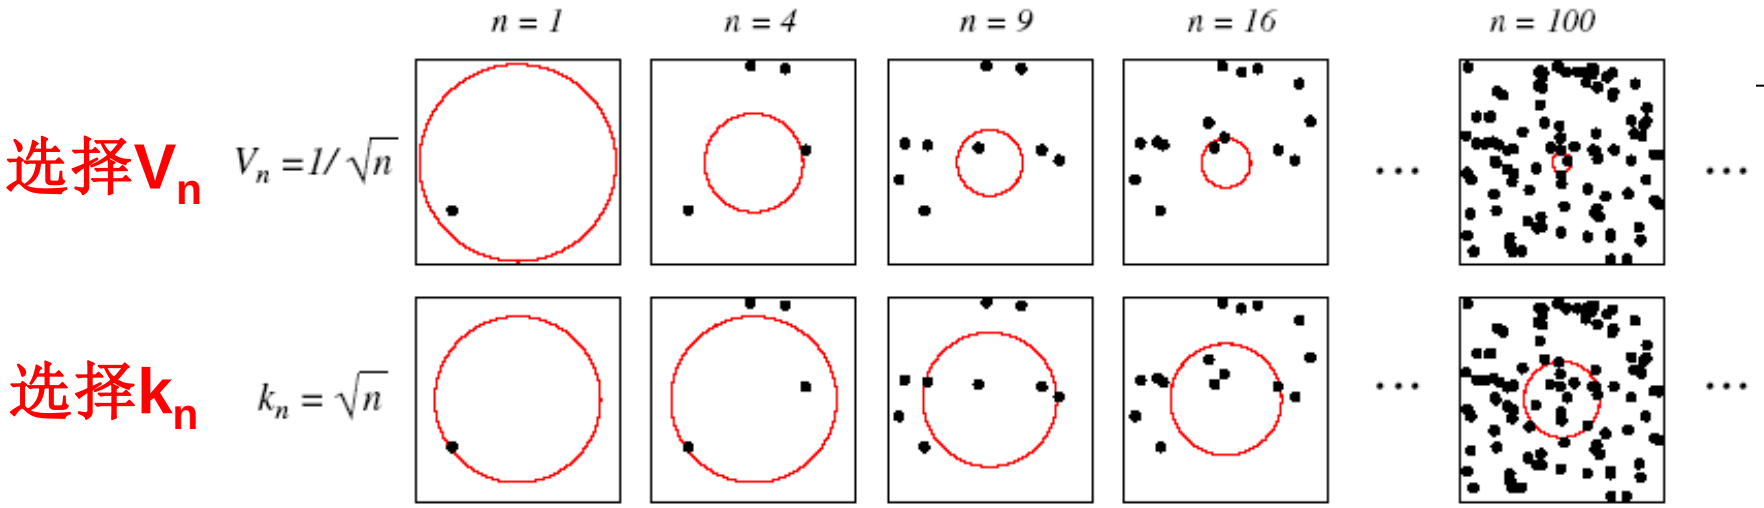
- 小舱选择

问题：采用将特征空间在样本取值范围等分，小舱的选择与估计效果紧密相关

  - 样本趋于无穷多时的收敛条件为（样本总数n，小舱体积为V_n，在x附近位置落入小舱的样本数为k）

$$\lim_{n\to\infty} V_n = 0, \lim_{n\to\infty} k_n = \infty, \lim_{n\to\infty} \frac{k_n}{n} = 0$$

小舱体积尽可能小，小舱内有充足样本且每个小舱样本数相较总体很小



Parzen窗法

- 基本做法
  - 固定小舱体积

    $x \in R^d$是d维特征向量，假设每个小舱是一个超立方体，且在每一维棱长为h,小舱体积为

    $$V = h^d$$

  - d维单位方窗函数

    $$\phi(\mathbf{u}) = \begin{cases} 1 & |u_j| \le \frac{1}{2}, j = 1, \cdots, d \\ 0 & \text{其他} \end{cases}$$

  - 滑动小舱来估计每点上的概率密度,对于任意一点的密度估计表达式

    $$\hat{p}(\boldsymbol{x}) = \frac{1}{NV} \sum_{i=1}^{N} \varphi(\frac{\boldsymbol{x} - \boldsymbol{x_i}}{h})$$

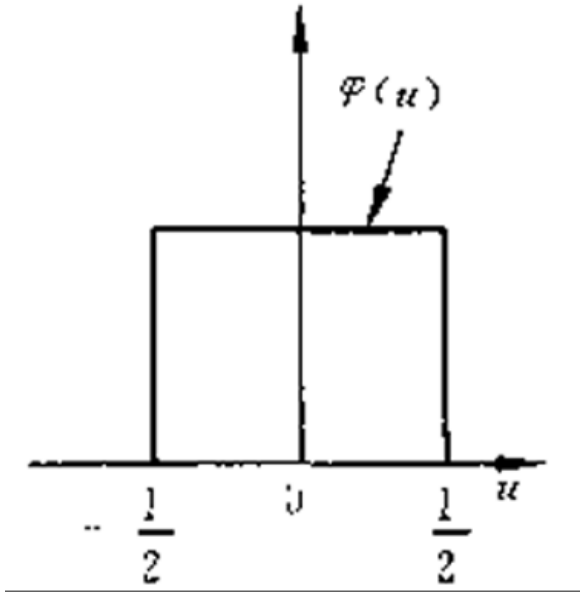
– 定义核函数（窗函数）

$$K(\boldsymbol{x}, \boldsymbol{x_i}) = \frac{1}{V}\varphi(\frac{\boldsymbol{x} - \boldsymbol{x_i}}{h})$$

– 概率密度估计则是每一点上观测样本贡献的平均

$$\hat{p}(\boldsymbol{x}) = \frac{1}{N}\sum_{i=1}^{N} K(\boldsymbol{x}, \boldsymbol{x_i})$$

– 核函数包括方窗、高斯窗、超球窗等



方窗函数

$$\varphi(u) = \begin{cases} 1, |u| \le \frac{1}{2} \\ 0.\text{其他} \end{cases}$$

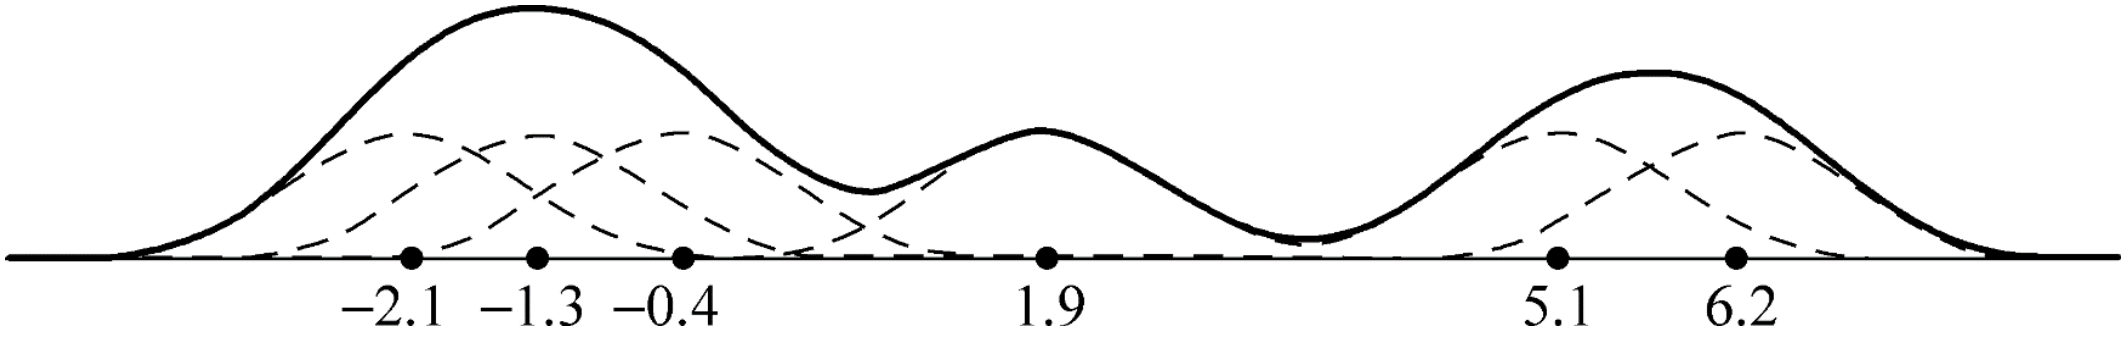
– 定义核函数

$$K(\boldsymbol{x}, \boldsymbol{x_i}) = \frac{1}{V}\varphi(\frac{\boldsymbol{x} - \boldsymbol{x_i}}{h})$$

– 概率密度估计则是每一点上观测样本贡献的平均

$$\hat{p}(\boldsymbol{x}) = \frac{1}{N}\sum_{i=1}^{N} K(\boldsymbol{x}, \boldsymbol{x_i})$$

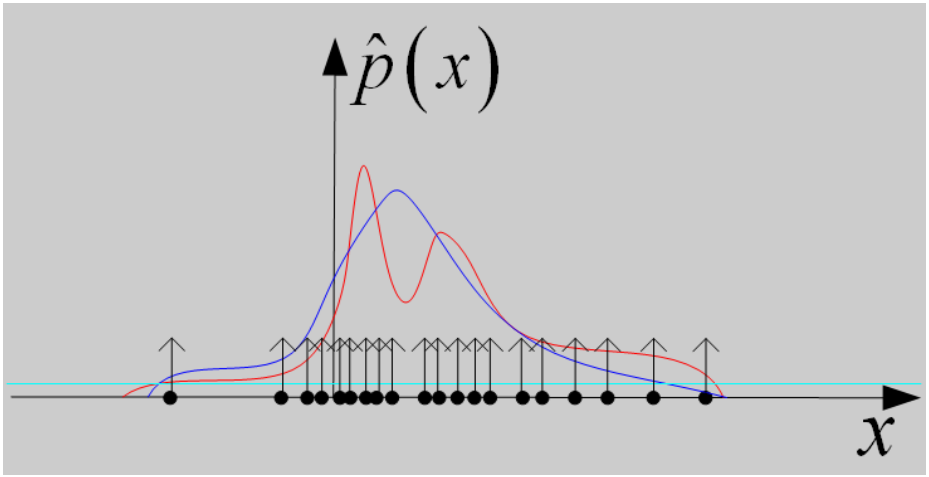
– 高斯窗作为核函数



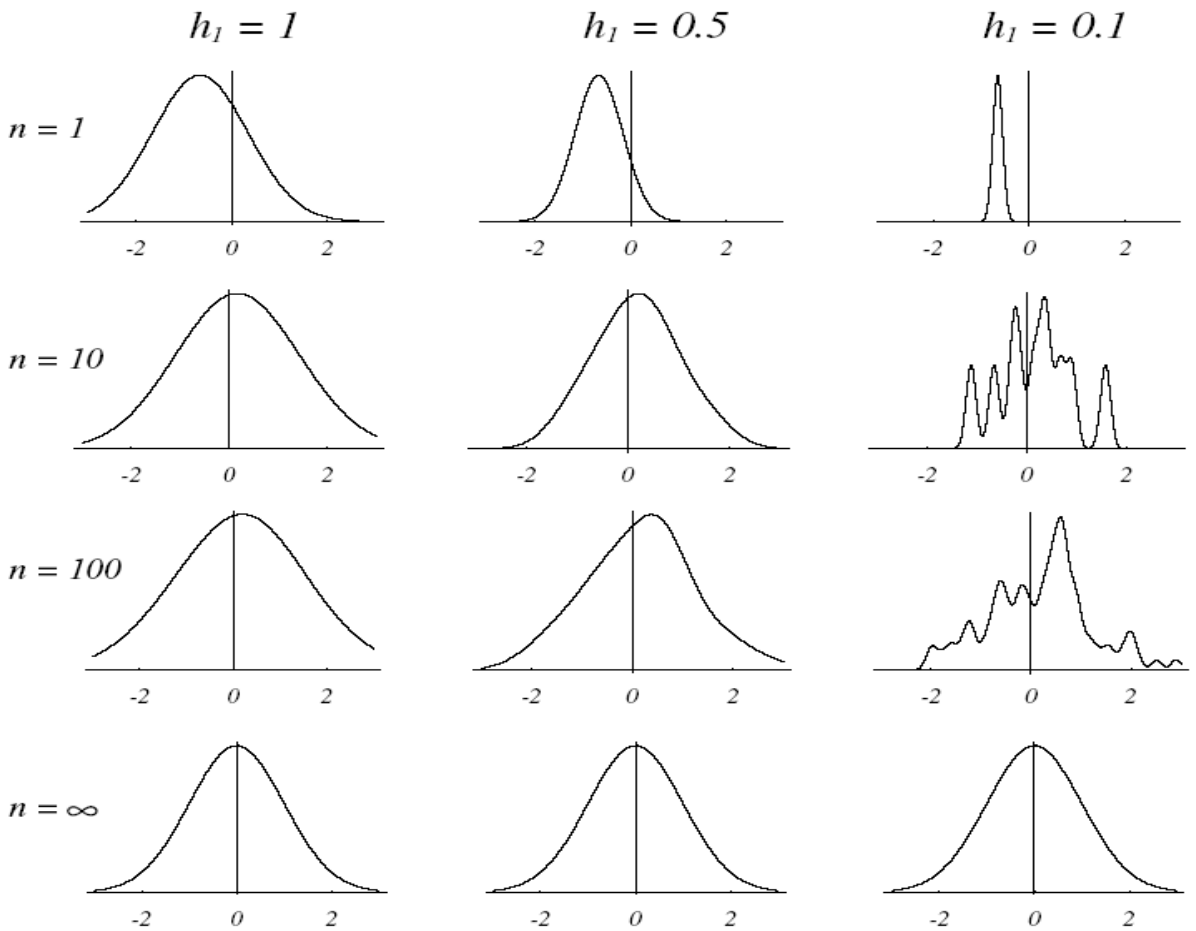
- 窗口宽度的影响

Parzen估计的性能与窗宽参数h_n紧密相关

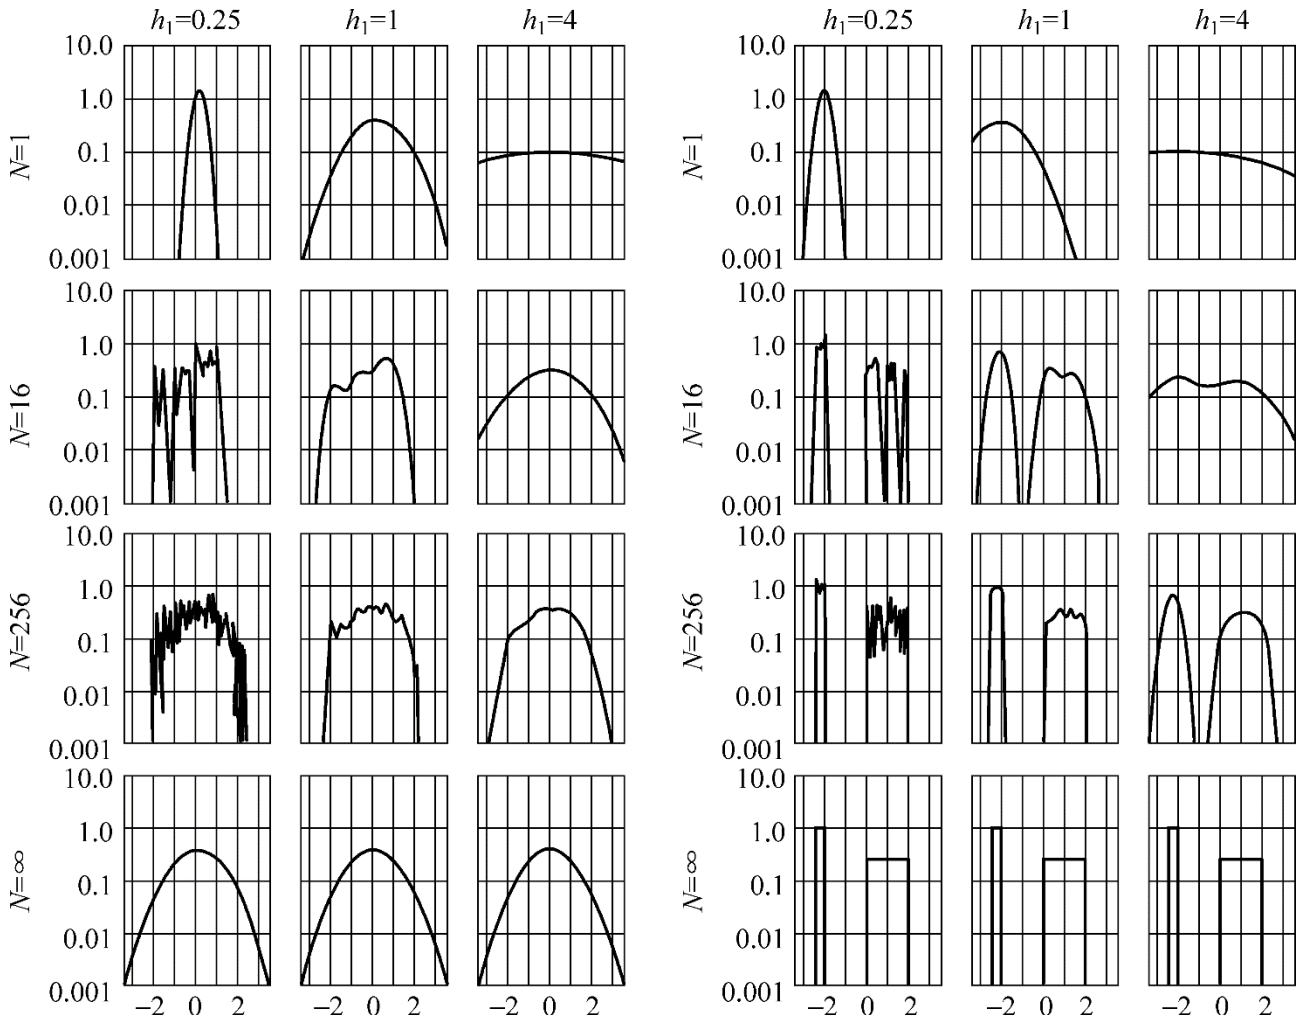
- 当h_n较大时，x和中心x_i距离大小的影响程度变弱，估计的p(x)较为平滑，分辨率较差
- 当h_n较小时，x和中心x_i距离大小的影响程度变强，估计的p(x)较为尖锐，分辨率较好



- 窗口宽度的影响

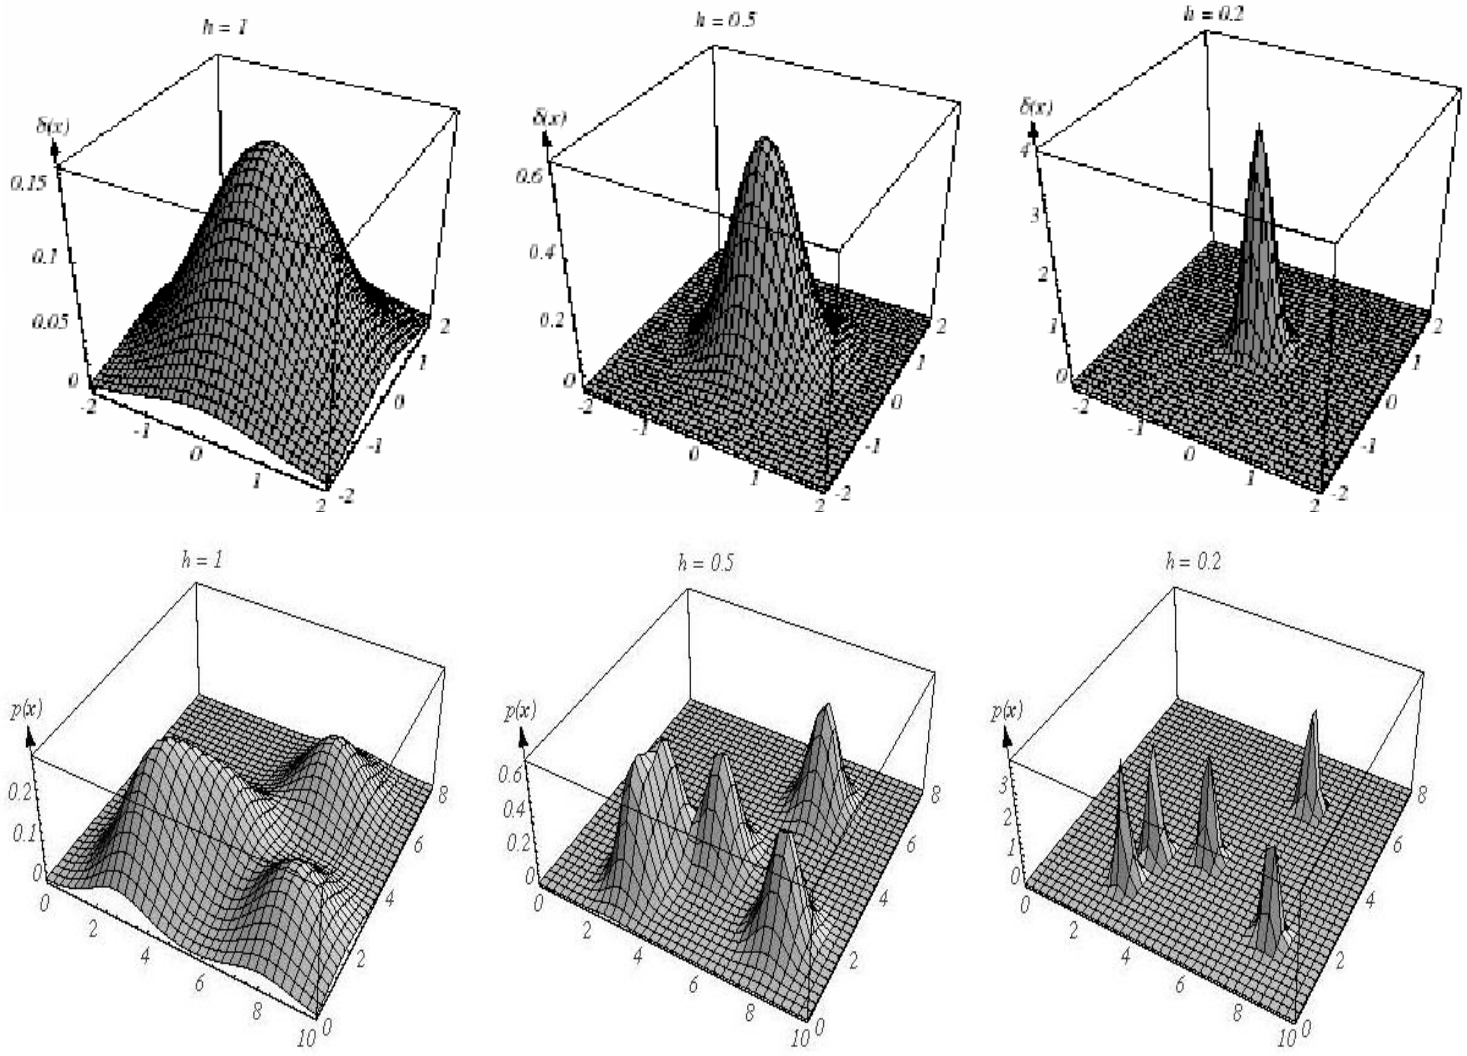


– 不同样本数和参数下的Parzen估计



70

- 5个样本的Parzen窗估计



窗函数

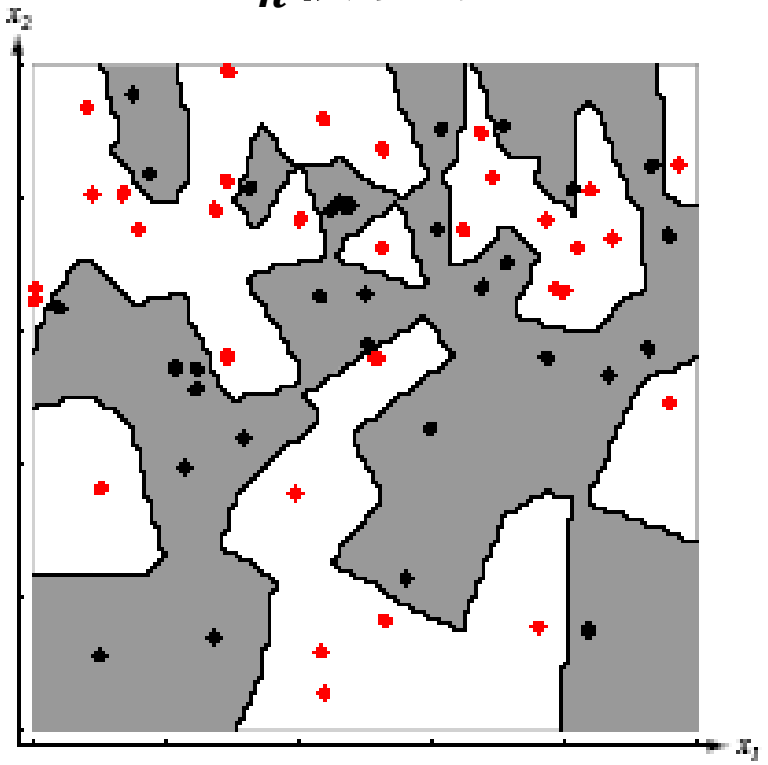
密度估计值

- Parzen窗估计的优缺点

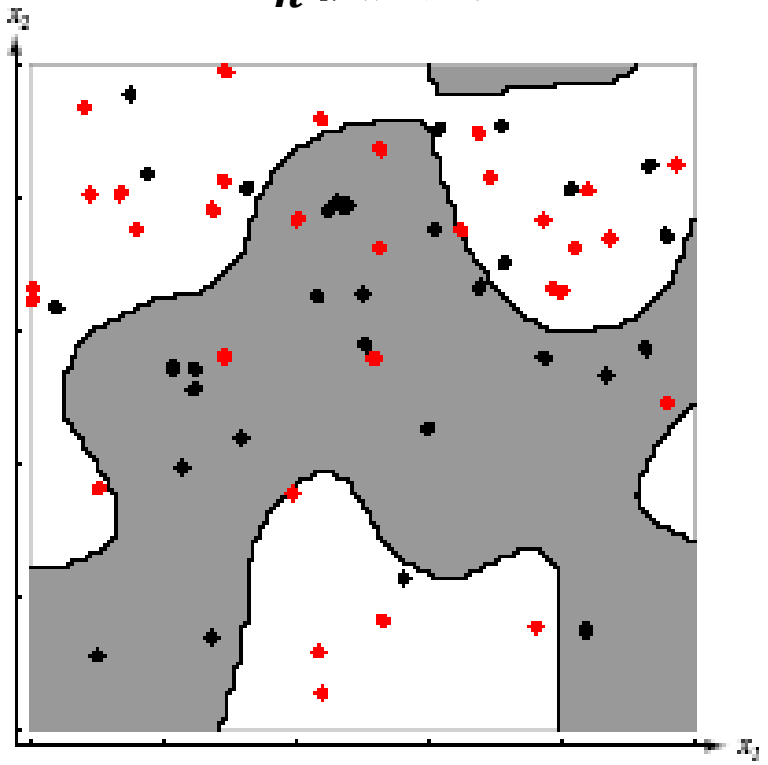
- **优点**
  - 由前面的例子可以看出， Parzen窗估计的优点是应用的普遍性。**对规则分布，非规则分布，单锋或多峰分布都可用此法进行密度估计**
  - 可以获得较为光滑且分辨率较高的密度估计，实现了光滑性和分辨率之间的一个较好平衡
- **缺点**
  - 要求样本足够多，才能有较好的估计。因此使计算量，存储量增大
  - 窗宽在整个样本空间固定不变，难以获得区域自适应的密度估计

- 例子：
  基于Parzen估计的Bayesian分类器

h_n较小时



h_n较大时

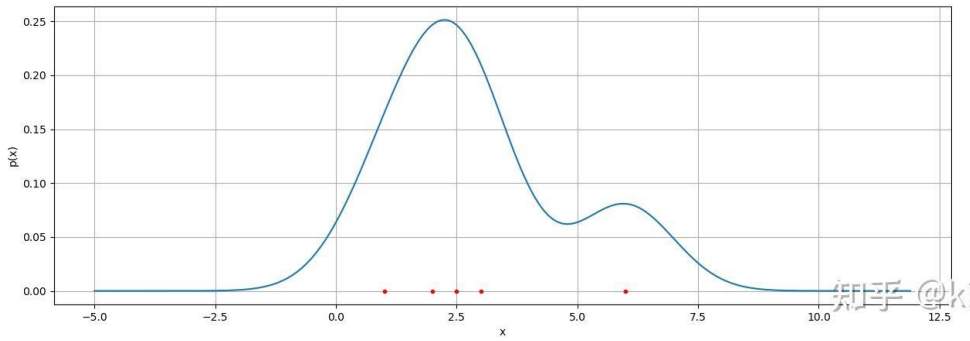


- 例题：
- 有给定点：$x_1 = 2, x_2 = 2.5, x_3 = 3, x_4 = 1, x_5 = 6$，利用Parzen window概率密度估计，且令高斯函数（一维情况）的$\sigma = 1$，求$x = 3$处的概率值：
  - 解：
  - $$p(3) = \frac{1}{5}\sum_{i=1}^{5} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x_i-3)^2}{2}\right)$$

$$= \frac{1}{5\sqrt{2\pi}}\left(\exp\left(-\frac{(2-3)^2}{2}\right) + \exp\left(-\frac{(2.5-3)^2}{2}\right) + \exp\left(-\frac{(3-3)^2}{2}\right) + \exp\left(-\frac{(1-3)^2}{2}\right) + \exp\left(-\frac{(6-3)^2}{2}\right)\right)$$

$$= \frac{1}{5\sqrt{2\pi}}(0.6065 + 0.8825 + 1 + 0.1353 + 0.0111) = 0.2103$$

绘制其概率密度函数图为：

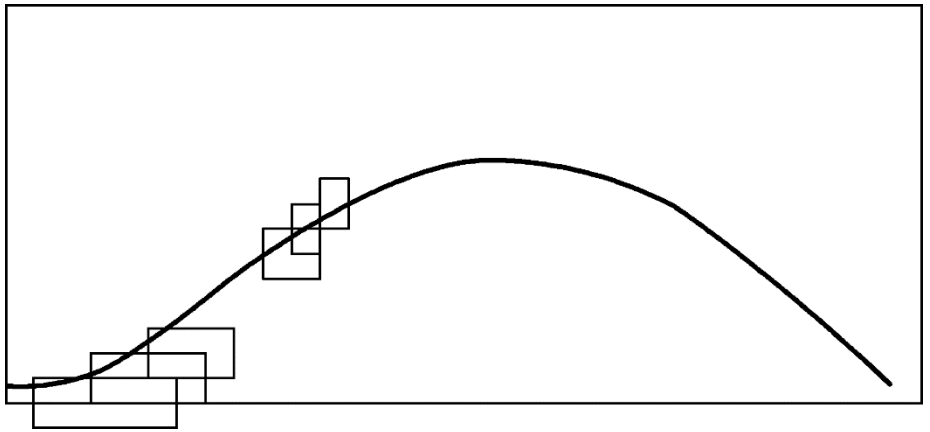


知乎 @kiyoxi

k_N近邻估计方法

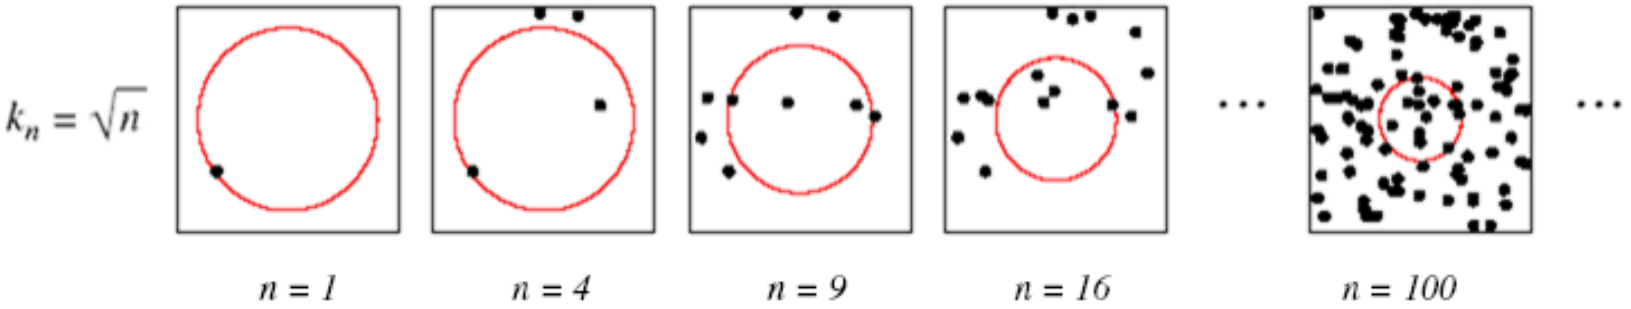
- 基本做法
  - 确定k_N：总样本为N时每个小舱内的样本数
  - **调整包含x小舱体积**，直到落入k_N个样本

$$p(\boldsymbol{x}) = \frac{k_N}{NV}$$



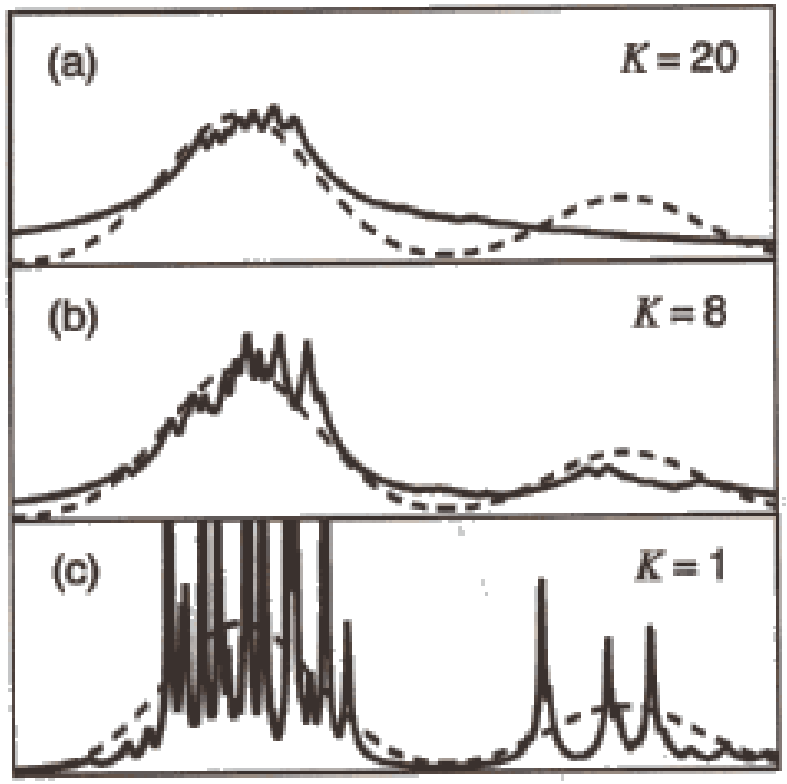
  - 在x取值范围内以每一点为中心进行估计，

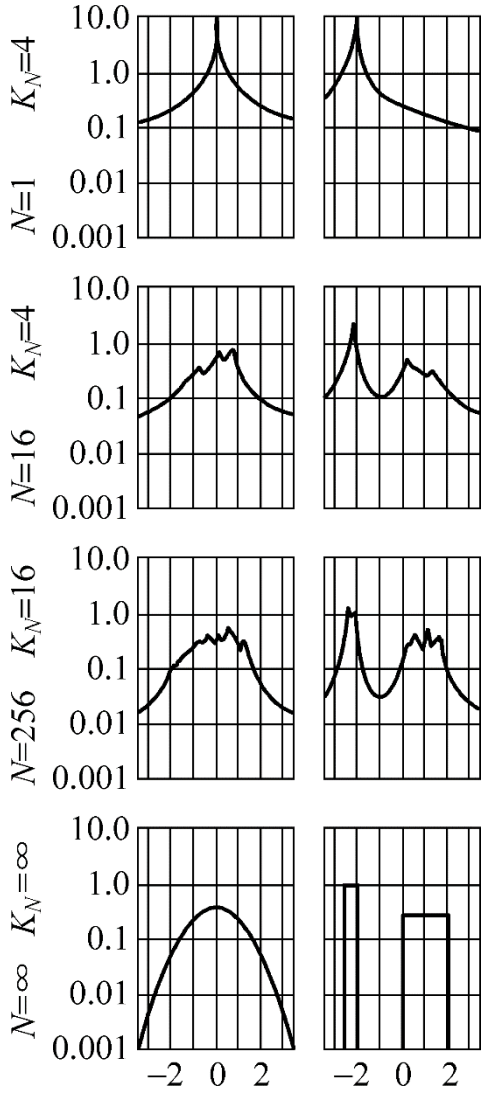
$p(\boldsymbol{x})$渐进收敛条件：$\lim_{n\to\infty} k_n = 0$，$\lim_{n\to\infty} \frac{k_n}{n} = 0$，通常取$k_N \sim k\sqrt{N}$



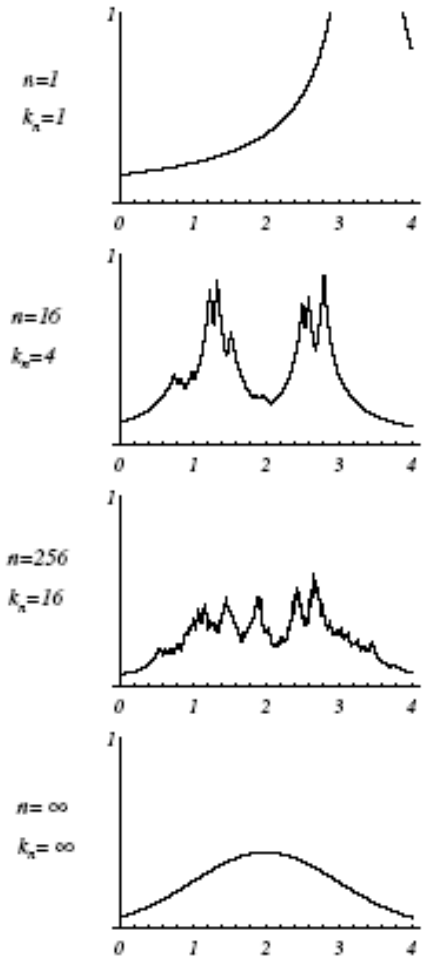
- 例

  估计效果对比





k_n-nearest-neighbor



2.5.7 朴素贝叶斯分类器

- 假设各个特征取值只依赖类别标签，特征间互相独立

$$p(x_l x_k|\omega_i) = \mathrm{p}(x_l|\omega_i)\mathrm{p}(x_k|\omega_i), \qquad l,k = 1,\cdots,d, k \neq l$$

- 联合概率可以分解

$$p(x_1, x_2, \cdots, x_d, \omega_i) = p(x_1|\omega_i)p(x_2|\omega_i)\cdots p(x_d|\omega_i)p(\omega_i)$$

- 各类别先验概率的估计

$$p(Y = \omega_{\mathrm{i}}) = \frac{\sum_{i=1}^{N} I(y_i = \omega_i)}{N}$$

- 参数的极大似然估计

$$p(x_j = v_i|Y = \omega_i) = \frac{\sum_{i=1}^{N} I(x_j^{(i)} = v_i, y_i = \omega_i)}{\sum_{i=1}^{N} I(y_i = \omega_i)}$$

- 拉普拉斯平滑：对概率值平滑矫正

$$p(Y = \omega_i) = \frac{\sum_{i=1}^{N} I(y_i = \omega_i) + 1}{N + C}$$

$$p(x_j = v_i|Y = \omega_i) = \frac{\sum_{i=1}^{N} I(x_j^{(i)} = v_i,\ y_i = \omega_i) + 1}{\sum_{i=1}^{N} I(y_i = \omega_i) + S}$$

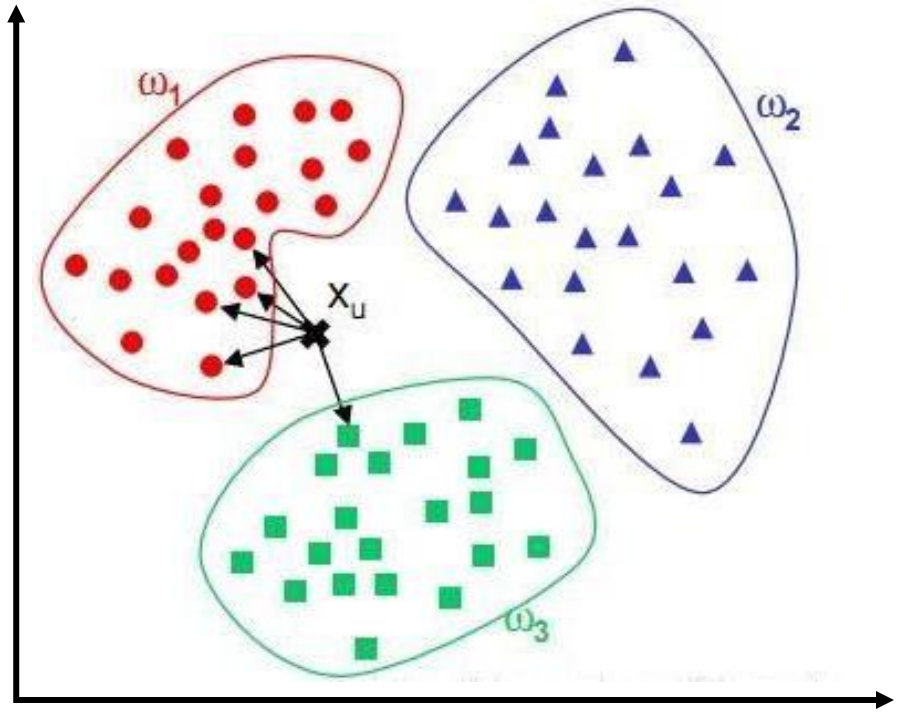
- 连续取值的变量特征：采用正态分布、均匀分布等模型

2.6 最近邻准则

k近邻算法(KNN)思路：

给定一组已知类别的训练数据，当新数据进入时，计算其与训练集中每个样本的距离，选取距离最近的 k 个样本，并根据多数样本的类别对新数据进行分类

当k＝1时该算法最简单，称为最近邻准则



优势：

- 简单易理解
- 非参数模型
- 适应多类别问题

劣优势：

- 计算复杂度高
- 对噪声敏感、鲁棒性差
- 维数灾难

经典算法与改进：

基本KNN算法、加权KNN（Weighted KNN）、 KD树（KD-Tree）、局部敏感哈希（LSH）、广义KNN（Generalized KNN）

2.7 贝叶斯网络

- 特征或事件之间具有一定的概率依赖关系
  - 下雨与路面湿滑
  - 穿凉鞋行人的比例与冰激凌的销量
- 描述存在依赖关系的多个事件之间的联合概率分布
- 马尔可夫模型和隐马尔可夫模型都是贝叶斯网络

贝叶斯网络的基本概念

- 随机变量的条件独立性

- 两个随机变量X和Y独立，当且仅当$p(x,y) = p(x)\,p(y)$

- 对于随机变量X,Y,Z，若满足$p(x,y|z) = p(x|z)p(y|z)$,则称随机变量X和Y关于Z条件独立可以表示为$X \perp Y|Z$：

$$p(x\,|\,y,z) = \frac{p(x,y,z)}{p(y,z)} = \frac{p(x,y|z)p(z)}{p(y|z)p(z)} = p(x|z)$$

- 链式法则

根据贝叶斯公式，高维随机变量的联合分布如下：

$$p(x_1, x_2, \dots, x_d) = p(x_d | x_1, x_2, \dots, x_{d-1}) p(x_1, x_2, \dots, x_{d-1})$$

反复利用该性质，则可推导得到（整体的联合概率可以分局为一系列条件概率的乘积）：

$$p(x_1, x_2, \dots, x_d) = p(x_1) p(x_2 | x_1) p(x_3 | x_1, x_2) \dots p(x_d | x_1, x_2, \dots, x_{d-1})$$

- 链式法则

可以对上式的随机变量进行任意排序，如果找到一种合适的排列方式，利用链式法则分解和条件独立行走进行化简，则有可能大大降低联合概率密度计算复杂性

例，对一个随时间变化的随机变量X，若 x_{t+1}与$x_1, x_2, \cdots, x_{t-1}$关于$x_t$条件独立，即随机变量下一时刻取值与过去无关，这时称为时间序列随机变量满足一阶马尔可夫模型假设，联合概率：

$$p(x_1, x_2, \ldots, x_d) = p(x_1) \prod_{t=1}^{d} p(x_t|x_{t-1})$$

马尔可夫链

即联合分布被分解为初始状态x_1取值概率与一阶条件概率$p(x_t|x_{t-1})$的连乘积

- 条件概率的图（graph）表示
  - 图G
    - 由节点集合N和连接节点的边的集合E组成
    - 总的节点数用n表示，所有边的总数用K表示
    - 集合N中的节点用x_i表示，$i = 1,2,\dots,n$
    - 边集合E中的元素用e_k表示，$k = 1,2,\dots,k$

$$e =< x_i, x_j >$$

- 条件概率的图表示
  - 无向图
    - 每一条边e都是没有方向的

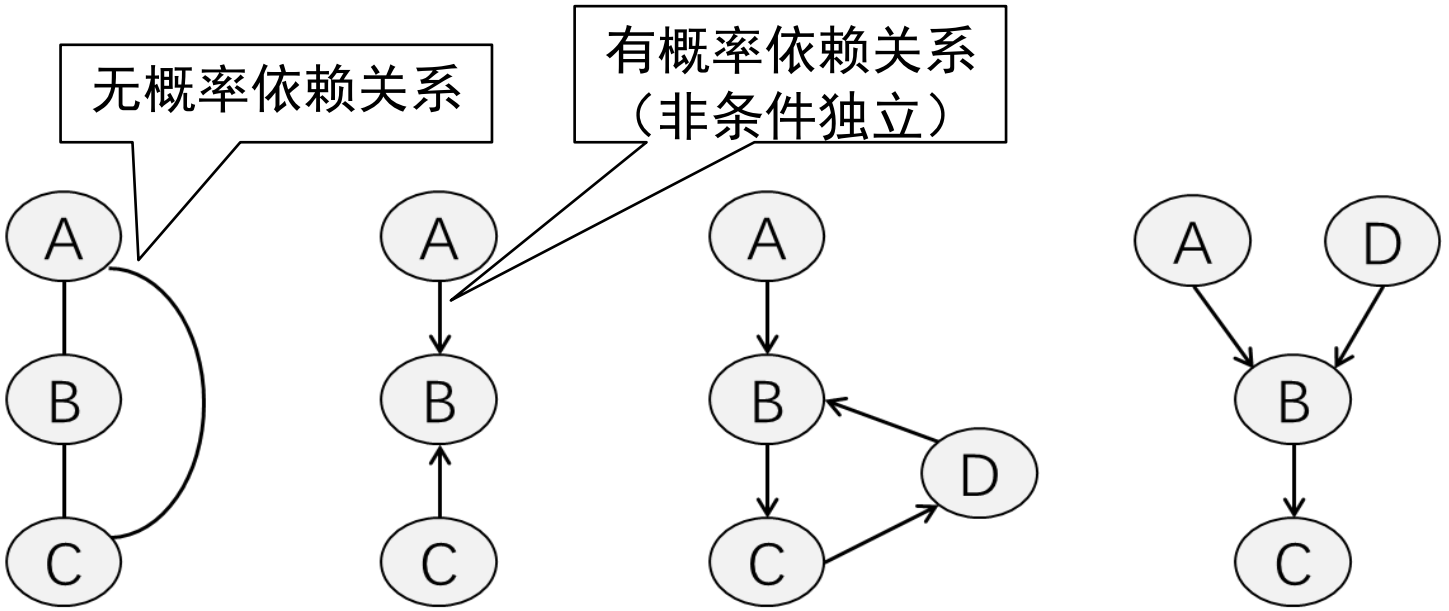
$$< x_i, x_j >=< x_j, x_i >$$

  - 有向图

$$e =< x_i, x_j >$$

    - x_i为父节点，x_j为子节点或终止结点
  - 路径起始节点与终止节点相同，则为环（cycle）
  - 一个有向图中没有环存在，改图称为有向无环图

- 几种图结构



- 有向边表示随机变量之间的条件依赖关系

$$p(\mathbf{x}) = \prod_{i=1}^{n} p(x_i|\boldsymbol{pa}_i)$$

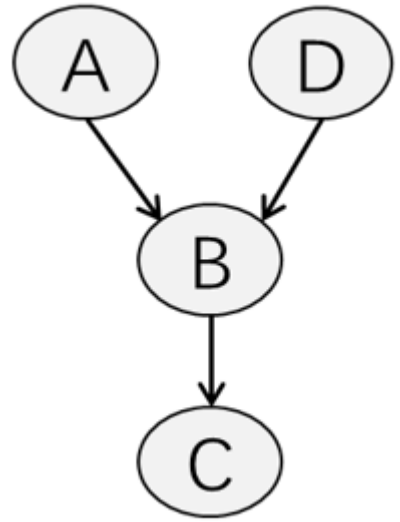
$\boldsymbol{pa}_i$表示x_i的父节点集合

- 有向边表示随机变量之间的条件依赖关系

$$p(\mathbf{x}) = \prod_{\mathrm{i}=1}^{\mathrm{n}} p(x_i|\boldsymbol{pa}_i)$$

例，右图所示的贝叶斯网络可以表示A、B、C、D四个概率事件的依赖关系：事件A和B概率独立，事件B概率依赖于A和D，事件C概率依赖与B，则四个事件的联合概率可分解为：

$$P(A,B,C,D) = P(A)P(D)P(B|A,D)P(C|B)$$



总结

- 贝叶斯决策理论
  - 最小化分类错误概率
  - 最小化平均风险
- 判别函数和决策面
- 正态分布的贝叶斯分类
- 未知概率密度函数的估计
  - 最大似然参数估计
  - 最大后验概率估计
  - 贝叶斯推论
  - 最大熵估计
  - 混合模型
  - 非参数估计
  - 朴素贝叶斯分类器

- 最近邻准则
  - KNN技术的优缺点
- 贝叶斯网络
  - DAG有向无环图