模式识别
——模式识别与机器学习

刘文黎

liu_wenli@hust.edu.cn

土木与水利工程学院

第3章 线性分类器

本章主要内容

3.1 引言
3.2 线性判别函数
3.3 感知器算法
3.4 最小二乘法
3.5 逻辑斯蒂判别
3.6 支持向量机

3.1 引言

从基于概率密度（估计）的分类器设计到基于样本的直接分类器设计

- **思路：**先选定判别函数类和一定的目标（准则），利用样本集确定函数类中的未定参数，使所选的准则最好
- **形式化：**判别函数类 $\{g(\alpha), \alpha \in \Lambda\}$，　α: 未定参数

  准则函数 $L(\alpha)$

  求 α^*: $L(\alpha^*) = \min\limits_{\alpha} L(\alpha)$

- 本章只考虑线性判别函数 $g(\boldsymbol{x}) = \boldsymbol{w}^T\boldsymbol{x} + w_0$
- 多类情况 $g_i(\boldsymbol{x}) = \boldsymbol{w}_i{}^T\boldsymbol{x} + w_{i0},\ i = 1,2,\ldots,c$

——次优分类器（相对于贝叶斯分类器）

当正态分布且各类协方差相同时可为最优分类器

- 决策规则

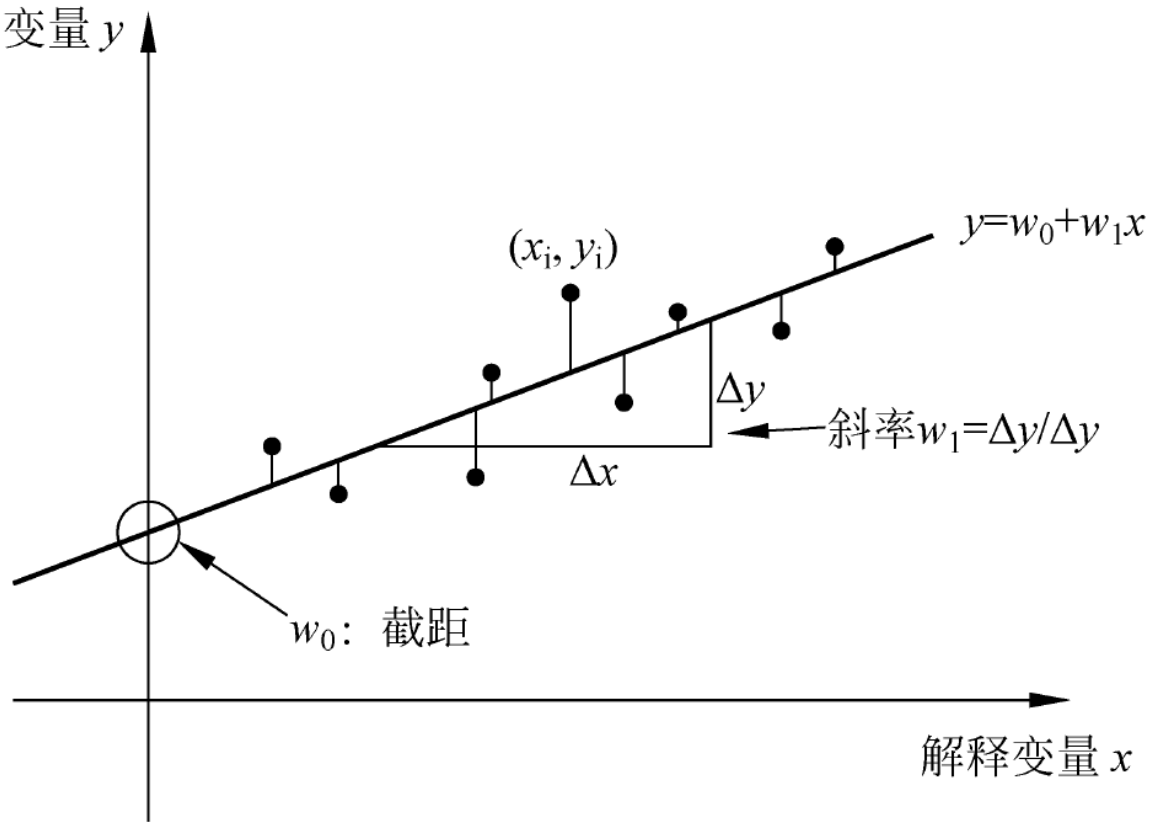
$g(x) = g_1(x) - g_2(x)$

$$\begin{cases} g(x) > 0, x \in w_1 \\ g(x) < 0, x \in w_2 \\ g(x) = 0, x\text{任意分类} \end{cases}$$

- **线性回归**

  通过数据发现或估计两个或多个变量之间可能存在的线性依赖关系的基本统计学方法

- **简单线性回归**
  - 响应变量y
  - 解释变量x
- 通过(x, y)的一系列观测样本，估计线性关系$y = w_0 + w_1 x$，即估计其中的系数w_0和w_1



- **多元线性回归**

  响应变量依赖于多个解释变量

$$y = w_0 + w_1 x + \cdots + w_d x_d = \sum_{i=0}^{d} w_i x_i = \boldsymbol{w}^T \boldsymbol{x}$$

- **机器学习领域的线性回归问题描述**

  假设有训练样本集

$$\{(x_1, y_1), \ldots, (x_N, y_N)\}, \quad \boldsymbol{x}_j \in R^{d+1}, \quad y_j \in R$$

  机器学习模型为

$$f(\boldsymbol{x}) = w_0 + w_1 x + \cdots + w_d x_d = \sum_{i=0}^{d} w_i x_i = \boldsymbol{w}^T \boldsymbol{x}$$

  其中，$\boldsymbol{w} = [w_0, w_1, \ldots, w_d]^T$是模型中待定的参数。

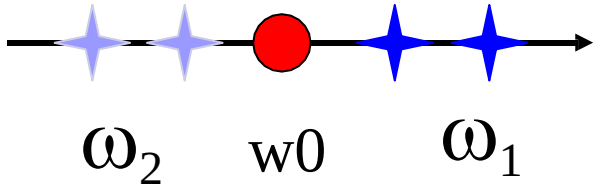
3.2 线性判别函数

线性判别函数是**线性分类器的核心概念**，**通过线性判别函数可以实现分类**，其基本概念为：

- 一维数据

两类的分界点为w0，判别函数表示为：

$$g(x)=x-w0$$

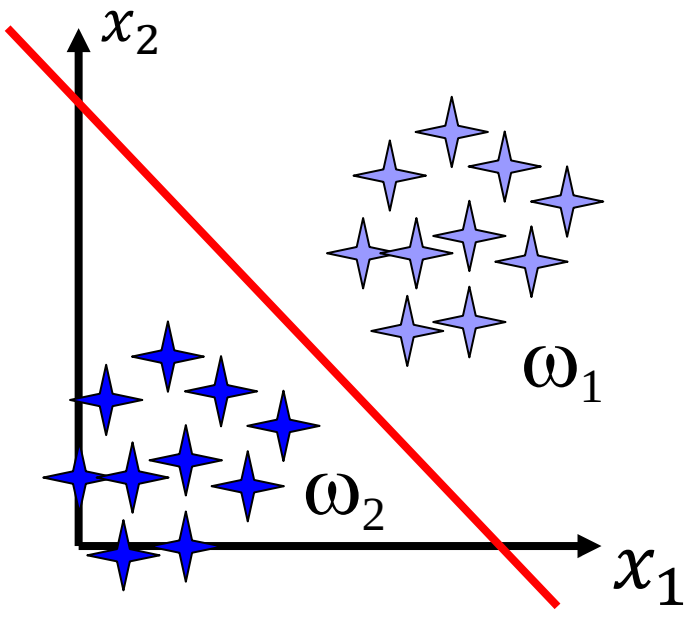


- 二维数据

两类的判别函数表示为：

$$g(x)=w_1x_1+w_2x_2+w_0=\mathbf{w}^T\mathbf{x}+w$$

w、**x**均为二维列向量

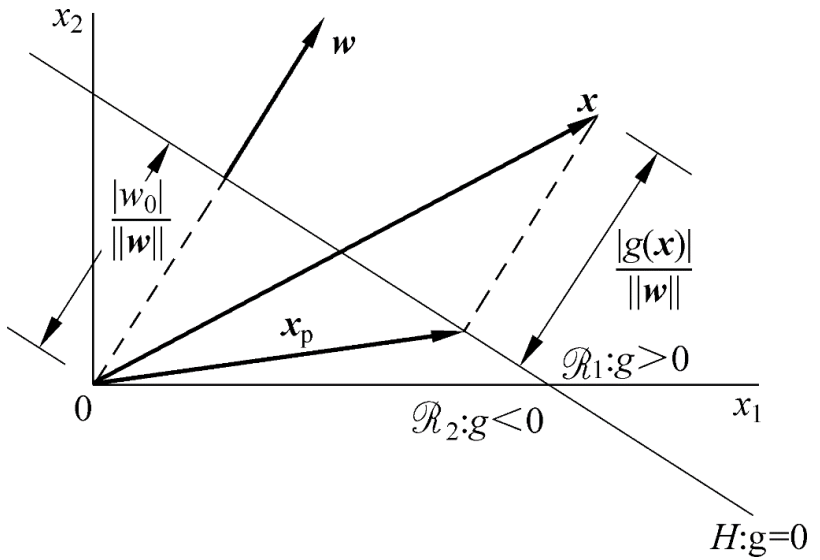


- 一般表达式

$$g(\boldsymbol{x}) = \boldsymbol{w}^T\boldsymbol{x} + w_0$$

$\boldsymbol{x}$: d维特征向量（样本向量），$\boldsymbol{x} = \begin{bmatrix} \boldsymbol{x}_1 \\ \boldsymbol{x}_2 \\ \vdots \\ \boldsymbol{x}_d \end{bmatrix}$

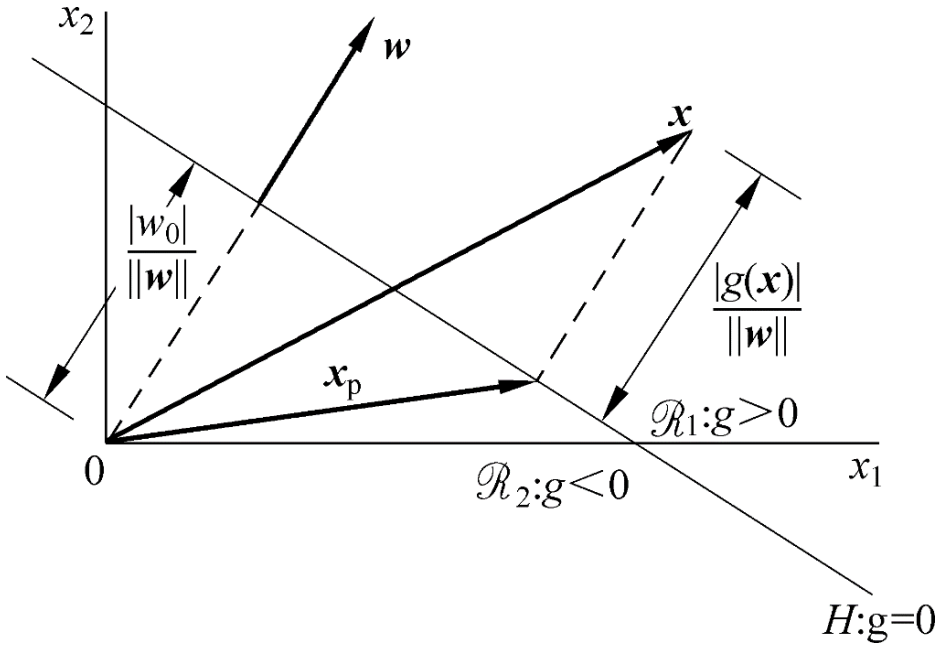
$\boldsymbol{w}$: 权向量，$\boldsymbol{w} = \begin{bmatrix} \boldsymbol{w}_1 \\ \boldsymbol{w}_2 \\ \vdots \\ \boldsymbol{w}_d \end{bmatrix}$



- 决策规则

令 $g(\boldsymbol{x}) = g_1(\boldsymbol{x}) - g_2(\boldsymbol{x})$。则

$$\begin{cases} \text{如果} g(\boldsymbol{x}) > 0\text{，则决策} \boldsymbol{x} \in \omega_1 \\ \text{如果} g(\boldsymbol{x}) < 0\text{，则决策} \boldsymbol{x} \in \omega_2 \\ \text{如果} g(\boldsymbol{x}) = 0\text{，可将} \boldsymbol{x} \text{任意分到某一类，或拒绝} \end{cases}$$



超平面H，决策区域$\mathcal{R}_1$和$\mathcal{R}_2$；

判别函数$g(\boldsymbol{x})$正比于$\boldsymbol{x}$点到超平面的代数

距离（带正负号）,$r = \frac{g(x)}{\|\omega\|}$;

$\boldsymbol{x}$在H正侧： $g(\boldsymbol{x}) > 0$；在负侧： $g(\boldsymbol{x}) < 0$

Fisher线性判别分析

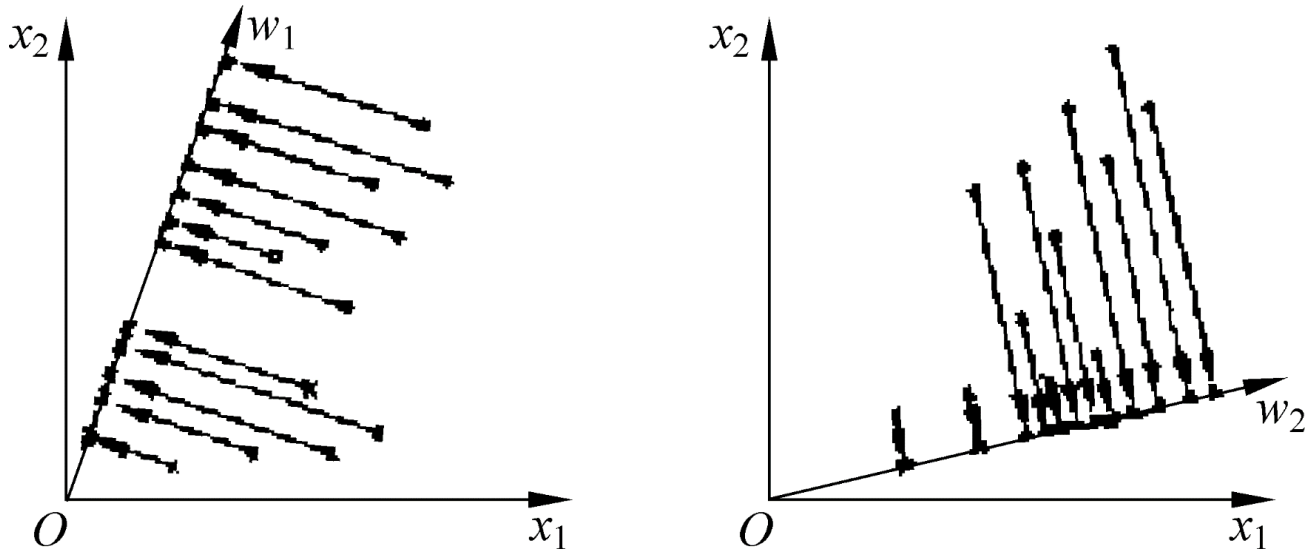
- 原理

降维：把多维空间的特征（样本）变换到低维， 简化问题。这在模式识别中是一个关键问题

- 思路：

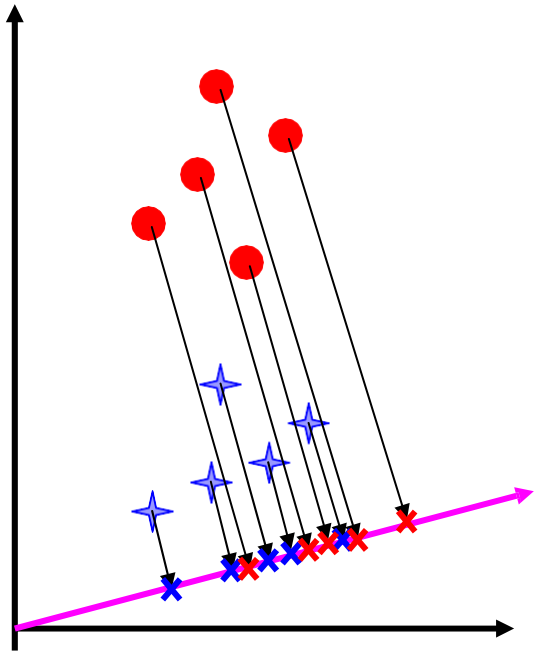
把所有样本都投影到一个方向上，在一维空间中确定一个分类的阈值

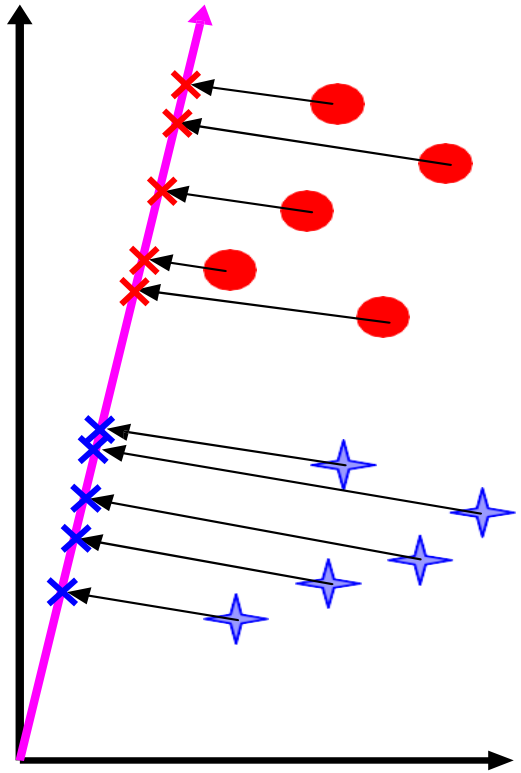
——寻找投影方向，使两类样本间隔远，同类样本聚集



- 思路

将原图加上颜色，如图所示：蓝色的星为一类数据，红色的圆为一类数据，选择紫色的直线为投影线，投影后两 类的数据混在一起，很难分开





- 选择另一个方向的投影线，投影后两类样本相互分开，很容易分类
- 对于d维样本，总是可以找到某一 个方向，样本投影在这个方向的直线上，分开的最好
- Fisher法就是要找到这条最易分类的投影线

- 基本定义

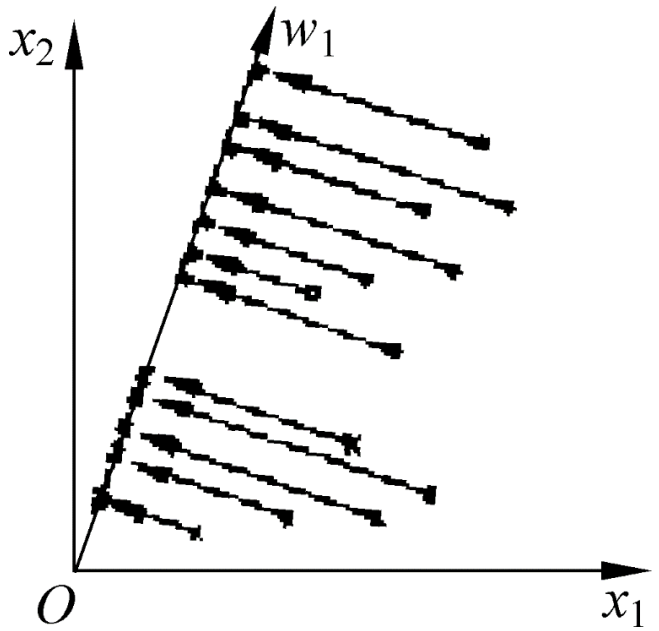
训练样本集$\mathcal{X} = \{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N\}$，每个样本为$d$维向量

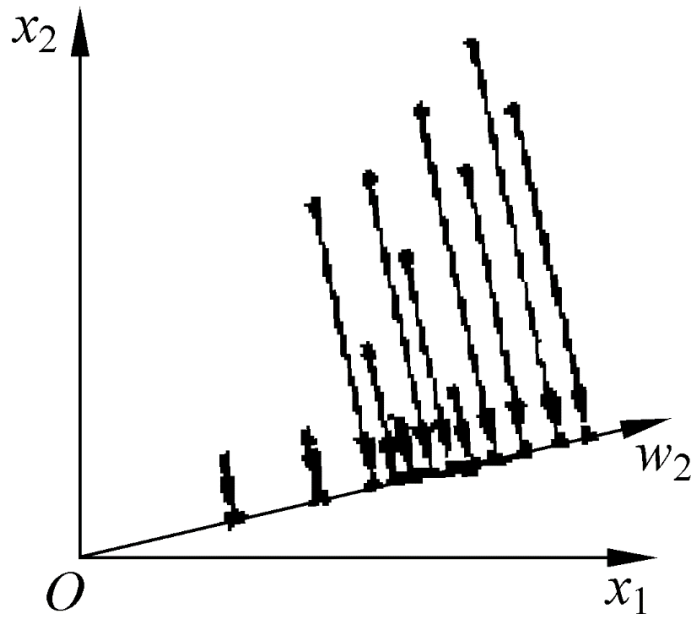
这里只讨论两类分类问题

ω_1类的样本$\mathcal{X}_1 = \{\boldsymbol{x}_1^1, \ldots, \boldsymbol{x}_{N_1}^1\}$，$\omega_2$类的样本$\mathcal{X}_2 = \{\boldsymbol{x}_1^2, \ldots, \boldsymbol{x}_{N_2}^2\}$

寻找投影方向$\boldsymbol{w}$，使得投影后的样本为

$$y_i = \boldsymbol{w}^T \boldsymbol{x}_i, \qquad i = 1, 2, \ldots, N$$





- 投影前
  - 类内离散度矩阵（within-class scatter matrix）

$$S_i = \sum_{x_j \epsilon X_i} (x_j - m_i)(x_j - m_i)^T, \qquad i = 1,2$$

在原样本空间中，类均值向量为

$$m_i = \frac{1}{N_i} \sum_{x_j \epsilon X_i} x_j, \qquad i = 1,2$$

  - 总类内离散度矩阵（pooled within-class scatter matrix）

$$S_w = S_1 + S_2$$

  - 类间离散度矩阵（between-class scatter matrix）

$$\boldsymbol{S}_b = (\boldsymbol{m}_1 - \boldsymbol{m}_2)(\boldsymbol{m}_1 - \boldsymbol{m}_2)^T, \qquad i = 1,2$$

- 投影后一维空间
  - 类内离散度

$$\tilde{S}_i^2 = \sum_{y_j \epsilon \mathcal{Y}_i} \left(y_j - \tilde{m}_i\right)^2$$

其中，两类均值为

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y_j \epsilon \mathcal{Y}_i} y_j = \sum_{x_j \epsilon \mathcal{X}_i} w^T x_j = w^T m_i, \qquad i = 1,2$$

  - 总类内离散度

$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$$

  - 类间离散度

$$\tilde{S}_b = (\tilde{m}_1 - \tilde{m}_2)^2, \qquad i = 1,2$$

- Fisher准则函数（Fisher's Criterion）

$$\max J_F(\omega) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

即，使投影后两类尽可能分开，而各类内部尽可能聚集

- 带入$y_i = \boldsymbol{w}^T \boldsymbol{x}_i$，Fisher判别准则变成

$$\max J_F(\omega) = \frac{\boldsymbol{w}^T \boldsymbol{S}_b \boldsymbol{w}}{\boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w}}$$

——数学物理学界称为广义Rayleigh熵（熵generalized Rayleigh quotient）

- 求解

$$\max \quad \boldsymbol{w}^T \boldsymbol{S}_b \boldsymbol{w}$$
$$\text{s.t.} \quad \boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w} = c \neq 0$$

定义拉格朗日（Lagrange）函数

$$L(\boldsymbol{w}, \lambda) = \boldsymbol{w}^T \boldsymbol{S}_b \boldsymbol{w} - \lambda\left(\boldsymbol{w}^T \boldsymbol{S}_b \boldsymbol{w} - c\right)$$

令$\frac{\partial L(\boldsymbol{w},\lambda)}{\partial \boldsymbol{w}}=0$，极值解$\boldsymbol{w}^*$应满足：

$$\boldsymbol{S}_b\boldsymbol{w}^*-\lambda\boldsymbol{S}_w\boldsymbol{w}^*=0$$

假设$\boldsymbol{S}_w$是非奇异的（$N>d$时通常非奇异），可得

$$\boldsymbol{S}_w^{-1}\boldsymbol{S}_b\boldsymbol{w}^*=\lambda\boldsymbol{w}^*$$

即$\boldsymbol{w}^*$为$\boldsymbol{S}_w^{-1}\boldsymbol{S}_b$的本征向量

将$\boldsymbol{S}_b$带入可得：

$$\lambda\boldsymbol{w}^*=\boldsymbol{S}_w^{-1}(\boldsymbol{m}_1-\boldsymbol{m}_2)(\boldsymbol{m}_1-\boldsymbol{m}_2)^T\boldsymbol{w}^*$$

标量

只考虑$\boldsymbol{w}^*$的方向，得

$$\boldsymbol{w}^*=\boldsymbol{S}_w^{-1}(\boldsymbol{m}_1-\boldsymbol{m}_2)$$

- 决策规则

$$若g(x)=\boldsymbol{w}^T\boldsymbol{x}+w_0\begin{matrix}>\\<\end{matrix}0，则x\in\begin{cases}\omega_1\\\omega_2\end{cases}$$

- **确定阈值w_0：**

（1）样本近似正态分布（d和N很大），可在投影空间内用贝叶斯分类器，即

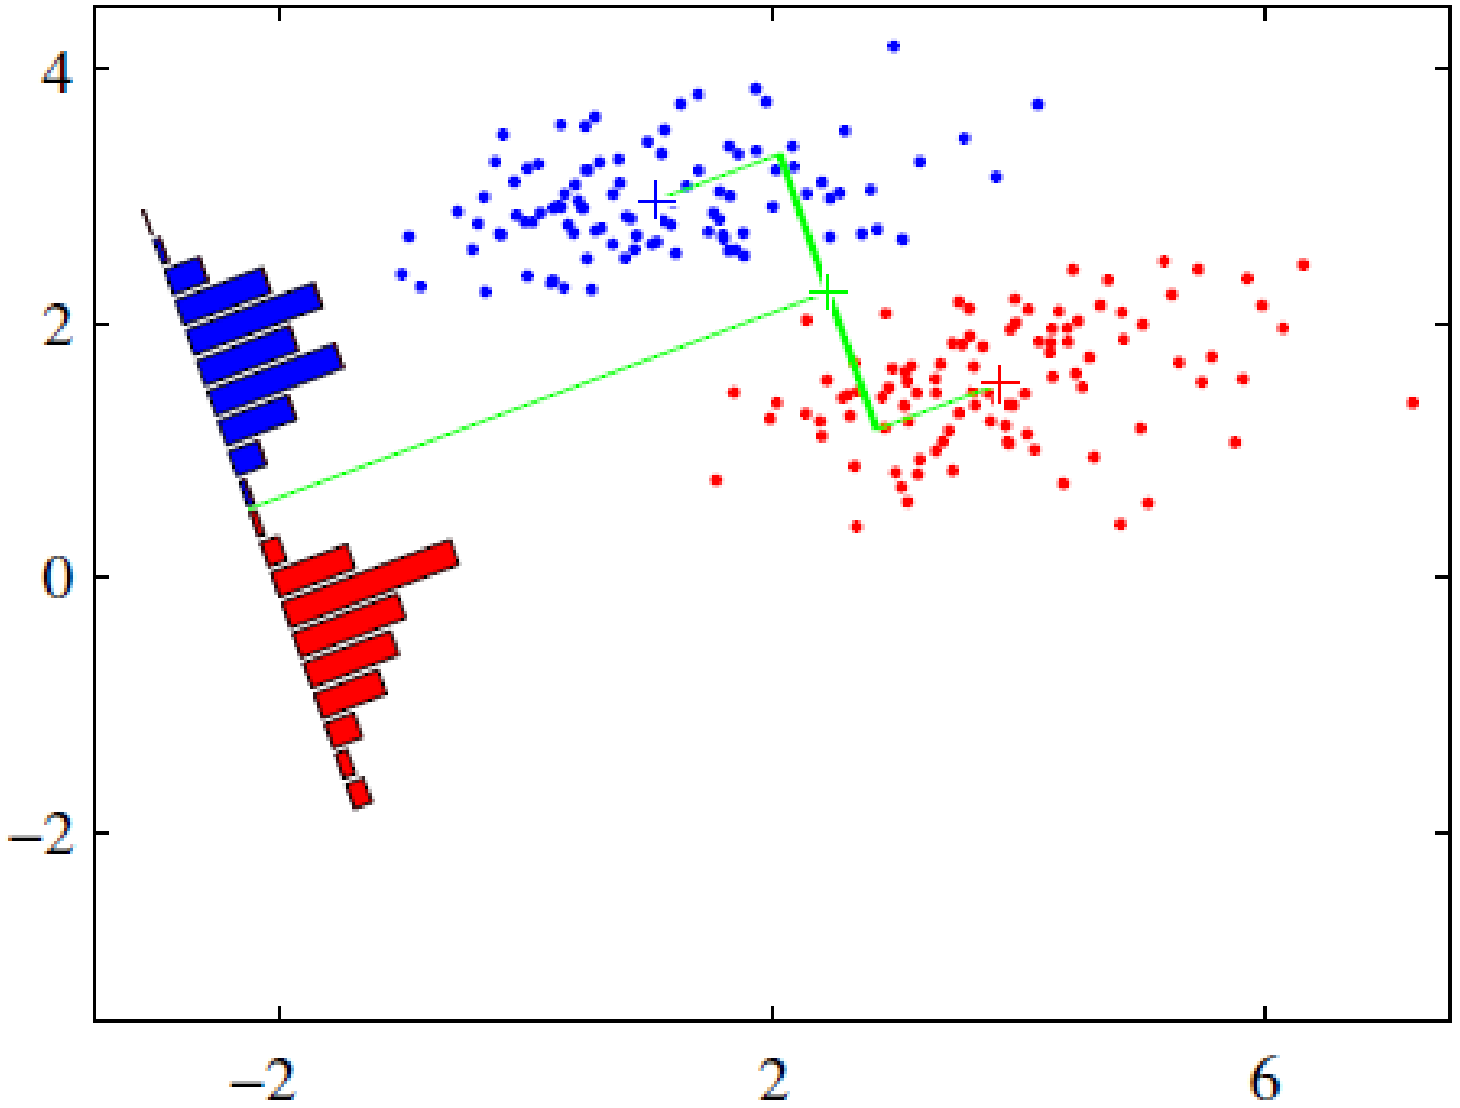
$$w_0=-\frac{1}{2}(\boldsymbol{m}_1-\boldsymbol{m}_2)^T\boldsymbol{S}_w^{-1}(\boldsymbol{m}_1-\boldsymbol{m}_2)-\ln\frac{P(\omega_2)}{P(\omega_1)}$$

（2）样本不是正态分布，可依据经验，如

$$w_0=-\frac{1}{2}(\tilde{m}_1+\tilde{m}_2)$$

$$w_0=-\tilde{m}（\tilde{m}\text{ 是所有样本在投影后的均值}）$$

Fisher线性判别分析



- 例题

蠓的二分类问题是源自美国大学生数学建模竞赛的一个题目，其大意是：生物学家W.L Grogan和W.W.Wirth试图将两种蠓Apf和Af进行鉴别，给出了9只Af和6只Apf蠓虫的触角长度和翅膀长度的数据，已知Af是宝贵的传粉益虫，Apf是某种疾病的载体，要求建立一种模型，正确区分两类蠓虫。

已知6只Apf蠓虫(Apf midges)和9只Af蠓虫(Af midges)的触长、翅长数据表见表1(Talbe 1)和表2(Table 2)所示。

Table 1 Apf midges

Antenna length (cm)	1.14	1.2	1.3	1.26	1.28	1.18
Wing length (cm)	1.78	1.86	1.96	2.0	2.0	1.96

Table 2 Af midges

Antenna length (cm)	1.24	1.24	1.36	1.4	1.38	1.48	1.38	1.54	1.56
Wing length (cm)	1.72	1.72	1.74	1.7	1.82	1.82	1.9	1.82	2.08

- 例题

问题1: 试给出该问题的Fisher分类器；

问题2：有三个待识别的模式样本，它们分别是(1.24,1.80)T，(1.28,1.84)T，(1.40,2.04)T，试问这三个样本属于哪一种蠓。

按照前面给出的两类问题Fisher线性分类器计算步骤，蠓的二分类问题计算过程如下：

- 例题

解：

（1）均值样本方差

$$\bar{x}_1^{(1)} = \frac{1}{6}(1.14 + 1.18 + \cdots + 1.28) = 1.227$$

$$\bar{x}_1^{(2)} = \frac{1}{6}(1.78 + 1.96 + \cdots + 1.96) = 1.927$$

- $$\bar{x}_2^{(1)} := \frac{1}{9}(1.24 + 1.36 + \cdots + 1.56) = 1.413$$

$$\bar{x}_2^{(2)} = \frac{1}{9}(1.72 + 1.74 + \cdots + 1.78) = 1.800$$

- $$\bar{\mathbf{x}}_1 = \begin{bmatrix} \bar{x}_1^{(1)} \\ \bar{x}_1^{(2)} \end{bmatrix} = \begin{bmatrix} 1.227 \\ 1.927 \end{bmatrix}$$

- $$\bar{\mathbf{x}}_2 = \begin{bmatrix} \bar{x}_2^{(1)} \\ \bar{x}_2^{(2)} \end{bmatrix} = \begin{bmatrix} 1.413 \\ 1.800 \end{bmatrix}$$

（2）求两类样本类内离散度矩阵S_i

$$S_1 = \begin{pmatrix} 1.14 - 1.227 \\ 1.78 - 1.927 \end{pmatrix}(1.14 - 1.227 \quad 1.78 - 1.927) + \cdots + \begin{pmatrix} 1.28 - 1.227 \\ 1.96 - 1.927 \end{pmatrix}(1.28 - 1.227 \quad 1.96 - 1.927) = \begin{pmatrix} 0.0197 & 0.0225 \\ 0.0225 & 0.0389 \end{pmatrix}$$

$$S_2 = \begin{pmatrix} 1.24 - 1.413 \\ 1.72 - 1.804 \end{pmatrix}(1.24 - 1.413 \quad 1.72 - 1.804) + \cdots + \begin{pmatrix} 1.56 - 1.413 \\ 1.78 - 1.804 \end{pmatrix}(1.56 - 1.413 \quad 1.78 - 1.804) = \begin{pmatrix} 0.0784 & 0.0536 \\ 0.0536 & 0.1352 \end{pmatrix}$$

（3）求总的类内离散度矩阵S_w

$$S_w = S_1 + S_2 = \begin{pmatrix} 0.0981 & 0.0761 \\ 0.0761 & 0.1741 \end{pmatrix}$$

- 例题

解：

（4）求权向量W^*

- $S_w^{-1} = \begin{pmatrix} 15.4209 & -6.7422 \\ -6.7422 & 8.6905 \end{pmatrix}$
- $W^* = S_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) = (-3.7326 \quad 2.3593)^T$

（5）求两类已知样本X_1和X_2在W^*上的投影点y_i

- $y_1 = \mathrm{W}^{*T}X_1, \qquad y_2 = \mathrm{W}^{*T}X_2$
- $y1 = [-0.05550.2199 - 0.09070.0156 - 0.1337 - 0.1534]^T$
- $y2 = \begin{matrix}[-0.5703 - 0.9711 - 1.2816 - 0.8570 - 0.6682 \\ -1.2147 - 1.2302 - 0.8407 - 1.6232]^T\end{matrix}$

（6）求各类样本的均值$\bar{Y}_i$

- $\bar{Y}_i = \frac{1}{N_i}\sum_{Y\in\omega} Y$
- $\bar{y}_1 = -0.0330$
  $\bar{y}_2 = -1.0286$

（7）选取分类阈值W_0，可以有三种取法，这里取

- $W_0 = \frac{\bar{Y}_1 + \bar{Y}_2}{2} = -0.5308$

（8）对待测样本x，计算它在W^*上的投影点y

公式:$\mathrm{y=W^{*T}x}$

$$X = \begin{pmatrix} 1.24 & 1.80 \\ 1.28 & 1.84 \\ 1.40 & 2.04 \end{pmatrix}$$

$$\Rightarrow$$

$$Y = (-0.3816, -0.4365, -0.4126)^T$$

（9）根据判别规则对样本X进行分类

$\mathrm{Y = W^{*T}X > W0}$，则$\mathbf{x} \in \omega 1$;

$\mathrm{Y = W^{*T}X < W0}$，则$\mathbf{x} \in \omega 2$。

根据（7），分类阈值$W_0 = -0.5308$

而：$Y = (-0.3816, -0.4365, -0.4126)^T$

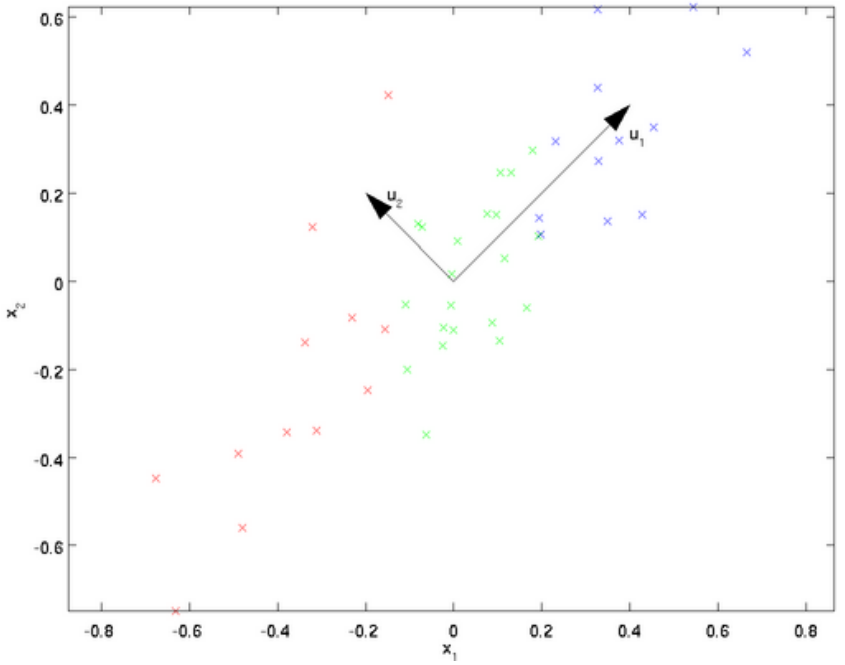
可以看出，$y_i > W_0$

因此，这三个样本都属于Apf蠓（$\omega 1$类）

主成分分析(PCA)

假定有N个d-维样本$x_1, \cdots, x_N$，并对输入数据进行了中心化处理，即$\sum_{i=1}^{N} x_i = 0$。投影矩阵$W \in \mathbb{R}^{d \times d'} = [w_1, \ldots, w_{d'}]$，其中$\|w_i\|_2 = 1, w_i^T w_j = 0$。

由$y_i = W^T x_i$可得到N个对应的低维表示$y_1, \cdots, y_N$。对于任意一个输入样本x_i，其投影后低维表示的方差为$W^T x_i x_i^T W$。为了使得所有低维投影方差和最大，即最大化$\sum_{i=1}^{N} W^T x_i x_i^T W$。



主成分分析(PCA)

PCA问题的目标函数为

$$\max_{W} \ \mathrm{Tr}(W^T X X^T W), \ \ \text{s.t.}, W^T W = I.$$

利用拉格朗日函数可得到

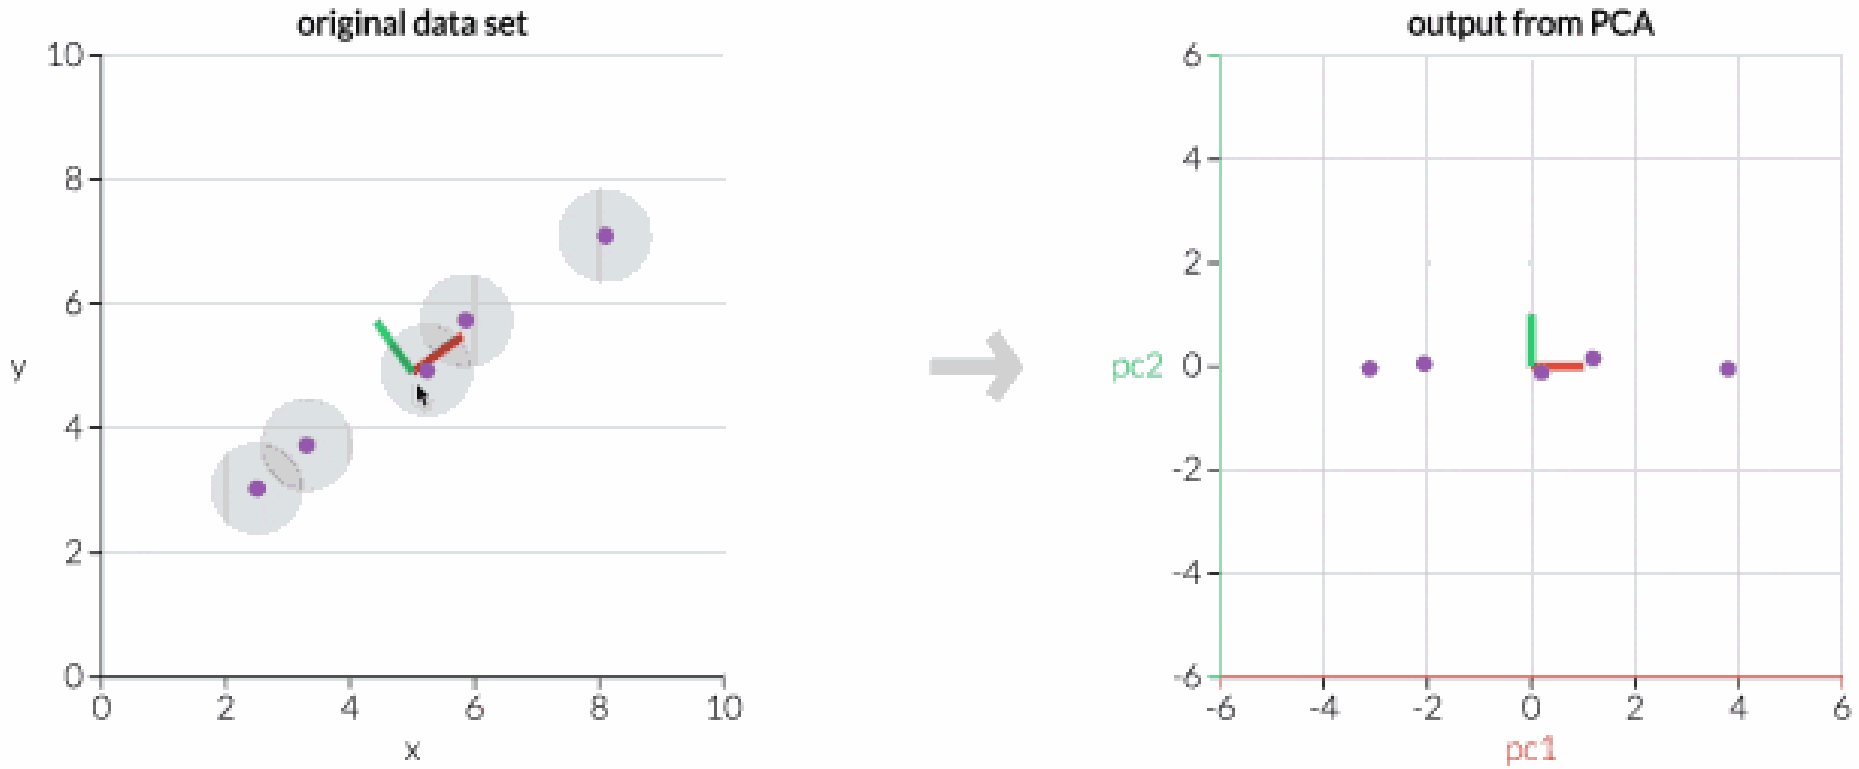
$$J(W) = \mathrm{Tr}(W^T X X^T W) + \lambda \|W^T W - I\|_F.$$

对W求导可得到$XX^TW + \lambda W = 0$，可整理为

$$XX^TW = (-\lambda)W.$$

2D示例

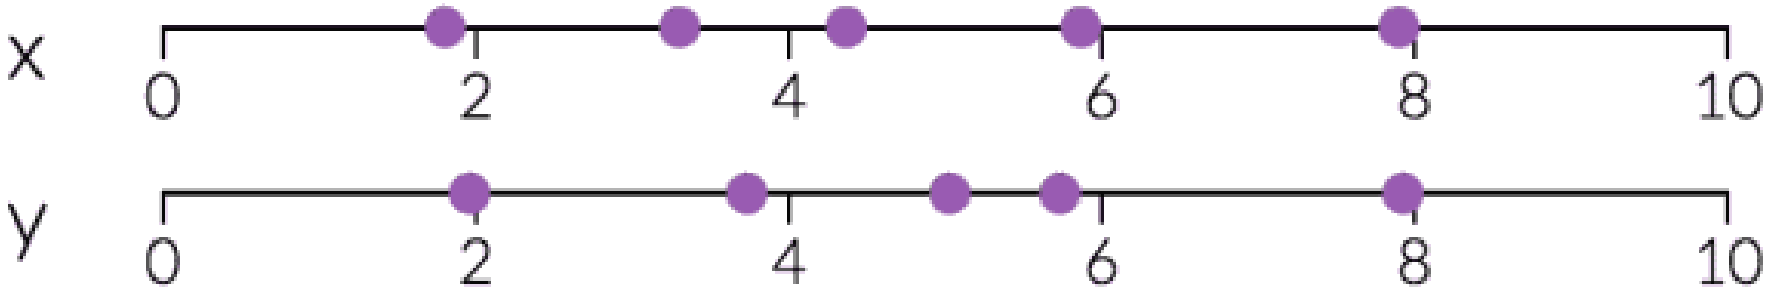
首先，只考虑两个维度的数据集，比如高度和重量。这个数据集可以绘制成平面上的点。但如果想要整理出变量，PCA会找到一个新的坐标系，其中每个点都有一个新的(x, y)值。坐标轴实际上没有任何物理意义。它们是高度和重量的组合，被称为“主分量”。



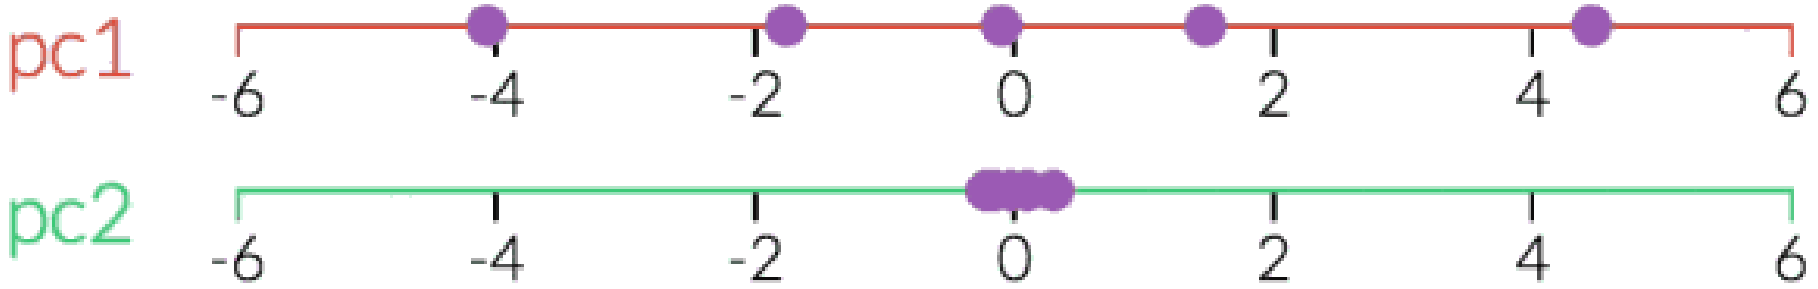
拖动原始数据集中的点，可以看到PC坐标系统正在调整

2D示例

PCA对于降维很有用。下面，我们将数据绘制成两条直线:一条由x值组成，另一条由y值组成。

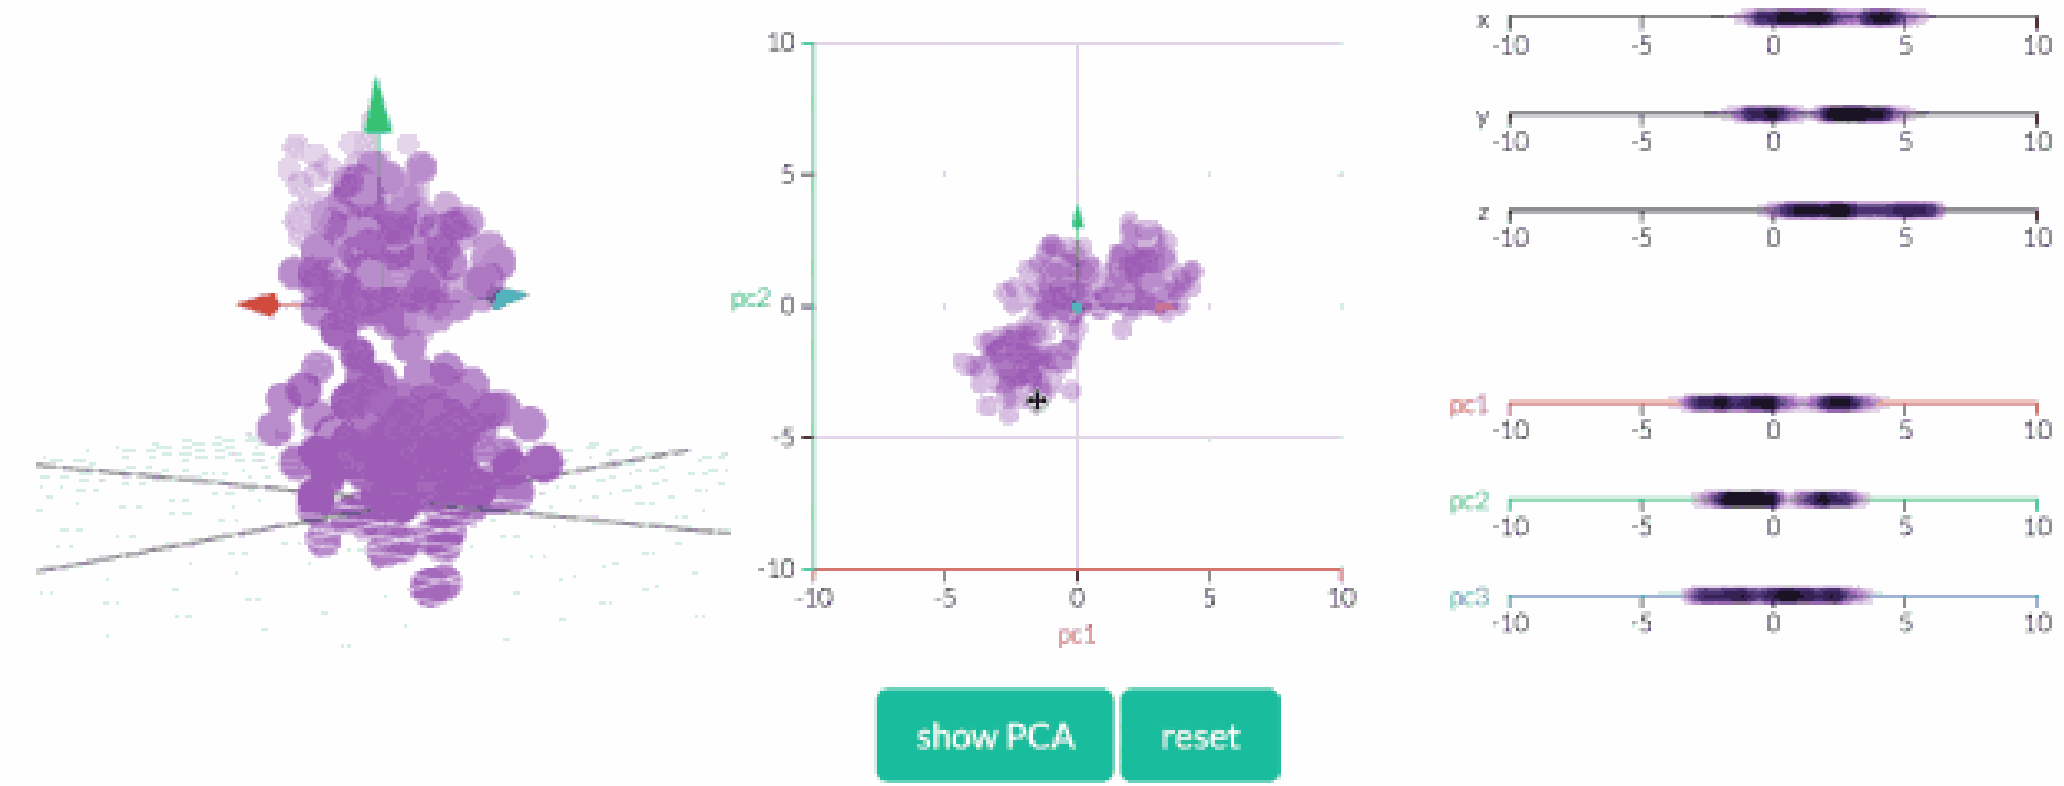


但是，如果我们只打算沿一个维度查看数据，那么将该维度作为具有最大变化的主成分可能会更好。通过减少PC2，不会造成太大损失，因为它对数据集的变化贡献最小。



3D示例

看透一个数据云是非常困难的，因此，在3D空间中，PCA显得更为重要。在下面的示例中，原始数据以3D的形式绘制，但可以通过不同的视角，将其投射到2D空间。确定好角度之后，点击“显示PCA”按钮，即可呈现2D的结果。在本例中，PCA变换确保水平轴PC1的变化量最大，垂直轴PC2的变化量次之，第三轴PC3的变化量最少。显然，PC3是丢弃的。



3D示例

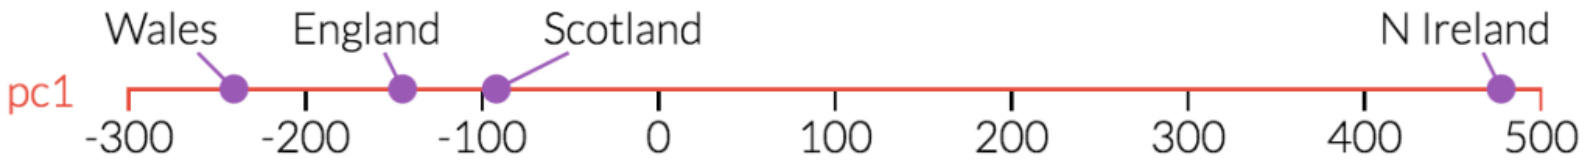
如果数据集不仅仅是三维的，而是17个维度的呢？！如下表所示：

表中是英国每个地区平均每人每周17种食物的消费量，单位为克。这张表显示了不同食物类型之间存在的一些有趣的差异，但总体差异并不显著。让我们看看PCA是否可以通过降维来强地区家之间的差异。

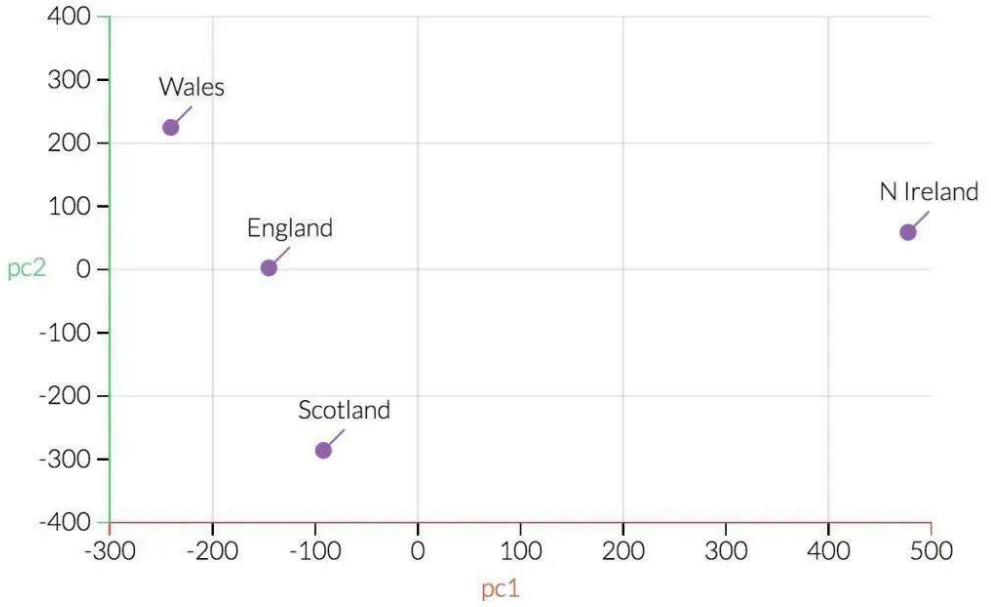
	England	N Ireland	Scotland	Wales
Alcoholic drinks	375	135	458	475
Beverages	57	47	53	73
Carcase meat	245	267	242	227
Cereals	1472	1494	1462	1582
Cheese	105	66	103	103
Confectionery	54	41	62	64
Fats and oils	193	209	184	235
Fish	147	93	122	160
Fresh fruit	1102	674	957	1137
Fresh potatoes	720	1033	566	874
Fresh Veg	253	143	171	265
Other meat	685	586	750	803
Other Veg	488	355	418	570
Processed potatoes	198	187	220	203
Processed Veg	360	334	337	365
Soft drinks	1374	1506	1572	1256
Sugars	156	139	147	175

3D示例

下图是第一个主成分的数据图。我们可以看到一些有关北爱尔兰的情况已经发生了变化。



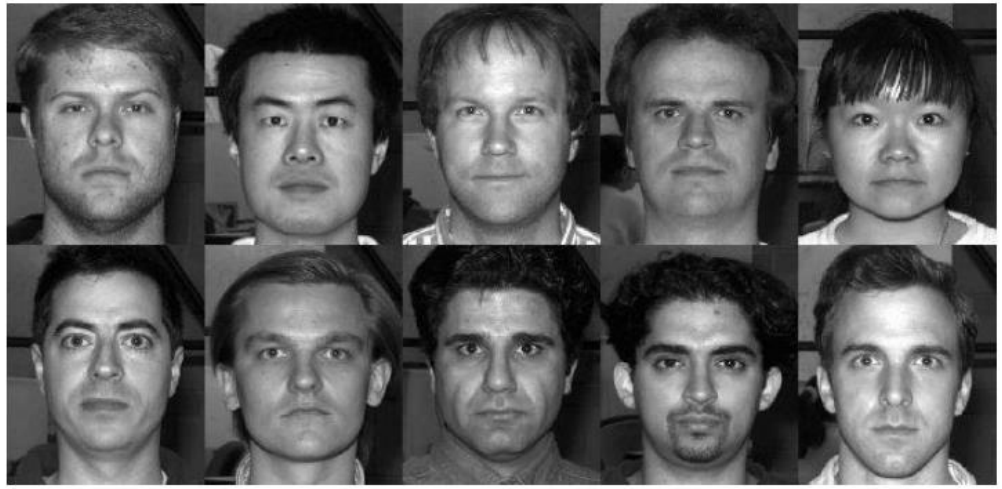
现在，看看第一和第二主成分，可以看到北爱尔兰是一个主要的异常值。一旦回过头来看看表格中的数据，这就显得很有道理了:北爱尔兰人吃的新鲜土豆要很多，吃的新鲜水果、奶酪、鱼和酒精饮料较少。这是一个很好的迹象，我们所看到的结构反映了现实世界地理的一个重要事实北爱尔兰是四个国家中唯一一个不在大不列颠岛上的。





Eigenfaces Example

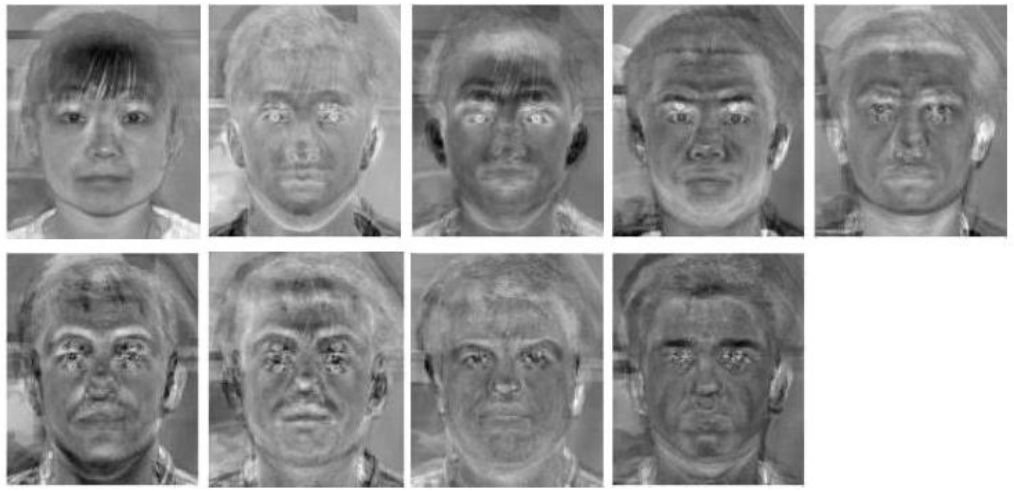
Face database



[11] Yale database

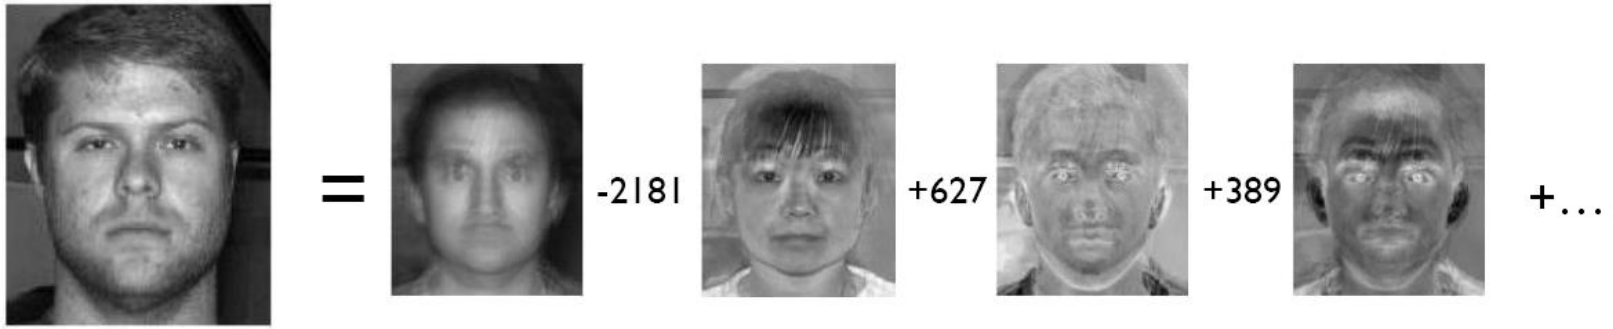
Eigenvectors





Eigenfaces Example

Face reconstruction



- M. Turk, A. Pentland, "Eigenfaces for Recognition", *Journal of Cognitive Neuroscience*, vol. 3, no. 1, pp. 71-86, 1991.

LDA vs PCA

相同点:

1. 两者均可以对数据进行降维;
2. 两者在降维时均使用了矩阵特征分解的思想;
3. 两者都假设数据符合高斯分布。

不同点:

1. LDA是有监督的降维方法，而PCA是无监督的降维方法;
2. LDA降维最多降到类别数C-1的维数，而PCA没有这个限制;
3. LDA除了可以用于降维，还可以用于分类;
4. LDA选择分类性能最好的投影方向，而PCA选择样本点投影具有最大方差的方向。

3.3 感知器算法

- 线性判别函数的齐次简化

$$g(\boldsymbol{x}) = \boldsymbol{w}^T\boldsymbol{x} + w_0 \quad \rightarrow \quad g(\boldsymbol{y}) = \boldsymbol{\alpha}^T\boldsymbol{y}$$

其中，$\boldsymbol{y} = [1, x_1, x_2, \ldots, x_d]^T$，$\alpha = [w_0, w_1, x_2, \ldots, w_{\mathrm{d}}]^T$

- 决策规则（两类ω_1、ω_2）

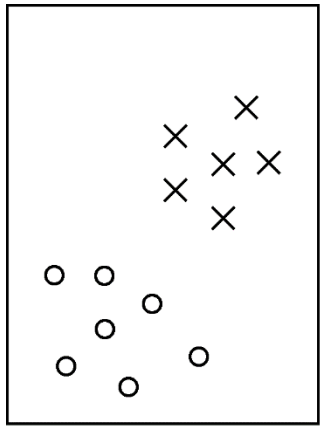
$$g(\boldsymbol{y}) \begin{matrix} > \\ < \end{matrix} 0，\text{则}\boldsymbol{y} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

- 线性可分性

  存在一个权限了$\boldsymbol{\alpha}$，使所有样本被正确分类。即：

  $\exists\alpha$，$\forall i=1,\ldots,N$，

$$\begin{cases}\text{若}\boldsymbol{y}_i\epsilon\omega_1\text{，则 }\boldsymbol{\alpha}^T\boldsymbol{y}_i>0\\ \text{若}\boldsymbol{y}_i\epsilon\omega_2\text{，则 }\boldsymbol{\alpha}^T\boldsymbol{y}_i<0\end{cases}$$

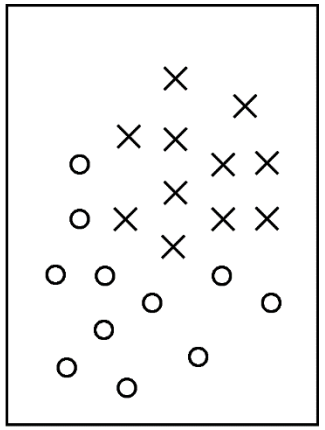


线性可分

- 令$\boldsymbol{y}_i'=\begin{cases}\boldsymbol{y}_i, & \text{若}\boldsymbol{y}_i\epsilon\omega_1\\ -\boldsymbol{y}_i, & \text{若}\boldsymbol{y}_i\epsilon\omega_2\end{cases}$

  则线性可分性变为：$\exists\alpha$，$\forall i=1,\ldots,N$，　$\boldsymbol{\alpha}^T\boldsymbol{y}_i'>0$

  $\boldsymbol{y}'$：规范化增广样本矩阵，记作$\boldsymbol{y}$



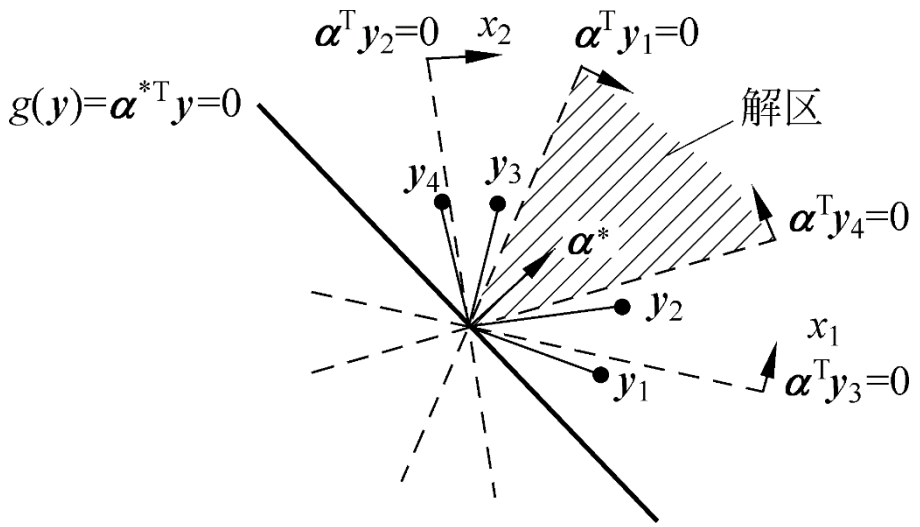
线性不可分

- 求解（线性可分情况）

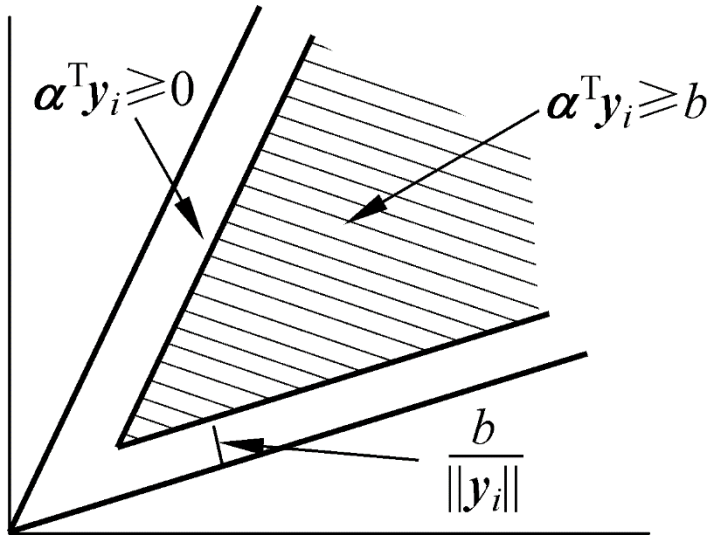
解向量$\boldsymbol{\alpha}^*$：满足 $\boldsymbol{\alpha}^T\boldsymbol{y}_i>0$，$i=1,2,\ldots,N$

解区：权值空间中所有解向量组成的区域

余量：把解区向中间缩小，不靠近边缘的解。即，引入余量$b>0$，使得解向量满足 $\boldsymbol{\alpha}^T\boldsymbol{y}_i>b$，$i=1,2,\ldots,N$



解向量和解区



余量

感知器是**一种经典的线性分类方法**，感知器算法可以视作一种利用线性判别函数实现分类的具体方法

- 感知器准则函数：

$$J_p(\boldsymbol{\alpha}) = \sum_{\boldsymbol{\alpha}^T \boldsymbol{y}_k \le 0} \left(-\boldsymbol{\alpha}^T \boldsymbol{y}_k\right)$$

当且仅当$J_p(\boldsymbol{\alpha}^*) = \min J_p(\boldsymbol{\alpha}) = 0$时，$\boldsymbol{\alpha}^*$是解向量

- 梯度下降法求解：

$$\boldsymbol{\alpha}(t+1) = \boldsymbol{\alpha}(t) - \rho_t \nabla J_p(\boldsymbol{\alpha})$$

$$\nabla J_p(\boldsymbol{\alpha}) = \frac{\partial J_p(\boldsymbol{\alpha})}{\partial \alpha} = \sum_{\boldsymbol{\alpha}^T \boldsymbol{y}_k \le 0} (-\boldsymbol{y}_k)$$

$$\therefore \ \boldsymbol{\alpha}(t+1) = \boldsymbol{\alpha}(t) + \rho_t \sum_{\boldsymbol{\alpha}^T \boldsymbol{y}_k \le 0} \boldsymbol{y}_k$$

- 梯度下降迭代算法步骤

（1）任意选择初始的权向量$\boldsymbol{\alpha}(0)$，置$t=0$；

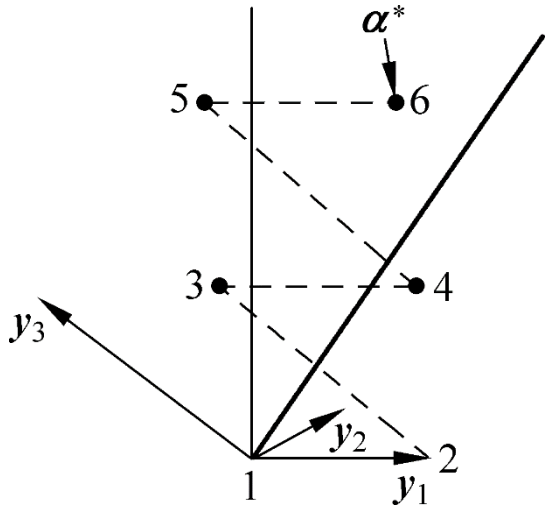
（2）考察样本$\boldsymbol{y}_j$，若 $\boldsymbol{\alpha}(t)^T\boldsymbol{y}_j \le 0$，则$\boldsymbol{\alpha}(t+1)=\boldsymbol{\alpha}(t)+\boldsymbol{y}_j$，否则继续；

（3）考察另一个样本，重复（2），直至对所有样本都有 $\boldsymbol{\alpha}(t)^T\boldsymbol{y}_j > 0$，即 $J_p(\boldsymbol{\alpha})=0$

- 说明：

（1）若考虑余量b，将错分判断条件变成 $\boldsymbol{\alpha}(t)^T\boldsymbol{y}_j \le b$即可

（2）收敛性：对于线性可分的样本集，梯度下降的迭代算法经过有限次修正后一定会收敛到一个解向量$\boldsymbol{\alpha}^*$



（3）可使用可变步长减少迭代步数：

$$\rho_t = \frac{\left|\boldsymbol{\alpha}(k)^T \boldsymbol{y}_j\right|}{\left\|\boldsymbol{y}_j\right\|^2}$$

- 例题

共给出三个零件的检验结果，利用感知机学习算法设计一个分类器

零件编号	宽度(wid)	长度(len)	检验类别
1	3	3	正品
2	4	3	正品
3	1	1	次品

令$\boldsymbol{x_1} = (3,3), y_1 = 1; \boldsymbol{x_2} = (4,3), y_2 = 1; \boldsymbol{x_3} = (1,1), y_3 = -1,$
则有$\boldsymbol{T} = \{(\boldsymbol{x_1}, y_1), (\boldsymbol{x_2}, y_2), (\boldsymbol{x_3}, y_3)\}$;
其中$(\boldsymbol{x_1}, y_1)$和$(\boldsymbol{x_2}, y_2)$为正实例点，$(\boldsymbol{x_3}, y_3)$为负实例点。

- 例题

解：

（1）设置初始值.$\boldsymbol{\omega_0} = (0,0), b_0 = 0, \eta = 1$（参数更新表达式中的η是步长或学习率。

（2）对$\boldsymbol{x_1} = (3,3), y_1(\boldsymbol{\omega} \cdot \boldsymbol{x_1} + b) = 0$，未能被正确分类，更新参数模型：

$$\boldsymbol{\omega_1} = \boldsymbol{\omega_0} + \eta y_1 \boldsymbol{x_1} = (3,3), b_1 = b_0 + \eta y_1 = 1$$

（3）$\boldsymbol{x_1}$，$\boldsymbol{x_2}$被正确分类，而$\boldsymbol{x_3} = (1,1), y_1(\boldsymbol{\omega} \cdot \boldsymbol{x_3} + b) < 0$，更新参数模型：

$$\boldsymbol{\omega_2} = \boldsymbol{\omega_1} + \eta y_3 \boldsymbol{x_3} = (2,2), b_2 = b_1 + \eta y_3 = 0$$

如此继续下去，直到$\boldsymbol{\omega_7} = (1,1), b_7 = -3$。分类正确，整个迭代过程见表：

迭代次数	误分类点	$\boldsymbol{\omega}$	b	$\boldsymbol{\omega} \cdot \boldsymbol{x_i} + b$
0		(0,0)	0	
1	$\boldsymbol{x_1}$	(3,3)	1	$3wid + 3len + 1$
2	$\boldsymbol{x_3}$	(2,2)	0	$2wid + 2len$
3	$\boldsymbol{x_3}$	(1,1)	-1	$wid + len - 1$
4	$\boldsymbol{x_3}$	(0,0)	-2	-2
5	$\boldsymbol{x_1}$	(3,3)	-1	$3wid + 3len - 1$
6	$\boldsymbol{x_3}$	(2,2)	-2	$2wid + 2len - 2$
7	$\boldsymbol{x_3}$	(1,1)	-3	$wid + len - 3$
8		(1,1)	-3	$wid + len - 3$

3.4 最小二乘法

- **“最小二乘法” 求解线性回归问题**

用训练样本集估计模型中的参数，使模型在最小平方误差意义下能够最好地拟合训练样本，即

$$\min_{\boldsymbol{w}} E = \frac{1}{N}\sum_{j=1}^{N}\left(f\left(\boldsymbol{x}_j\right) - y_j\right)^2$$

目标函数可进一步写成矩阵形式

$$E(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}\|^2 = \frac{1}{N}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})^T(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})$$

其中，$\boldsymbol{X} = \begin{bmatrix} \boldsymbol{x}_1^T \\ \vdots \\ \boldsymbol{x}_N^T \end{bmatrix}$是全部训练样本的解释变量向量组成的矩阵，$\boldsymbol{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}$是全部训练样本的响应变量组成的向量

使目标函数$E(\boldsymbol{w})$最小化的参数$\boldsymbol{w}$应满足

$$\frac{\partial E(\boldsymbol{w})}{\partial(\boldsymbol{w})}=\frac{2}{N}\boldsymbol{X}^T(\boldsymbol{X}\boldsymbol{w}-\boldsymbol{y})=0$$

即

$$\boldsymbol{X}^T\boldsymbol{X}\boldsymbol{w}=\boldsymbol{X}^T\boldsymbol{y}$$

因此，当矩阵$(\boldsymbol{X}^T\boldsymbol{X})$可逆时，最优参数的解为

$$\boldsymbol{w}^*=(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{y}$$

$(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T$ 被称为$\boldsymbol{X}$的伪逆（pseudo-inverse）矩阵，记作$\boldsymbol{X}^+$

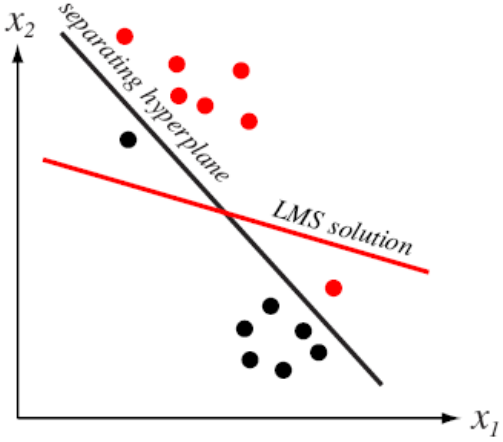
- 线性回归给出了在**最小均方差**意义下对解释变量与响应变量间线性关系的最好估计

3.4.1 均方差估计（Mean Square Error Estimation）

- 均方误差（MSE）的概念
- 在最小二乘法中，**均方误差估计通过最小化预测误差的平方和**，来求解线性模型的最佳参数

3.4.2 随机逼近和LMS算法（Least Mean Squares，最小均方）

- 与标准最小二乘法不同，**LMS算法随机梯度下降的方式来迭代更新模型参数，**使得误差平方和逐渐减小。这种随机比较方式使得算法更加适应动态环境，尤其适合**在线学习场景**

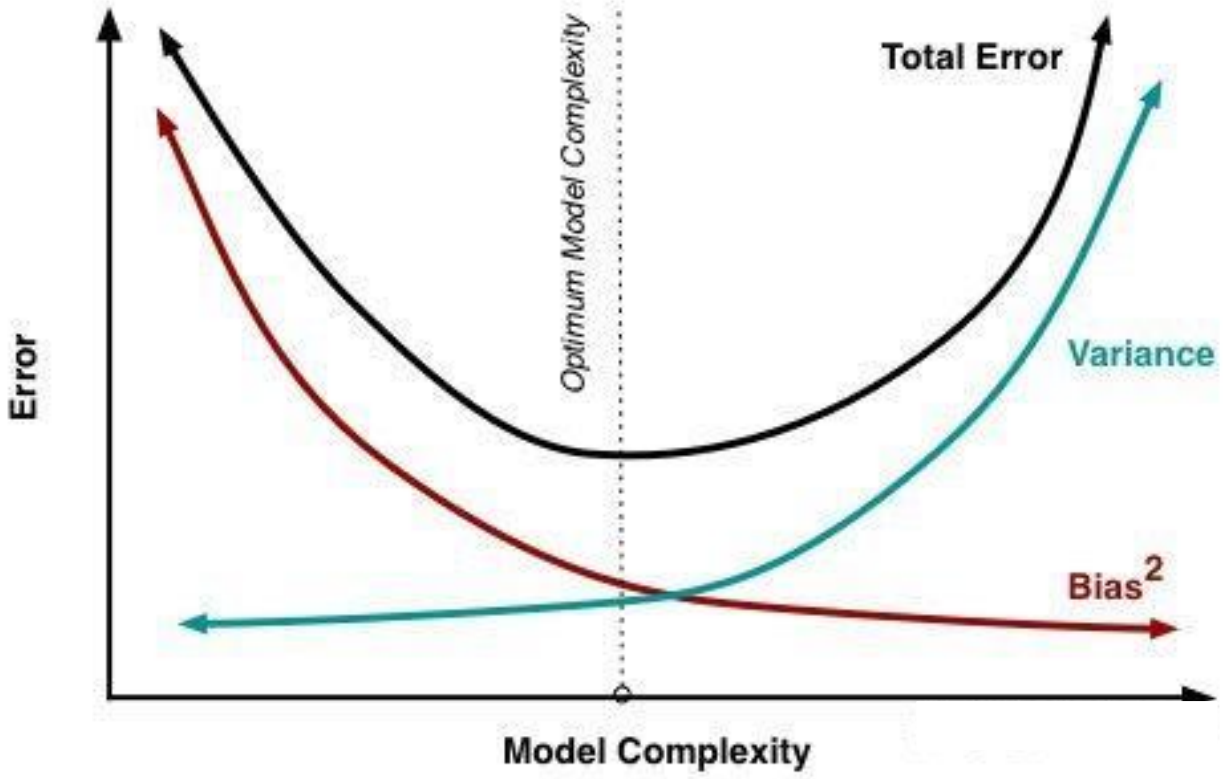


3.4.3 误差平方和SSE估计（Sum of Squares due to Error）

- 关注总误差平方和在模型拟合中的作用
- 误差平方和是**批量最小二乘法的核心**，它**直接反映了模型预测值与真实值之间的整体差异**，越小的误差平方和意味着模型越接近真实数据分布

偏差-方差困境

Bias - Variance Dilemma



Bias - Variance Dilemma描述了模型在泛化能力和拟合能力之间的权衡。

偏差和方差分别衡量了模型的系统误差和对数据噪声的敏感度，而偏差-方差窘境就是指这两者很难同时达到最优，通常需要在两者之间进行权衡

3.5 逻辑斯蒂判别

逻辑斯蒂判别通过**将线性分类与概率解释结合**，实现对分类结果的概率预测。
不仅仅判断样本属于哪个类别，还**通过逻辑函数将分类结果映射为一个概率值**，
这样可以更灵活地应用在不完全线性可分的场景中

- 线性回归（最小二乘法）

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m + \varepsilon$$

- 逻辑斯蒂函数（logistic function）

形式一

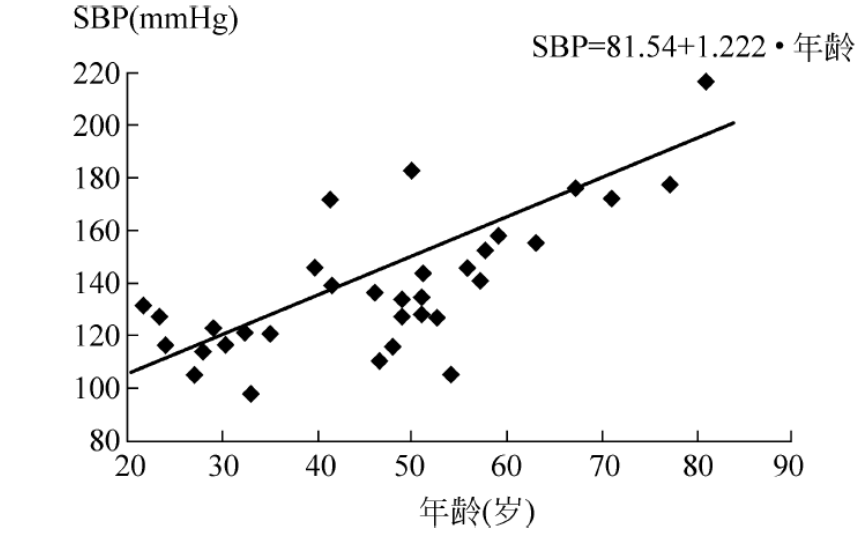
患病y=1，不患病y=−1

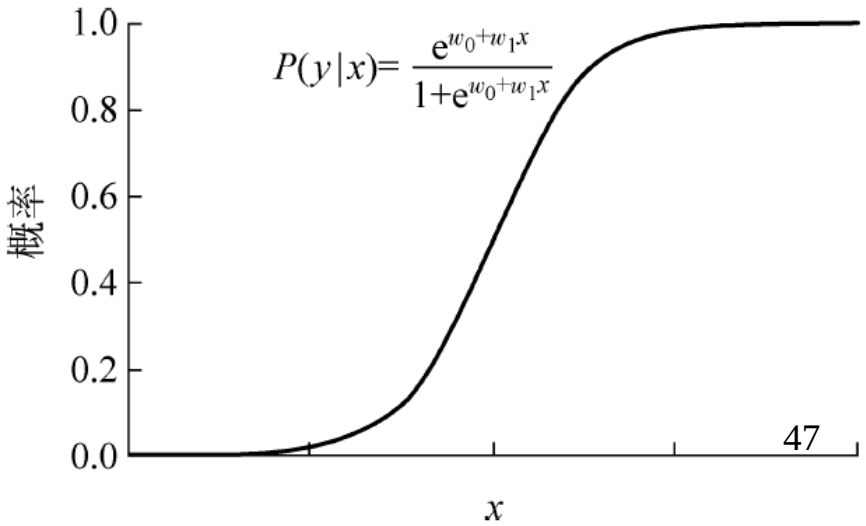
$$P(y=1|x) = \frac{e^{w_0+w_1 x}}{1+e^{w_0+w_1 x}}$$

也被记为$P(y|x)$

形式二（Sigmoid函数）

$$\theta(s) = \frac{e^s}{1+e^s} = \frac{1}{1+e^{-s}}$$





- 几率（odds）

患病与不患病之比

$$\frac{P(y|x)}{1-P(y|x)} = e^{w_0+w_1x}$$

- 对数几率（log odds）

$$\ln\left(\frac{P(y|x)}{1-P(y|x)}\right) = w_0 + w_1x$$

- 逻辑斯蒂回归（logistic regression）

$$\text{logit}(\boldsymbol{x}) = \ln\left(\frac{P(y|\boldsymbol{x})}{1-P(y|\boldsymbol{x})}\right) = w_0 + w_1x_1 + \cdots + w_mx_m$$

$$P(y|\boldsymbol{x}) = \frac{e^{w_0+w_1x_1+\cdots+w_mx_m}}{1+e^{w_0+w_1x_1+\cdots+w_mx_m}}$$

- 决策规则

$$\text{若 logit}(\boldsymbol{x})\begin{matrix}>0\\<0\end{matrix}\text{，则}\begin{matrix}\boldsymbol{x}\epsilon\omega_1\\\boldsymbol{x}\epsilon\omega_2\end{matrix}$$

- 学习算法：最大似然法

设共有N个独立的训练样本$\{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)\}$，$\boldsymbol{x}_j \epsilon R^{d+1}$，$y_j \epsilon \{-1, 1\}$

假设样本类别从某未知概率$f(\boldsymbol{x})$中产生，以概率$f(\boldsymbol{x})$属于所关心类别，即

$$P(y|\boldsymbol{x}) = \begin{cases} f(\boldsymbol{x}), & y = +1 \\ 1 - f(\boldsymbol{x}), & y = -1 \end{cases}$$

用逻辑斯蒂函数$h(\boldsymbol{x}) = \theta\left(\boldsymbol{\omega}^T \boldsymbol{x}\right)$估计$f(\boldsymbol{x})$，其中$\boldsymbol{\omega}$为逻辑斯蒂函数中待求参数组成的向量

模型h在样本$(\boldsymbol{x}_j, \boldsymbol{y}_j)$上的似然函数：

$$P(y_j|\boldsymbol{x}_j) = \begin{cases} h(\boldsymbol{x}_j), & y_j = +1 \\ 1 - h(\boldsymbol{x}_j), & y_j = -1 \end{cases}$$

或

$$l\left(h \mid (\boldsymbol{x}_j, y_j)\right) \triangleq P(y_j|\boldsymbol{x}_j, h) = \theta(y_j\, \boldsymbol{w}^T \boldsymbol{x}_j)$$

对于所有样本，模型的似然函数是

$$L(\boldsymbol{w}) = \prod_{j=1}^{N} P(y_j|\boldsymbol{x}_j) = \prod_{j=1}^{N} \theta(y_j\, \boldsymbol{w}^T \boldsymbol{x}_j)$$

- 梯度下降法最优化目标函数

优化问题：

$$\min E(\boldsymbol{w}) = -\frac{1}{N}\ln\big(L(\boldsymbol{w})\big) = -\frac{1}{N}\ln\left(\prod_{j=1}^{N}\theta\big(y_j\,\boldsymbol{w}^T\boldsymbol{x}_j\big)\right)$$

$$= \frac{1}{N}\sum_{j=1}^{N}\ln\left(\frac{1}{\theta\big(y_j\,\boldsymbol{w}^T\boldsymbol{x}_j\big)}\right) = \frac{1}{N}\sum_{j=1}^{N}\ln\left(1+e^{-y_j\,\boldsymbol{w}^T\boldsymbol{x}_j}\right)$$

- 算法步骤：

（1）记时刻为$k=0$，初始化参数$\boldsymbol{w}(0)$

（2）计算目标函数的负梯度方向

$$\nabla E=-\frac{1}{N}\sum_{j=1}^{N}\frac{y_j\boldsymbol{x}_j}{1+e^{y_j\,\boldsymbol{w}(k)^T\boldsymbol{x}_j}}$$

按步长（学习率）η更新下一时刻参数

$$\boldsymbol{w}(k+1)=\boldsymbol{w}(k)-\eta\nabla E$$

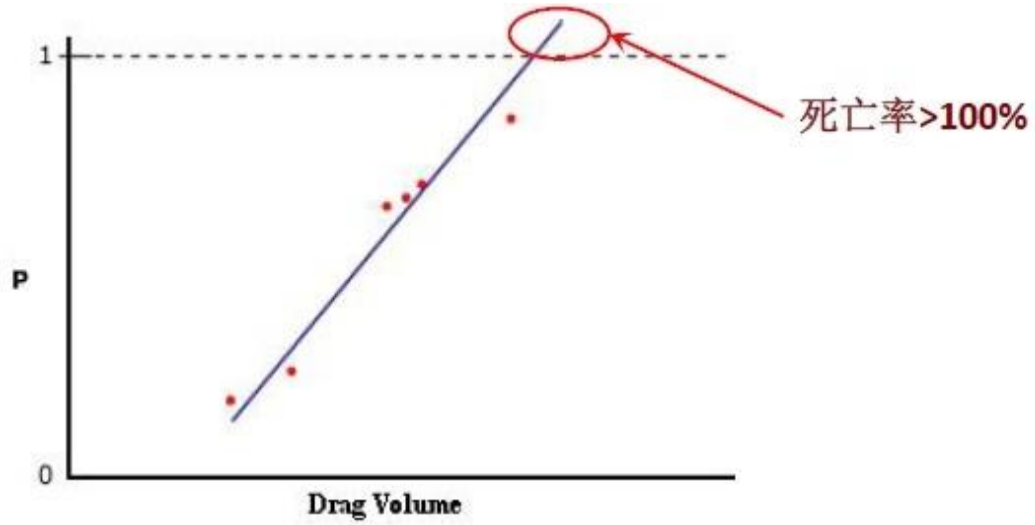
检查是否达到终止条件，如未达到，令$k=k+1$，重新进行（2）

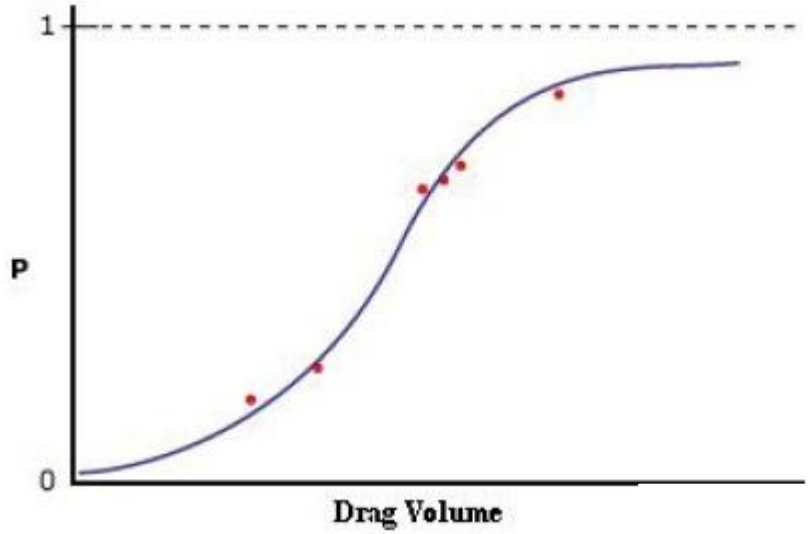
（3）算法停止，输出得到的参数$\boldsymbol{w}$

终止条件可以是似然函数的梯度小于某个预设值，训练过程不再有显著更新，或迭代达到预设的上限等

应用

- 逻辑斯蒂回归和线性回归一样，都是线性模型，线性回归多数是发散型方程式，在许多应用上会有不适合的情形发生
- 例，毒物用量和白鼠死亡率的关系，由于拟合的是线性模型，在一定程度的毒物用量下死亡率会超过100%
- 我们应该将线性回归的值压制在0~1之间，才能产生出合理的值， Logistic Regression就是将线性回归所产生的值带入Logistic Function，以将输出值压制在0~1之间





3.6 支持向量机

- 分类超平面

假设有训练样本集$(x_1, y_1), (x_2, y_2) \ldots, (x_N, y_N)$， $x_i \epsilon R^d$， $y_i \epsilon \{+1, -1\}$

其中每个样本是d维向量，y是类别标号， ω_1类用$+1$表示， ω_2类用-1表示。这些样本线性可分。即存在超平面

$$g(x) = (w \cdot x) + b = 0$$

把所有N个样本都没有错误地分开。

- 最优分类超平面

一个分类超平面，如果它能将训练样本没有错误地分开，且两类训练样本中离超平面最近的样本与超平面之间的距离是最大的，则这个超平面称作最优分类超平面（optimal separating hyperplane），简称最优超平面（optimal hyperplane）。

  - 两类样本中离分类面最近的样本到分类面的距离称作分类间隔（margin）
  - 最优超平面也称作最大间隔超平面

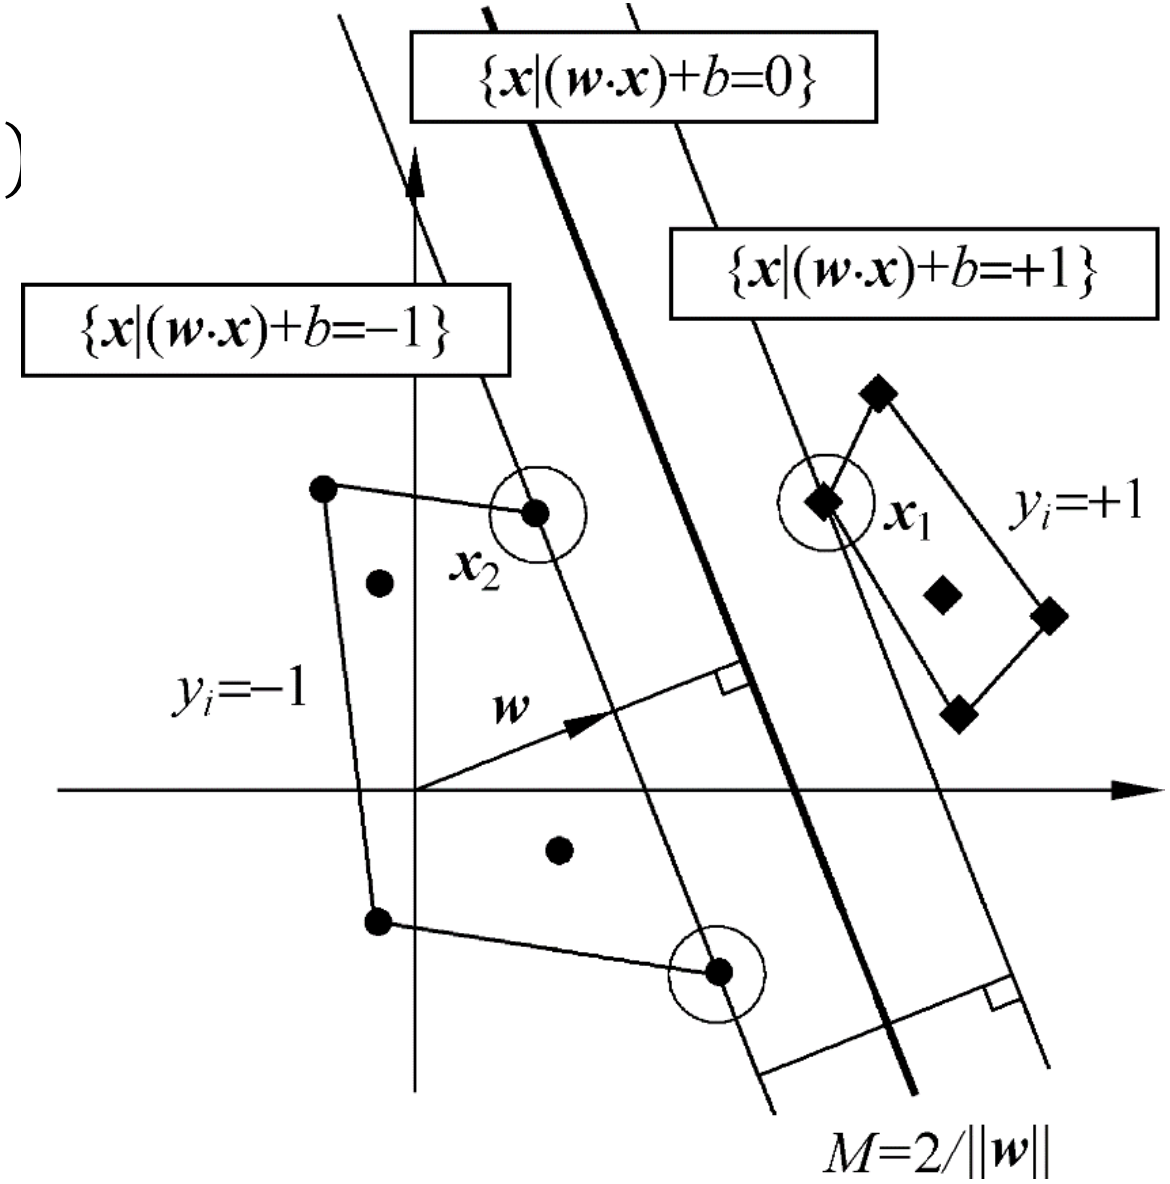
最优超平面定义的分类决策函数

$$f(\boldsymbol{x}) = \mathrm{sgn}\big(g(\boldsymbol{x})\big) = \mathrm{sgn}\big((\boldsymbol{w}\cdot\boldsymbol{x}) + b\big)$$

- 规范化的分类超平面

$$\begin{cases} (\boldsymbol{w}\cdot\boldsymbol{x}_i) + b \geq 1, & y_i = +1 \\ (\boldsymbol{w}\cdot\boldsymbol{x}_i) + b \leq -1, & y_i = -1 \end{cases}$$，即

$$y_i[(\boldsymbol{w}\cdot\boldsymbol{x}_i) + b] \geq 1, \quad i = 1,2,\ldots,N$$



- 求解最优超平面

$$\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2$$ 间隔

$$\text{s.t.} \quad y_i[(\boldsymbol{w}\cdot\boldsymbol{x}_i)+b]-1 \geq 0, \quad i=1,2,\ldots,N$$

支持向量

引入拉格朗日系数

$$\alpha_i \geq 0, \qquad i=1,\ldots,N$$

等价问题

$$\min_{\boldsymbol{w},b}\max_{\boldsymbol{\alpha}} L(\boldsymbol{w},b,\boldsymbol{\alpha}) = \frac{1}{2}(\boldsymbol{w}\cdot\boldsymbol{w}) - \sum_{i=1}^{N}\alpha_i\{y_i[(\boldsymbol{w}\cdot\boldsymbol{x}_i)+b]-1\}$$

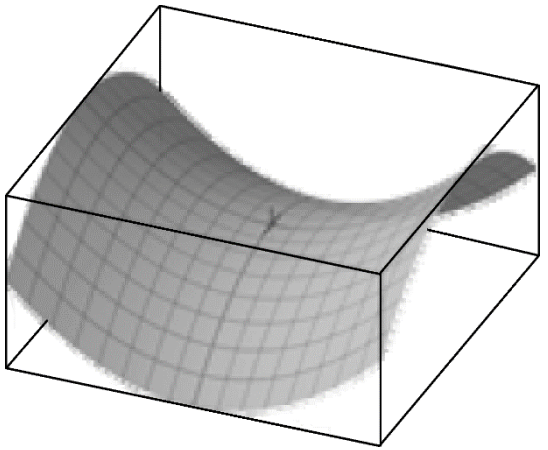
最优解在$L(\boldsymbol{w}, b, \boldsymbol{\alpha})$的鞍点上取得，即$L(\boldsymbol{w}, b, \boldsymbol{\alpha})$ 对$\boldsymbol{w}$ 和b 的偏导数均为0

最优解处：

$$\boldsymbol{w}^* = \sum_{i=1}^{N} \alpha_i^* y_i \boldsymbol{x}_i$$

且

$$\sum_{i=1}^{N} y_i \alpha_i^* = 0$$



鞍点

最优超平面的对偶问题（the dual problem）：

$$\max_{\boldsymbol{\alpha}} Q(\boldsymbol{\alpha}) = \sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{N} \alpha_i \alpha_j y_i y_j \left(\boldsymbol{x}_i \cdot \boldsymbol{x}_j\right)$$

$$\text{s.t.} \quad \sum_{i=1}^{N} y_i \alpha_i = 0 \quad \text{且} \quad \alpha_i \geq 0, \quad i = 1, \ldots, N$$

通过对偶问题的解，可求出原问题的解：

$$\boldsymbol{w}^* = \sum_{i=1}^{N} \alpha_i^* y_i \boldsymbol{x}_i$$

$$f(\boldsymbol{x}) = \mathrm{sgn}\{g(\boldsymbol{x})\} = \mathrm{sgn}\{(\boldsymbol{w}^* \cdot \boldsymbol{x}) + b\} = \mathrm{sgn}\left\{\sum_{i=1}^{N} \alpha_i^* y_i (\boldsymbol{x}_i \cdot \boldsymbol{x}) + b^*\right\}$$

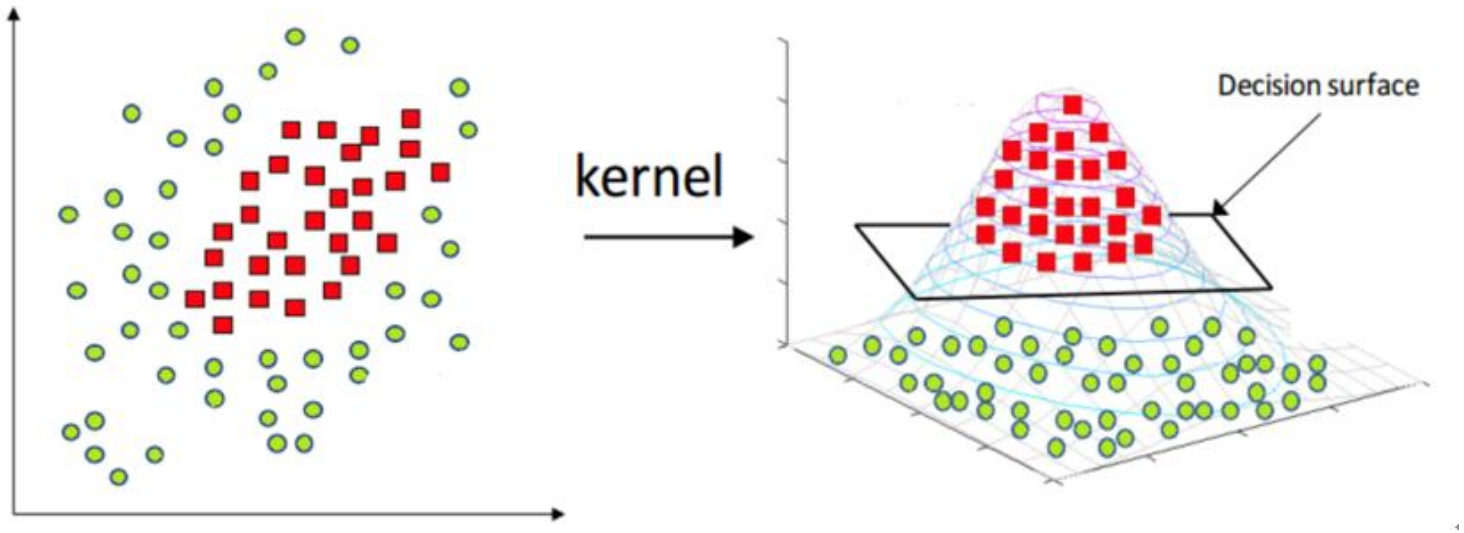
库恩-塔克（Kuhn-Tucker）条件：拉格朗日泛函的鞍点处满足

$$\alpha_i\{y_i[(\boldsymbol{w} \cdot \boldsymbol{x}_i) + b] - 1\} = 0, \quad i = 1,2,\ldots,N$$

等号成立的样本所对应的α_i才会大于0　　——支持向量（support vectors）

求解b：　$y_i[(\boldsymbol{w}^* \cdot \boldsymbol{x}_i) + b^*] - 1 = 0$

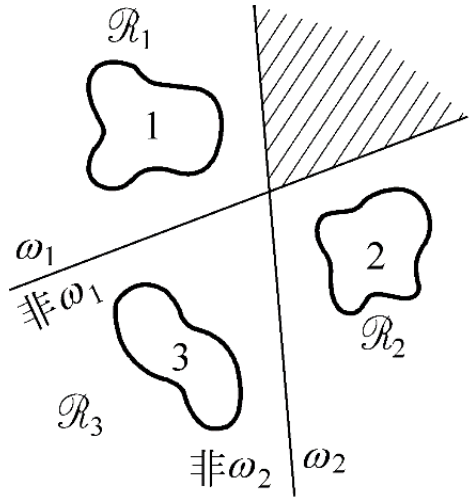
- 支持向量机(SVM)方法的优点：分类器的复杂度取决于支持向量的个数，而不是变换空间的维数，因此SVM不容易发生过拟合的现象
- 当原训练样本线性不可分时，可利用某个非线性变换将原数据空间中的样本点映射到更高维空间中，使得在此高维空间中的映射点线性可分



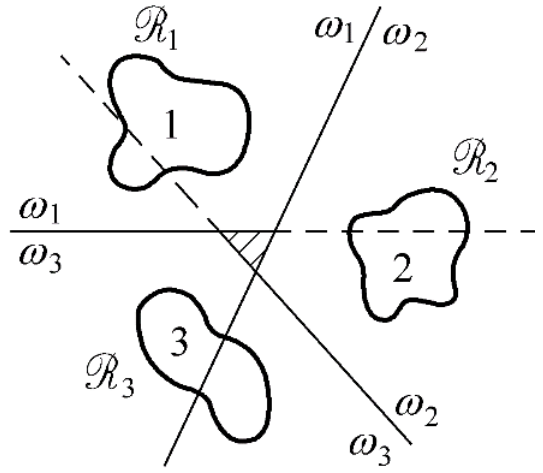
多类线性分类器

两个多类线性分类器的组合

- 做法一：“一对多”
  - c类转化为$c-1$个两类问题。one-vs-rest, one-over-all
  - 问题：训练样本不均衡；歧义区
- 做法二：“逐对”（pairwise）分类
  - 每两类构造一个分类器，则c类需要$\frac{c(c-1)}{2}$个两类分类器
  - 问题：分类器多



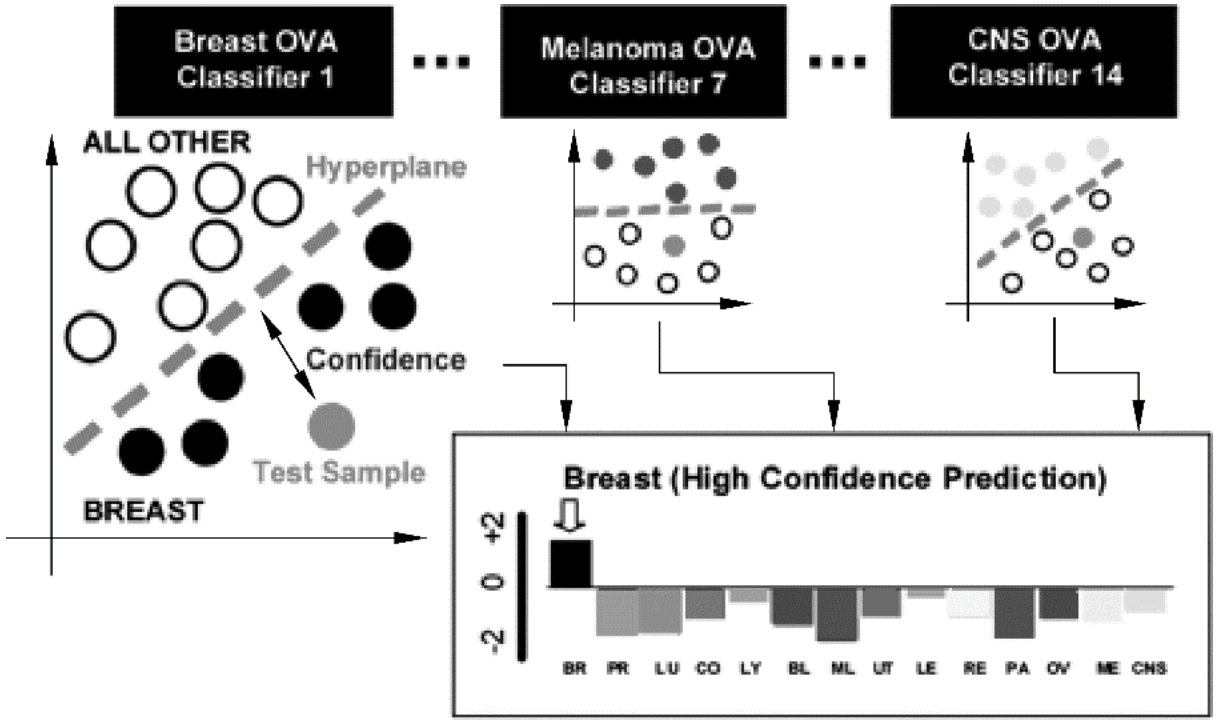
(a) ω_2/非ω_1

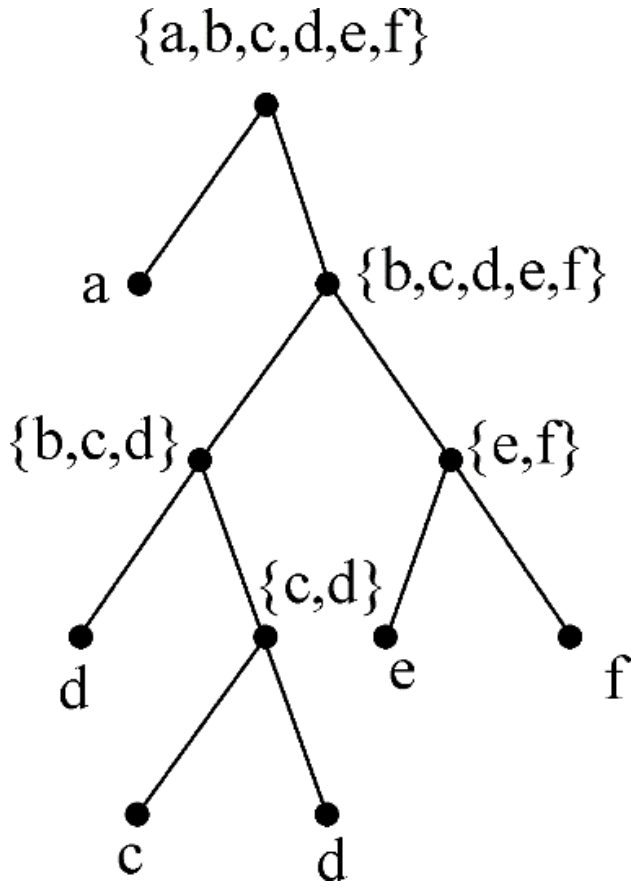


(b) ω_1/ω_2

- 用多个两类SVM实现多类分类的例子

  对多种癌症进行分类





- 用二叉树把多类分类问题分解成多个两类问题

多类线性判别函数

- 多类线性判别函数

对c类设计c个判别函数

$$g_i(\boldsymbol{x}) = \boldsymbol{w}_i^T \boldsymbol{x} + w_{i0}, \quad i = 1,2,\dots,c$$

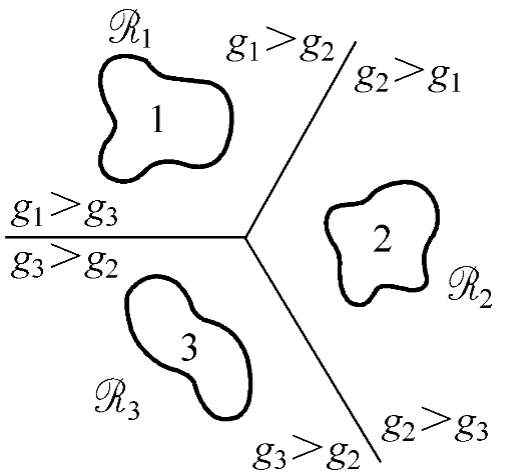
取判别函数最大的类，即

若$g_i(\boldsymbol{x}) > g_j(\boldsymbol{x})$，$\forall j \neq i$，则$\boldsymbol{x} \in \omega_i$

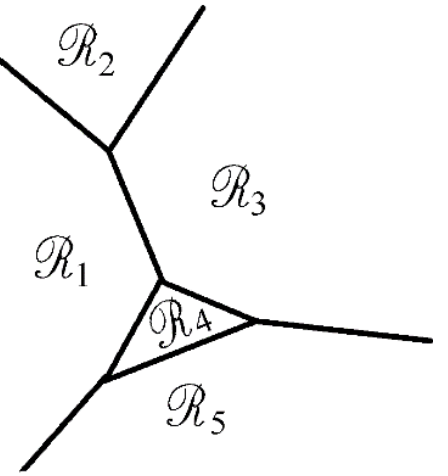
增广向量形式：$g_i(\boldsymbol{x}) = \boldsymbol{\alpha}_i^T \boldsymbol{y}, \quad i = 1,2,\dots,c$

其中，$\boldsymbol{\alpha}_i = \begin{bmatrix} \boldsymbol{w}_i \\ w_{i0} \end{bmatrix}$为增广权向量。

多类线性判别函数也称作多类线性机器，可记作$L(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2, \dots, \boldsymbol{\alpha}_c)$



(a) 三类



(b) 五类

- 逐步修正法求解线性机器

（1）任意选择初始的权向量$\boldsymbol{\alpha}_i(0)$，$i = 1,2,\ldots,c$，置$t = 0$。

（2）考察某个样本$\boldsymbol{y}^k \in w_i$，若$\boldsymbol{\alpha}_i(t)^T\boldsymbol{y}^k > \boldsymbol{\alpha}_j(t)^T\boldsymbol{y}^k$，则所有权向量不变；若存在某个类$j$，使$\boldsymbol{\alpha}_i(t)^T\boldsymbol{y}^k \leq \boldsymbol{\alpha}_j(t)^T\boldsymbol{y}^k$，则选择$\boldsymbol{\alpha}_j(t)^T\boldsymbol{y}^k$最大的类别$j$，对各类权值进行如下修正

$$\begin{cases}\boldsymbol{\alpha}_i(t+1) = \boldsymbol{\alpha}_i(t) + \rho_t\boldsymbol{y}^k \\ \boldsymbol{\alpha}_j(t+1) = \boldsymbol{\alpha}_j(t) - \rho_t\boldsymbol{y}^k \\ \boldsymbol{\alpha}_l(t+1) = \boldsymbol{\alpha}_l(t),\ l \neq i,j\end{cases}$$

（3）如果所有样本都分类正确，则停止；否则考查另一个样本，重复（2）

- 若样本集线性可分，则该算法可在有限步内收敛于一组解向量。

多类罗杰斯特回归与软最大

- 多类罗杰斯特回归

样本属于每一类j都与一个参数为$\boldsymbol{w}_j$的指数判别函数成正比，即

$$P(y = j \mid \boldsymbol{x}) \propto e^{\boldsymbol{w}_j \cdot \boldsymbol{x}}$$

归一化后得：

$$P(y = j \mid \boldsymbol{x}) = \frac{e^{\boldsymbol{w}_j \cdot \boldsymbol{x}}}{\sum_{k=1}^{c} e^{\boldsymbol{w}_k \cdot \boldsymbol{x}}}, \quad j = 1, \ldots, c$$

——软最大（Softmax）函数

讨论

- 线性判别函数
  - 形式最简单
  - 一定条件下能实现或逼近最优分类器的性能
  - 非线性问题应用场景：样本数目有限；样本观测中有较大噪声
  - 更好的推广能力
- 线性方法→非线性方法