模式识别
——模式识别与机器学习

刘文黎

liu_wenli@hust.edu.cn

土木与水利工程学院

第5章 特征选择与特征生成

本章主要内容

5.1 特征选择
5.2 预处理
5.3 峰值现象
5.4 用于分类的特征评价标准
5.5 特征选择算法
5.6 特征生成
5.7 基于类别可分性判据的特征提取
5.8 主成成分分析
5.9 Karhunen-Loève 变换*
5.10 **奇异值分解***
5.11 独立成分分析
5.12 非负矩阵因子分解
5.13 非线性降维
5.14 离散傅里叶变换*
5.15 哈尔变换
5.16 离散小波变换*
5.17 图像的区域特征
5.18 形状和尺寸特征
5.19 语言和声音分类*

5.1 引言

- 什么是特征选择问题？
  - 用计算方法从一组给定的特征中选择一部分特征进行分类
- 为什么要进行特征选择？
  - 计算上的考虑
  - 性能上的考虑
- 已知许多特征时，如何选择其中最重要的特征以减少特征数，同时尽可能地保留它们的分类信息？（**特征选择**）

5.2 预处理
5.2.1 剔除离群点

因为**过大或过小**的数据可能会影响到分析结果，尤其是在做**回归**的时候，我们需要对那些离群值进行处理

离群值的判断标准有三种，分别为 MAD、 3σ、百分位法：

- 绝对值差中位数法（Median Absolute Deviation）
  - 找出中位数x_{median}
  - 计算偏差$|x_i - x_{median}|$
  - 得到绝对偏差的中位数MAD
  - 确定参数n,确定合理范围$[x_{median} - nMAD, x_{median} + nMAD]$，剔除超出范围的值
- 3σ法
- 百分位法

5.2.2 数据归一化与遗漏数据

当数据(x)按照最小值中心化后，再按极差（最大值 - 最小值）缩放，数据移动了最小值个单位，并且会被收敛到[0,1]之间，而这个过程，就叫做数据归一化

$$x' = \frac{x - Min}{Max - Min}$$

其中Max为样本的最大值，Min为样本的最小值

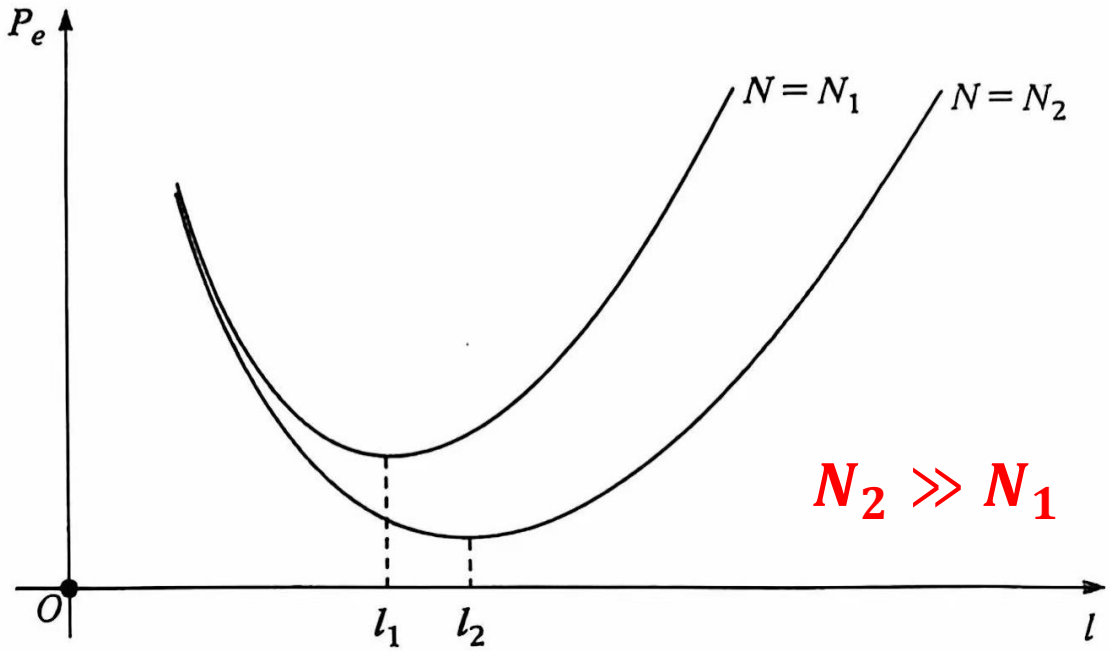
处理遗漏数据：

- 补充零值
- 由各个特征的已知值算的非条件均值
- 条件均值（已知观测数据时，能够估计遗漏值的概率密度函数）
- 抛弃有遗漏值的特征向量

5.3 峰值现象

要设计通用性能良好的分类器，训练点数N必须**远大于**特征数（特征空间的维数）$\boldsymbol{l}$

对于有限的N，增加特征数可以初步改善性能，但在达到某个临界后，再增加特征数会使**错误概率增大**，这种现象称为**峰值现象**



- $N_2 \gg N_1$时，对应于N_2的错误概率要比对应于N_1的错误概率小，且在$l_2 > l_1$时出现峰值现象
- 对于每个N值，随着l的增加，错误概率开始下降，达到一个临值后错误概率开始上升

在实际工作中：

✓ **当训练数据较少时，必须使用较少的特征**

✓ **当可以使用大量训练数据时，选择大量训练数据可以得到更好的性能**

5.4 用于分类的特征评价标准

- 特征选择的任务是找出一组分类最好的特征 → 评价准则

- 概念
  - 数学上定义的用以衡量特征对分类的效果的准则
  - 实际问题中需要根据实际情况人为确定

5.4.1 基于类内间距的可分性判据

- 可分性准则 J_{ij}：衡量两类的可分程度

  满足

  - 与错误率有单调关系，J_{ij} 大⇒ P_e 小
  - $J_{ij} \geq 0,\ J_{ii} = 0,\ J_{ij} = J_{ji}$
  - 对独立的特征有可加性
  - 增加特征时判据不减小

- 类间平均距离：

$$J_D = \frac{1}{2}\sum_{i=1}^{c} P_i \sum_{j=1}^{c} P_j \frac{1}{n_i n_j} \sum_{k=1}^{n_i}\sum_{l=1}^{n_j} \delta(\boldsymbol{x}_k^{(i)}, \boldsymbol{x}_l^{(j)})$$

其中，$\boldsymbol{x}_k^{(i)} \in \omega_i\,, k = 1,\cdots, n_i$

$\boldsymbol{x}_l^{(j)} \in \omega_j\,, l = 1,\cdots, n_j$

$P_i\,, P_j$：先验概率

$\delta(\boldsymbol{x}_k^{(i)}, \boldsymbol{x}_l^{(j)})$：$\boldsymbol{x}_k^{(i)}$和$\boldsymbol{x}_l^{(j)}$的距离度量，通常采用欧式距离：

$$\delta\left(\boldsymbol{x}_k^{(i)}, \boldsymbol{x}_l^{(j)}\right) = \left(\boldsymbol{x}_k^{(i)} - \boldsymbol{x}_l^{(j)}\right)^T \left(\boldsymbol{x}_k^{(i)} - \boldsymbol{x}_l^{(j)}\right)$$

- 定义：

  类均值向量：$\boldsymbol{m}_i = \frac{1}{n_i}\sum_{k=1}^{n_i} \boldsymbol{x}_k^{(i)}$

  总均值向量：$\boldsymbol{m} = \sum_{i=1}^{c} P_i \boldsymbol{m}_i$

  类间离散度矩阵S_b的估计：$\widetilde{S_b} = \sum_{i=1}^{c} P_i(\boldsymbol{m}_i - \boldsymbol{m})(\boldsymbol{m}_i - \boldsymbol{m})^T$

  类内离散度矩阵S_w的估计：$\widetilde{S_w} = \sum_{i=1}^{c} P_i \frac{1}{n_i}\sum_{k=1}^{n_i}\left(\boldsymbol{x}_k^{(i)} - \boldsymbol{m}\right)\left(\boldsymbol{x}_i^{(i)} - \boldsymbol{m}\right)^T$

  则：$J_D = tr(\widetilde{S_w} + \widetilde{S_b})$

- 常用的基于类内类间距离的可分性判据：

$$J_1 = tr(S_w + S_b)$$

$$J_2 = tr(S_w^{-1} S_b)$$

$$J_3 = \ln \frac{|S_b|}{|S_w|}$$

$$J_4 = \frac{trS_b}{trS_w}$$

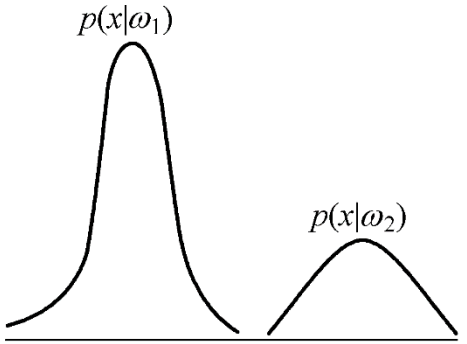
$$J_5 = \frac{|S_b - S_w|}{|S_w|}$$

5.4.2 基于概率分布的可分性判据

考察两类分布密度间的交叠程度

定义：两个密度函数间距离：

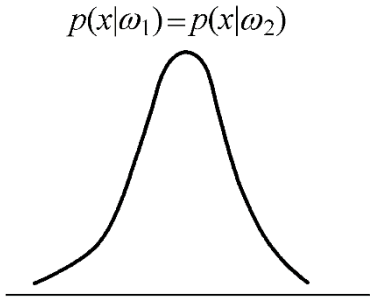
$$J_P(\cdot) = \int g[p(\boldsymbol{x}|\omega_1), p(\boldsymbol{x}|\omega_2), P_1, P_2]d\boldsymbol{x}$$



(a)

必须满足三个条件：

1. $J_P \geq 0$
2. 若$p(\boldsymbol{x}|\omega_1)p(\boldsymbol{x}|\omega_2) = 0, \forall \boldsymbol{x}$，则$J_P = Max$ （完全不重叠，a图）
3. 若$p(\boldsymbol{x}|\omega_1) = p(\boldsymbol{x}|\omega_2), \forall \boldsymbol{x}$，则$J_P = 0$ （完全重叠，b图）



(b)

常用的概率距离度量

- Bhattacharyya距离：

$$J_B = -\ln \int [p(\boldsymbol{x}|\omega_1)p(\boldsymbol{x}|\omega_2)]^{\frac{1}{2}} d\boldsymbol{x}$$

  两类完全重合时，$J_B = 0$；两类完全不交叠时，$J_B = \infty$

- Chernoff界：

$$J_C = -\ln \int p^s(\boldsymbol{x}|\omega_1)p^{1-s}(\boldsymbol{x}|\omega_2) d\boldsymbol{x}$$

  当$s = 0.5$时，Chernoff界限与Bhattacharyya距离相同。

- 散度：

$$J_D = \int_x [p(\boldsymbol{x}|\omega_1) - p(\boldsymbol{x}|\omega_2)] \ln \frac{p(\boldsymbol{x}|\omega_1)}{p(\boldsymbol{x}|\omega_2)} d\boldsymbol{x}$$

在两类样本都是正态分布情况下，散度为：

$$J_D = \frac{1}{2} tr\left[\boldsymbol{\Sigma}_1^{-1}\boldsymbol{\Sigma}_2 + \boldsymbol{\Sigma}_2^{-1}\boldsymbol{\Sigma}_1 - 2\boldsymbol{I}\right] + \frac{1}{2}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T(\boldsymbol{\Sigma}_1^{-1} + \boldsymbol{\Sigma}_2^{-1})(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$$

当两类协方差矩阵相等时，散度和Bhattacharyya距离有如下关系：

$$J_D = (\mu_1 - \mu_2)^T \Sigma^{-1}(\mu_1 - \mu_2) = 8J_B$$

也等于两类均值之间的Mahalanobis距离

5.4.3 基于熵的可分性判据

- 熵：事件的不确定性度量

  A事件的不确定性越大（熵大），则对A的事件的观察所提供的信息量大。

思路：

把各类ω_i看作一系列事件

把后验概率$P(\omega_i|\boldsymbol{x})$看作特征$\boldsymbol{x}$上出现$\omega_i$的频率

如从$\boldsymbol{x}$能确定ω_i，则对ω_i的观察不提供信息量，熵为0。（特征$\boldsymbol{x}$有利于分类）

如$\boldsymbol{x}$完全不能确定ω_i，则对ω_i的观察信息量大，熵大。（特征$\boldsymbol{x}$无助于分类）

5.4.4 利用统计检验作为可分性判据

t-检验（t-test）：

基本假设：两类样本均服从正态分布：$x_i \sim N(\mu_x, \sigma^2); y_i \sim N(\mu_y, \sigma^2)$

总体样本方差为：

$$s_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{m+n-2}$$

其中，S_x^2, S_y^2为两类样本各自的估计方差，并记两类样本的均值为$\bar{x}, \bar{y}$。

则，t-检验的统计量为：

$$t = \frac{(\bar{x} - \bar{y})}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

t-检验：参数化检验方法，对数据分布有一定的假设

非参数检验：不对数据分布作特殊假设

如：Wilcoxon秩和检验（rank-sum test）, 亦称Mann-Whitney U 检验

基本做法：

- 把两类样本混合在一起，按照所考察的特征从小到大排序
- 如果一类样本的排序序号之和（秩和）显著的比另一类样本小（或大），则两类样本在所考察的特征上有显著差异。

5.5 特征选择算法
5.5.1 特征选择的最优算法

- 穷举算法

  计算每一可能的组合，逐一比较准则函数。

  适用于：d或$D-d$很小（组合数较少）的情况。

- 分支界定法

  从顶向下，有回溯

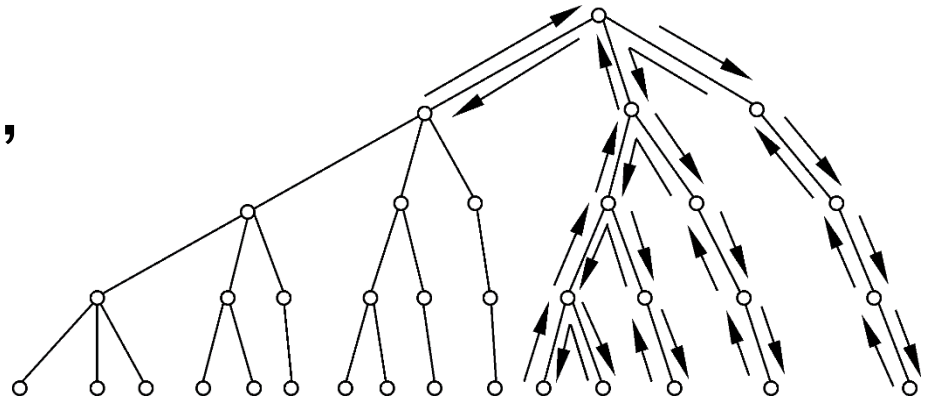
  应用条件：准则函数有单调性，即：

  对特征组 $\overline{\chi_1} \supset \overline{\chi_2} \supset \cdots \supset \overline{\chi_i}$，有 $J(\overline{\chi_1}) \geq J(\overline{\chi_2}) \geq \cdots \geq J(\overline{\chi_i})$

特征选择的分支定界法

- 基本思想

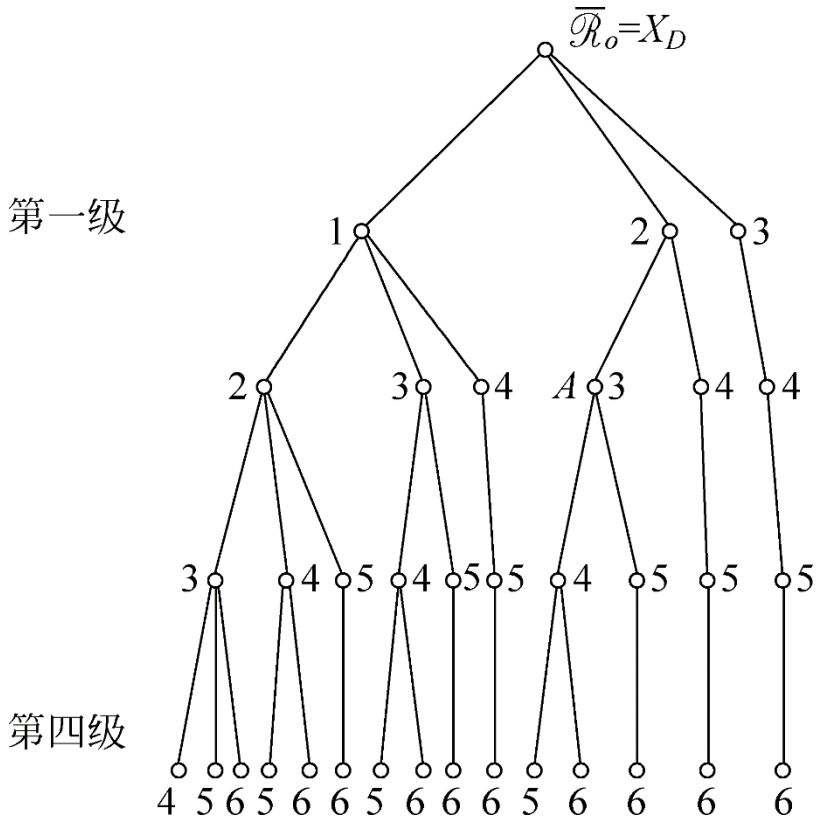
  按照一定顺序将所有可能的组合排列成一棵树，沿途搜索，避免一些不必要的计算，使找到最优解的机会更早。



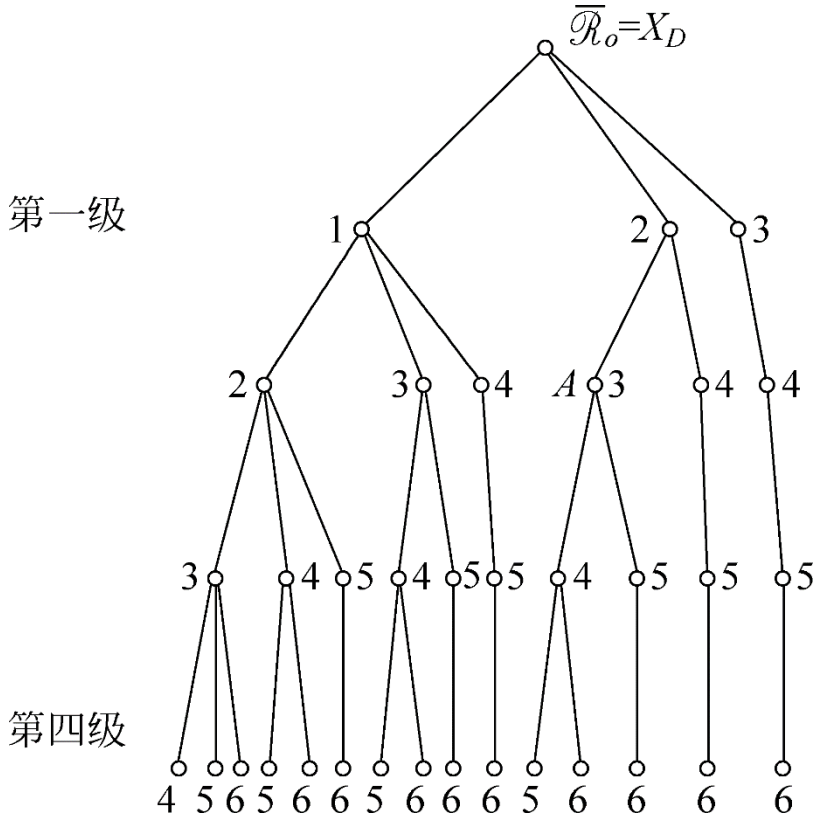
- 特点
  - 最优搜索算法，所有可能的组合都被考虑到
  - 前提：准则函数单调性 （注：实际中可能不满足，因 J 是估计值。
  - 节约计算与存储
  - $d \approx D/2$时最经济

特征选择的分支定界法

- 算法要点
  - 根节点为第0级，包含全体特征
  - 每个节点舍弃一个特征，各叶结点代表选择的各种组合
  - 避免在整个树中出现相同组合的树枝和叶结点
  - 记录当前搜索到的叶结点的最大准则函数（界限B），初值置零
  - 每级中将最不可能被舍弃（即舍弃后 J 最小）的特征放在最左侧
  - 从右侧开始搜索



- 从左侧同级中将舍弃的特征不在本结点以下各级中舍弃
- 搜索到叶结点后，更新B值，然后回溯到上一分支处
- 如果结点上 $J < B$，则不向下搜索，向上回溯
- 每次回溯将已舍弃的特征放回（放回待舍弃之列）
- 如已回溯到顶（根）而不能再向下搜索，则 $J = B$的叶结点即为解



5.5.2 特征选择的次优算法

- 单独最优组合
  - 选前d个单独最佳的特征
- 顺序前进法（sequential forward selection, SFS）
  - 从底向上，每次加入一个特征寻优一次，使加入该特征后所得组合最大
  - 特点：考虑了特征间的组合，但某一特征一经入选，则无法淘汰
  - 广义SFS法：每次增加l个特征。
- 顺序后退法（sequential backward selection, SBS）
  - 从顶向下，每次删减一个特征寻优一次，使加入该特征后所得组合最大
  - 特点：考虑了特征间的组合，但某一特征一经剔除，则无法入选
  - 广义SBS法：每次删减r个特征

- 增l减r法（$l-r$法）
  - 从底向上，每次增l个特征再减r个特征（$l>r$）
  - 或从顶向下，每次减r个特征再增l个特征（$l<r$）
  - 特点：带有局部回溯过程
  - 广义l-r法：每次选择或提出多个特征

5.5.3 遗传算法

- 基本思想
  - 随机搜索算法
  - 模拟生物进化的现象
  - 把优化问题比喻成在无数可能的重组和突变组合中发现适应性最强的组合的问题
  - 开创新的领域：进化计算（Evolutionary Computing）

- 用遗传算法进行特征选择（D个特征里面选择d个）
  - 染色体（chromosome)编码：二进制字符串m
  - 适应度（fitness）函数：每条染色体对应一个适应度值$f(m)$
  - 选择概率模型 $p(f(m))$

- 遗传算法基本步骤
  1. 初始化，$t = 0$，随机产生一个包含L个染色体的种群$M(0)$
  2. 计算当前种群$M(t)$中每一条染色体的适应度$f(m)$
  3. 按照选择概率$p(f(m))$对种群中的染色体进行采样，由采样出的染色体经过一定的操作繁殖出下一代染色体，组成下一代种群$M(t+1)$
  4. 回到 2，直到到达终止条件，输出适应度最大的染色体作为找到的最优解。终止条件是某条染色体的适应度达到设定的阈值

- 遗传与变异
  1. 重组（recombination），也称交叉（crossover）
  2. 突变（mutation）
  3. 基因组反转（inversion）、转座（transposition）
  4. …

5.5.4 包裹法：以分类性能为准则的特征选择方法

- 包裹法（wrapper法）：
  - 集成分类器与特征选择、利用分类器进行特征选择的方法

- 例如：R-SVM（递归SVM)和SVM-RFE（SVM递归特征剔除）
  1. 用当前所有候选特征训练支持向量机
  2. 评估当前所有特征再支持向量机的相对贡献，按贡献大小排序
  3. 根据事先确定的递归选择特征的数目选择出排序在前面的特征，用这组特征构成新的候选特征，转1，直到达到所规定的特征选择数目

- 区别：评估特征在分类器中的贡献
  - 线性核

R-SVM：$s_j = \omega_j\left(m_j^+ - m_j^-\right), j = 1,\cdots,d$

SVM-RFE：$s_j^{RFE} = \omega_j^2$

  - 非线性核

$$Q = \sum_{i=1}^{n}\alpha_i - \frac{1}{2}\sum_{i,j=1}^{n}\alpha_i\alpha_j y_i y_j K(x_i, x_j)$$

$$DQ(k) = \frac{1}{2}\sum_{i,j=1}^{n}\alpha_i\alpha_j y_i y_j\left[K\left(x_i, x_j\right) - K(x_i^{(-k)}, x_j^{(-k)})\right]$$

5.6 特征生成

- 特征选择：从D个特征中选出d个
- 特征生成：把D个特征变为d个新特征
  - 最常采用线性变换：

$$y = \mathrm{W}^{\mathrm{T}}\mathrm{x}$$

其中，W是$D \times d$维矩阵，称作变换阵。通常，$d < D$。

5.7 基于类别可分性判据的特征提取

- 准则函数（变换后的可分离判据）：

$$J_1 = tr(W^T(S_w + S_b)W)$$

$$J_2 = tr\left[\left(W^T S_w W\right)^{-1}(W^T S_b W)\right]$$

$$J_3 = \ln\frac{|W^T S_b W|}{|W^T S_w W|}$$

$$J_4 = \frac{tr(W^T S_b W)}{tr(W^T S_w W)}$$

$$J_5 = \frac{|W^T \Sigma W|}{|W^T S_w W|}, \Sigma = S_w + S_b$$

- 目标：求得最优W^*，使

$$W^* = \underset{\{W\}}{arg\max} J(W^T x)$$

- 结论：
  - 设矩阵$S_w^{-1}S_b$的本征值为$\lambda_1, \lambda_2, \cdots, \lambda_D$，且$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_D$
  - 选前d个本征值对应的本征向量$u_1, u_2, \cdots, u_d$组成矩阵

$$W = [u_1\ u_2 \cdots u_d]$$

即为最佳变换阵

- 推导（以J_1为例）：

  优化问题：

$$\max J_1(W)$$
$$s.t.\ tr\left(W^T S_w W\right) = 1$$

  拉格朗日函数：

$$g(W) = J_1(W) - tr\left[\Lambda\left(W^T S_w W - I\right)\right]$$

  令：

$$\frac{\partial}{\partial W} g(W) = 0$$

整理可得：

$$S_w^{-1}S_bW = W(\Lambda - \mathrm{I})$$

考虑限制条件，可得：

$$J_1(W) = tr\left(W^T(S_w + S_b)W\right) = tr\left(W^T S_w W\Lambda\right) = tr\Lambda$$

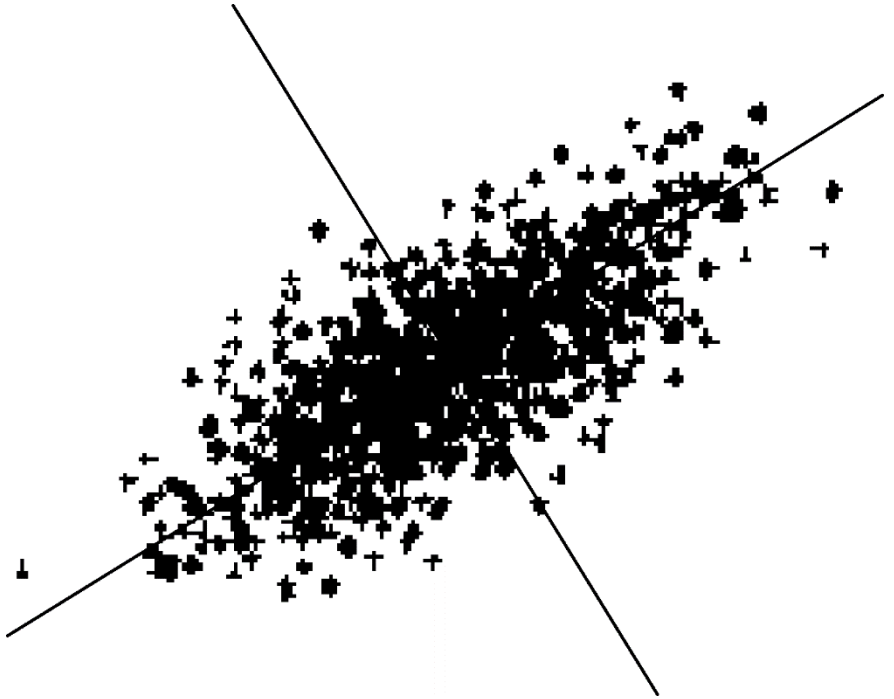
对$D \times d$维变换矩阵

$$J_1(W) = \sum_{i=1}^{d}(1 + \lambda_i)$$

5.8 主成分分析

- 目的

  从一组特征中计算一组重要性从大到小排列的新特征，他们是原特征的线性组合，并且相互之间不相关



- 数学表示

  原特征：$x_1,\cdots,x_p$

  新特征：$\xi_i, i=1,\cdots,p$

$$\xi_i = \sum_{j=1}^{p} \alpha_{ij} x_j = \boldsymbol{\alpha}_i^T \boldsymbol{x}$$

$$\boldsymbol{\xi} = \boldsymbol{A}^T \boldsymbol{x}$$

  尺度：$\boldsymbol{\alpha}_i^T \boldsymbol{\alpha}_i = 1$

考虑第一个新特征ξ_1

$$\xi_1 = \sum_{j=1}^{p} \alpha_{1j} x_j = \boldsymbol{\alpha}_1^T \boldsymbol{x}$$

$$var(\xi_1) = E\left[\xi_1^2\right] - E[\xi_1]^2 = E\left[\alpha_1^T x x^T \alpha_1\right] - E\left[\alpha_1^T x\right] E[x^T \alpha_1] = \alpha_1^T \Sigma \alpha_1$$

其中，Σ是x的协方差矩阵

求下列拉格朗日函数的极值：

$$f(\alpha_1) = \alpha_1^T \Sigma \alpha_1 - v\alpha_1^T \alpha_1$$

得：

$$\Sigma\alpha_1 = v\alpha_1; var(\xi_1) = \alpha_1^T \Sigma \alpha_1 = v\alpha_1^T \alpha_1 = v$$

最优的α_1为Σ的最大本质值对应的本征向量，ξ_1称作第一主成分

考虑第二个新特征ξ_2

$$E[\xi_2\xi_1] - E[\xi_2]E[\xi_1] = 0$$

$$\alpha_2^T \Sigma \alpha_1 = 0$$

$$\alpha_2^T \alpha_1 = 0$$

$$\alpha_2^T \alpha_2 = 1$$

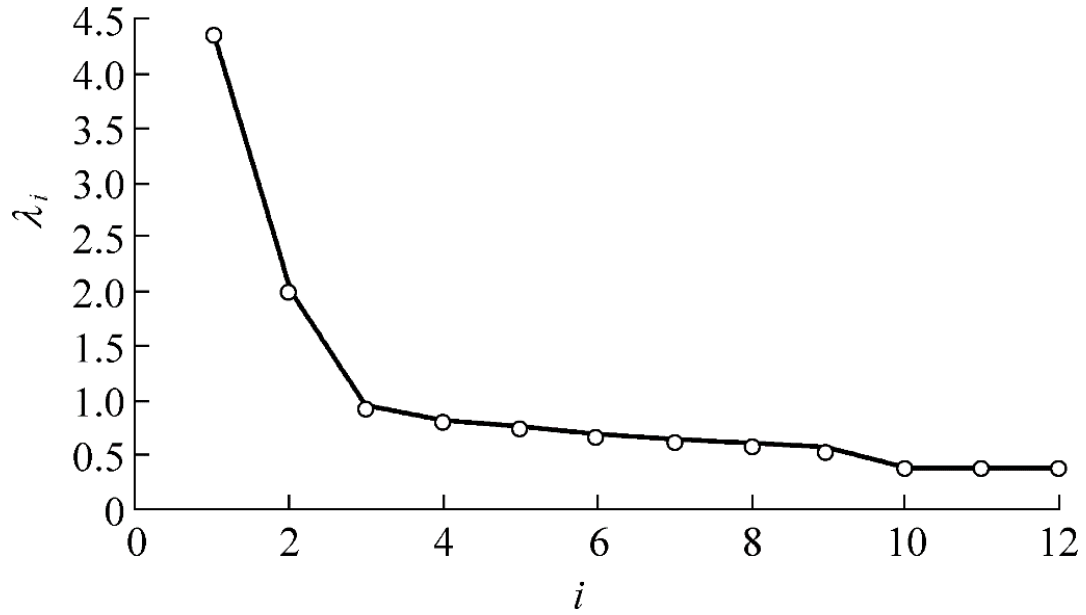
α_2为Σ的第二本征值对应的本征向量，ξ_2称作第二主成分

全部主成分方差之和等于各个原始特征方差之和：

$$\sum_{i=1}^{p} var(\xi_i) = \sum_{i=1}^{p} \lambda_i$$

前k个主成分代表了数据全部方差的比例：

$$\frac{\sum_{i=1}^{k} \lambda_i}{\sum_{i=1}^{p} \lambda_i}$$



5.9 Karhunen-Loève 变换

- 简介
  - Karhunen-Loève 变换简称K-L变换，是一种常用的特征提取方法
  - 最基本的形式原理与主成分分析相同
  - K-L变换可以实现有监督的特征提取

5.9.1 K-L 变换

- 基本原理
  - 函数的级数展开：将函数用一组（正交）基函数展开，用展开系数表示原函数
  - 离散K-L展开：把随机向量用一组正交基向量展开，用展开系数代表原向量
  - 基向量所张成的空间：新的特征空间

    展开系数组成的向量：新特征空间中的样本向量

- 离散K-L展开

对随机向量$\boldsymbol{x}$，用确定的完备正交归一向量系$u_j, \mathrm{j} = 1,2,\cdots,\infty$展开，得

$$x = \sum_{j=1}^{\infty} c_j \boldsymbol{u}_j$$

$$c_j = \boldsymbol{u}_j^T \boldsymbol{x}$$

其中，$\boldsymbol{u}_i^T \boldsymbol{u}_j = \begin{cases} 1 \; i = j \\ 0 \; i \neq j \end{cases}$

只用有限项来逼近$\boldsymbol{x}$，即：

$$\hat{\boldsymbol{x}} = \sum_{j=1}^{d} c_j u_j$$

其中，$\boldsymbol{x}$为D维度，且$d < D$。则与原向量的均方误差为：

$$e = E[(\boldsymbol{x} - \hat{\boldsymbol{x}})^T(\boldsymbol{x} - \hat{\boldsymbol{x}})] = E\left[\left(\sum_{j=d+1}^{\infty} c_j \boldsymbol{u}_j\right)^T \left(\sum_{j=d+1}^{\infty} c_j \boldsymbol{u}_j\right)\right]$$

$$= E\left[\sum_{j=d+1}^{\infty} c_j^2\right] = E\left[\sum_{j=d+1}^{\infty} \boldsymbol{u}_j^T \boldsymbol{x}\boldsymbol{x}^T \boldsymbol{u}_j\right] = \sum_{j=d+1}^{\infty} \boldsymbol{u}^T E[\boldsymbol{x}\boldsymbol{x}^T]\boldsymbol{u}_j$$

其中，$R = E[\boldsymbol{x}\boldsymbol{x}^T]$是自相关矩阵（因为$\boldsymbol{x}$是列向量），当输入向量$\boldsymbol{x}$给定时，该矩阵就是确定的。

因此，要使估计误差e最小，就要求合理选择归一正交向量系$\{\boldsymbol{u}_j\}$

记$\Psi = E[xx^T]$，则

$$e = \sum_{j=d+1}^{\infty} \boldsymbol{u}_j^T \psi \boldsymbol{u}_j$$

最小化均方误差，即

$$\min e$$
$$s.t. \quad u_j^T u_j = 1, \ \forall j$$

得拉格朗日函数

$$g(u) = \sum_{j=d+1}^{\infty} \boldsymbol{u}_j^T \psi \boldsymbol{u}_j - \sum_{j=d+1}^{\infty} \lambda \left[\boldsymbol{u}_j^T \boldsymbol{u}_j - 1 \right]$$

令$\frac{\partial}{\partial u_j} g(u) = 0, j = d+1, \cdots, \infty$得

$$(\psi - \lambda_j I) u_j = 0, j = d+1, \cdots, \infty$$

令$d = 0$，则得

$$\psi u_j = \lambda_j u_j, j = 1,2, \cdots, \infty$$

$$e = \sum_{j=d+1}^{\infty} \lambda_j$$

如果我们选取最大特征值对应的特征向量系，
作为正交向量系，那么估计误差将会是最小的

即，

- 用矩阵ψ的前d个本征值（从大到小排序）对应的本征向量作为基来展开x时，截断误差在所有d维正交坐标展开中是最小的
- $\boldsymbol{u}_j, j = 1,2, \cdots, d$张成了新特征空间，展开系数$C_j = \boldsymbol{u}_j^T x$组成新特征向量

把大特征值用作估计，把小特征值留给误差

- K-L展开式的性质
  - 信号的最佳（压缩）表达：均方误差最小
  - 新空间中的特征是互不相关
  - 用K-L变换坐标系表示原数据，表示熵最小
    - 即这种坐标系统下，样本的方差信息最大程度地集中在较少的维数上
  - 用本征值最小的K-L变换坐标来表示数据，总体熵最小
    - 本征值大的本征向量代表的是样本集中变化大的方向，即方差大的方向
    - 本征值小的本征向量对应样本分布集中的地方，这项方向方差小，均值可以更好的代表样本

两个模式类的样本分别为：

$w_1: X_1 = [2,2]^T,\ X_2 = [2,3]^T\ X_3 = [3,3]^T$

$w_2: X_4 = [-2,-2]^T,\ X_5 = [-2,-3]^T\ X_6 = [-3,-3]^T$

利用自相关矩阵R作K-L变换，把原本集压缩成一维样本集(计算结果**保留两位小数**)

解：第一步：计算总体自相关矩阵R

$$R = E[XX^T] = \frac{1}{6}\sum_{j=1}^{6} X_j X_j^T = ?$$

第二步：计算R的本征值，并选择较大者

$$|\boldsymbol{R} - \lambda \boldsymbol{I}| = 0 \qquad \lambda_1 = ?\ ,\quad \lambda_2 = ?$$

- 构造特征方程$a\lambda^2 + b\lambda + c = 0$
- 利用求根公式解出λ

第三步：根据$\boldsymbol{Ru_1} = \lambda_1 \boldsymbol{u_1}$，计算$\lambda_1$对应的特征向量$\boldsymbol{u_1}$，归一化后为

$\boldsymbol{u_1} = [?\ ,?\ ]^T$　变换矩阵$\boldsymbol{U} = [\boldsymbol{u_1}] = \begin{bmatrix} ? \\ ? \end{bmatrix}$

第四步：利用$\boldsymbol{U}$对样本集中每个样本进行K-L变换

$\boldsymbol{X_1^* = U^T X_1 = ?}$　$\boldsymbol{X_2^* = ?}$　$\boldsymbol{X_3^* = ?}$

$\boldsymbol{X_4^* = ?}$　$\boldsymbol{X_5^* = ?}$　$\boldsymbol{X_6^* = ?}$

练习

两个模式类的样本分别为：

$w_1: X_1 = [2,2]^T$，$X_2 = [2,3]^T$ $X_3 = [3,3]^T$

$w_2: X_4 = [-2,-2]^T$，$X_5 = [-2,-3]^T$ $X_6 = [-3,-3]^T$

利用自相关矩阵R作K-L变换，把原本集压缩成一维样本集。

解：第一步：计算总体自相关矩阵R

$$R = E[XX^T] = \frac{1}{6}\sum_{j=1}^{6} X_j X_j^T = \begin{bmatrix} 5.7 & 6.3 \\ 6.3 & 7.3 \end{bmatrix}$$

第二步：计算R的本征值，并选择较大者

$$|\boldsymbol{R} - \lambda \boldsymbol{I}| = 0$$

$$\lambda_1 = 12.85, \quad \lambda_2 = 0.15$$

第三步：根据$\boldsymbol{Ru_1} = \lambda_1 \boldsymbol{u_1}$，计算$\lambda_1$对应的特征向量$\boldsymbol{u_1}$，归一化后为

$$\boldsymbol{u_1} = \frac{1}{\sqrt{2.3}}[1, 1.14]^T = [0.66, 0.75]^T$$

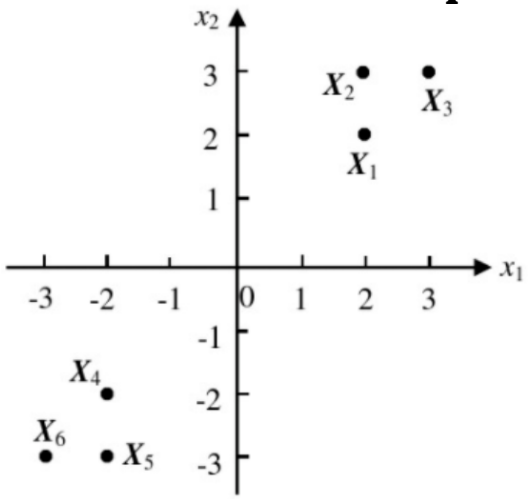
$$\text{变换矩阵}\boldsymbol{U} = [\boldsymbol{u_1}] = \begin{bmatrix} 0.66 \\ 0.75 \end{bmatrix}$$

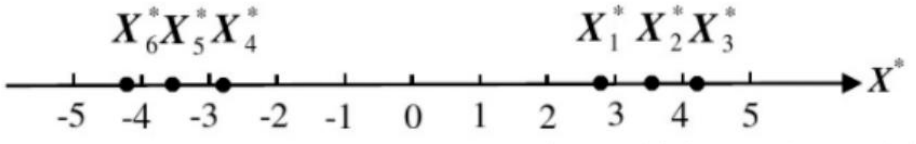
第四步：利用$\boldsymbol{U}$对样本集中每个样本进行K-L变换

$$\boldsymbol{X_1^*} = \boldsymbol{U^T X_1} = [0.66, 0.75]\begin{bmatrix} 2 \\ 2 \end{bmatrix} = 2.82$$

$$\boldsymbol{X_2^*} = 3.57 \qquad \boldsymbol{X_3^*} = 4.23$$

$$\boldsymbol{X_4^*} = -2.82 \quad \boldsymbol{X_5^*} = -3.57 \quad \boldsymbol{X_6^*} = -4.23$$





5.9.2 用于监督模式识别的K-L变换

- 样本中没有类别信息时
  - 常用（二阶矩矩阵）$\psi = E[xx^T]$
  - 去均值（协方差矩阵）$\Sigma = E[(x-\mu)(x-\mu)^T]$
- 样本类别已知时，三种典型策略：
  - 从类均值中提取判别信息
  - 包含在类平均向量中判别信息的最优压缩
  - 类中心化特征向量中分类信息的提取

策略1：从类均值中提取判别信息

- 出发点：
  (1) 消除特征各分量之间的相关性
  (2) 考查变换后各特征的类均值和方差，选择方差小，类均值与总体均值差别大的特征
- 三步：
  (1) 计算K-L变换的产生矩阵

$$S_w = \sum_{i=1}^{c} P_i \Sigma_i$$

  (2) 用S_w作KL变换，得本征值为λ_i的本征向量$u_i, i = 1,\cdots, D$

  新特征$y_i = u_i^T x, i = 1,\cdots, D$，方差为$\lambda_i$

(3) 计算

$$J(y_i) = \frac{u_j S_b u_j}{\lambda_i}, \qquad j = 1,\cdots,D$$

作为评价新特征的各个分量的分类性能的指标

其中，$S_b = \sum_{i=1}^{c} P(\omega_i)(\mu_i - \mu)(\mu_i - \mu)^T$为类间离散度矩阵

用$J(y_i)$排序

$$J(y_1) \geq J(y_2) \geq \cdots \geq J(y_d) \geq \cdots \geq J(y_D)$$

选择前d个分量组成新的特征向量，相应的u_j组成变换阵

$$U = [u_1\ u_2\ \cdots\ u_d]$$

策略2：包含在类平均向量中判别信息的最优压缩

- 出发点：

(1) 最优压缩类均值向量中包含的分类信息

(2) 使特征间互不相关

- 两步：

(1) 对S_w做K-L变换，消除相关性 $U^T S_w U = \Lambda$

令 $B = U\Lambda^{-1/2}$

从而使 $B^T S_w B = I$（白化变化，之后再进行任何正交归一变换，类内离散度矩阵不变）

变换后的类间离散度矩阵：

$$S_b' = B^T S_b B$$

(2) 对S_b'做K-L变换，以压缩包含在类平均向量中的信息

$rank(S_b') \geq c-1$，故最多有$d=c-1$个非零本征值

$$V' = [v_1, \cdots, v_d]$$

总的变换阵是：

$$W = U\Lambda^{-\frac{1}{2}}V'$$

可以证明，这种特征提取得到的新特征方向就是Fisher线性判别器的最佳投影方向

策略3：类中心化特征向量中分类信息的提取

- 出发点：
  - 类中心化特征向量：

    把原来的样本向量中减去类均值，只考虑各类的协方差不同中可能包含的分类信息。

- 做法：

首先，对S_w做KL变换，消除特征间相关性，考察各个新特征在各类中的方差r_{ij}（第i类第j个特征的方差）

归一化方差：

$$\widetilde{r_{ij}} = p(\omega_i)\frac{r_{ij}}{\lambda_j}, \qquad i = 1,\cdots,c, \qquad j = 1,\cdots,D$$

显然，归一化方差满足：$\sum_{i=1}^{c}\widetilde{r_{ij}} = 1$

定义总体熵来表示方差的分散程度：

$$J(x_j) = -\sum_{i=1}^{c}\widetilde{r_{ij}}\log\widetilde{r_{ij}}$$

或：$J(x_j) = \prod_{i=1}^{c}\widetilde{r_{ij}}$

把KL变化的新特征按照$J(x_j)$排序

$$J(x_1) \le J(x_2) \le \cdots \le J(x_d) \le \cdots \le J(x_D)$$

选取其中前d个特征组成新的特征

- 一般情况下，可以
  1. 用均值分类信息的最优压缩获得$d' \le c-1$个特征
  2. 利用类中心化特征的方差信息获得另外$d-d'$个信息

5.10 奇异值分解

在2006年，Netflix曾经举办了一个奖金为100万美元的推荐系统算法比赛，最后的获奖者就使用了矩阵分解中的明星：**奇异值分解SVD**

奇异值分解SVD的解释：

许多数学对象可以通过将它们分解成多个组成部分或者找到它们的一些属性来**更好地理解**，这些属性是通用的，而不是由我们选择它们的方式所产生的。（例如，我们可以通过**分解质因数**来发现整数的一些**内在性质**）

$$12 = 2 \times 3 \times 3$$

从这个表示中我们可以获得一些**有用的信息**，比如12不能被5整除，或者12的倍数能够被3整除

对应地，我们也可以通过**分解矩阵**来发现矩阵表示成数组元素时**不明显的函数性质**。**特征分解**是使用最广的矩阵分解之一，在这个分解中，我们将矩阵分解成一组特征向量和特征值。这样可以帮助我们分析矩阵的特定性质，就像质因数分解有助于我们理解整数

对于一个矩阵$\boldsymbol{A}$，我们使用特征分解去分析矩阵$\boldsymbol{A}$时，会得到特征向量构成的矩阵$\boldsymbol{V}$和特征值构成的向量$\boldsymbol{\lambda}$，我们可以重新将$\boldsymbol{A}$写作

$$\boldsymbol{A} = \boldsymbol{V} diag(\boldsymbol{\lambda}) \boldsymbol{V}^{-1}$$

奇异值分解是将矩阵分解为**奇异向量**和**奇异值**。通过奇异值分解，我们会得到一些与特征分解相同类型的信息。然而，奇异值分解有**更广泛的应用**。每一个实数矩阵都有一个奇异值分解，但不一定都有特征分解（**例如非方阵矩阵**）

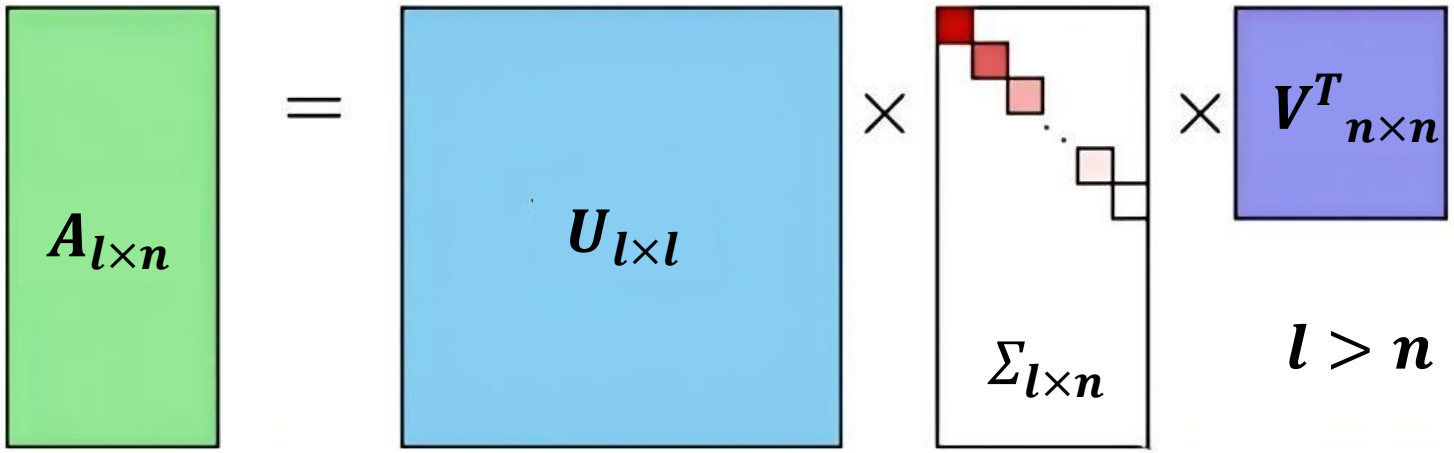
$$\boldsymbol{A} = \boldsymbol{U} \boldsymbol{\Sigma} \boldsymbol{V}^{T}$$

$$A = U\Sigma V^T$$

其中， A的秩为r，U是l阶正交矩阵， V^T是n阶正交矩阵，Σ是由降序排列的非负的对角线元素组成的$l \times n$矩形对角矩阵，对角线上的元素就叫做**奇异值**，满足：

$$UU^T = I$$
$$VV^T = I$$
$$\Sigma = diag(\sqrt{\lambda_0}, \sqrt{\lambda_1} \cdots \sqrt{\lambda_{r-1}})$$

$U\Sigma V^T$称为矩阵A的**奇异值分解**，$\sqrt{\lambda_i}$称为矩阵A的**奇异值**，U的列向量被称为**左奇异向量**，V的列向量被称为**右奇异向量**



$l > n$

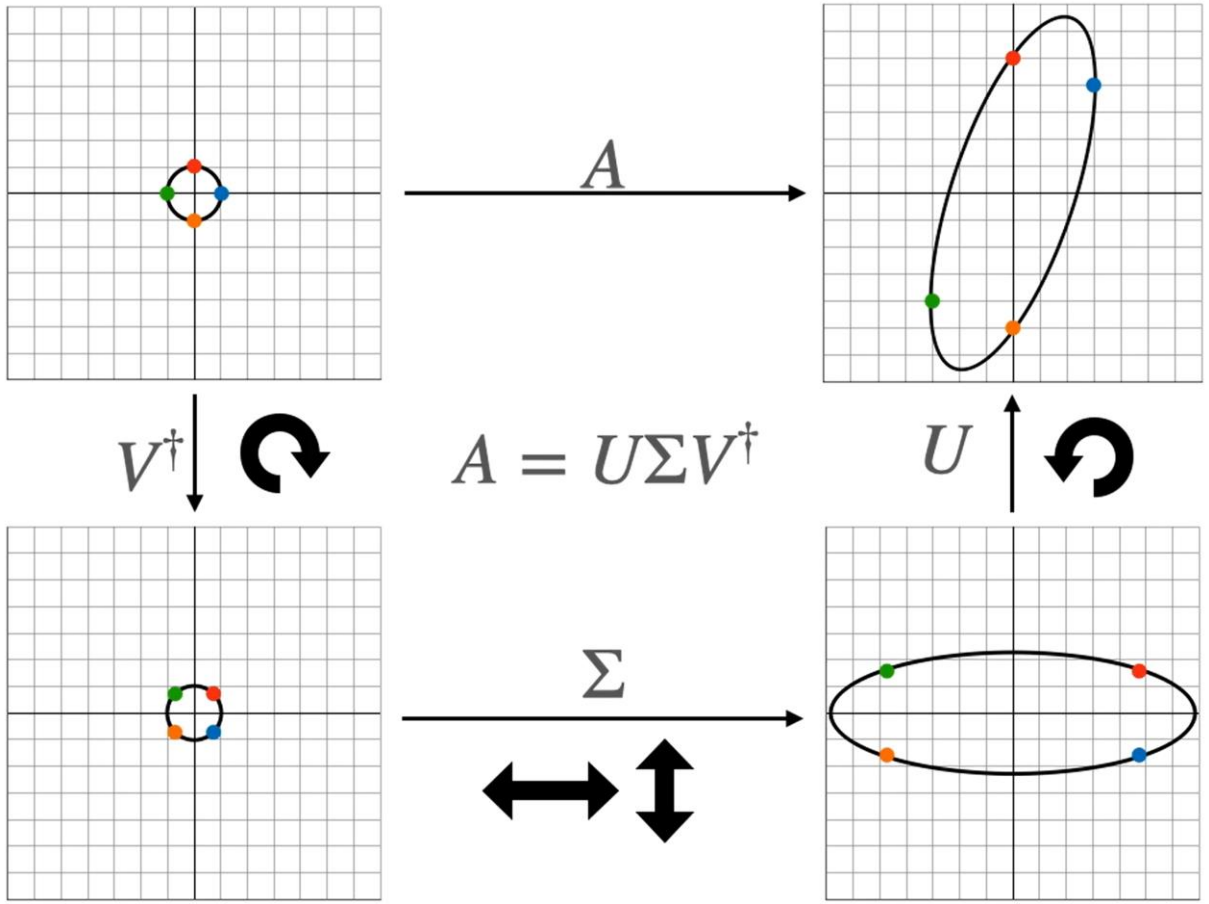
奇异值分解的基本定理：

任意给定一个实矩阵，其奇异值分解一定存在，但不唯一

示例：

$$A = U\Sigma V^T$$

$$\begin{bmatrix} 3 & 0 \\ 4 & 2 \end{bmatrix} = \begin{bmatrix} 1/\sqrt{10} & -3/\sqrt{10} \\ 3/\sqrt{10} & 1/\sqrt{10} \end{bmatrix} \begin{bmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$



奇异值分解在图像处理中的应用

$$\text{IMG}= \boldsymbol{U\Sigma V^T} = (\boldsymbol{u_1}, \boldsymbol{u_2} \cdots \boldsymbol{u_l}) \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \sigma_r \end{bmatrix} \begin{bmatrix} \boldsymbol{v_1^T} \\ \boldsymbol{v_2^T} \\ \vdots \\ \boldsymbol{v_n^T} \end{bmatrix} (\sigma_1 > \sigma_2 > \cdots > \sigma_r > 0)$$

$$= \boxed{\sigma_1 \boldsymbol{u_1 v_1^T}} + \sigma_2 \boldsymbol{u_2 v_2^T} + \sigma_3 \boldsymbol{u_3 v_3^T} + \cdots + \sigma_r \boldsymbol{u_r v_r^T}$$

$$= \boxed{\boldsymbol{T_1}} + \boldsymbol{T_2} + \boldsymbol{T_3} + \cdots + \boldsymbol{T_r}$$

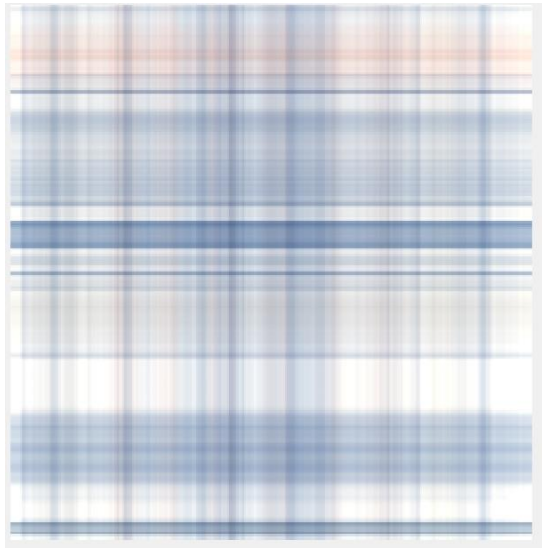
图像IMG可以分解为一系列秩1矩阵之和，考前的项所占图像的“份额”更大

奇异值分解在图像处理中的应用

$$\text{IMG}= \sigma_1 \boldsymbol{u_1 v_1^T} + \sigma_2 \boldsymbol{u_2 v_2^T} + \sigma_3 \boldsymbol{u_3 v_3^T} + \cdots + \sigma_{270} \boldsymbol{u_{270} v_{270}^T}$$



原图$r = 270$



$r_1 = 1$



$r_2 = 10$



$r_3 = 100$

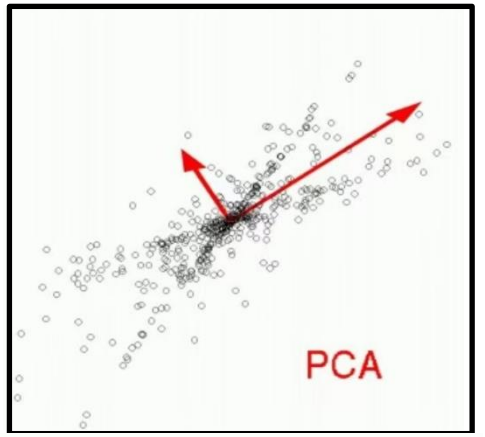
对于数字图像来说，越靠近前面的展开项所占图像“份额”越大，所以可以使用前k项展开式近似表示图像

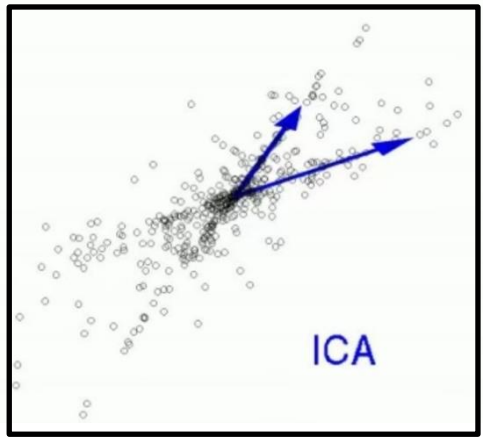
5.11 独立成分分析

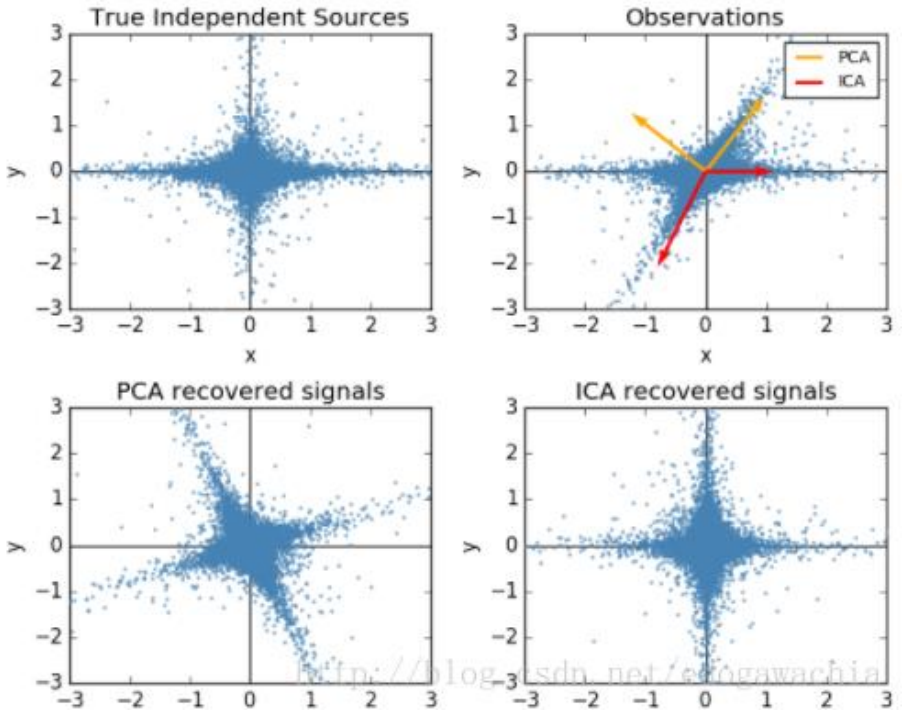
独立成分分析（Independent Component Analysis，简称ICA）是一种用于多维信号分离的统计方法，旨在将多个混合信号分解为**独立的成分**。与其他线性变换方法（如主成分分析）不同，ICA假设**原始信号是相互独立**的，而不仅仅是相关性低的。

ICA的原理:

- **独立性假设**:假设观测到的多维信号是多个独立成分的线性混合，其中每个成分都具有自己的统计分布
- **目标函数**：找到一个线性变换，使得变换后的结果具有最强的独立性







5.12 非负矩阵因子分解

非负矩阵分解（Non-negative Matrix Factorization, NMF）是将一个矩阵分解成**两个或更多非负矩阵**的过程。设我们有一个非负矩阵 V，其尺寸为 m×n。NMF的目标是找到两个非负矩阵 W（尺寸为 m×k）和 H（尺寸为 k×n），使得它们的乘积近似等于原始矩阵：

$$V \approx W \times H$$

其中，k是一个小于m和n的数，它代表数据潜在特征的数量。通过选择适当的k，NMF可以捕捉数据的主要特征，同时减少数据的维度。

相较于SVD和PCA，NMF具有：

- **非负性**：要求分解矩阵W和H的所有元素均为非负值，适合处理自然数据（如图像、文本），这些数据通常只有非负值
- **部分数据表示**：倾向于使用少量基础成分的加权和来表示原始数据点，与 PCA 的全局表示不同。
- **解释性**：非负性约束使得分解结果更易理解，分解出的特征通常有明确的物理或实际意义。

5.13 非线性降维
5.13.1 核主成分分析（KPCA）

- 核主成分分析（kernel KPCA, KPCA）基本思想
  - 对样本进行非线性主成分分析
  - 根据可再生希尔伯特空间的性质，在变换空间中的协方差矩阵可以通过原空间中的核函数进行运算，从而绕过了复杂的非线性变换
- 步骤
  - 通过和函数计算矩阵

$$K_{ij} = \left(\phi\left(\boldsymbol{x}_i \cdot \phi\left(\boldsymbol{x}_j\right)\right)\right) = k(\boldsymbol{x}_i \cdot \boldsymbol{x}_j)$$

其中，n为样本数，$\boldsymbol{x}_i, \boldsymbol{x}_j$是原空间中的样本，$k(\cdot,\cdot)$是与支持向量机中类似的函数。$\phi(\cdot)$是非线性变换

– 解矩阵K的特征方程

$$\frac{1}{n}\boldsymbol{K}\boldsymbol{\alpha} = \lambda\boldsymbol{\alpha}$$

并将得到的归一化本征向量$\boldsymbol{\alpha}^l, l = 1,2,\cdots$按照对应的本征值从大到小排列。本征向量的维数是$n$，向量的元素记为$\alpha^l = \left[\alpha_1^l, \alpha_2^l, \cdots, \alpha_n^l\right]$。根据需要选择前若干个本征值对应的本征向量作为非线性主成分

第l个非线性主成分是

$$\boldsymbol{v}^l = \sum_{i=1}^{n} \alpha_i^l \phi(\boldsymbol{x}_i)$$

– 计算样本在非线性主成分上的投影。样本x在第l个非线性主成分上的投影为

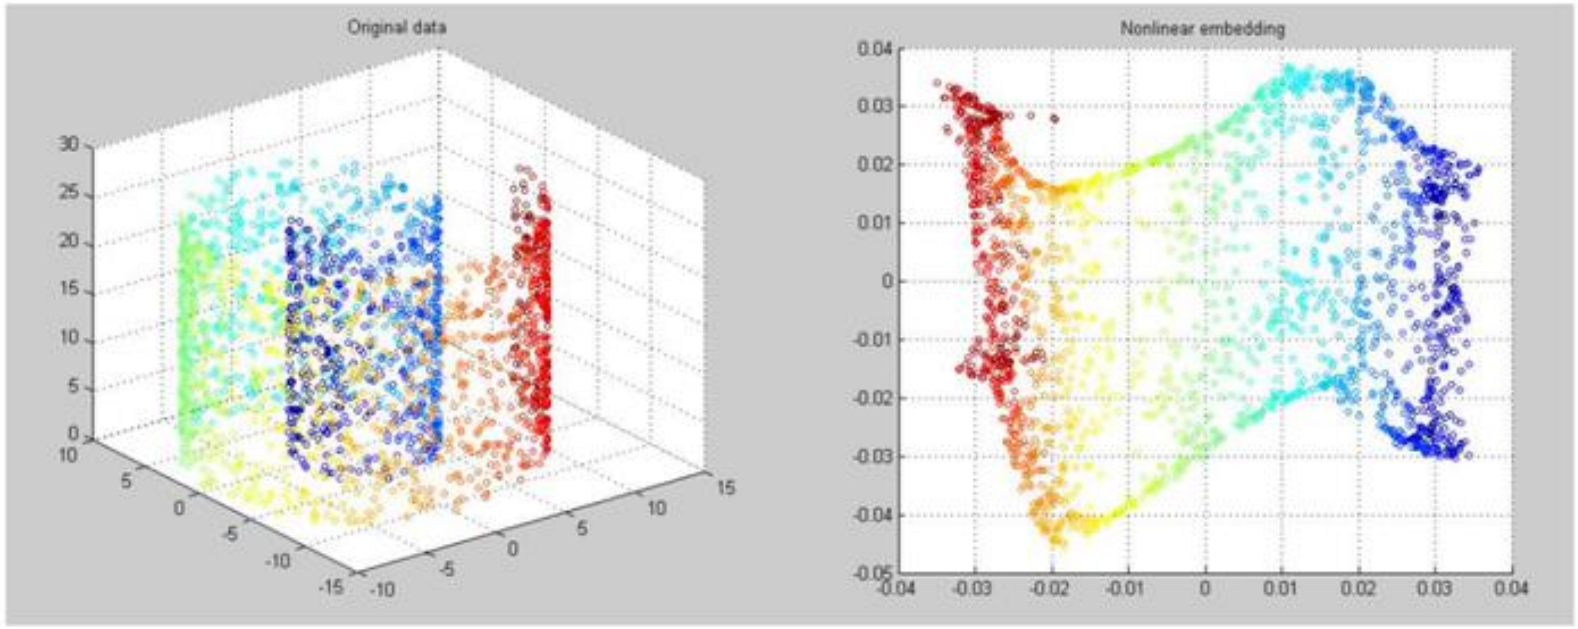
$$z^l(\boldsymbol{x}) = \left(\boldsymbol{v}^l \cdot \phi(\boldsymbol{x})\right) = \sum_{i=1}^{n} \alpha_i^l k(\boldsymbol{x}_i, \boldsymbol{x})$$

如果选择m个非线性主成分，则样本$\boldsymbol{x}$在前m个非线性主成分上的坐标构成样本在新空间的表示

$$[z^1(\boldsymbol{x}), \cdots, z^m(\boldsymbol{x})]^T$$

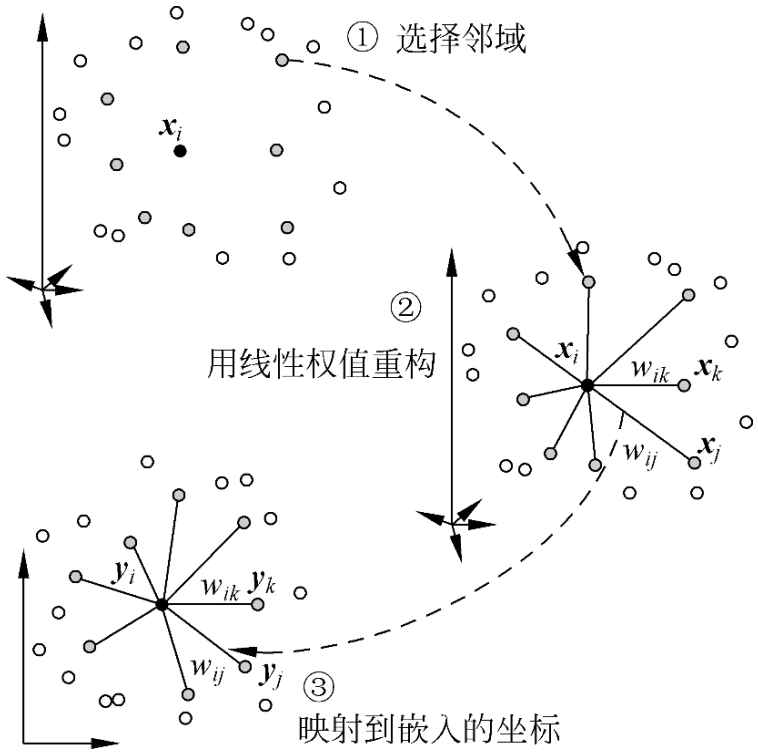
5.13.2 基于图的方法
5.13.2.1 拉普拉斯特征映射

拉普拉斯特征映射（Laplacian Eigenmaps）是从**局部近似**的角度去构建数据之间的关系。 LE是基于图的降维算法，它将要降维的数据构建成图，图中的每个节点和距离它最近的K个节点建立边关系。然后它希望图中相连的点（原始空间中相互靠近的点）在降维后的空间中也尽可能地靠近，从而在降维后仍能**保持原有的局部结构关系**。



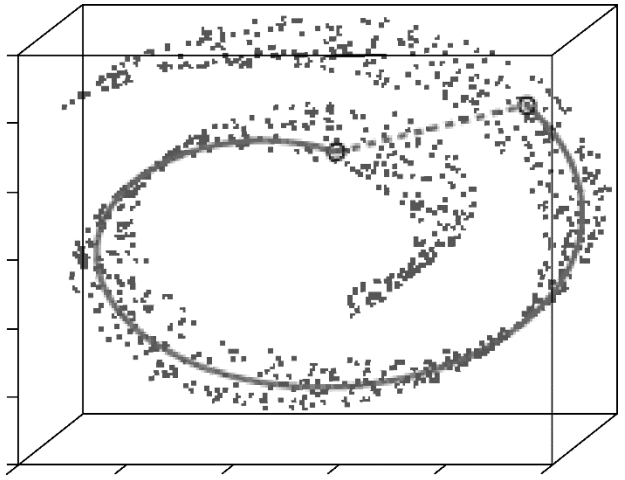
5.13.2.2 局部线性嵌入

- 局部线性嵌入LLE（locally linear embedding）：
  - 在原空间中，对样本$\boldsymbol{x}_i$选择一组邻近样本
  - 用这一组邻近样本的线性加权组合重构x，得到一组使重构误差$\left|\boldsymbol{x}_i - \sum_j \omega_{ij}\boldsymbol{x}_j\right|$最小的权值$\omega_{ij}$
  - 在低维空间里求向量y_i及其邻域的映射，使得对所有样本用同样的权值进行重构得到的误差$\left|\boldsymbol{y}_i - \sum_j \omega_{ij}\boldsymbol{y}_j\right|$最小



5.13.2.3 等距映射

- 等距映射IsoMap（isometric feature mapping）
  - 考虑样本分布接结构信息
  - 样本分布密集，假定样本集的复杂结构在每个小的局部都可以用欧式空间近似，计算每个样本与邻近样本的欧氏距离
  - 对于不相邻样本，寻找一系列两两相邻的样本构成两个样本的路径，用两个样本间最短路径的局部距离之和作为两个样本间的距离。（测地距离，geodesic distance）



5.14 离散傅里叶变换

5.14.1 傅里叶变换提出的背景

基于分析函数的方式将时域中的信号转换到频域的方式，可以获得更多关于原信号的额外信息和性质。

- 学者Joseph Fourier于1807年提出的**傅里叶变换**
- 学者Alfred Haar在1909年首先提出的是**小波变换**

傅里叶变换：

傅里叶是一位法国数学家和物理学家，他对热传递很感兴趣，于1807年在法国科学学会上发表了一篇论文，论文里描述运用正弦曲线来描述温度分布，论文里有个在当时具有争议性的决断：**任何连续周期信号都可以由一组适当的正弦曲线组合而成**

5.14.1 傅里叶变换提出的背景

当时审查这个论文的人，其中有两位是历史上著名的数学家拉格朗日和拉普拉斯，当拉普拉斯和其它审查者投票通过并要发表这个论文时，拉格朗日坚决反对，在近50年的时间里，拉格朗日坚持认为傅里叶的方法无法表示带有棱角的信号，如在方波中出现非连续变化斜率。法国科学学会屈服于拉格朗日的威望，否定了傅里叶的工作成果。直到拉格朗日死后15年这个论文才被发表出来。

谁是对的呢？拉格朗日是对的：正弦曲线无法组合成一个带有棱角的信号。但是，我们可以用正弦曲线来非常逼近地表示它，逼近到两种表示方法不存在能量差别，基于此，傅里叶是对的。

为什么要用正弦曲线来代替原来的曲线呢？可以用方波或三角波来代替吗？

因为正余弦拥有原信号所不具有的性质：**正弦曲线保真度**。一个正余弦曲线信号输入后，输出的仍是正余弦曲线，只有幅度和相位可能发生变化，但是频率和波的形状仍是一样的。且只有正余弦曲线才拥有这样的性质，正因如此才不用方波或三角波来表示。

5.14.2 傅里叶变换分类的类别

根据原信号的不同类型，可以把傅里叶变换分为四种类别：

原信号的类型	傅里叶变化的类别
非周期性 连续信号	傅里叶变换 （Fourier Transform）
周期性 连续信号	傅里叶级数 (Fourier Series)
非周期性 离散信号	离散时域傅里叶变换 （Discrete Time Fourier Transform）
周期性 离散信号	离散傅里叶变换 (Discrete Fourier Transform)

Type of Transform	Example Signal
Fourier Transform *signals that are continious and aperiodic*	
Fourier Series *signals that are continious and periodic*	
Discrete Time Fourier Transform *signals that are discrete and aperiodic*	
Discrete Fourier Transform *signals that are discrete and periodic*	

5.14.3 一维离散傅里叶变换

给定N个输入样本$x(0),x(1),\ldots$，$x(N\text{-}1)$，它们的离散傅里叶变换(DFT)为

$$y(k)=\frac{1}{\sqrt{N}}\sum_{n=0}^{N-1}x(n)\exp\left(-j\frac{2\pi}{N}kn\right),k=0,1,\cdots N-1$$

逆DFT(IDFT)定义为

$$x(n)=\frac{1}{\sqrt{N}}\sum_{k=0}^{N-1}y(k)\exp\left(j\frac{2\pi}{N}kn\right),k=0,1,\cdots N-1$$

5.14.4 二维离散傅里叶变换

给定一个$N \times N$维矩阵或图像，它的二维DFT定义为

$$Y(k,l) = \frac{1}{N} \sum_{m=0}^{N-1} \sum_{n=0}^{N-1} X(m,n)\, W_N^{km} W_N^{ln}$$

IDFT为

$$X(m,n) = \frac{1}{N} \sum_{k=0}^{N-1} \sum_{l=0}^{N-1} Y(k,l)\, W_N^{-km} W_N^{-ln}$$

5.15 哈达玛变换

哈达玛变换的酉矩阵由±1组成，且变换由加法和减法计算，不涉及乘法运算。相比于需要乘法运算的DFT、DCT，节省了处理器的运算时间。

n阶哈达玛酉矩阵是$N \times N$ 维矩阵， $N = 2^n$,它是由如下迭代规则得到：

$$H_n = H_1 \otimes H_{n-1}$$

其中H_n 具有正交性，对于有N个样本的向量$\boldsymbol{x}$和$N = 2^n$，变换对为：

$$Y = H_n X, \qquad X = H_n Y$$

二维哈达玛变换为：

$$Y = H_n X H_n, \qquad X = H_n Y H_n$$

5.16 离散小波变换

5.16.1 小波变换提出的背景

傅里叶变换仅仅分析信号的**全局频率内容**，因此只对平稳或伪平稳信号有效。对于高度不平稳的，有噪声的或是非周期性的信号，傅里叶变换经常不能给出令人满意的结果。

短时傅里叶变换能够克服傅里叶变换仅能给出信号整体频率特征的局限性，并能够从信号中同时恢复出频率和时间信息。短时傅里叶变换的解决方法是通过在进行傅里叶变换的同时对原始信号添加**窗函数**，并在变换过程中随时间移动窗函数。但是短时傅里叶变换的缺点在于**窗函数在选取不当**时会导致分辨率降低。

对于非平稳，非周期信号傅里叶变换或短时傅里叶变换难以取得令人满意的结果，这时可以考虑使用小波变换（Wavelet Transform, WT）。小波变换与离散傅里叶变换的本质区别在于**小波变换拥有动态分辨率特性**，因此使得它能够揭示出其他分析方法可能遗漏的细节，诸如突变，不连续性和变化趋势等。与傅里叶变换类似，**连续小波变换**最开始的作用对象也是连续时间信号。

连续小波变换

$$X_{WT}(\tau,s)=\frac{1}{\sqrt{|s|}}\int_{-\infty}^{\infty}x(t)\varphi^{*}\left(\frac{t-\tau}{s}\right)dt$$

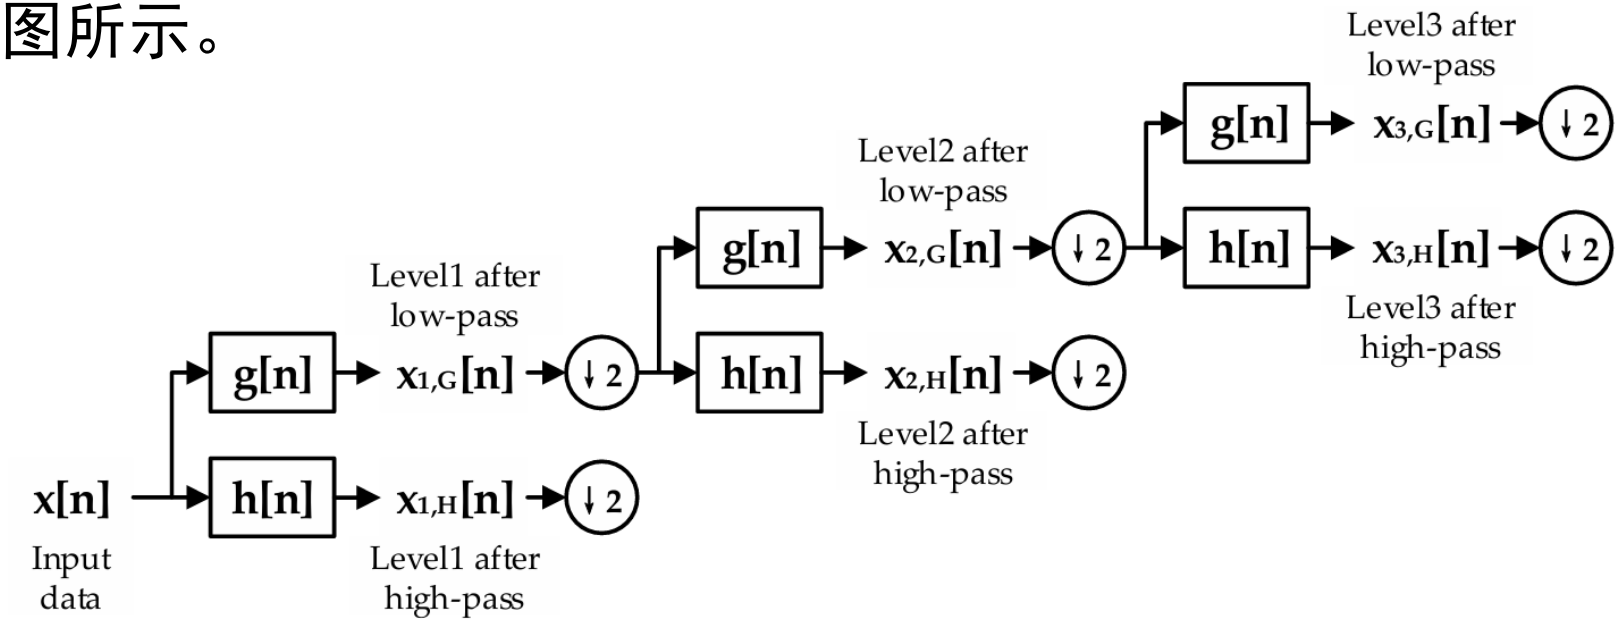
式中，$\varphi(t)$称为小波基函数（也称为母小波）。*表示复数窗函数的共轭。与傅里叶变换需要使用正弦形式的基函数不同，小波变换的基函数的选择更自由。

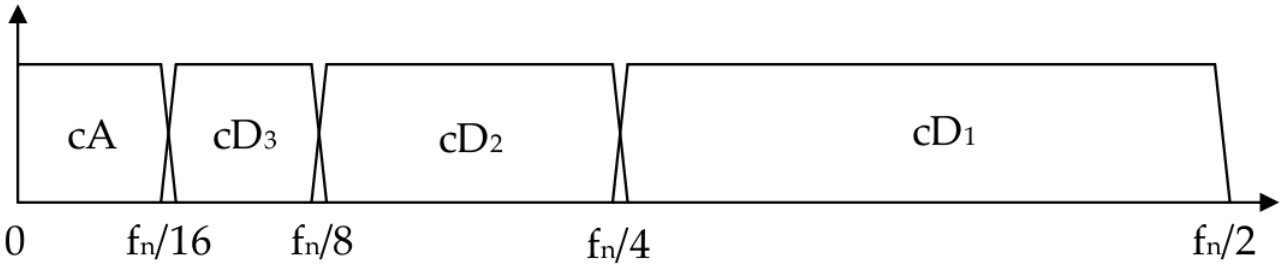
τ和s分别代表平移系数和伸缩系数。母小波函数通过伸缩系数改变其中心频率并同时改变窗函数的大小，通过平移系数改变在时域中的位置。当固定伸缩系数时，平移系数的改变则可以在时域遍历整个信号，而当平移系数固定时，伸缩系数的改变则可以在某一时间点观察丰富的频率信息。

小波分析具有动态分辨率特性的主要原因正是因为伸缩系数的使用。伸缩系数越小，等效的时间窗越小，原始信号局部高频特性则更容易体现出来。伸缩系数越大，等效的时间窗越大，原始信号的全局特性则更容易体现出来。

5.16.2 离散小波变换

离散小波变换使用滤波器阵列构造多分辨率时频来执行小波分析，即Mallat算法。离散小波变换**将信号分解为小波系数**，各层小波系数分别表示了各个频带中的信号，从中可以再次重构原始信号。滤波器阵列由多个滤波器组成，一个三层的离散小波分解过程如下图所示。





当信号进行一个三层的离散小波变换后，会得到不同分辨率的4组输出。

下式表示了该滤波器阵列，同时也是Mallat算法的工作原理。

$$\begin{cases} x_{L,G}[n] = \sum_{k=0}^{K-1} x_{L-1,G}[2n-k]g[k] \\ x_{L,H}[n] = \sum_{k=0}^{K-1} x_{L-1,G}[2n-k]h[k] \end{cases}$$

式中$x[n]$代表原始离散信号，长度为N。$g[k]$和$h[k]$分别代表低通滤波器和高通滤波器，当滤波器的长度为K时，则会产生K个采样点的延迟，这也是滤波器本身的延迟。$x_{L,G}[n]$和$x_{L,H}[n]$分别表示第L层低通滤波器和高通滤波器的输出。

如果滤波器阵列是理想的矩形滤波器，则不会造成信号混叠、幅度和相位失真的现象。然而实际中不存在矩形滤波器，只能通过构造正交的滤波器组来避免这些现象。这些滤波器在z域中应当满足下式的条件以抗混叠（其中$G'(z)$和$H'(z)$分别代表离散小波变换的重构滤波器）

$$\begin{cases} G'(z) = H(-z) \\ H'(z) = -G(-z) \end{cases}$$

同时还应满足下式的条件以防止幅度和相位失真

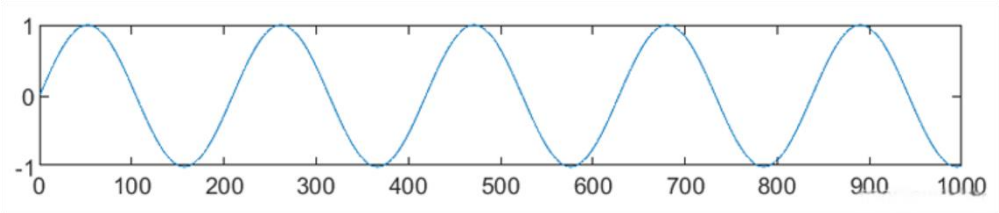
$$\begin{cases} P_0(z) - P_0(-z) = 2z^{-N} \\ P_0(z) = G(z)G'(z) \end{cases}$$

对于离散小波变换而言，针对各种场景出现了许多不同的小波函数族。其中最典型也最常使用的便是Daubechies小波。常见的小波还包含Harr（Daubechies小波的特殊形式）、Biorthogonal小波、Coiflets小波和Symlets小波等。它们之间的各项特性对比见下表所示。

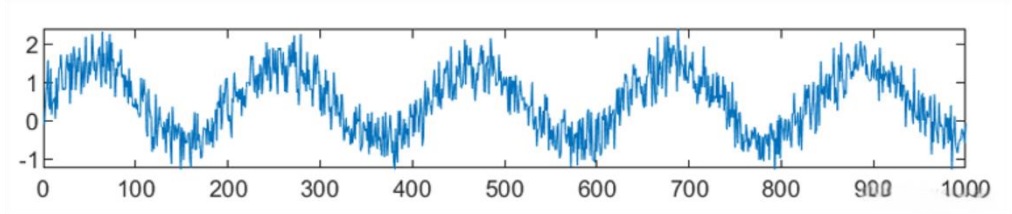
函数名称	Harr	Daubechies	Biorthogonal	Coiflets	Symlets
表现形式	Haar	Db N	Bior $Nr.Nd$	Coif N	Sym N
正交性	是	是	否	是	是
双正交性	是	是	是	是	是
紧支持性	是	是	是	是	是
连续形式	有	有	有	有	有
离散形式	有	有	有	有	有
滤波器长度	2	$2N$	$Max(Nr,Nd)*2+2$	$6N$	$2N$
对称性	对称	准对称	不对称	准对称	准对称

5.16.3 小波变换的应用

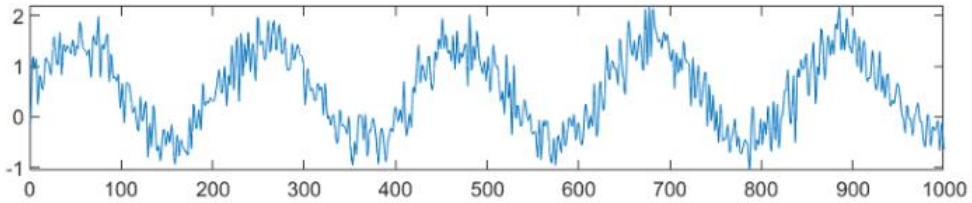
信号去噪



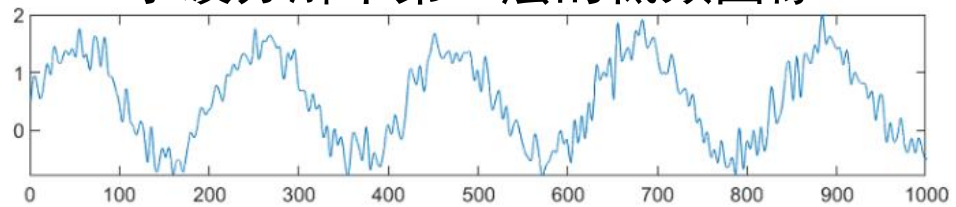
原始信号



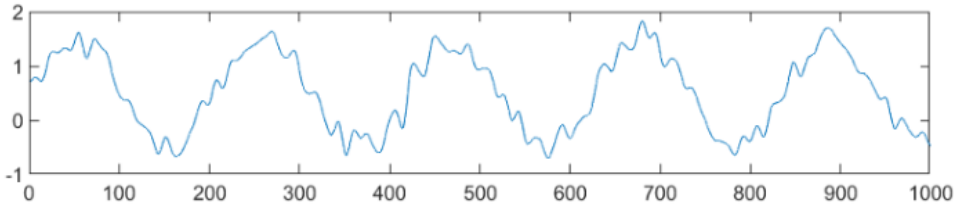
噪声信号



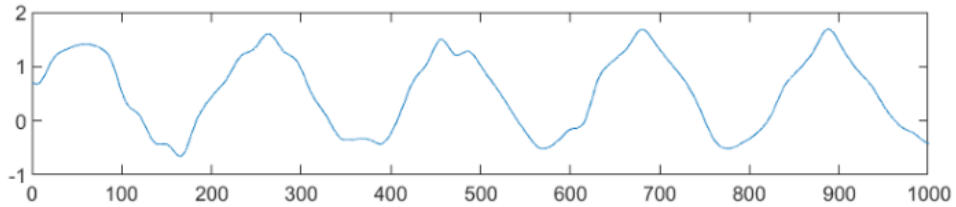
小波分解中第一层的低频图像



小波分解中第二层的低频图像



小波分解中第三层的低频图像



小波分解中第四层的低频图像

图像去噪



原始图像



添加噪声后的图像



第一次去噪后的图像



第二次去噪后的图像

5.17 图像的区域特征

一阶统计量特征

设I是一个代表感兴趣区域中的灰度级的随机变量。一阶直方图 P(I)定义为：

$$P(I)=\frac{\text{灰度级为I的像素数}}{\text{区域中的总像素数}}$$

矩：

$$m_i = E\left[I^i\right] = \sum_{I=0}^{N_g-1} I^i\, P(i), i = 1, 2, \cdots$$

中心矩：

$$\mu_i = E\left[(I - E[I])^i\right] = \sum_{I=0}^{N_g-1} (I - m_1)^i\, P(i)$$

绝对矩，熵，…

二阶统计量特征——共生矩阵

灰度共生矩阵 (Grey Level Co-occurrence Matrix) 中的元素，表示的是具有某种空间位置关系的两个像素灰度的联合分布

对于距离d和角度ϕ的每个组合，定义二维直方图为：

$$0°：P(I(m,n)=I_1, I(m\pm d,n)=I_2)=\frac{\text{具有}(I_1,I_2)\text{值且距离为}d\text{的像素对数量}}{\text{可能像素对的总数}}$$

$$45°：P(I(m,n)=I_1, I(m\pm d,n\mp d)=I_2)$$

$$90°：P(I(m,n)=I_1, I(m,n\mp d)=I_2)$$

$$135°：P(I(m,n)=I_1, I(m\pm d,n\pm d)=I_2)$$

例如，设图像数组$I(m,n)$是

$$I=\begin{bmatrix}0&0&2&2\\1&1&0&0\\3&2&3&3\\3&2&2&2\end{bmatrix}$$

$$A^0(d=1)=\frac{1}{24}\begin{bmatrix}4&1&1&0\\1&2&0&0\\1&0&6&3\\0&0&3&2\end{bmatrix}$$

(d,ϕ)的共生矩阵定义为：

$$A=\frac{1}{R}\begin{bmatrix}\eta(0,0)&\eta(0,1)&\eta(0,2)&\eta(0,3)\\\eta(1,0)&\eta(1,1)&\eta(1,2)&\eta(1,3)\\\eta(2,0)&\eta(2,1)&\eta(2,2)&\eta(2,3)\\\eta(3,0)&\eta(3,1)&\eta(3,2)&\eta(3,3)\end{bmatrix}$$

式中，$\eta(I_1,I_2)$是在相对位置(d,ϕ)的像素对的数量，它们的灰度值分别是I_1和I_2；
R是可能的像素对的总数

角二阶矩(Angular Second Moment，ASM)：

$$ASM = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} (p(i,j))^2$$

对比度(Constrast，CON)：

$$CON = \sum_{n=0}^{N_g-1} n^2 \left\{ \sum_{i=0}^{N_g-1} \sum_{|i-j|=n} \sum_{j=0}^{N_g-1} p(i,j) \right\}$$

逆差矩(Inverse Difference Moment，IDF)：

$$IDF = \sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} \frac{p(i,j)}{1+(i-j)^2}$$

熵：

$$H_{xy} = -\sum_{i=0}^{N_g-1} \sum_{j=0}^{N_g-1} p(i,j) \log_2 p(i,j)$$

使用灰度级行程长度的特征

考虑矩阵：

$$I = \begin{bmatrix} 0 & 0 & 2 & 2 \\ 1 & 1 & 0 & 0 \\ 3 & 2 & 3 & 3 \\ 3 & 2 & 2 & 2 \end{bmatrix}$$

该图像有4个灰度级($N_g = 4$)。对于4个方向$(0°, 45°, 90°, 135°)$之一，我们定义对应的行程长度矩阵 Q_{RL}，它的第(i, j)个元素给出灰度级$i - 1, i = 1, \ldots, N_g$，以行程长度$j, j = 1,2 \ldots, N_r$，出现在图像中的次数。这是一个$N_g \times N_r$维数组，其中$N_r$是图像中的最大可能行程长度。对于$0°$，我们得到：

$$Q_{RL}(0°) = \begin{bmatrix} 0 & 2 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 2 & 1 & 0 & 0 \end{bmatrix}$$

短行程强调，长行程强调，灰度级不均匀性，行程长度不均匀性、行程百分比

5.18 形状和尺寸特征

当物体从图象中分割出来以后，形状描述特征与尺寸测量结合起来可以作为区分不同物体的依据，在机器视觉系统中起着十分重要的作用

两种用于得到一个区域或一个目标的形状特征的方法：

- 以再生的方式开发能够完全描述目标的边界的技术
- 使用不可再生的描述区域形状性质的特征



(a) (b) (c)

OCR系统：(a)分割扫描图像后得到的字符“5”;(b)二值化后的字符“5”;(c)对二值化边界应用边界提取算法后得到的边界

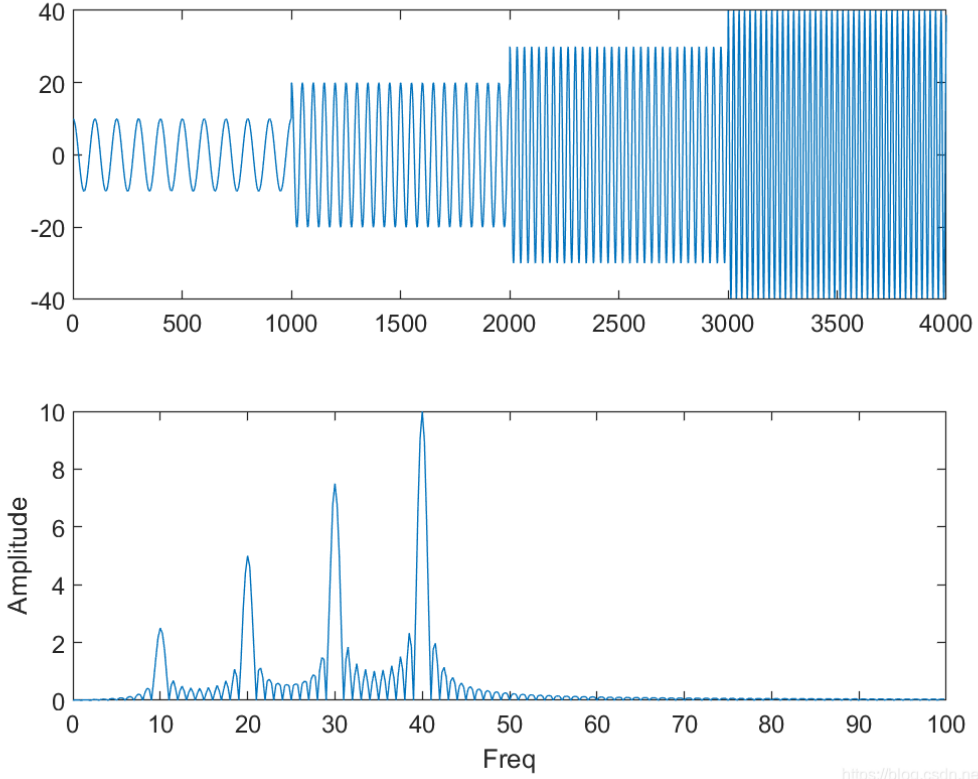
5.19 语音和声音分类

特征生成是与具体的语音和声音分类任务密切关联的，设计者只有结合关于具体任务的想象和知识，才能生成有用的特征用以完成准确分类的任务

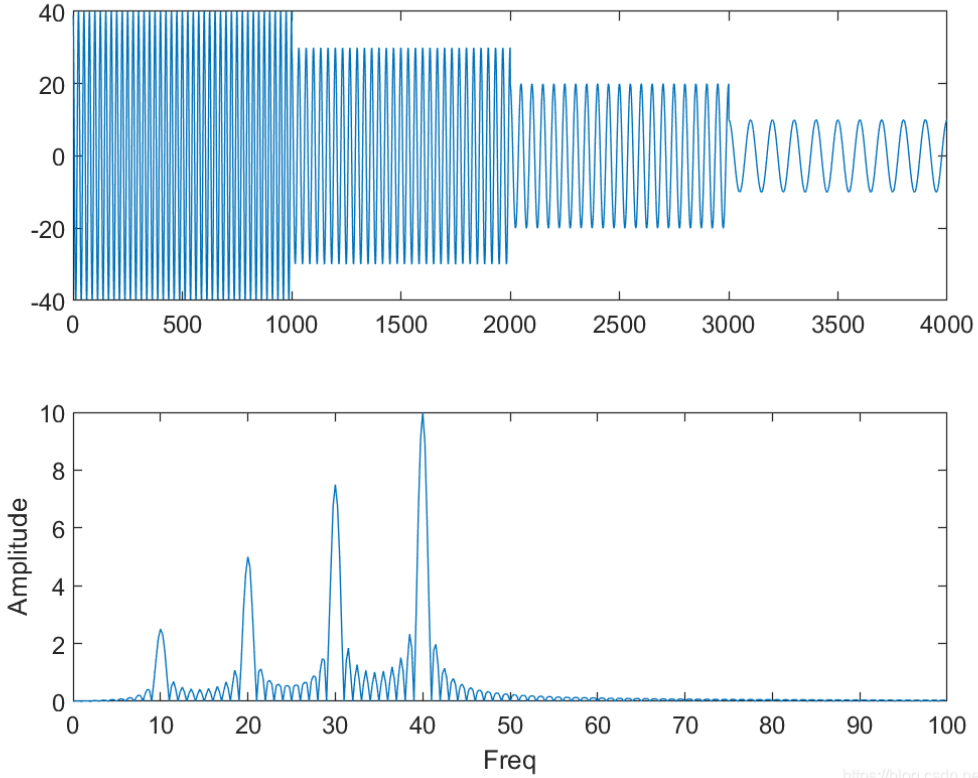
- 信号的短时处理
- 倒谱
- 梅尔倒谱
- 频谱特征
- 时域特征

信号的短时处理

傅里叶变换FFT在处理信号时存在的问题：



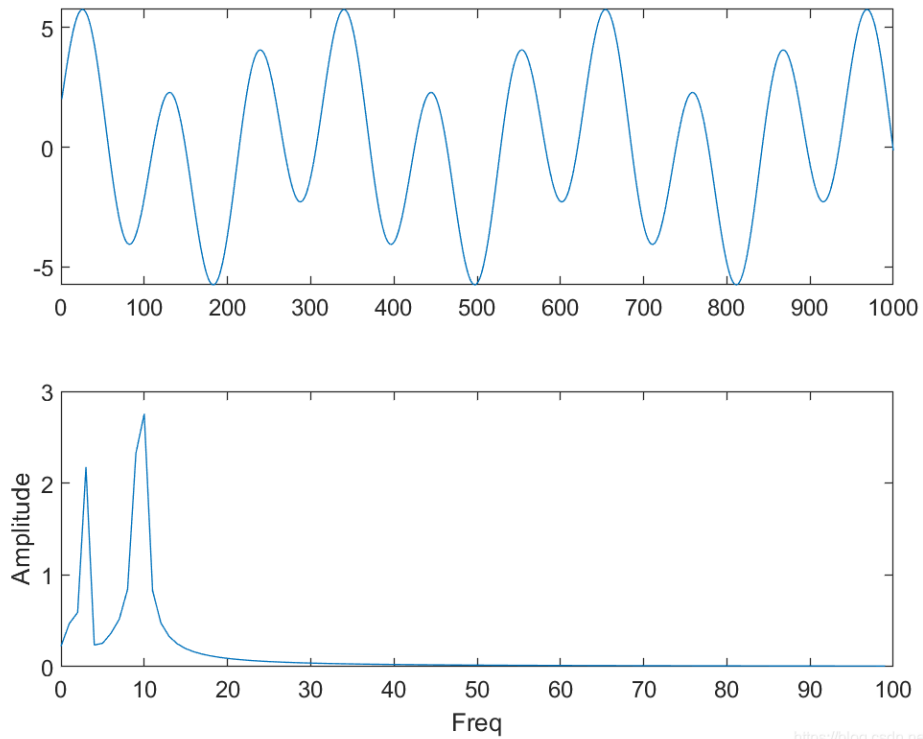
信号的时域图和经过傅立叶变换后的频谱图



将信号反过来后

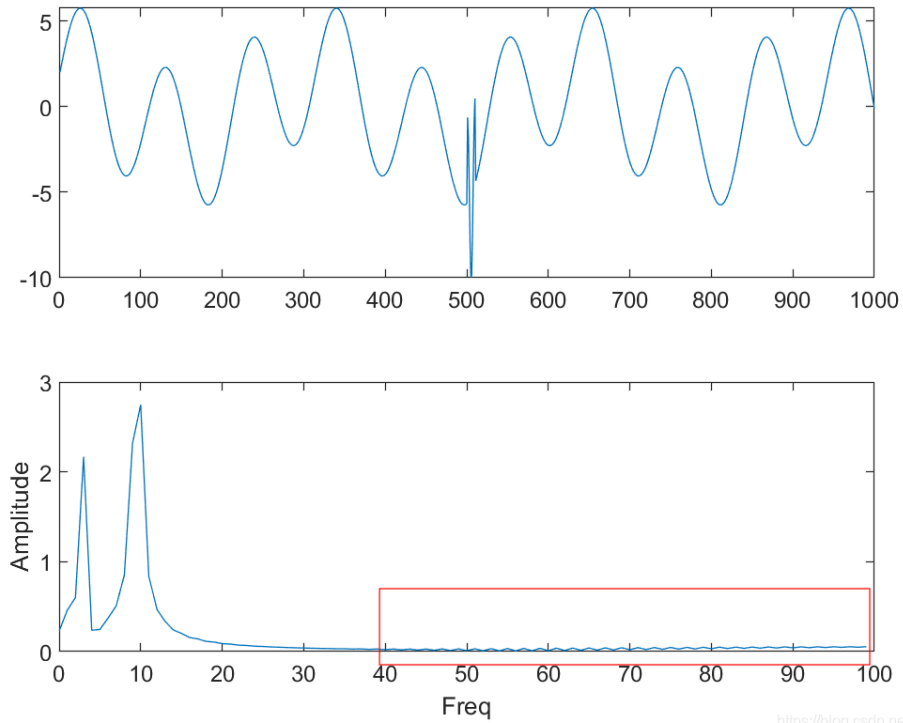
尽管这两个信号的时域分布完全相反，但是它们的频谱图是完全一致的。显然，FFT无法捕捉到信号在时域分布上的不同

傅里叶变换FFT在处理信号时存在的问题：



原始信号的时域图和频域图

加入一个
高频突变

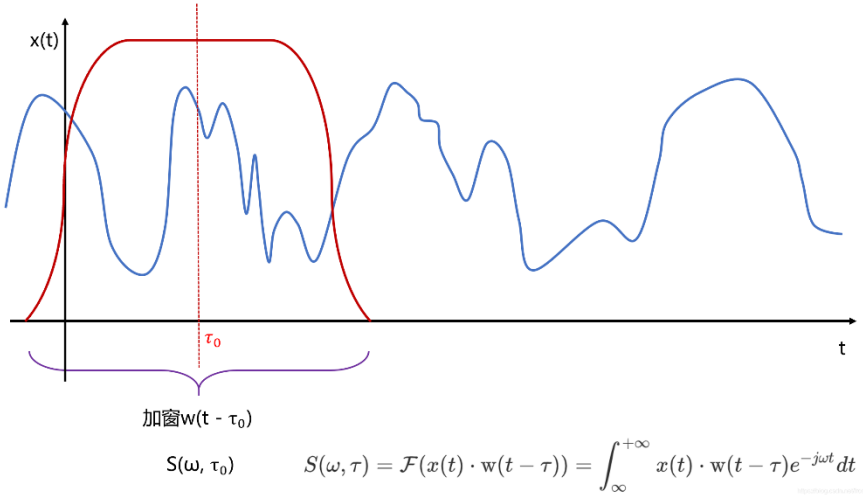


混合信号的时域图和频域图

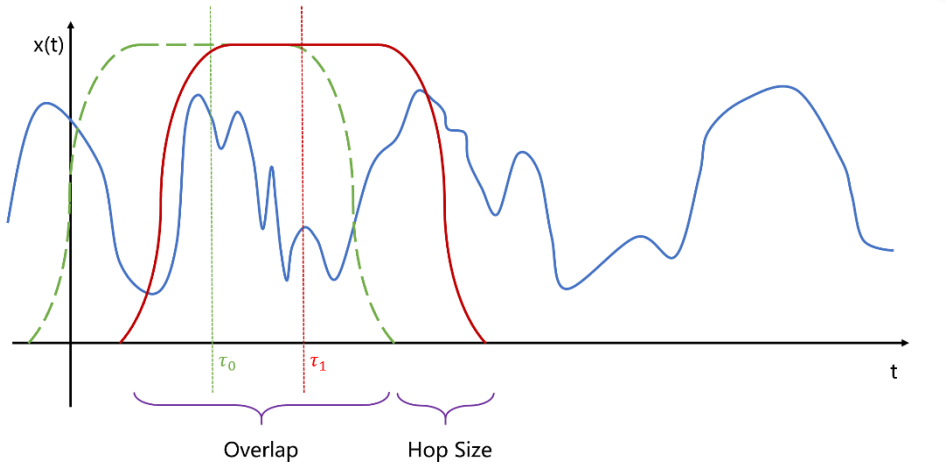
对比两个信号的时域图，第二个信号中央出现了突变扰动，但频域图未能有效捕捉这一变化。从红框部分可见，傅里叶变换将突变视为多种低幅高频信号的叠加，

FFT未能准确反映突变对信号的影响

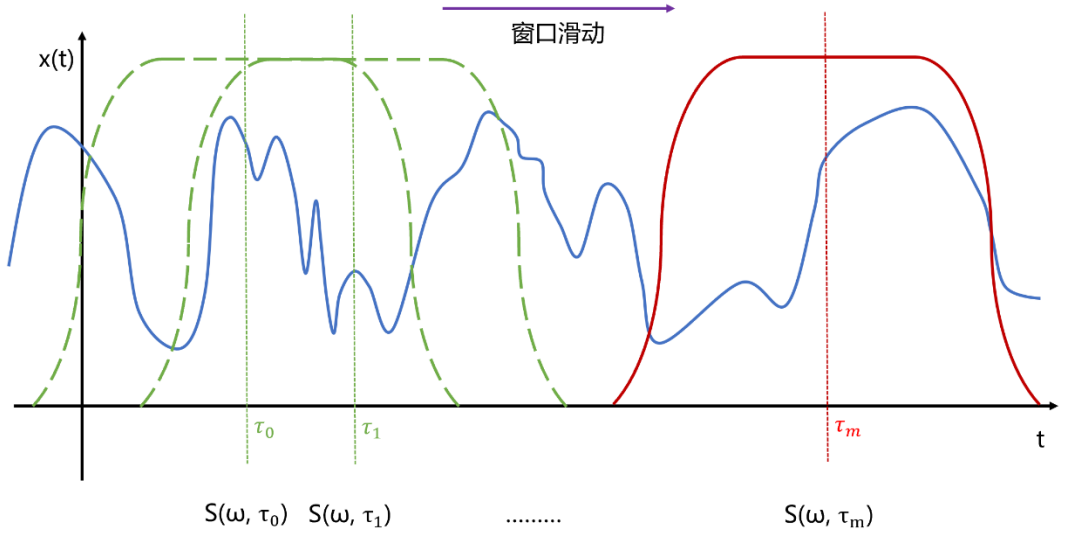
短时傅里叶变换STFT：对一小段序列做 FFT



定义一个窗函数，然后进行FFT

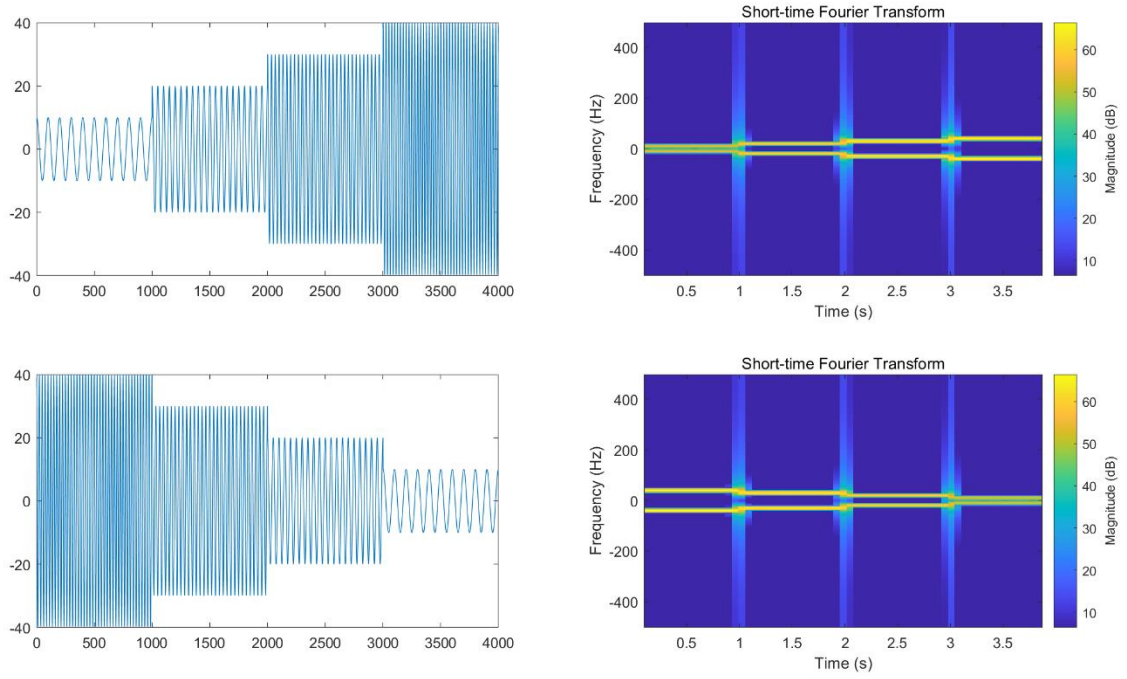


完成了对第一个分段的FFT操作后，移动窗函数到 τ_1

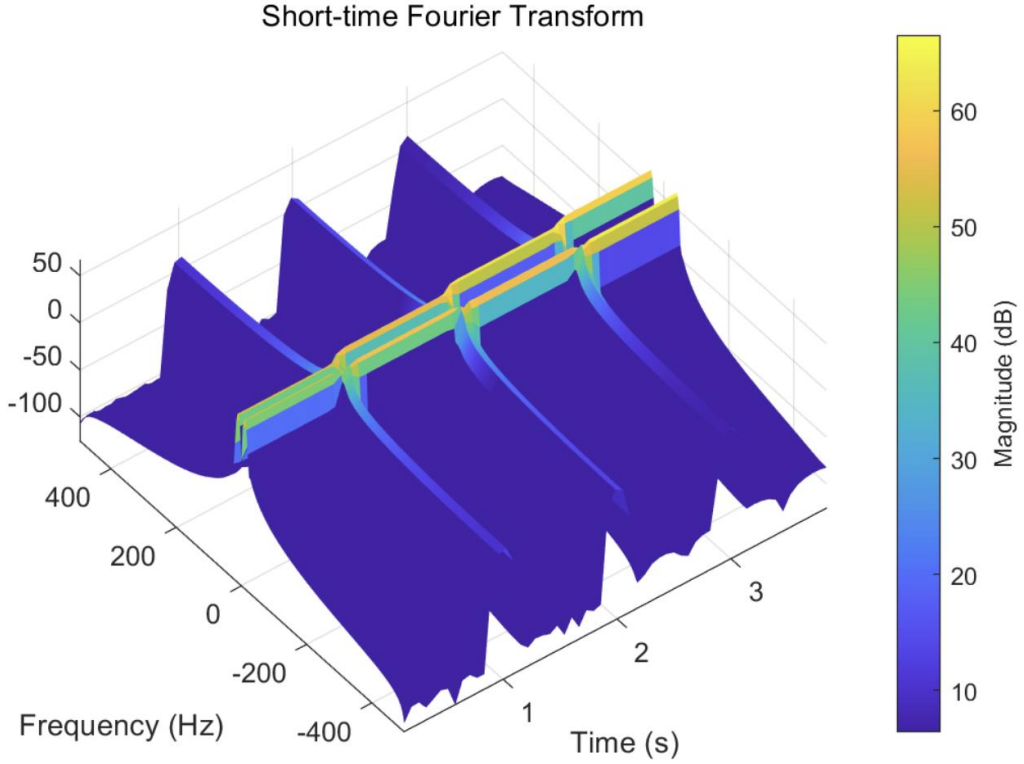


重复以上操作，不断滑动窗口、FFT，最终得到从 $\tau_0 \sim \tau_m$ 上所有分段的频谱结果

短时傅里叶变换STFT：对一小段序列做 FFT



STFT变换



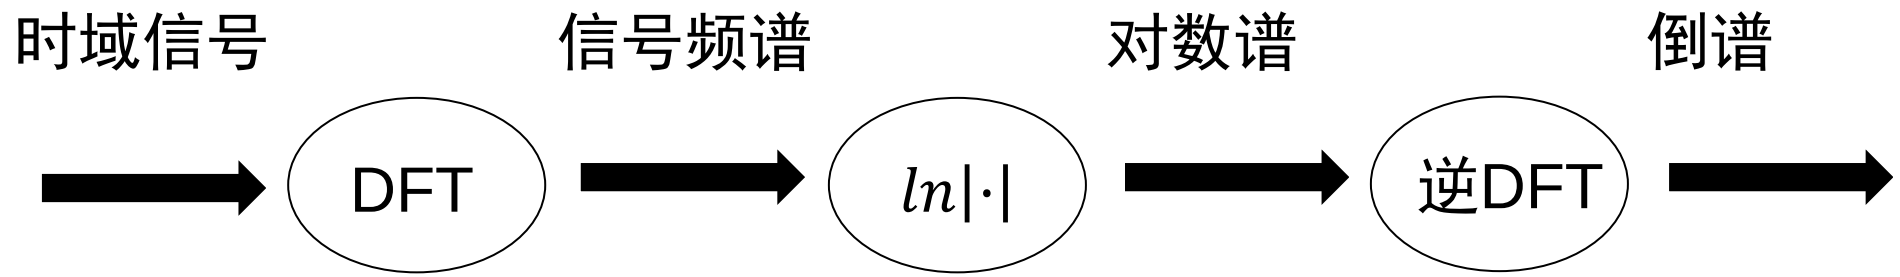
STFT变换三维化

相比 FFT，STFT 能清晰展现频谱的时变特性，通过时间分段揭示不同区间内的频率动态变化，**适用于非平稳信号分析**

分界线处的异常高频成分（STFT 图中的三条竖线）由**时域信号的突变**引起

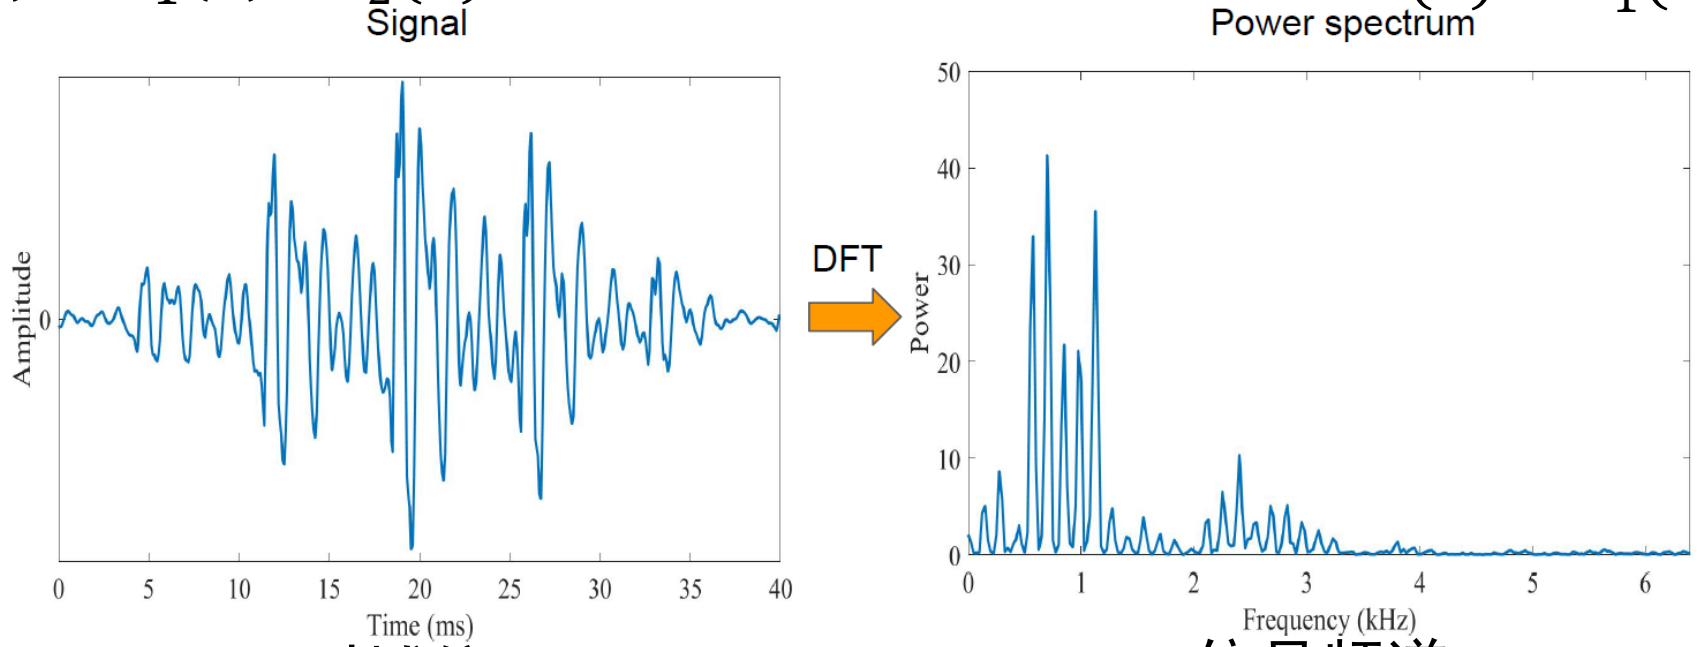
倒谱

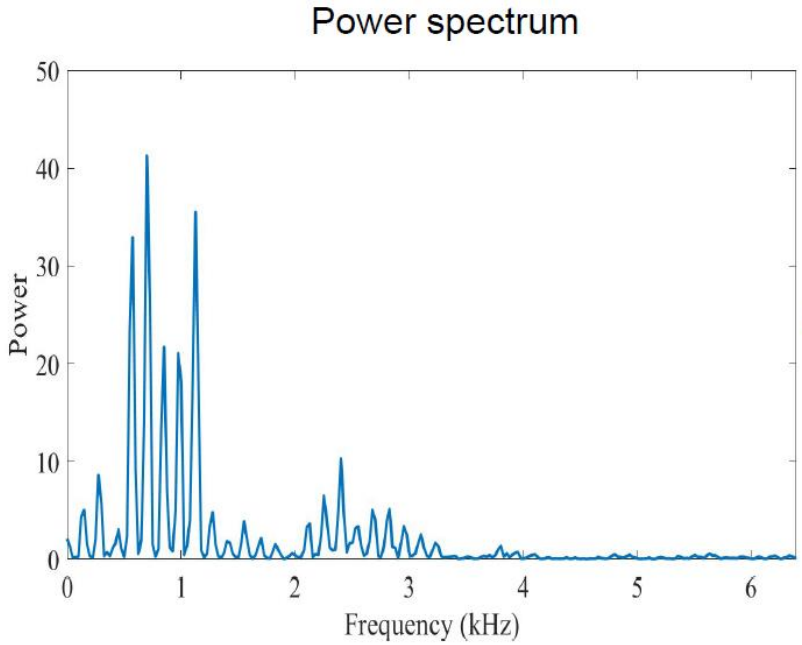
倒谱（cepstrum）就是一种信号的傅里叶变换经对数运算后再进行傅里叶反变换得到的谱



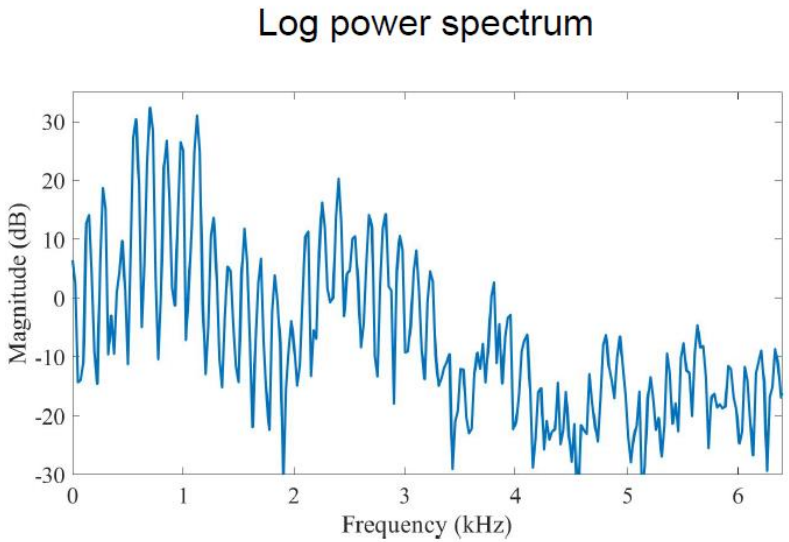
$$x(n) = x_1(n) * x_2(n)$$

$$c(n) = \widehat{x_1}(n) + \widehat{x_2}(n)$$

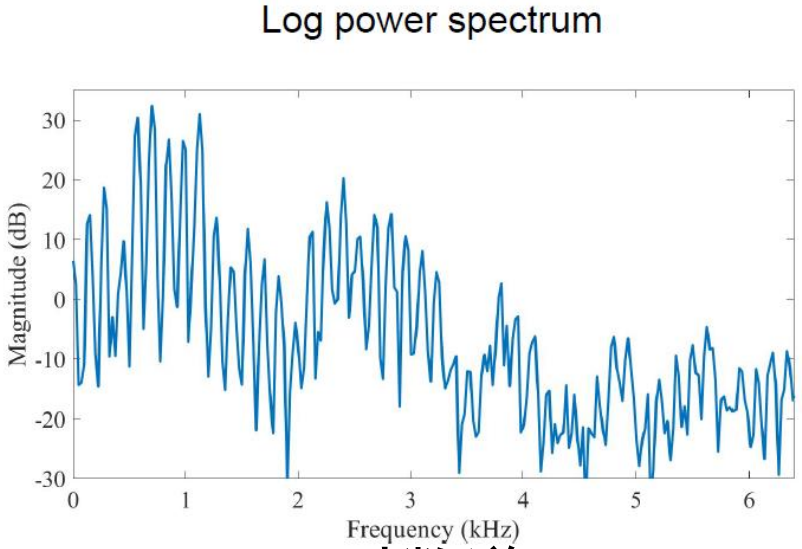




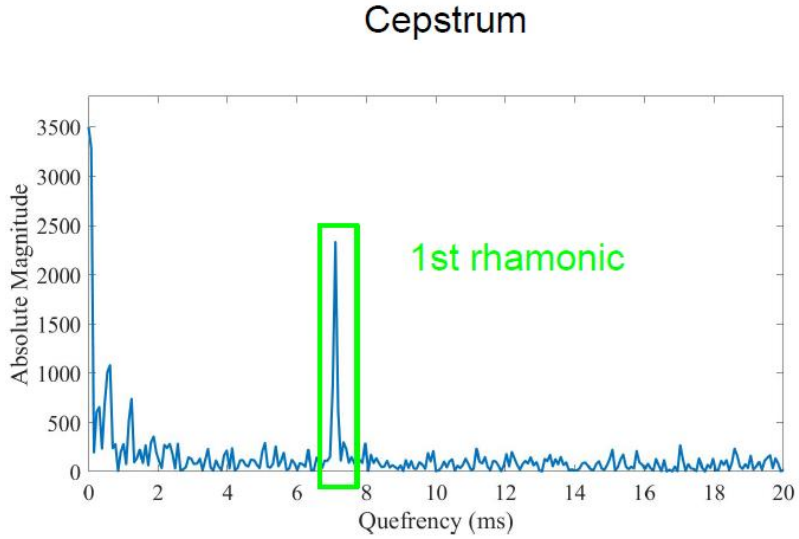
log



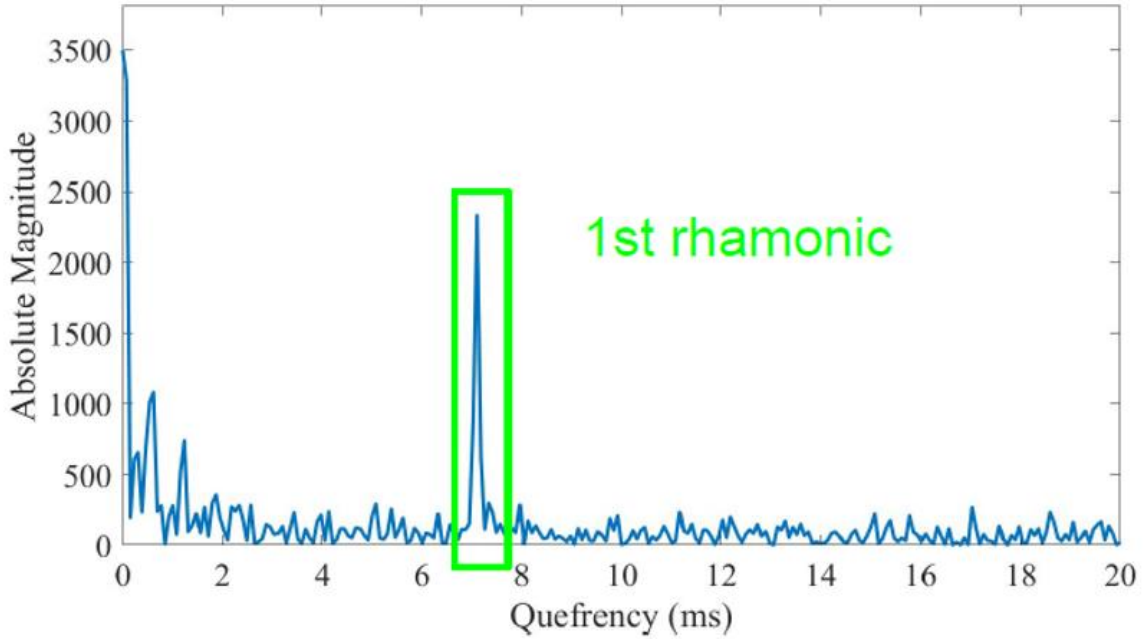
信号频谱 → 对数谱



IDFT



对数谱 → 倒谱



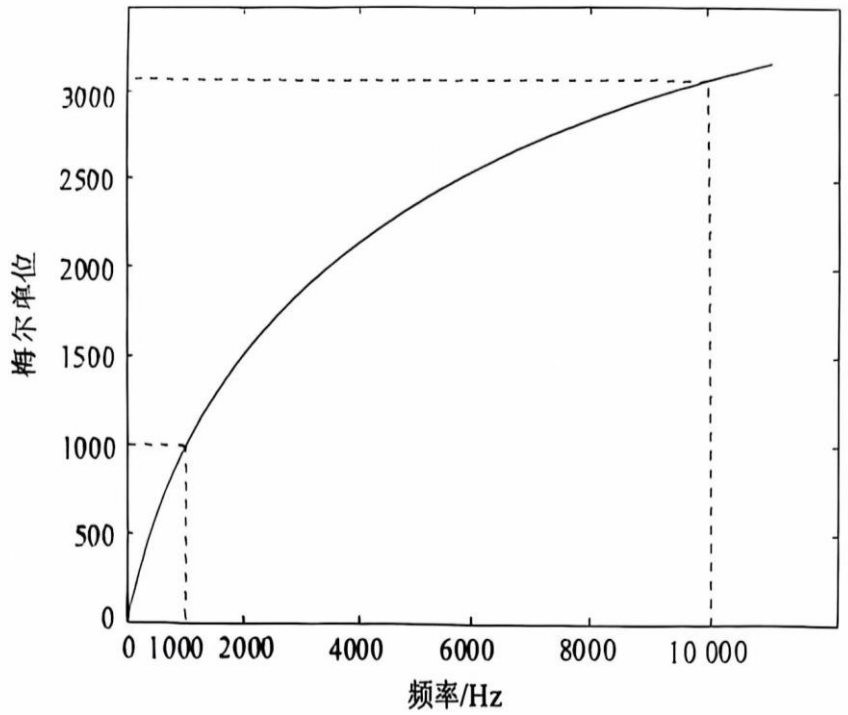
•最后逆变换得到的倒谱图，横坐标为倒频率（Quefrency，频率的倒数，单位是毫秒），纵坐标是振幅。

•最后一张图中的所谓1st rhamonic，是从倒谱图的右边往左看的第一个尖峰，实际上，这个1st rhamonic对应原始信号的基频。

梅尔倒谱

梅尔倒谱系数（Mel-scale Frequency Cepstral Coefficients，简称MFCC）是在Mel尺度频率域提取出来的倒谱参数，Mel尺度描述了人耳频率的非线性特性，它与频率的关系可用下式近似表示

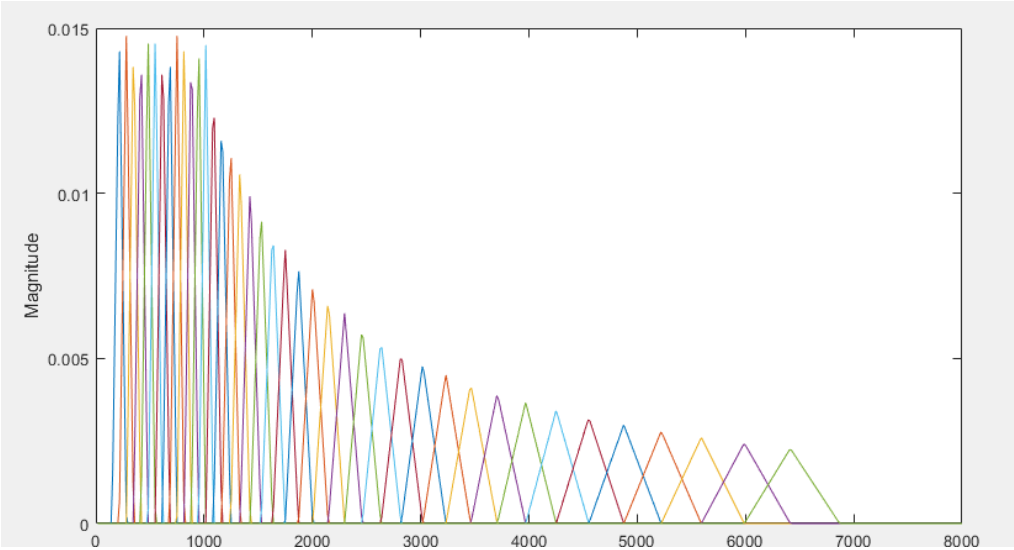
$$f_{mel} = 25951 \log 10(1 + {}^{f}/_{700})$$



- 人类对频率的感知并不是线性的，并且对低频信号的感知要比高频信号敏感
- 人们可以比较容易地发现500和1000Hz的区别，但很难发现7500和8000Hz的区别

梅尔滤波器

人耳对低频音调的感知较灵敏，在高频时人耳是很迟钝的，**梅尔滤波器组**启发于此

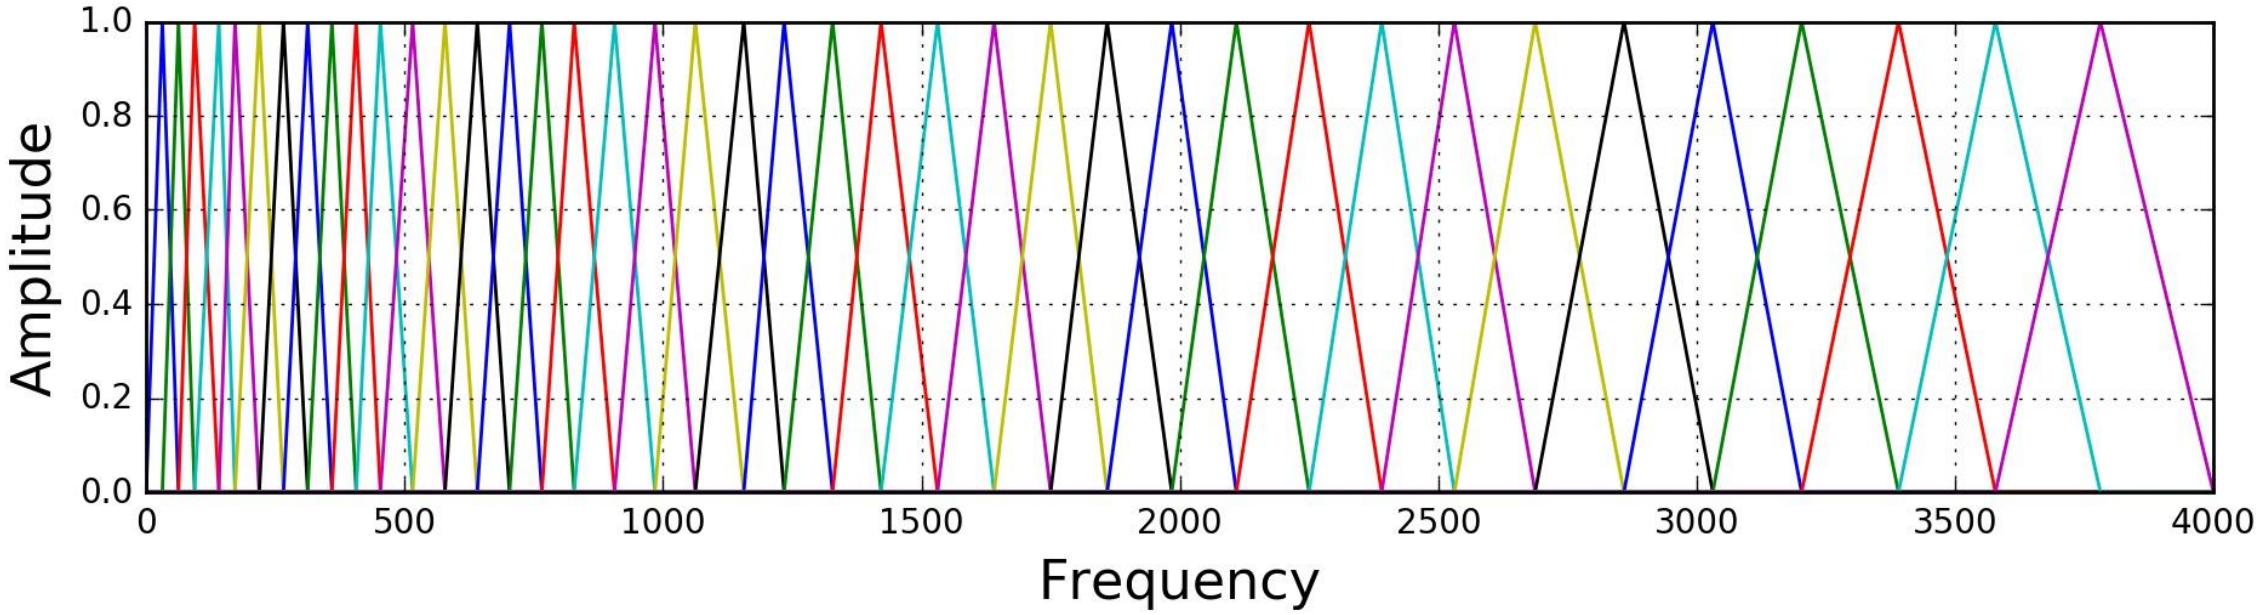


等面积梅尔滤波器（Mel-filter bank with same bank area）

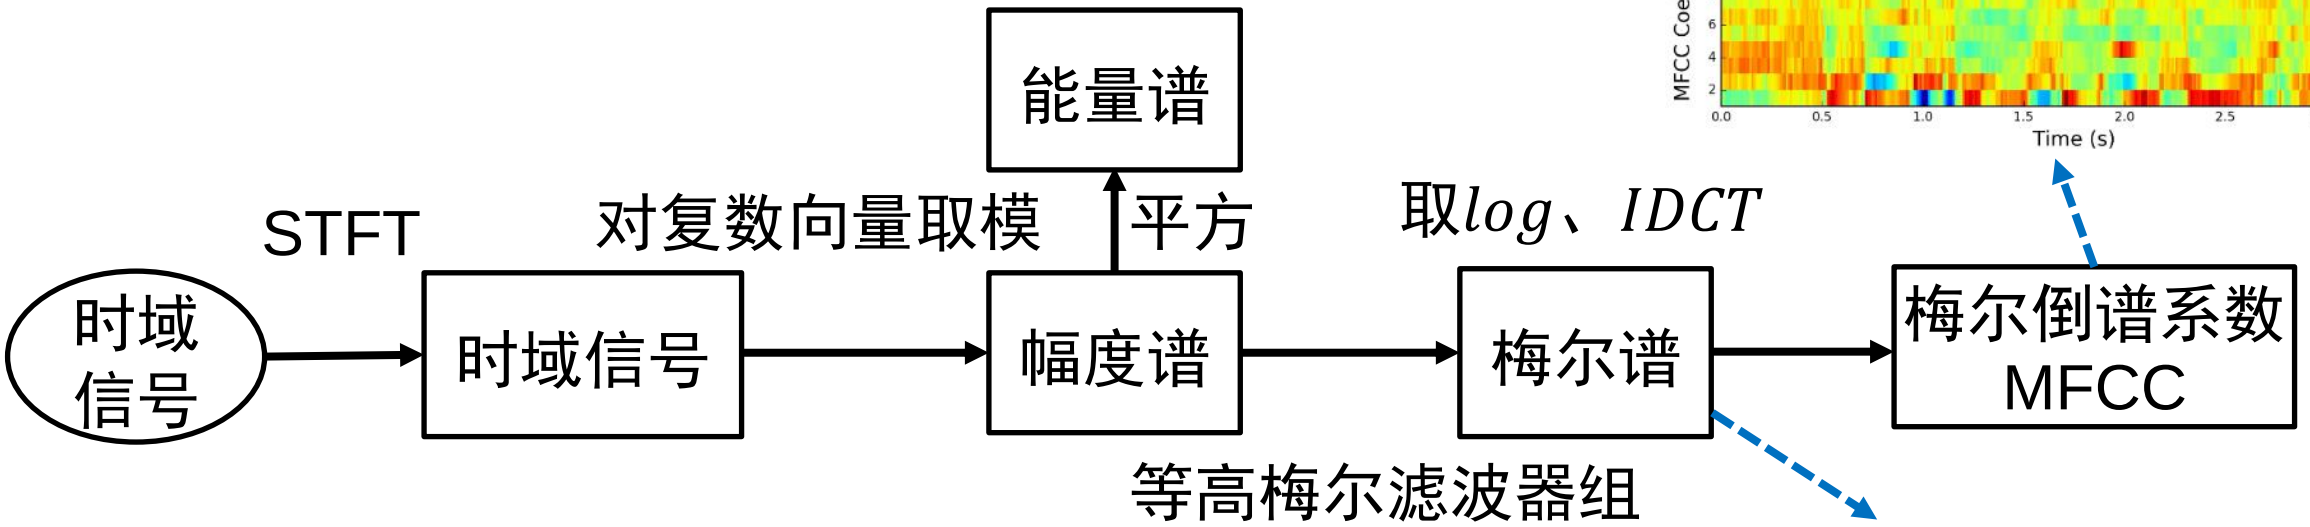
等面积梅尔滤波器在低频处滤波器密集，门限值大，高频处滤波器稀疏，门限值低。恰好对应了频率越高人耳越迟钝这一客观规律。在人声领域（语音识别，说话人辨认）等领域应用广泛，但是如果用到非人声领域，就会**丢掉很多高频信息**

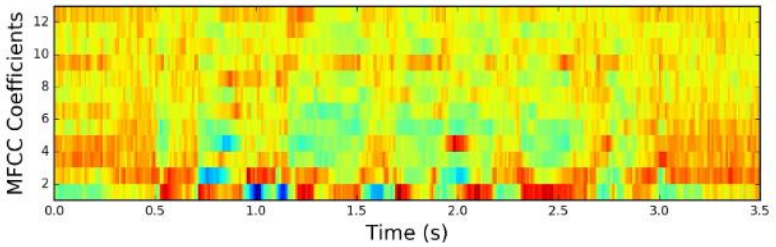
梅尔滤波器

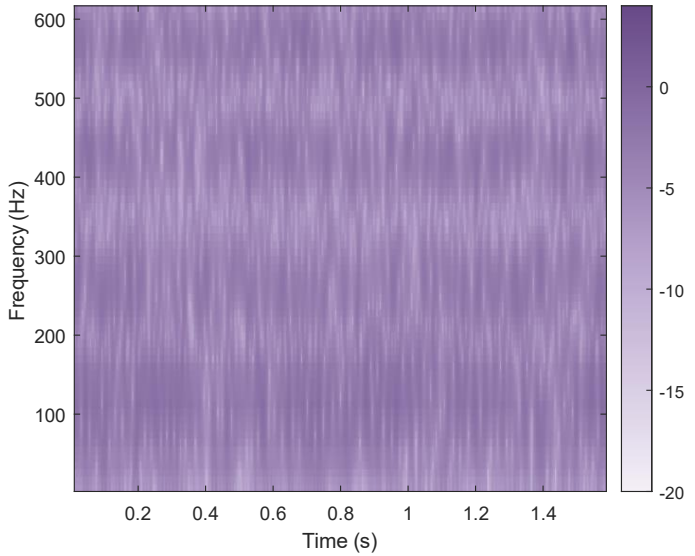
如果用到非人声领域，这时常用的是**等高梅尔滤波器**（Mel-filter bank with same bank height）：



完整的梅尔倒谱系数MFCC及其动态特征提取过程：







- MFCC 基于梅尔频率尺度，**模拟了人类耳蜗对频率的非线性感知特性**
- MFCC 广泛应用于语音识别、说话人识别、情感识别等任务，具有很高的**通用性**
- MFCC 的计算过程（短时傅里叶变换、梅尔滤波、对数压缩、DCT）在现代硬件上非常高效，适合**实时处理**

频谱特征

频谱质心：

$$C(i) = \frac{\sum_{m=0}^{N-1} m|X_i(m)|}{\sum_{m=0}^{N-1}|X_i(m)|}$$

频谱滚降：

$$\sum_{m=0}^{m_c^R(i)} |X_i(m)| = \frac{c}{100}\sum_{m=0}^{N-1}|X_i(m)|$$

频谱通量：

$$F(i) = \sum_{m=0}^{N-1} (N_i(m) - N_{i-1}(m))^2$$

基频：复杂声音中最低且通常情况下最强的频率

时域特征

过零率：

$$Z(i) = \frac{1}{2N}\sum_{n=0}^{N-1}|sgn[x_i(n)12] - sgn[x_i(n-1)]|$$

式中，$sgn[x_i(n)] = \begin{cases} 1, x_i(n) \geq 0 \\ -1, x_i(n) \leq 0 \end{cases}$

能量：

$$E(i) = \frac{1}{N}\sum_{n=0}^{N-1}|x_i(n)|^2$$