模式识别
——模式识别与机器学习

刘文黎

liu_wenli@hust.edu.cn

土木与水利工程学院

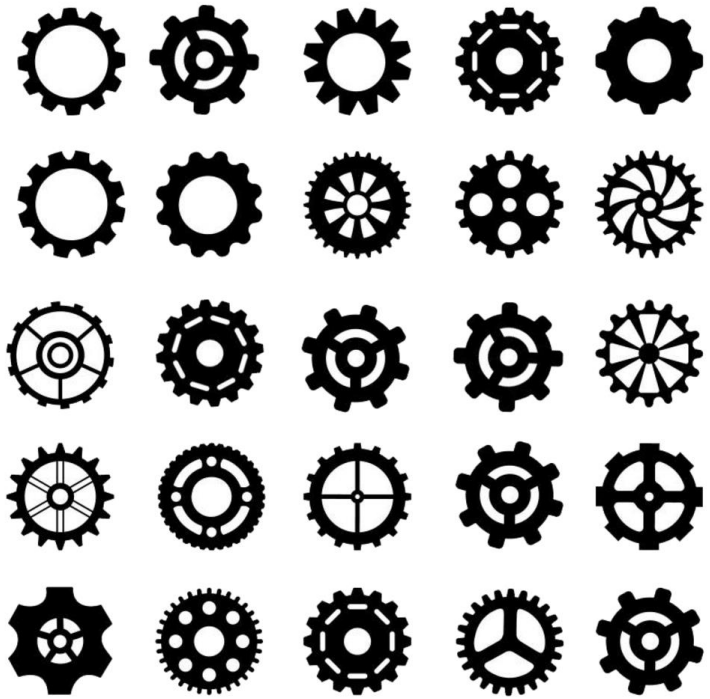
第6章 模板匹配

本章主要内容

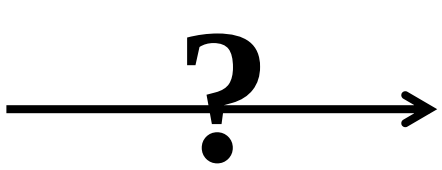
6.1 引言
6.2 基于最优路径搜索技术的度量
6.3 基于相关的度量
6.4 可变形模板模型
6.5 基于内容的信息检索：相关反馈

6.1 引言

- 模板匹配是一种模式识别和计算机视觉技术，通过将输入信号或图像与预定义模板进行比较，从而在数据中找到目标模式。



测试模式





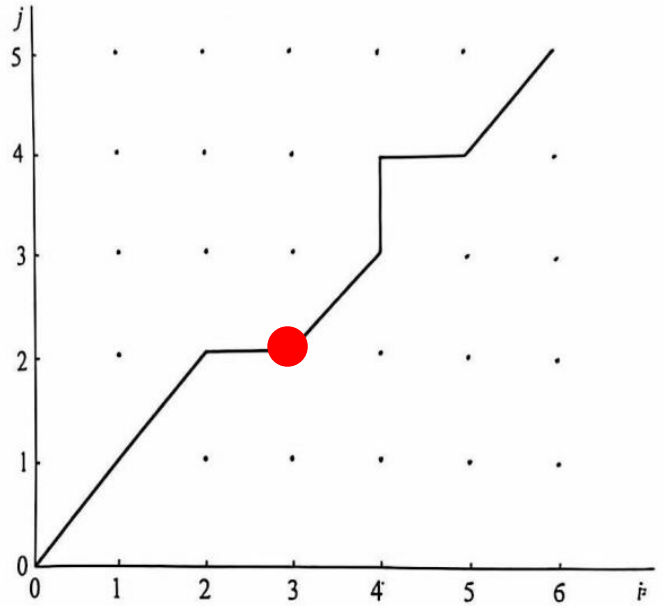
参考模式（模板）

6.2 基于最优路径搜索技术的度量

- 模式由已识别的**符号串**或**特征向量**(字符串模式)组成。
- 设$r(i), i = 1,2,\cdots,I$是参考模式的特征向量序列

$t(j), j = 1,2,\cdots,J$是测试模式的特征向量序列。其中$I \neq J$。

为找到两个序列之间的合适距离度量，建立二维网络，使得两个字列中的元素成为各自坐标轴上的点，即参考模式字符串位于横坐标轴（I轴）上，测试模式字符串位于纵坐标轴（ J轴）上。右图为I =6, J=5的例子。



节点$(3,2)$将元素$r(3)$映射为元素$t(2)$

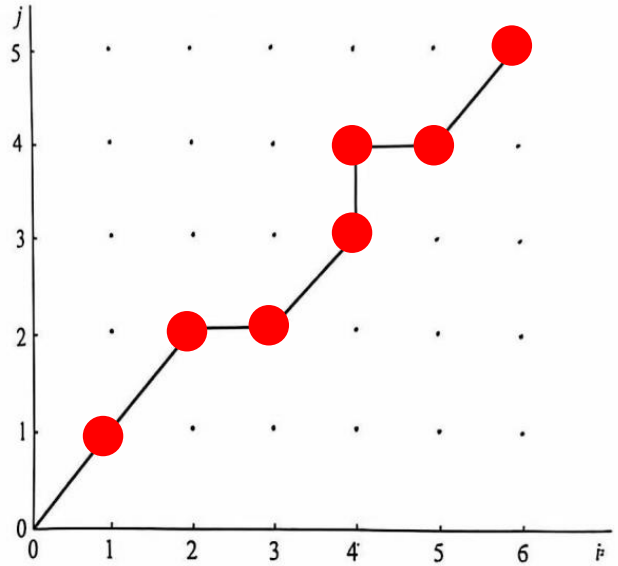
6.2 基于最优路径搜索技术的度量

- 网格中的每个节点(i,j)都与一个代价相关联，这个代价适当地定义了函数$d(i,j)$，以便度量字符串$r(i)$和$t(j)$中各个字符之间的“距离”。网格中从初始节点(i_0,j_0)到最终节点(i_f,j_f)的路径，是一个形如下式的有序节点集：

$$(i_0,j_0),(i_1,j_1),(i_2,j_2),\cdots,(i_f,j_f)$$

每条路径都与一个形如下式的总代价函数D相关联：

$$D=\sum_{K=0}^{K-1}d(i_k,j_k)$$



式中，K是路径上的节点数。

对于上页的例子，$K=8$。

到节点(i_k,j_k)的总代价记为$D(i_k,j_k)$.

当$(i_0,j_0)=(0,0)$，$(i_f,j_f)=(I,J)$时，认为路径是完整的。

6.2 基于最优路径搜索技术的度量

- 两个序列间的“距离”定义为所有可能**路径上的最小D值**。同时，最小代价路径揭示了两个序的元素之间的最优对应关系，由于两个序列的长度不同，因此这种对应关系很重要。换句话说最优路径过程会使得测试字符串中的各个元素与参考字符串中的各个元素对齐，此时对应于一个好的匹配分数。
- 我们可能不会强加必须具有一条完整路径的约束，而采用更松散的约束——端点约束。此外，我们不仅可以让每个节点关联一个代价，而且可以让节点之间的每个过渡关联一个代价，使得某些过渡代价更大。在这些情形下，节点(i_k, j_k)的代价还取决于从节点(i_{k-1}, j_{k-1})到达节点(i_k, j_k)的过渡。因此，代价d现在变为$d(i_k, j_k | i_{k-1}, j_{k-1})$，总路径代价是

$$D = \sum_k d(i_k, j_k | i_{k-1}, j_{k-1})$$

在一些情况下，总路径代价定义为 $D = \prod_k d(i_k, j_k | i_{k-1}, j_{k-1})$

6.2.1贝尔曼最优性原理

- 在有些情形下，选择d是使得代价最大而不是使得代价最小。显然，在所有这些方法中必须采用合适的初始条件。现在回到优化问题本身。为了得到最好的路径，必须搜索所有可能的路径，但这样做的计算开销很大。基于**贝尔曼最优性原理**的动态规划算法，是可以降低计算复杂性的强大工具。
- 假设从初始节点(i_0, j_0)到最终节点(i_f, j_f)的最优路径为

$$(i_0, j_0) \overset{\text{opt}}{\rightarrow} (i_f, j_f)$$

- 当(i, j)是初始节点(i_0, j_0)和最终节点(i_f, j_f)之间的节点时，我们将过点(i, j)的最优路径表示为

$$(i_0, j_0) \overset{\text{opt}}{\underset{(i,j)}{\rightarrow}} (i_f, j_f)$$

6.2.1贝尔曼最优性原理

- 贝尔曼最优性原理说

$$(i_0, j_0) \overset{\text{opt}}{\underset{(i,j)}{\rightarrow}} (i_f, j_f) = (i_0, j_0) \overset{\text{opt}}{\rightarrow} (i, j) \oplus (i, j) \overset{\text{opt}}{\rightarrow} (i_f, j_f)$$

式中，$\oplus$表示路径的级联。换句话说，过(i, j)的从(i_0, j_0)到(i_f, j_f)的最优路径是从(i_0, j_0)到(i, j)的最优路径与从(i, j)到(i_f, j_f)的最优路径的级联。

这个原理的推论是：一旦经由最优路径到达节点(i, j)，为了最优地到达节点(i_f, j_f)，就只需要搜索从(i, j)到(i_f, j_f)的最优路径。

6.2.1贝尔曼最优性原理

- 假设我们已经离开(i_0, j_0)，并且第k个节点是(i_k, j_k)。我们的目的是计算到达第k个节点的最小代价。要过渡到(i_k, j_k)，就要从路径上的第$k-1$个节点(i_{k-1}, j_{k-1})开始。假设网格中的每个节点都有一组定义局部约束的前序节点。由贝尔曼最优性原理可得

$$D_{min}(i_k, j_k) = \min_{i_{k-1}, j_{k-1}} [D_{min}(i_{k-1}, j_{k-1}) + d(i_k, j_k | i_{k-1}, j_{k-1})]$$

事实上，到达节点(i_k, j_k)的总最小代价，是到达节点(i_{k-1}, j_{k-1})的最小代价与从节点(i_{k-1}, j_{k-1})过渡到节点(i_k, j_k)的代价之和。

6.3 基于相关的度量

- 已知一段录制的数据，确定某个已知(参考)模式是否包含于其中及它在数据段中的位置。典型的此类应用是场景分析，即在一幅图像内搜索特定的目标。这类问题会出现在许多应用中，如目标检测、机器人视觉和视频编码。例如，在视频编码中，一个主要的步骤是运动估计——在连续的图像帧中找到对应像素的过程，然后进入运动补偿阶段，以便补偿目标从一帧运动到另一帧的位移。再后，对帧差进行编码：

$$e(i,j,t) = r(i,j,t) - r(i-m, j-n, t-1)$$

式中，$r(i,j,t)$是图像帧于时刻t的像素灰度级，$r(i-m,j-n,t-1)$是前一帧于时刻$t-1$在空间位置$i-m, j-n$的对应像素值。

6.3 基于相关的度量

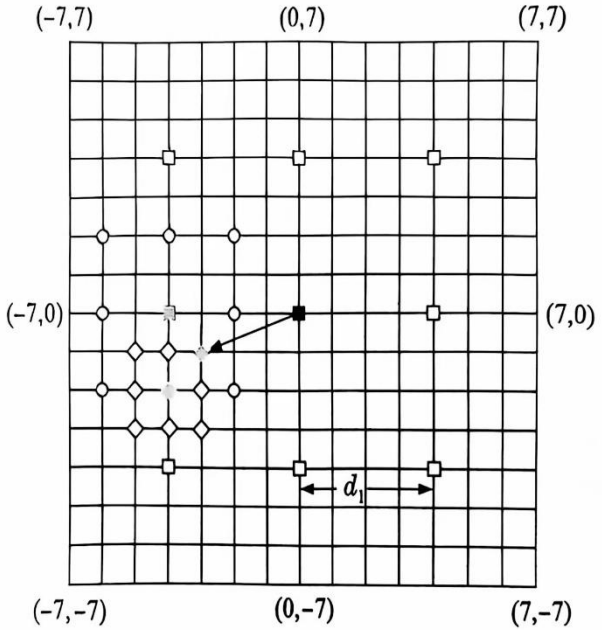
- 假设有一个已知的参考模式，记为一个$M \times N$图像数组$r(i,j), i = 0, \cdots, M-1, j = 0, \cdots, N-1.$
- 有一个测试模式，记为一个$I \times J$图像数组$t(i,j), i = 0, \cdots, I-1, j = 0, \cdots, J-1.$ 其中，$M \leq I, N \leq J$。
- 我们的目的是找到一个度量，在$t(i,j)$内检测与参考模式$r(i,j)$最优匹配的一幅 $M \times N$ 子图像。为此，将参考图像 $r(i,j)$ 叠加到测试图像上，并将参考图像平移到测试图像内的所有位置(m,n) 。对于每个点(m,n)，根据下式计算$r(i,j)$和$t(i,j)$的$M \times N$子图像之间的失配：

$$D(m,n) = \sum_{i=m}^{m+M-1} \sum_{j=n}^{n+N-1} |t(i,j) - r(i-m, j-n)|^2$$

模板匹配就是搜索$D(m,n)$最小的位置(m,n)。

6.3 基于相关的度量

- 计算方面的考虑
  - 通过傅里叶变换使计算更高效
  - 采用次优的启发式搜索技术，降低运算量
- 二维对数搜索
  - 二维对数搜索通过多层次逐步逼近的方法，在降低计算复杂度的同时，实现目标区域的快速搜索定位。这种方法适合需要实时处理的场景
- 分层搜索
- 顺序搜索方法



6.3 基于相关的度量

- 分层搜索
  - 通过多分辨率方法减少了每次搜索的候选点数量，节省计算资源
  - 分层搜索大幅降低了角度空间和模板匹配计算的复杂度
  - 但局限性是，如果低分辨率图像无法正确捕获目标的全局特性，可能陷入局部最优解

- 顺序搜索方法
  - 通过对不好的位置只需少量计算，达到节省计算量的目的

6.4 可变形模板模型

可变形模板模型，即在模板匹配的过程中，**允许参考模板和图像中的对应测试模式之间存在偏差**。

- 在讨论过程中，我们假设参考模板的形式是图像阵列，其中包含了目标的边界信息(轮廓)。也就是说，我们只关注形状信息，扩展到包含更多的信息(如纹理)也是可行的

于是，我们可以计算最优向量参数，使其满足：

$$\xi: min_{\xi}\{E_m(\xi) + CE_d(\xi)\}$$

其中，对原型形状的改变越大，为其花费的能量就越多。记为$E_m(\xi)$的这个参量，取决于原型的形状，称其为内部能量。记为$E_d(\xi)$的能量依赖于输人数据(测试图像)，我们通常称其为外部能量，C为权重因子

目前，对参数的确定有两种主要方法，**梯度下降法和遗传算法**

6.5 基于内容的信息检索：相关反馈

相关反馈，起源于信息检索系统领域，其思路是将给定查询最先返回的结果，和这些结果是否与新查询是否相关的信息利用起来。区别三种类型的反馈将很有意义：**显式反馈**、**隐式反馈**和**盲式或伪反馈**。

显示反馈

显式反馈是从相关性评估者那里获取的，这里的相关性表示检索文档与查询的相关程度。只有当评估者（或系统的其他用户）清楚所提供的反馈是被解释为**相关性**判断依据时，这种类型的反馈才能称为是显式的。

用户可能将相关性用二元或分级的相关机制来显式表示。二元相关反馈表示文档相对于给定的查询要么相关，要么不相关。而分级的相关反馈则使用数字、字母或其它描述（如“不相关”，“一点相关”，“相关”，或“很相关”）来表示文档与查询的相关程度。当评估者将结果中的文档按照相关性排序（通常时降序）时，分级的相关反馈也需要使用这种由评估者创建的文档序号形式，**Google在搜索网站中实现的SearchWiki就是这样一个例子。**

相关反馈信息需要结合原始查询才能提高检索性能，如著名的Rocchio算法。

隐式反馈

隐式反馈是从用户行为中推断出来的，这些行为比如观察用户选择**查看或不查看哪些文档**，查看文档所持续的**时间**，或者浏览页面、卷动滚动条**操作**（页面存档备份，存于互联网档案馆）。

隐式反馈与显式反馈最主要的区别包括：

1.用户并不需要为了考虑FR系统需要而去评估相关性，而只关注自己的需要能否满足即可；

2.并不需要告知用户他们的行为会被用于相关反馈。

其中的一个例子是Surf Canyon浏览器扩展，基于用户交互（点击图标）和搜索结果链接页面上的时间花费，来提前从结果集中的后续页面中搜索结果。

伪相关反馈

伪相关反馈，也称之为盲式相关反馈，提供的是一种**自动局部分析方法**，它可以自动化相关反馈的手动操作部分，因此用户可不用参与额外的交互也可以获得更好的检索性能。这种方法首先通过普通检索从最相关的文档中寻找到一个初始结果，然后假定其中的前"k"排名文档是相关的，最后在这个假设条件下像前面一样进行相关反馈。过程步骤如下：

1.把初始查询返回的结果当成相关结果（在大多数实验中仅前k个，k位于10和50之间的数）

2.使用如TF-IDF权重的方法从这些文档中选择前20-30个词语

3.执行查询扩展，将这些词语加入到查询中，然后再去匹配查询所返回的文档，最终返回最相关的文档