模式识别
——模式识别与机器学习

刘文黎

liu_wenli@hust.edu.cn

土木与水利工程学院

第7章 上下文相关分类与监督学习尾声

本章主要内容

7.1 引言

7.2 贝叶斯分类器

7.3 马尔可夫链模型

7.4 Viterbi算法

7.5 信道均衡

7.6 隐马尔可夫模型

7.7 基于状态持续时间建模的HHM

7.8 使用神经网络训练的马尔可夫模型

7.9 马尔可夫随机场的讨论

7.10 在贝叶斯网络上的条件独立性

7.11 贝叶斯网络模型的学习

7.12 监督学习尾声

7.13 讨论

7.1 引言

- 连续的特征向量不是独立的，特征向量所属的类别依赖于：
  - 它本身的值
  - 其他特征向量的值
  - 各个类别之间的关系

如果 $p(w_i|x) > p(w_j|x), \forall j \neq i$，那么将一个特征向量赋给类别$w_i$

7.2 贝叶斯分类器

朴素贝叶斯分类器

- 假设各个特征取值只依赖类别标签，特征间互相独立

$$p(x_l x_k|\omega_i) = \mathrm{p}(x_l|\omega_i)\mathrm{p}(x_k|\omega_i), \qquad l,k = 1,\cdots,d, k \neq l$$

- 联合概率可以分解

$$p(x_1, x_2, \cdots, x_d, \omega_i) = p(x_1|\omega_i)p(x_2|\omega_i)\cdots p(x_d|\omega_i)p(\omega_i)$$

- 各类别先验概率的估计

$$p(Y = \omega_{\mathrm{i}}) = \frac{\sum_{i=1}^{N} I(y_i = \omega_i)}{N}$$

- 参数的极大似然估计

$$p(x_j = v_i|Y = \omega_i) = \frac{\sum_{i=1}^{N} I(x_j^{(i)} = v_i, y_i = \omega_i)}{\sum_{i=1}^{N} I(y_i = \omega_i)}$$

- 拉普拉斯平滑：对概率值平滑矫正

$$p(Y = \omega_i) = \frac{\sum_{i=1}^{N} I(y_i = \omega_i) + 1}{N + C}$$

$$p(x_j = v_i|Y = \omega_i) = \frac{\sum_{i=1}^{N} I(x_j^{(i)} = v_i,\ y_i = \omega_i) + 1}{\sum_{i=1}^{N} I(y_i = \omega_i) + S}$$

- 连续取值的变量特征：采用正态分布、均匀分布等模型

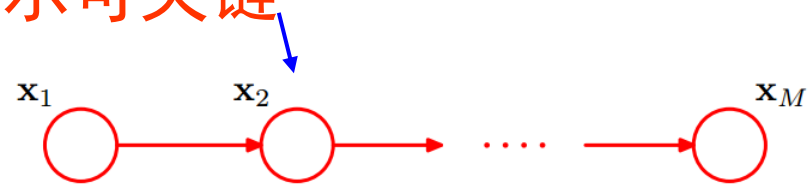
7.3 马尔科夫链模型

马尔可夫过程与马尔可夫链

设$x(t)$是一随机过程，过程在时刻$t0$所处的状态与时刻$t0$所处的状态相关，而与过程在时刻$t0$之前的状态无关，这个特性成为无后效性. 无后效的随机过程称为马尔可夫过程(Markov Process).

马尔可夫过程中的时间和状态既可以是连续的，又可以是离散的. 我们称时间离散、状态离散的马尔可夫过程为马尔可夫链

$$p(x_1, x_2, \ldots, x_d) = p(x_1) \prod_{t=1}^{d} p(x_t | x_{t-1})$$



7.4 Viterbi算法

- 维特比（Viterbi）算法
  - 递推计算在每一时刻各条部分路径的最大概率

$$v_t(j) = \max_{q_1 \cdots q_{t-1}} p(q_1 \cdots q_{t-1}, o_1 \cdots o_t, x_t = q_j | M)$$

  - 根据递推关系

$$v_t(j) = \max_{i=1:n} v_{t-1}(i) a_{ij} e_j(o_t)$$

$$pa_t(j) = \operatorname{argmax}_{i=1:n} v_{t-1}(i) a_{ij} e_j(o_t)$$

  - 记录最大值对应的隐状态路径
  - Viterbi 算法也是类似于前向算法的一种网格结构

- 维特比算法具体流程
  - 定义初值$v_1(j) = e_j(o_1)\pi_j, pa_1(j) = 0, j = 1,2,\cdots,n$
  - 迭代求解$j = 1{:}n, t = 1,2,\cdots,L$:

$$v_t(j) = \max_{i=1:n} v_{t-1}(i)a_{ij}e_j(o_t)$$

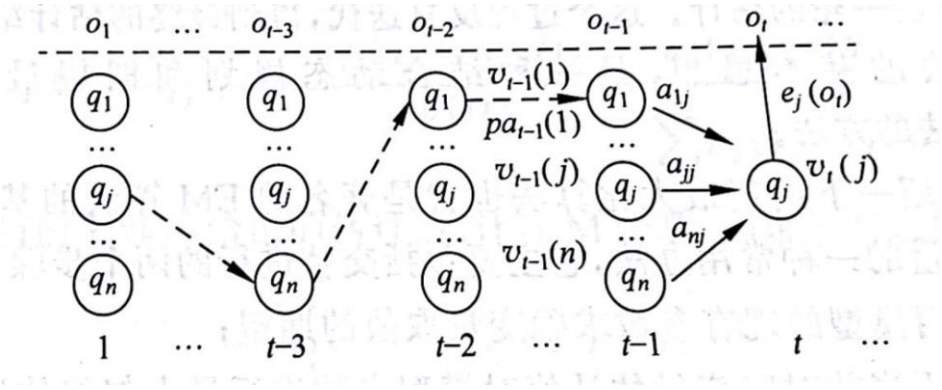
$$pa_t(j) = \operatorname{argmax}_{i=1:n} v_{t-1}(i)a_{ij}e_j(o_t)$$

  - 终止结果：$p^* = \max_{i=1:n} v_L(i);$

$$x_L^* = \operatorname{argmax}_{i=1:n} v_L(i)$$

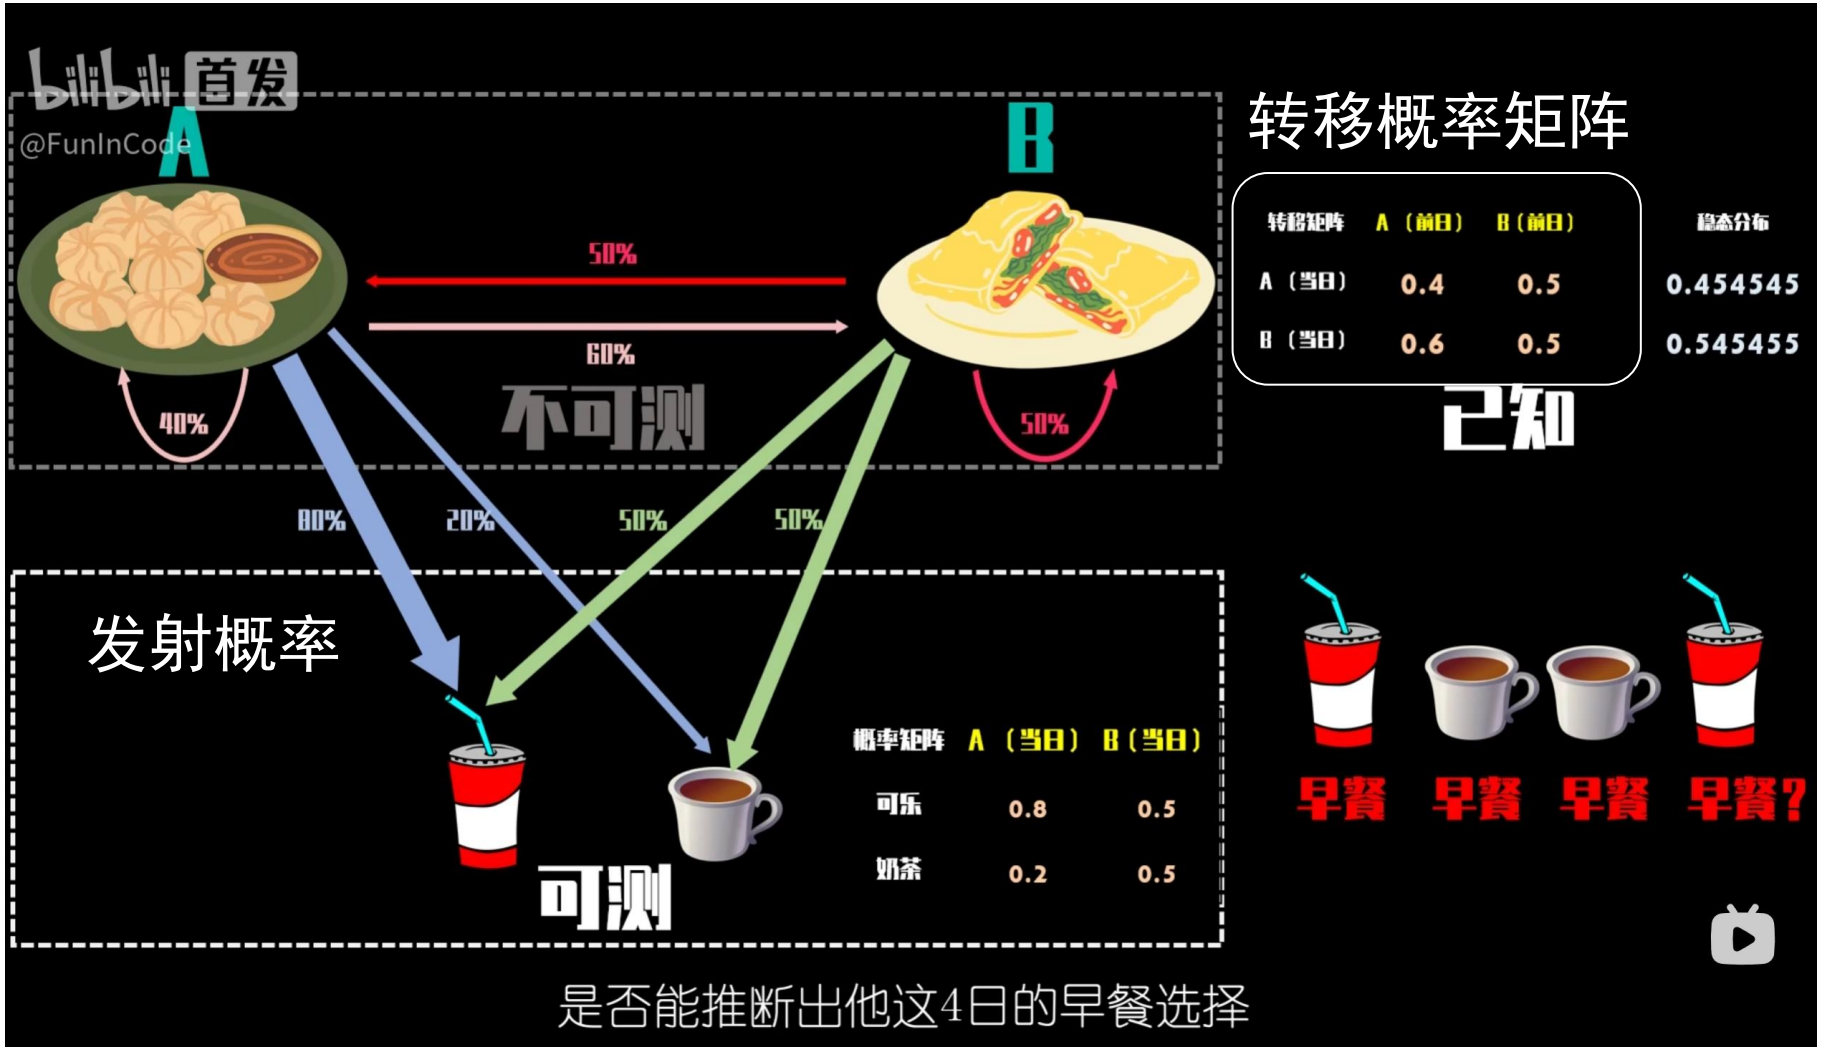
  - 路径回溯：对$t = L-1,\cdots,1,$

$$x_t^* = pa_{t+1}(x_{t+1}^*)$$



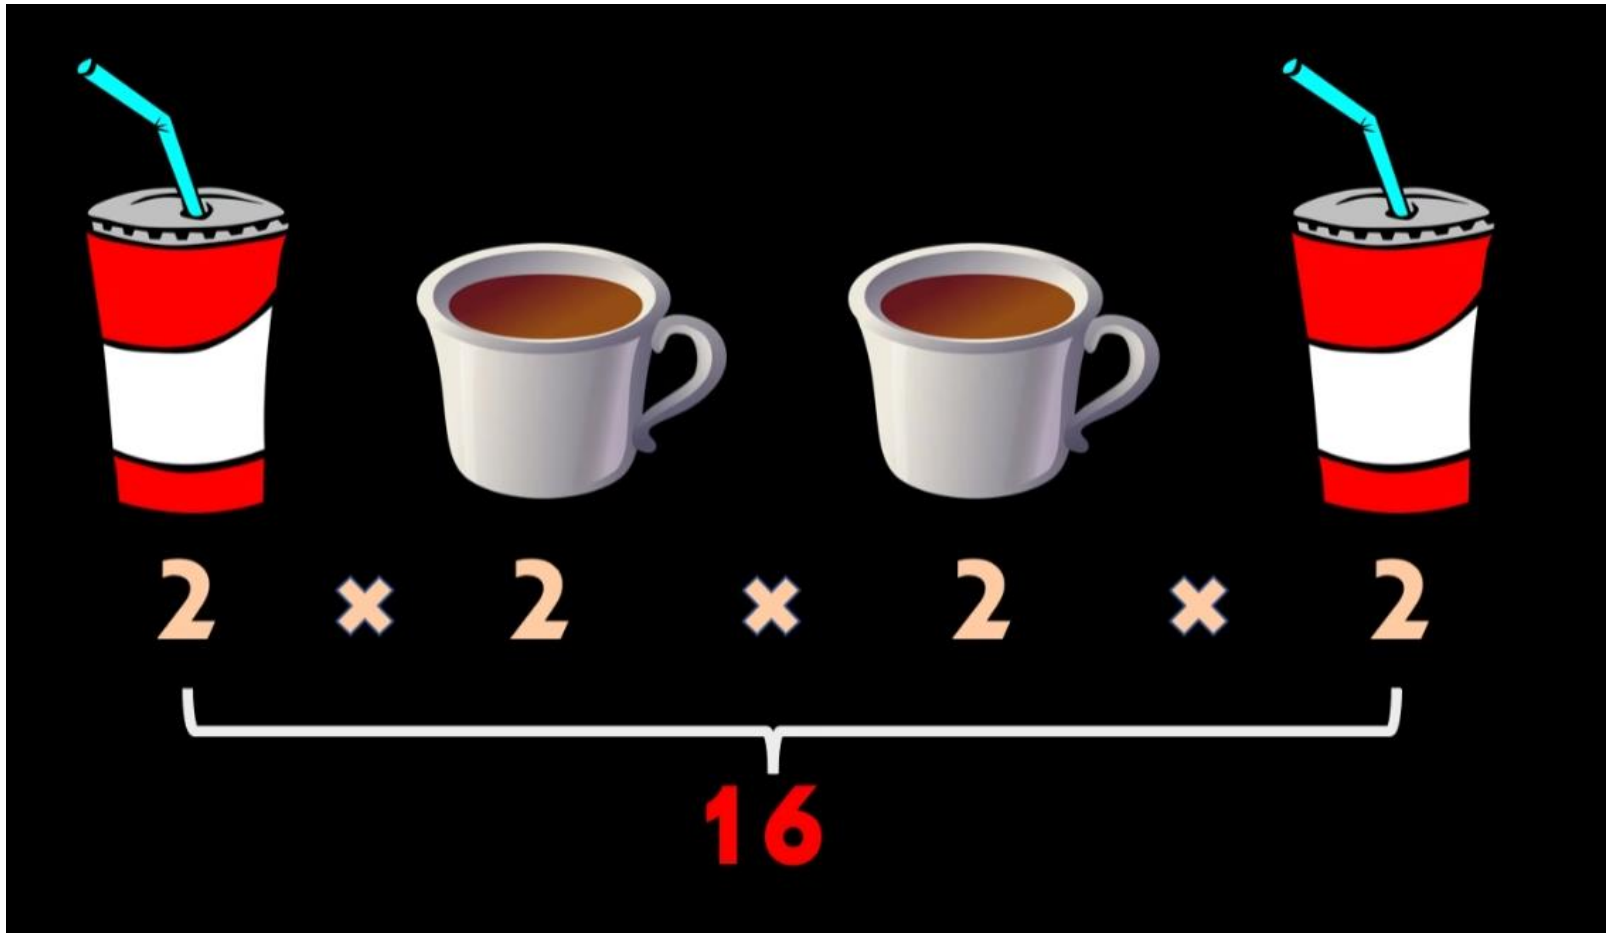
- 维特比算法例子

A为包子，B为煎饼，已知早餐转移概率矩阵和发射概率，小明四天选择的饮料为{可乐，奶茶，奶茶，可乐}，求小明这四天选择的早餐序列？



- 维特比算法例子

  如果使用暴力算法每一种可能的组合都算一遍来选择最优解，就可能面临指数爆炸问题，因此选用维特比算法进行优化处理。



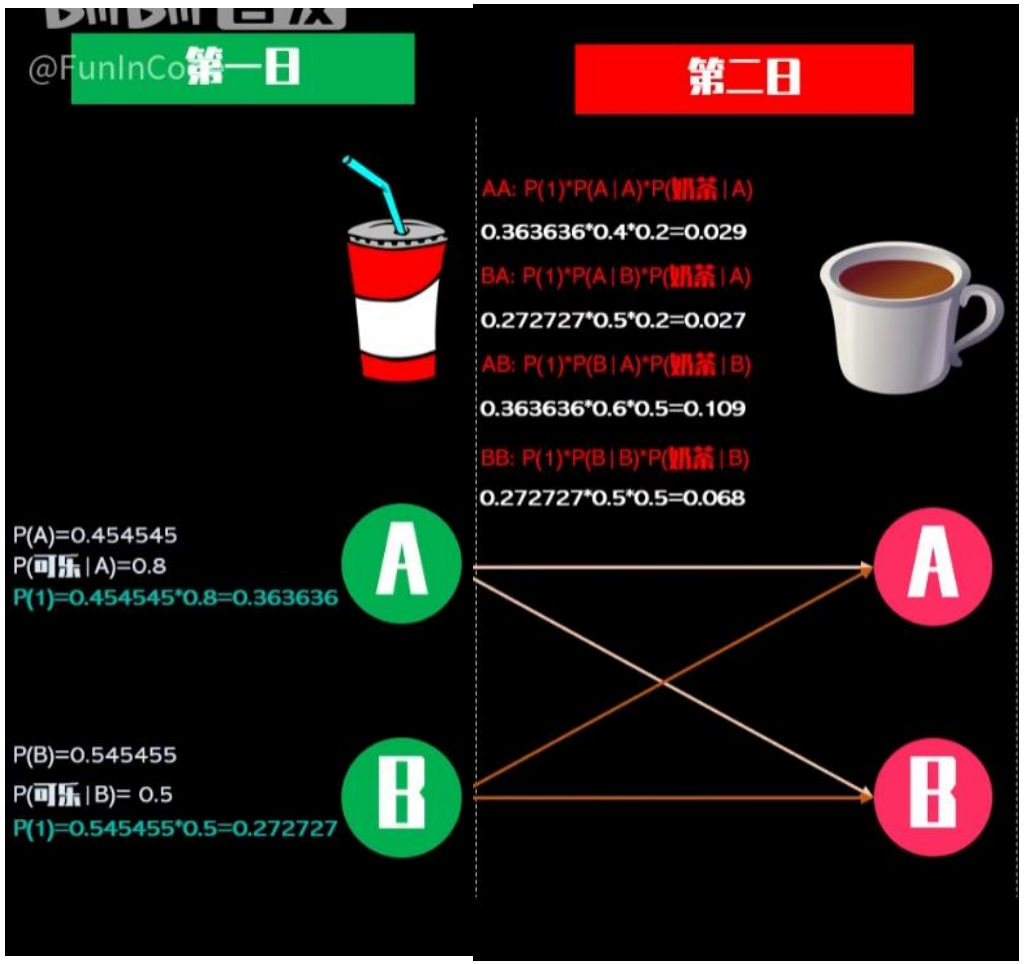
- 维特比算法例子

  第一日：通过稳态×发射概率计算选择早餐A再选可乐和选择早餐B再选可乐的概率



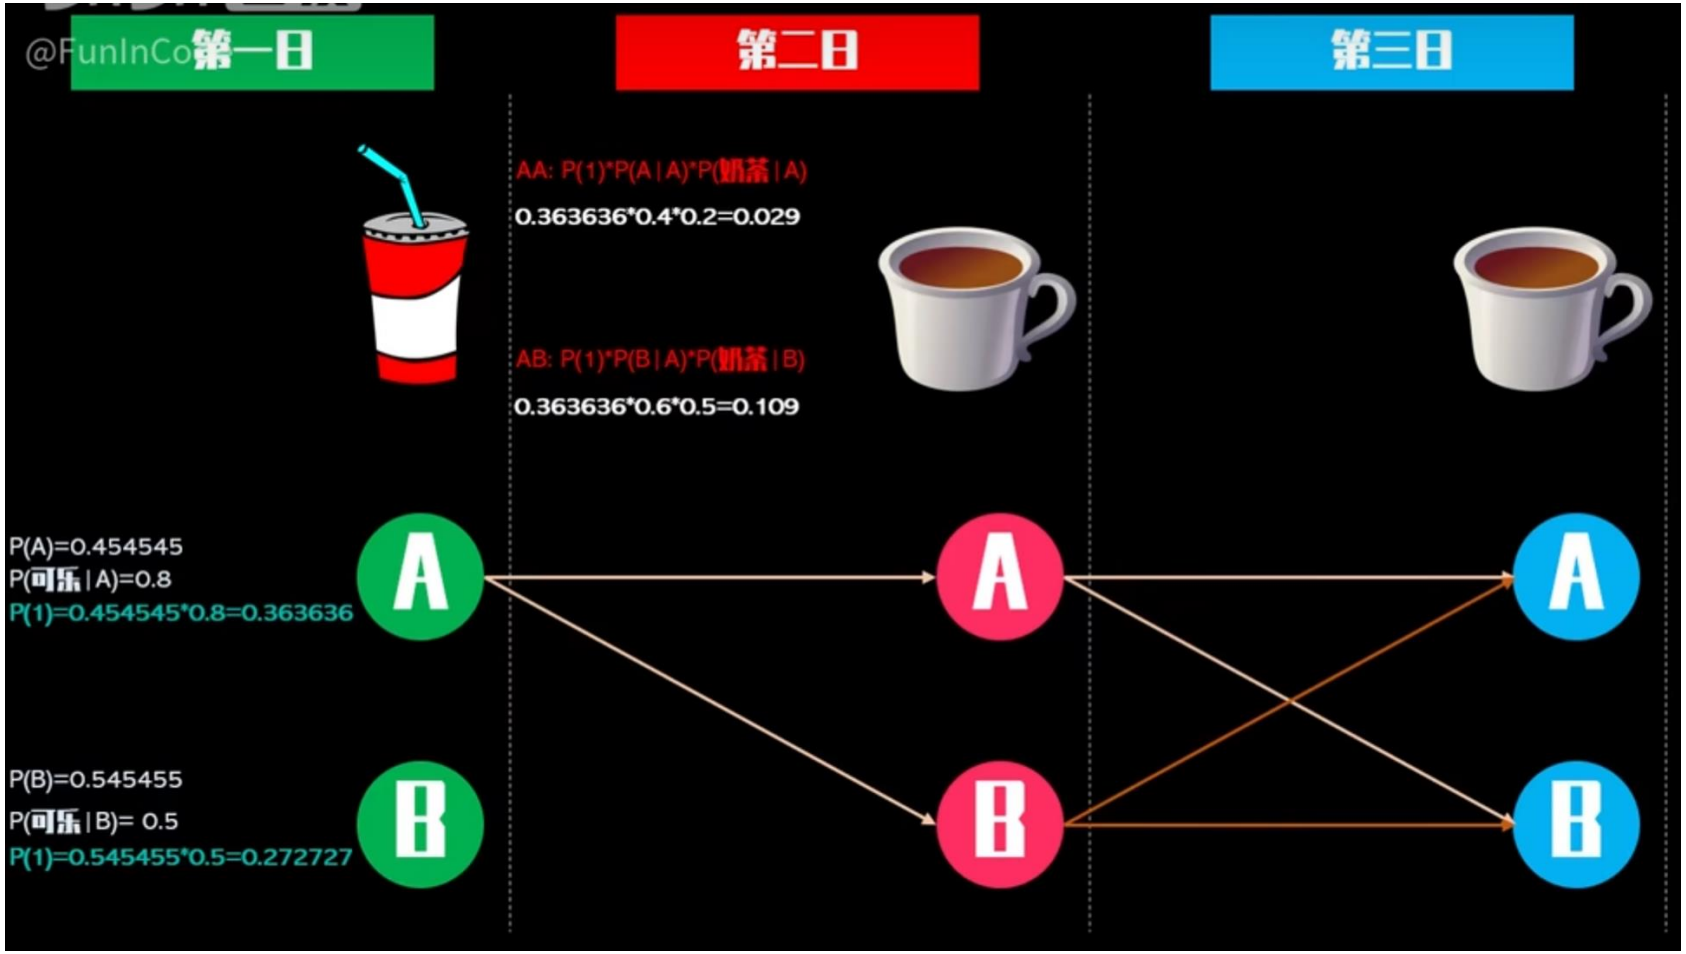
- 维特比算法例子

  第二日：第一日概率结果×转移概率矩阵中的概率值×早餐-饮料条件概率（发射概率），有四条路径，去除两个无效路径



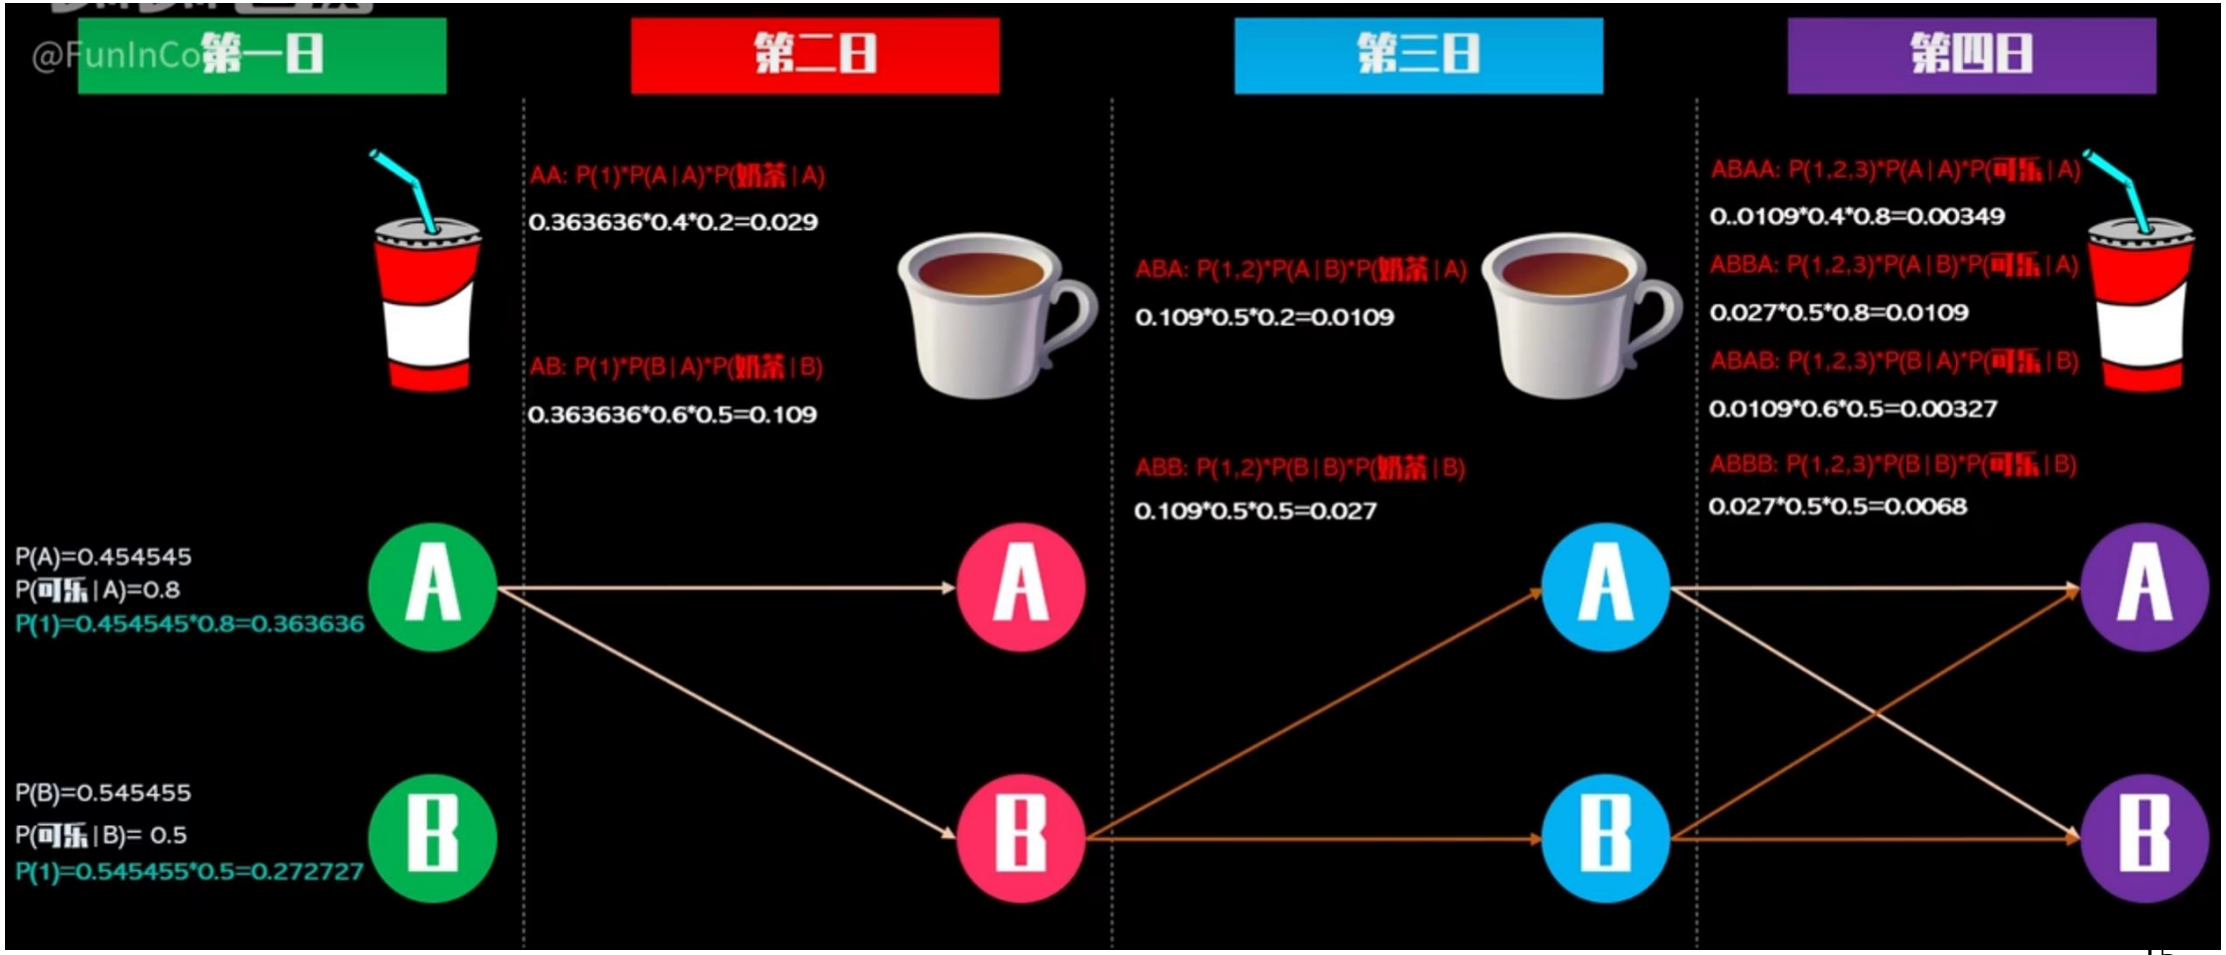
- 维特比算法例子

  第三日：和第二日操作一样



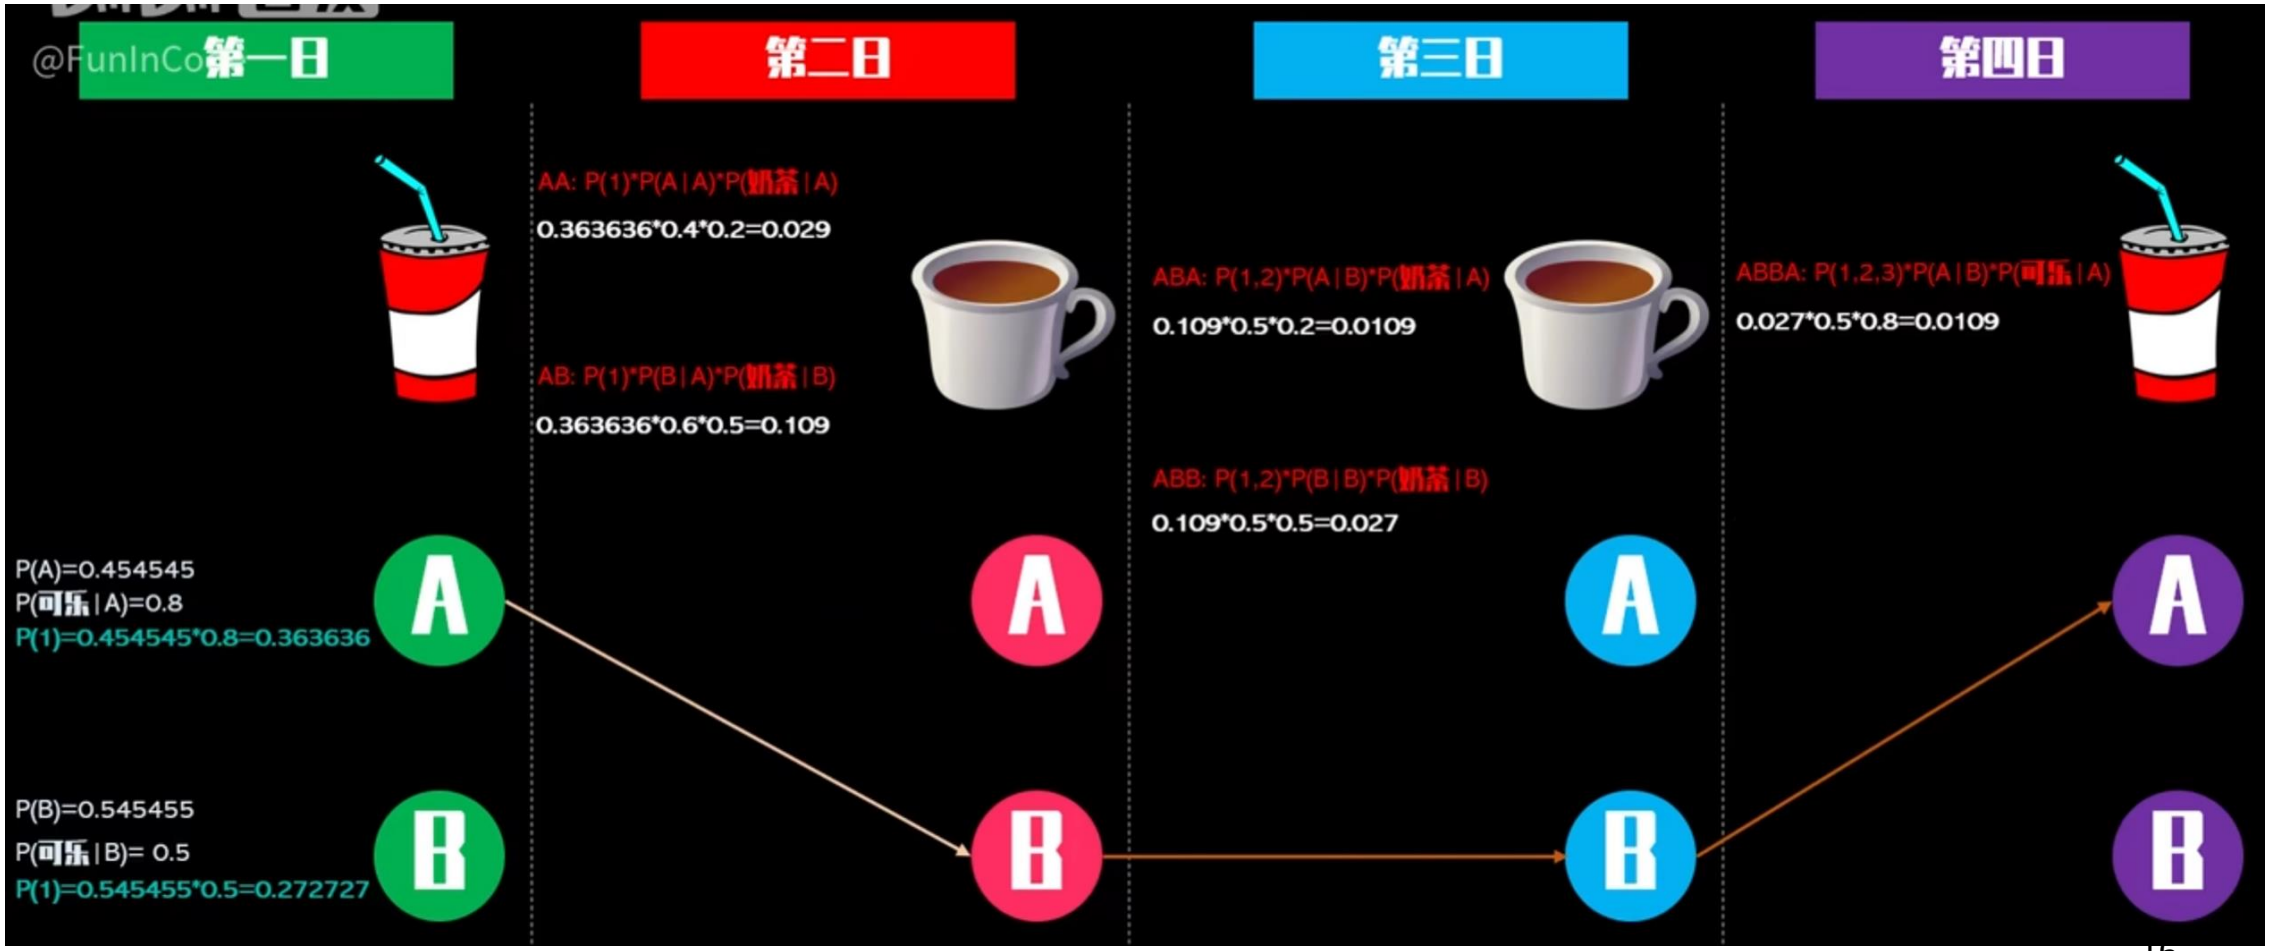
- 维特比算法例子

  第四日：可以得到所有路径概率值最大的路径（最优序列）



- 维特比算法例子

  最终：选择出来的序列为ABBA



7.5 信道均衡

信道均衡的任务是恢复被传输信道和噪声毁坏的信息比特序列I_k（1或0）

接收机端的样本：

$$x_k = f(I_k, I_{k-1}, \cdots, I_{k-n+1}) + \eta_k$$

均衡器：

均衡器是一个逆系统，任务是根据收到的l**个连续样本**$[x_k, x_{k-1}, \cdots, x_{k-n+1}] \equiv x_k^T$**来提供关于已传输信息比特**$I_k$**的决策**$\widehat{I_k}$

马尔可夫模型通常用于描述信道的状态转移（如衰落或噪声干扰的状态），这些状态之间的变化具有一定的规律性和时间相关性。信道均衡技术可以通过对这些状态转移的建模，进行**有效的补偿**。例如，通过马尔可夫过程的状态转移概率，可以预估信道的衰落状态，从而对接收信号进行更精确的补偿，减少误差和干扰

7.6 隐马尔可夫模型（HMM）

对于状态无法直接观测的系统，认为观测值是与**每个状态相关联**的运作的结果，并由一组概率函效来描述。此外，由后续观测值访问的状态序列，本身是另一个随机过程的结果，我们看不到这个随机过程，且描述它的**关联参数只能由收到的观测值集合来推断**，这类马尔可夫模型称为隐马尔可夫模型

概率过程隐藏

隐马尔可夫模型适用前提

- 系统的状态取值服从马尔可夫链
- 系统状态的变化我们无法直接观察到
- 可能的状态和观测是贝叶斯网络的隐节点和可观测节点
- 跳转概率为隐节点之间的边

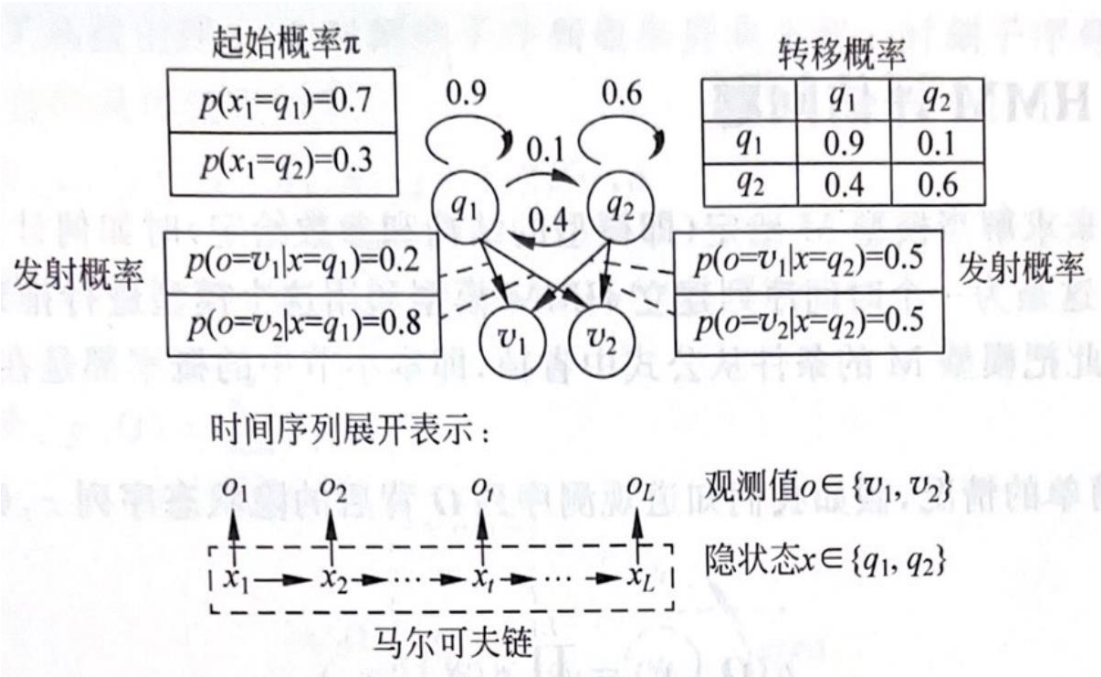
- 模型符号意义

变量表示	说明
$Q=\{q_1,q_2,\cdots,q_n\}$	模型含有n个隐状态
$V=\{v_1,v_2,\cdots,v_V\}$	观测值的取值范围
$\boldsymbol{A}=\left[a_{ij}\right]_{n\times n}$	状态转移概率矩阵，a_{ij}表示从状态i转到状态j的概率，满足$\sum_{j=1}^{n}a_{ij}=1,\forall i$
$\boldsymbol{O}=o_1o_2\cdots o_L$	长度为L的观测序列，o_t的取值为V中某个值
$\boldsymbol{x}=x_1x_2\cdots x_L$	长度为L的隐状态序列，x_t的取值为Q中某个值
$\boldsymbol{E}=\left[e_{ij}\right]_{n\times V}$	发射概率矩阵，$e_{ij}=p(o=v_j\|x=q_i)$表示模型隐状态取值q_i时观测到v_j的概率，满足$\sum_{j=1}^{V}e_{ij}=1,\forall i$
$\boldsymbol{\pi}=[\pi_1,\pi_2,\cdots,\pi_n]$	初始概率分布，π_i表示马氏链从该状态起始的概率，满足$\sum_{i=1}^{n}\pi_i=1$

- 给定观测序列O和隐状态序列$\boldsymbol{x}$的情况下，联合概率为

$$p(\mathbf{x}, O) = \pi_{x_1} e_{x_1}(o_1) \prod_{t=2}^{L} e_{x_t}(o_t) a_{x_t x_{t-1}}$$

- 隐马尔科夫模型的三种典型问题
  - 模型评估问题（Evaluation）
  - 隐状态推断问题（Decoding）
  - 模型学习问题（Learning）



7.6.1 HMM模型评估问题

给定模型M和观测序列O，求在该模型下观测到该序列的概率$p(\boldsymbol{O}|M)$,即计算该序列来自该模型的似然度（likelihood）

给定模型 M的前提下

- 观测序列O背后的隐状态序列$\boldsymbol{x}$（已知），似然度

$$p(O|\mathbf{x}) = \prod_{i=1}^{L} p(o_i|\, x_i)$$

- 观测序列和隐状态序列在模型下的联合概率

$$p(O,\mathbf{x}) = p(O|\mathbf{x})p(\mathbf{x}) = \prod_{i=1}^{L} p(o_i|\, x_i)\left(\pi_{x_1}\prod_{i=2}^{L} p(x_i|\, x_{i-1})\right)$$

在未知隐形状态序列的情况下，穷尽模型M下出现观测序列O的概率，来计算观测序列O来自模型M的似然度

- 概率分解

$$p(O) = \sum_{\mathbf{x}} p(O, \mathbf{x}) = \sum_{\mathbf{x}} p(O, \mathbf{x}) p(\mathbf{x})$$

- 存在的问题问题：
  - 对于n个可能的隐状态、长度为L的序列来说，隐状态序列取值有n^L种组合，计算量巨大会出现指数爆炸

穷举过程，有相当一部分中间概率值重复计算

解决方法——向前算法、向后算法

- 前向算法：
  - 一种动态规划算法
  - 通过不断迭代求解， $\alpha_t(j)$表示对长度为t的观察子序列$o_1 o_2 \ldots o_t$且t时刻隐变量取值为q_j时所对应的概率

$$\alpha_t(j) = p\left(o_1 o_2 \ldots o_t, x_t = q_j\right)$$

$\alpha_t(j)$可以通过截止到$t-1$概率计算

$$\alpha_t(j) = e_j(o_t) \sum_{i=1}^{n} \alpha_{t-1}(i) a_{ij}$$

- 对L时刻所有可能的隐变量取值求和

$$p(O) = \sum_{i=1}^{n} \alpha_L(i)$$

- 后向算法：
  - 一种动态规划算法
  - 采取从后往前的方式

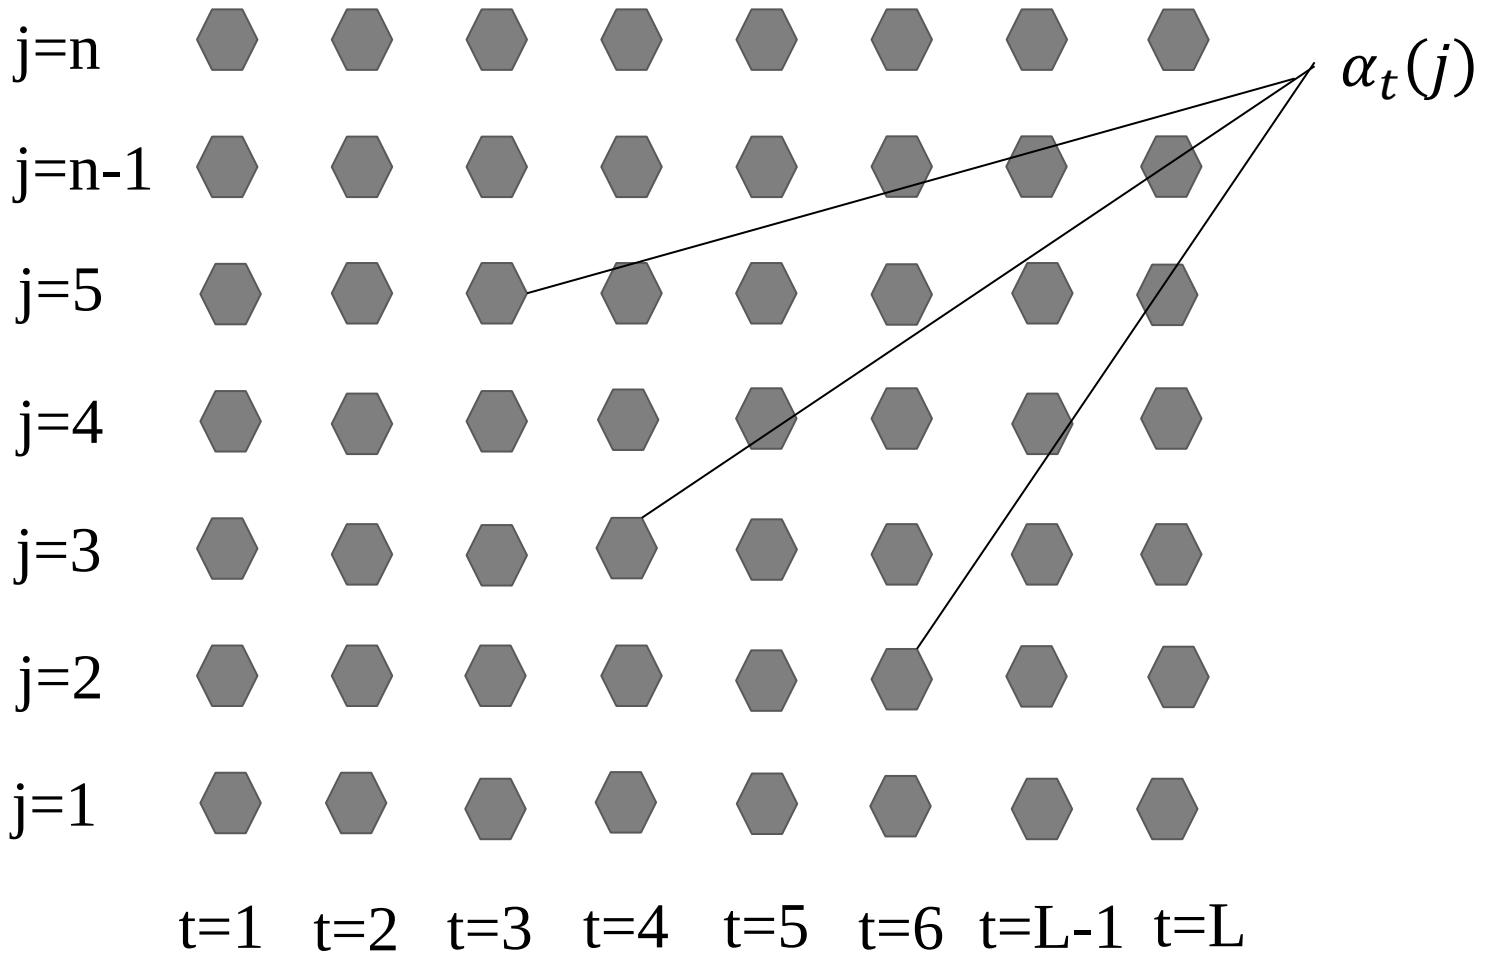
$$\beta_t(j) = p(o_{t+1}o_{t+2}\dots o_L|x_t = q_j)$$

$$\beta_t(j) = \sum_{i=1}^{n} a_{ji}e_i(o_{t+1})\beta_{t+1}(i)$$

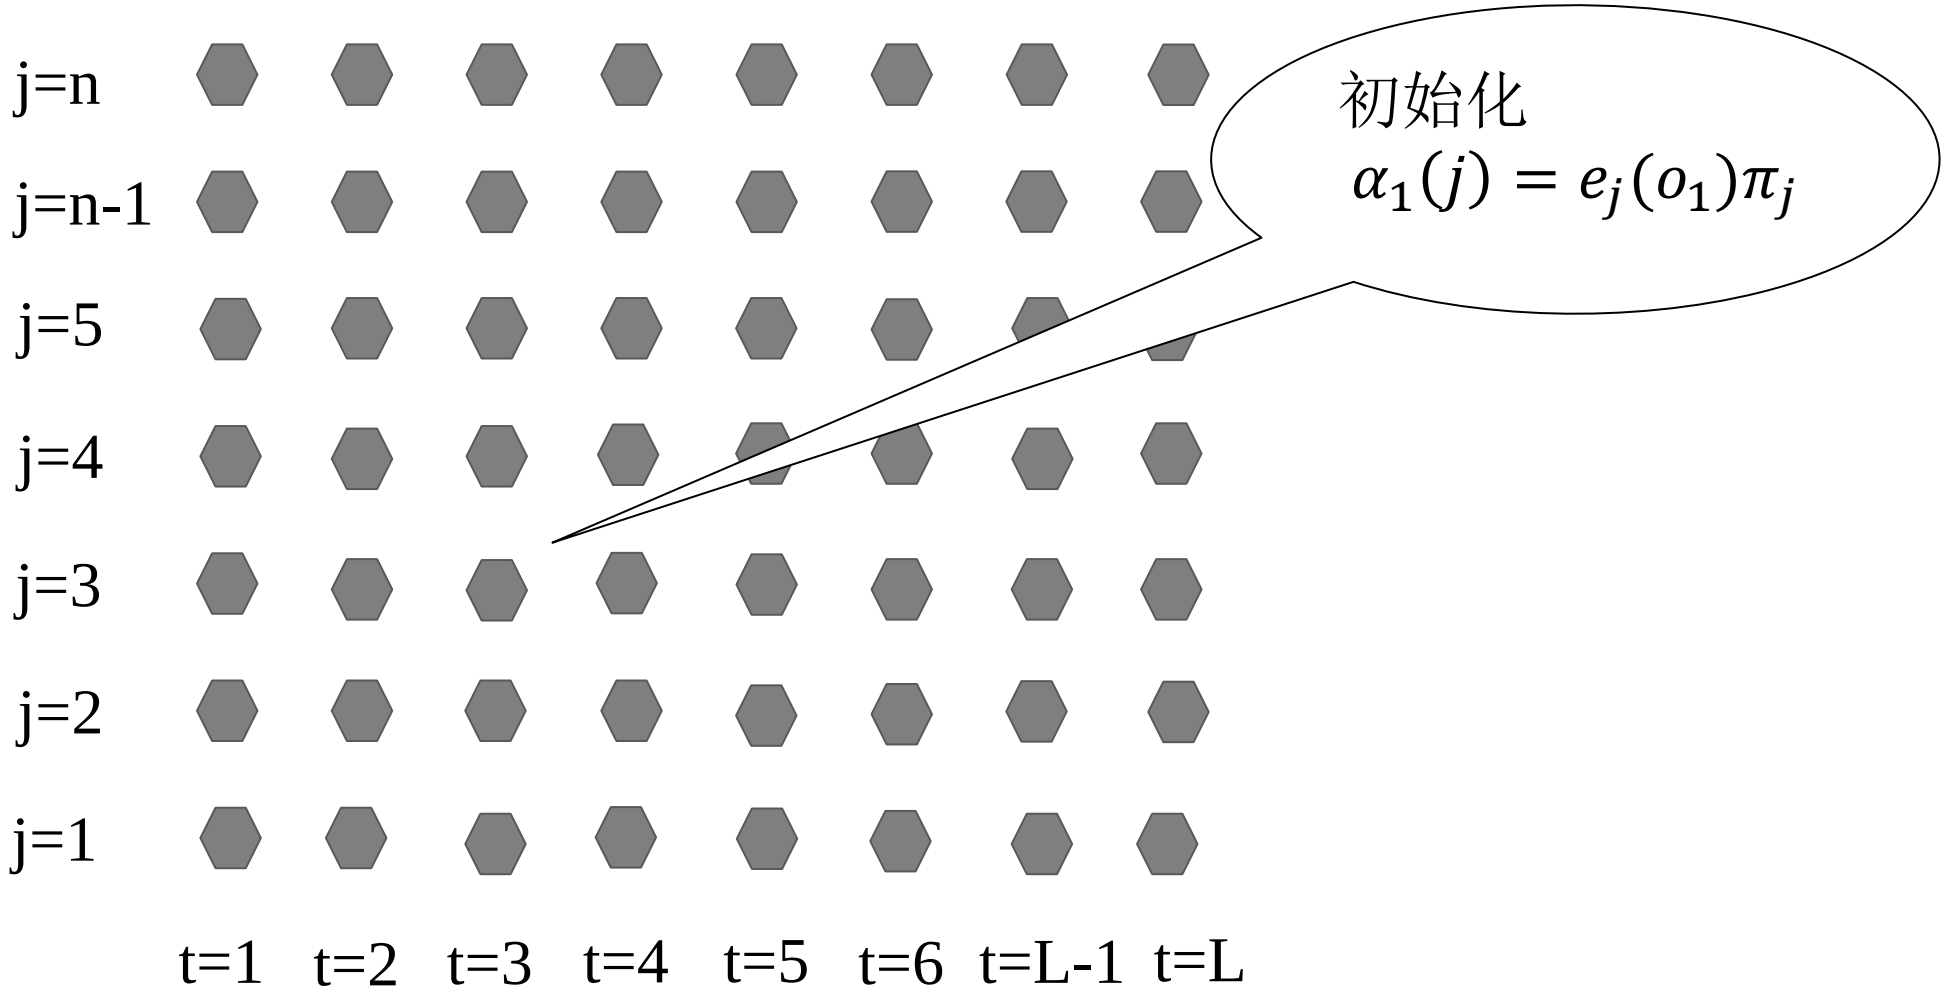
- 将前向算法和后向算法统一

$$P(O|M) = \sum_{i=1}^{n}\sum_{j=1}^{n} \alpha_t(i)a_{ij}e_j(o_{t+1})\beta_{t+1}(j), \qquad t = 1,2,\cdots,L-1$$

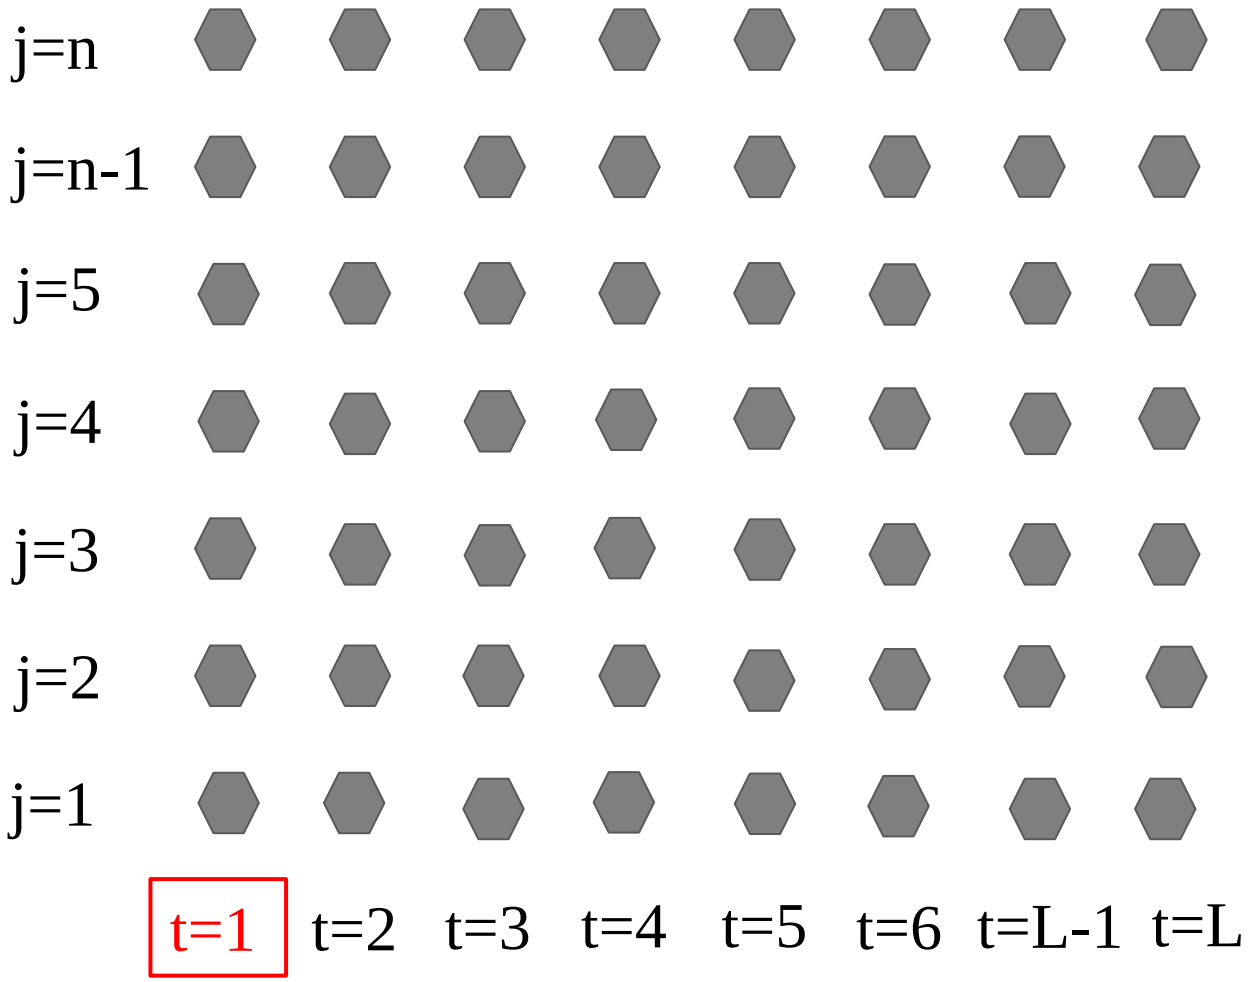
前向算法过程演示



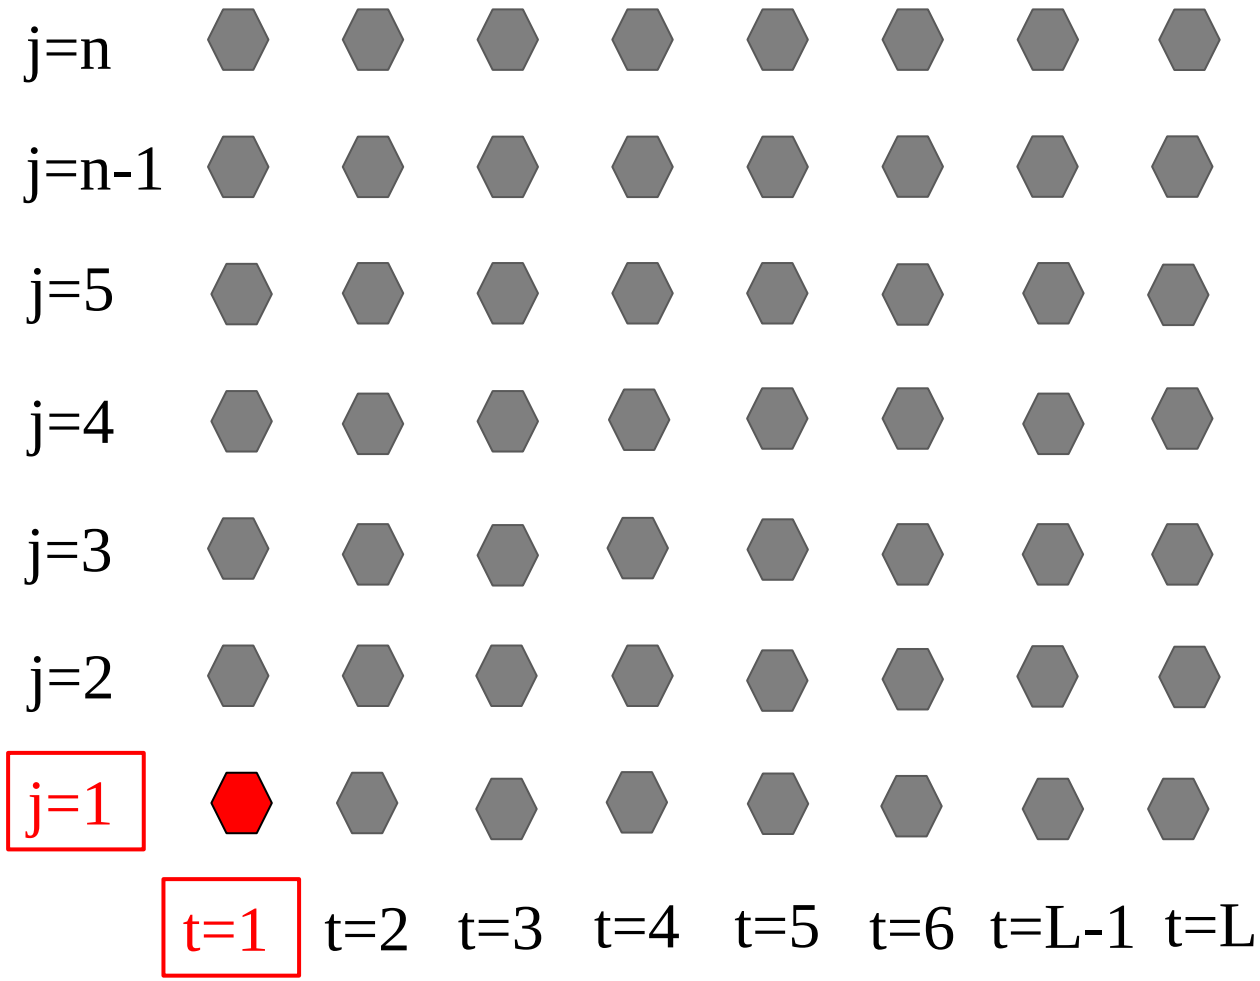
前向算法过程演示



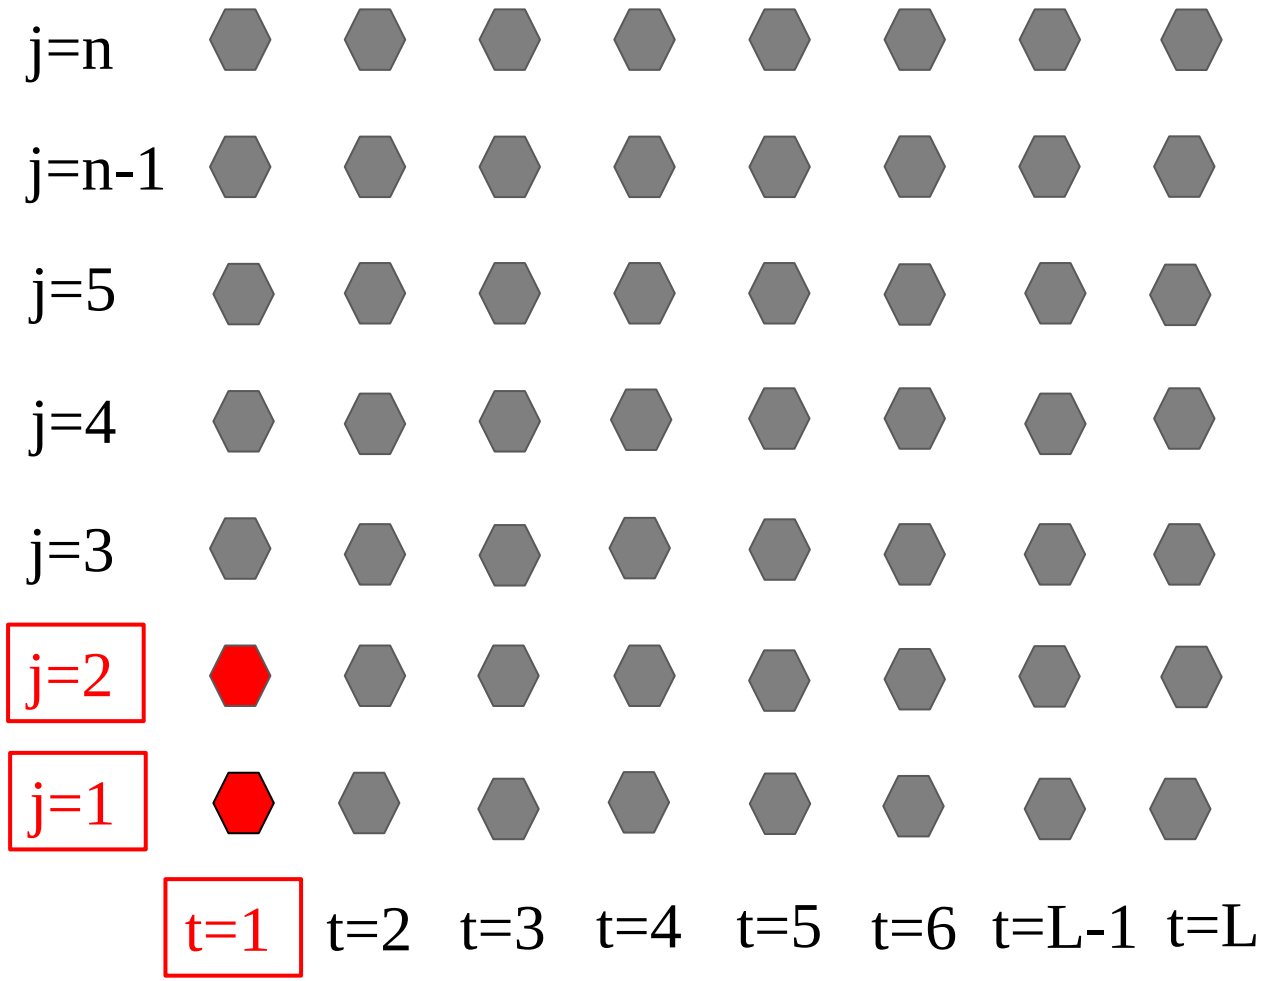
前向算法过程演示



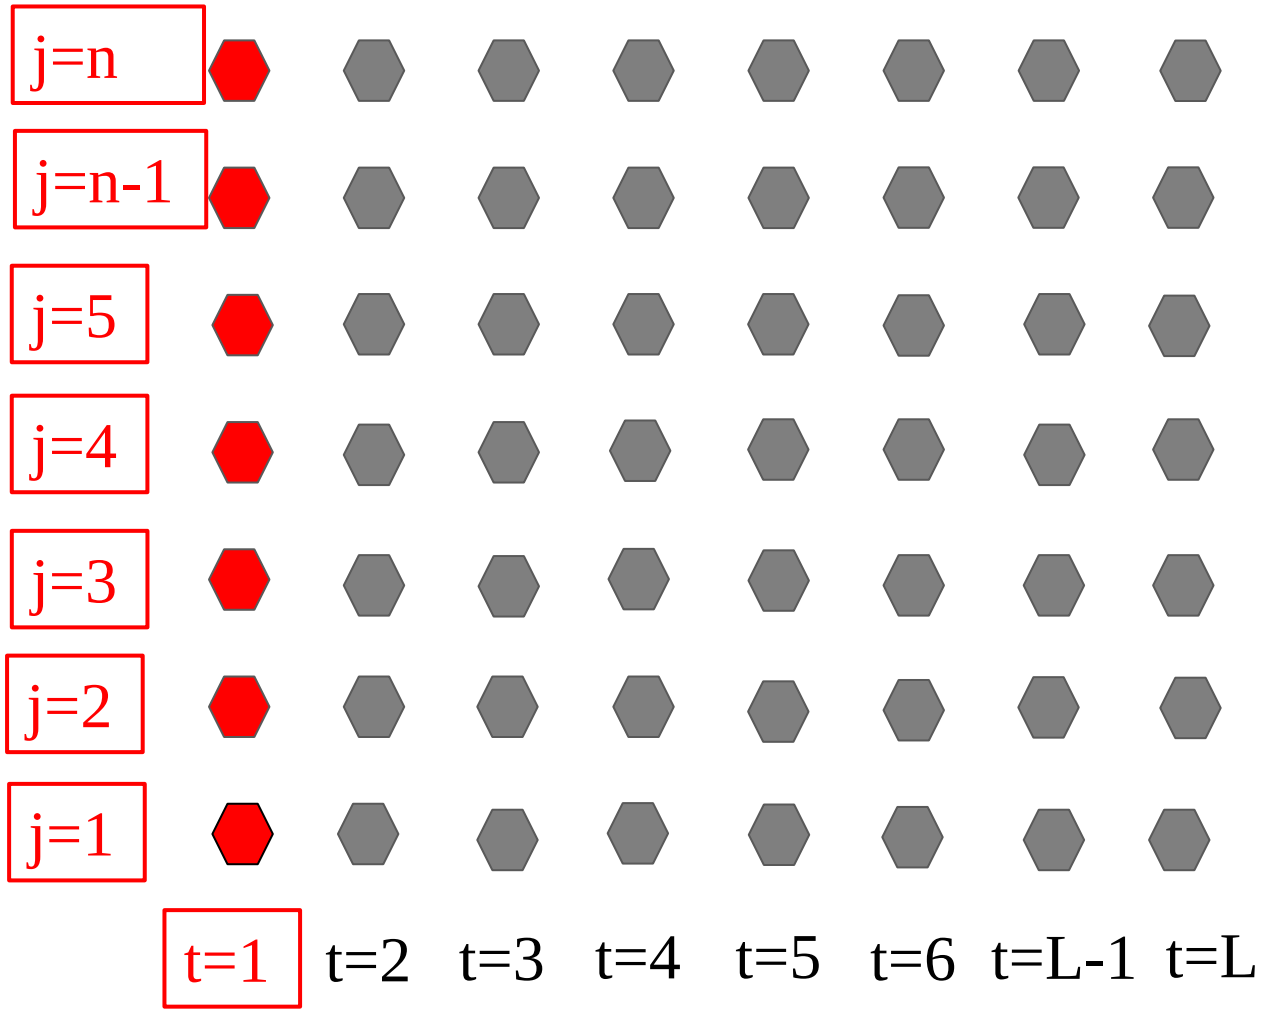
前向算法过程演示



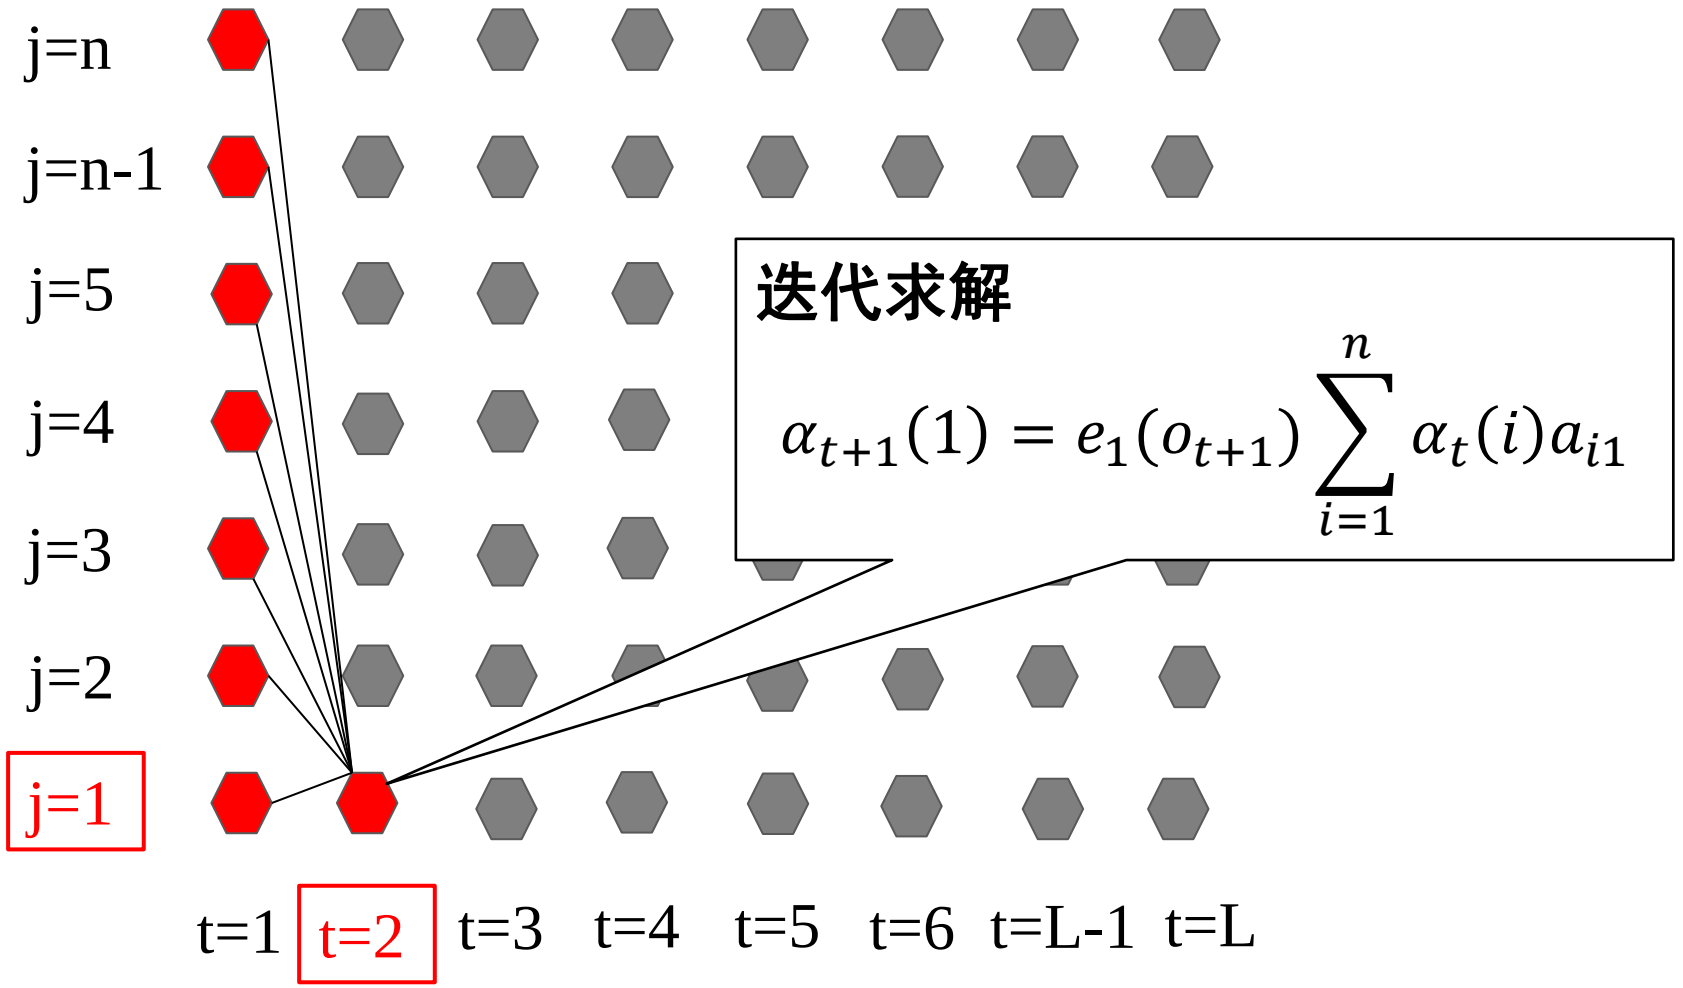
前向算法过程演示



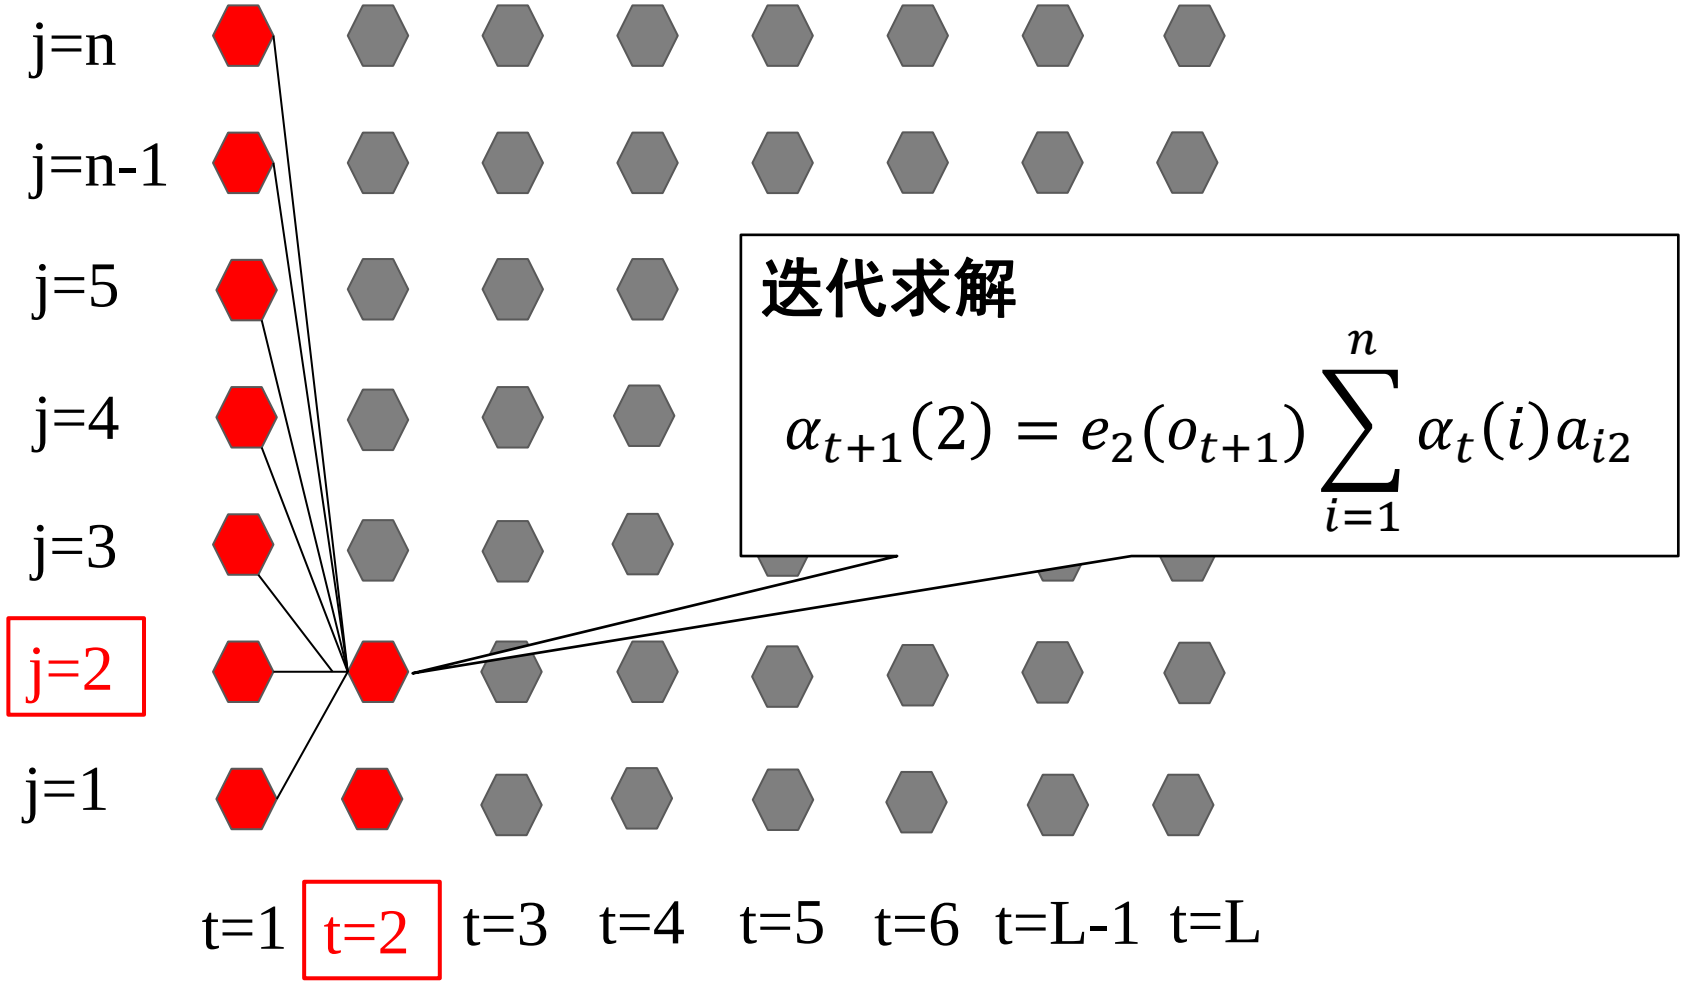
前向算法过程演示



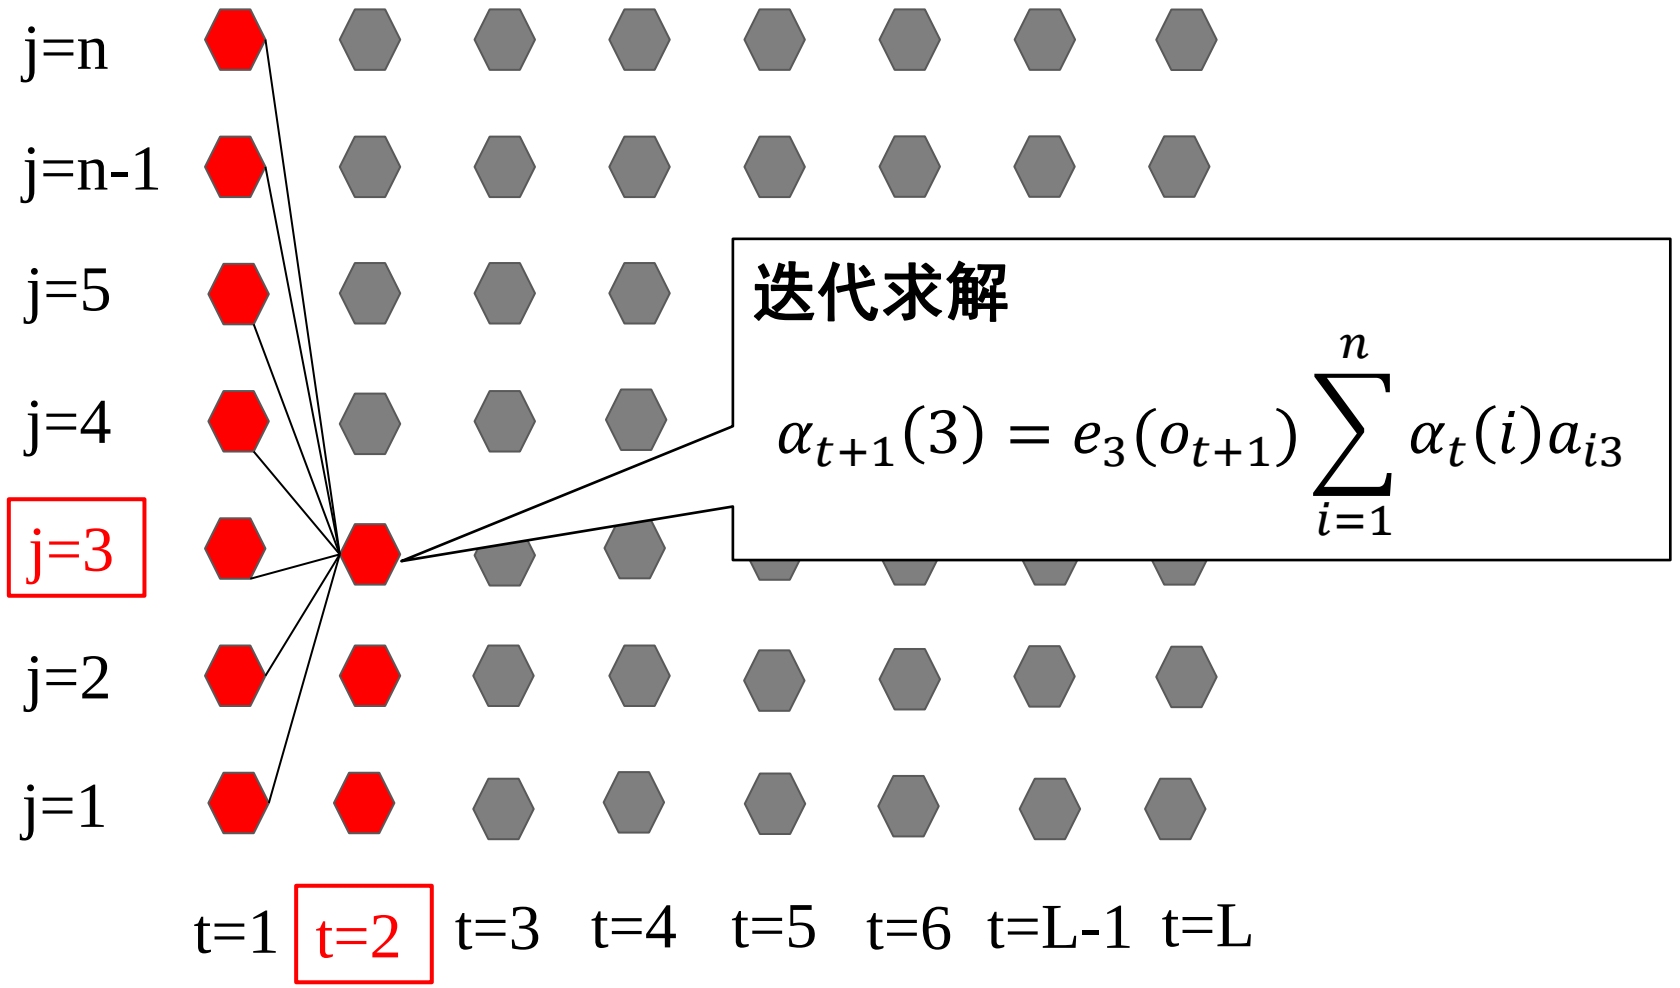
前向算法过程演示


j=n
j=n-1
j=5
j=4
j=3
j=2
j=1
t=1
t=2
t=3
t=4
t=5
t=6
t=L-1
t=L
迭代求解
$\alpha_{t+1}(1) = e_1(o_{t+1}) \sum_{i=1}^{n} \alpha_t(i) a_{i1}$

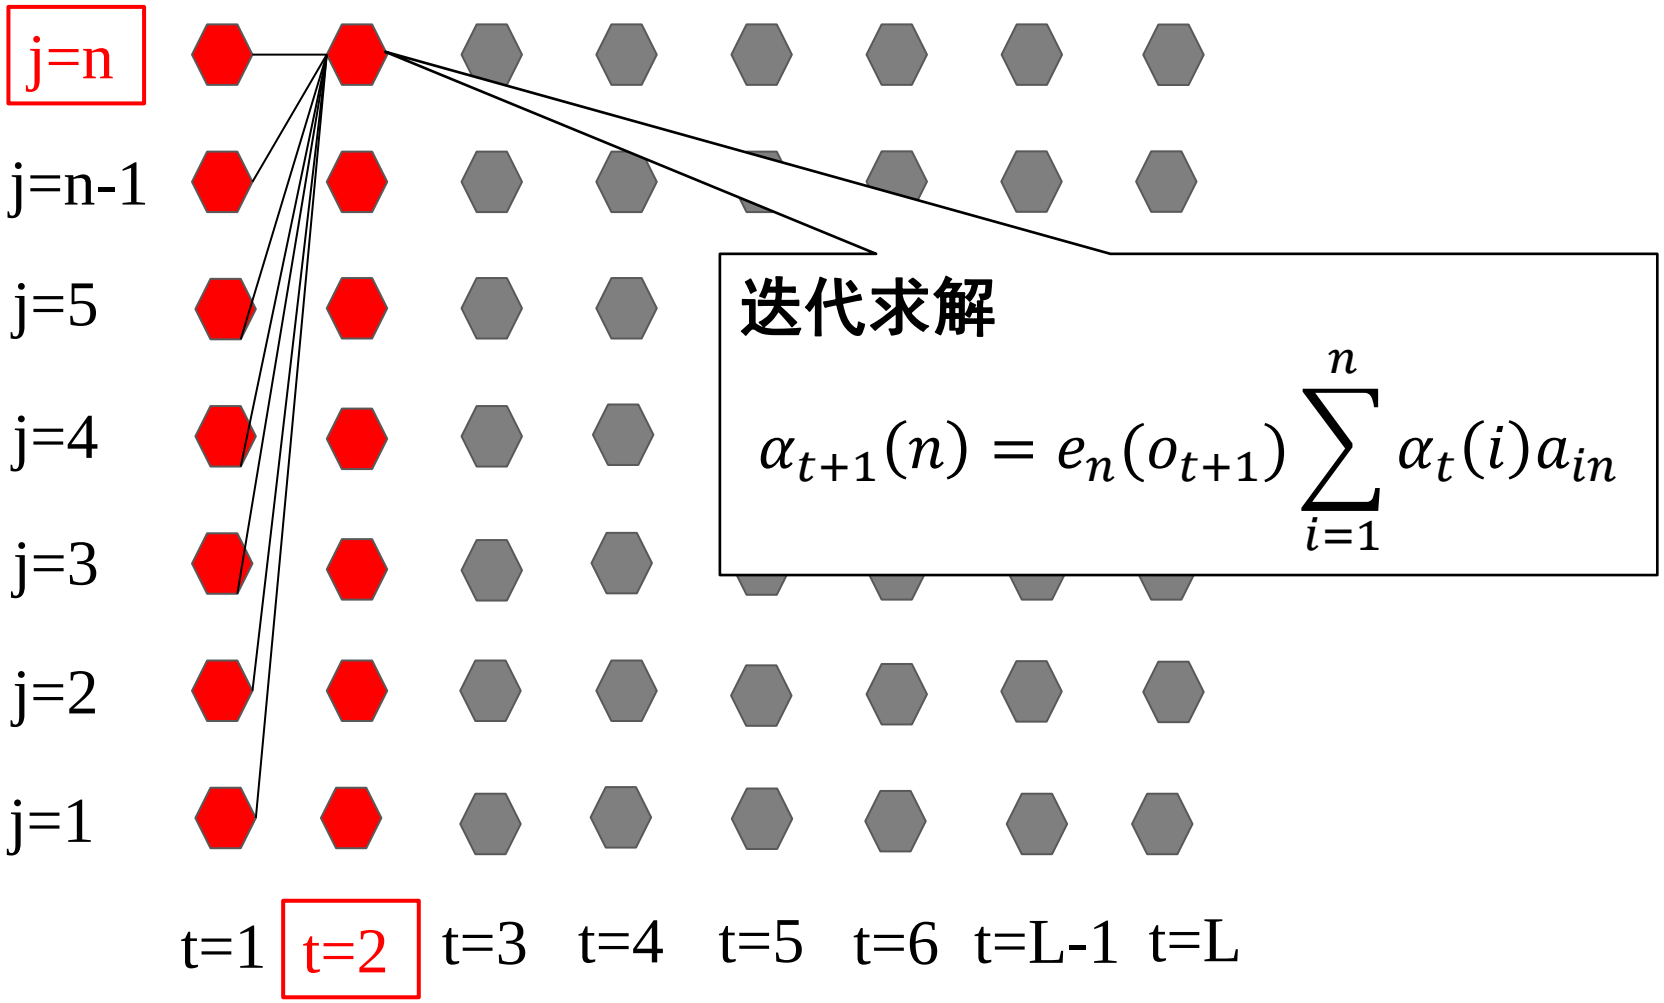
前向算法过程演示


j=n
j=n-1
j=5
j=4
j=3
j=2
j=1
t=1
t=2
t=3
t=4
t=5
t=6
t=L-1
t=L
迭代求解
$\alpha_{t+1}(2) = e_2(o_{t+1}) \sum_{i=1}^{n} \alpha_t(i) a_{i2}$

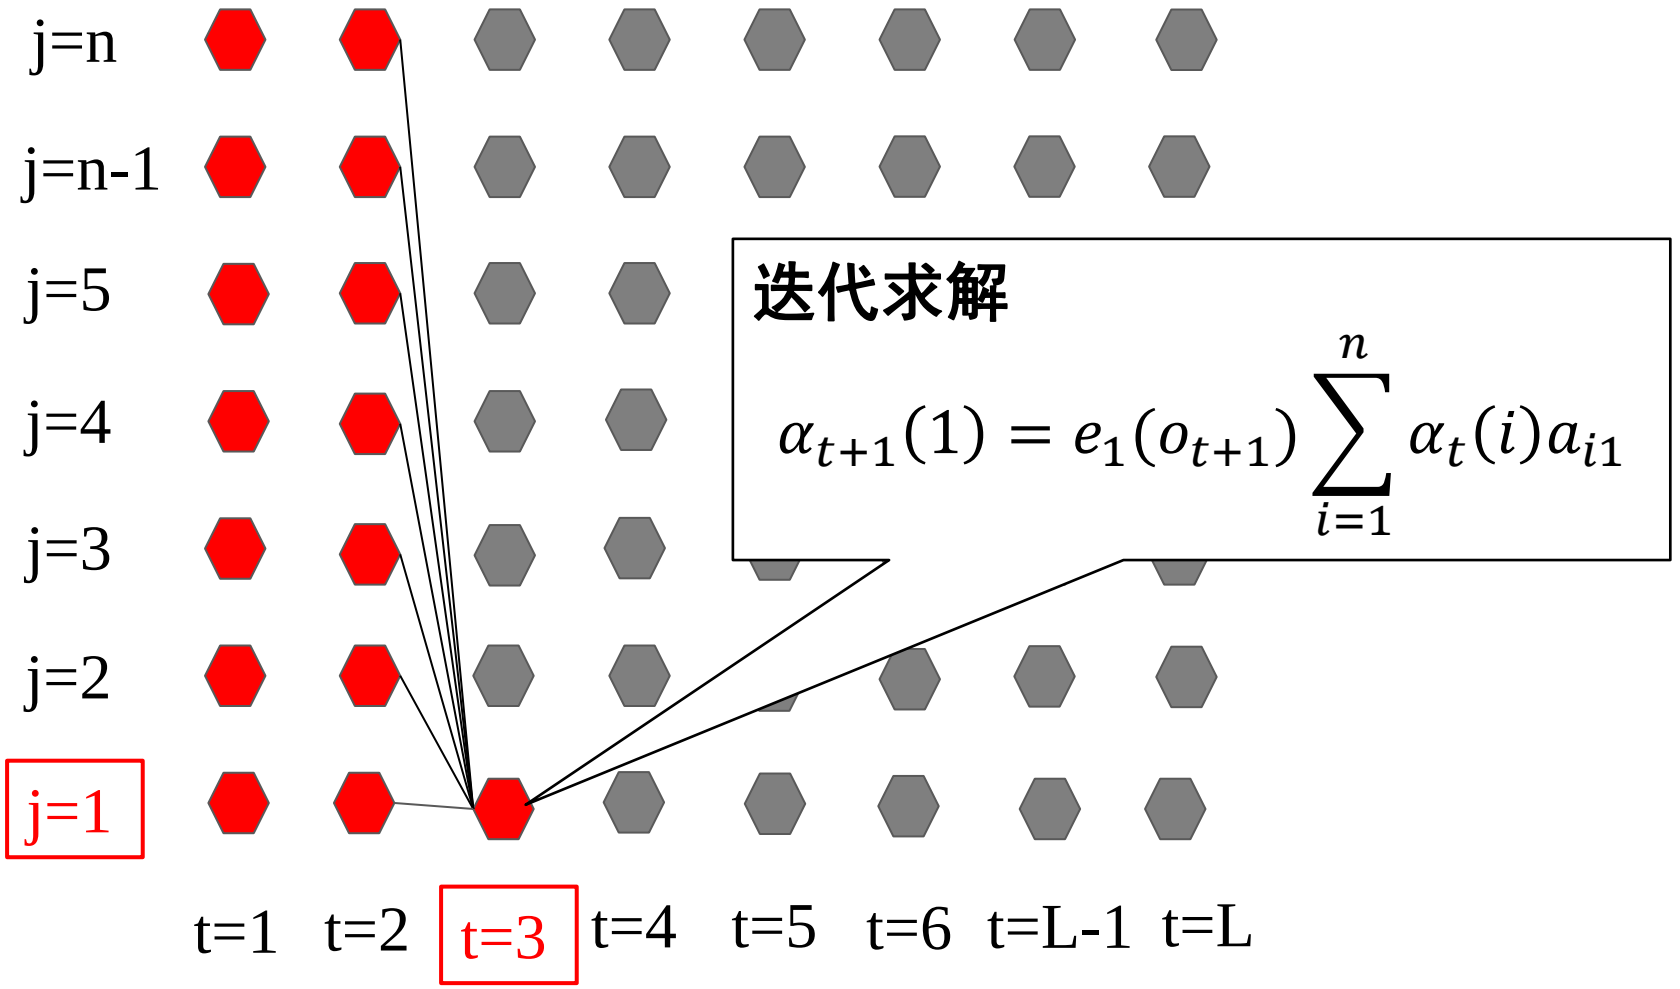
前向算法过程演示


j=n
j=n-1
j=5
j=4
j=3
j=2
j=1
t=1
t=2
t=3
t=4
t=5
t=6
t=L-1
t=L
迭代求解
$\alpha_{t+1}(3) = e_3(o_{t+1}) \sum_{i=1}^{n} \alpha_t(i) a_{i3}$

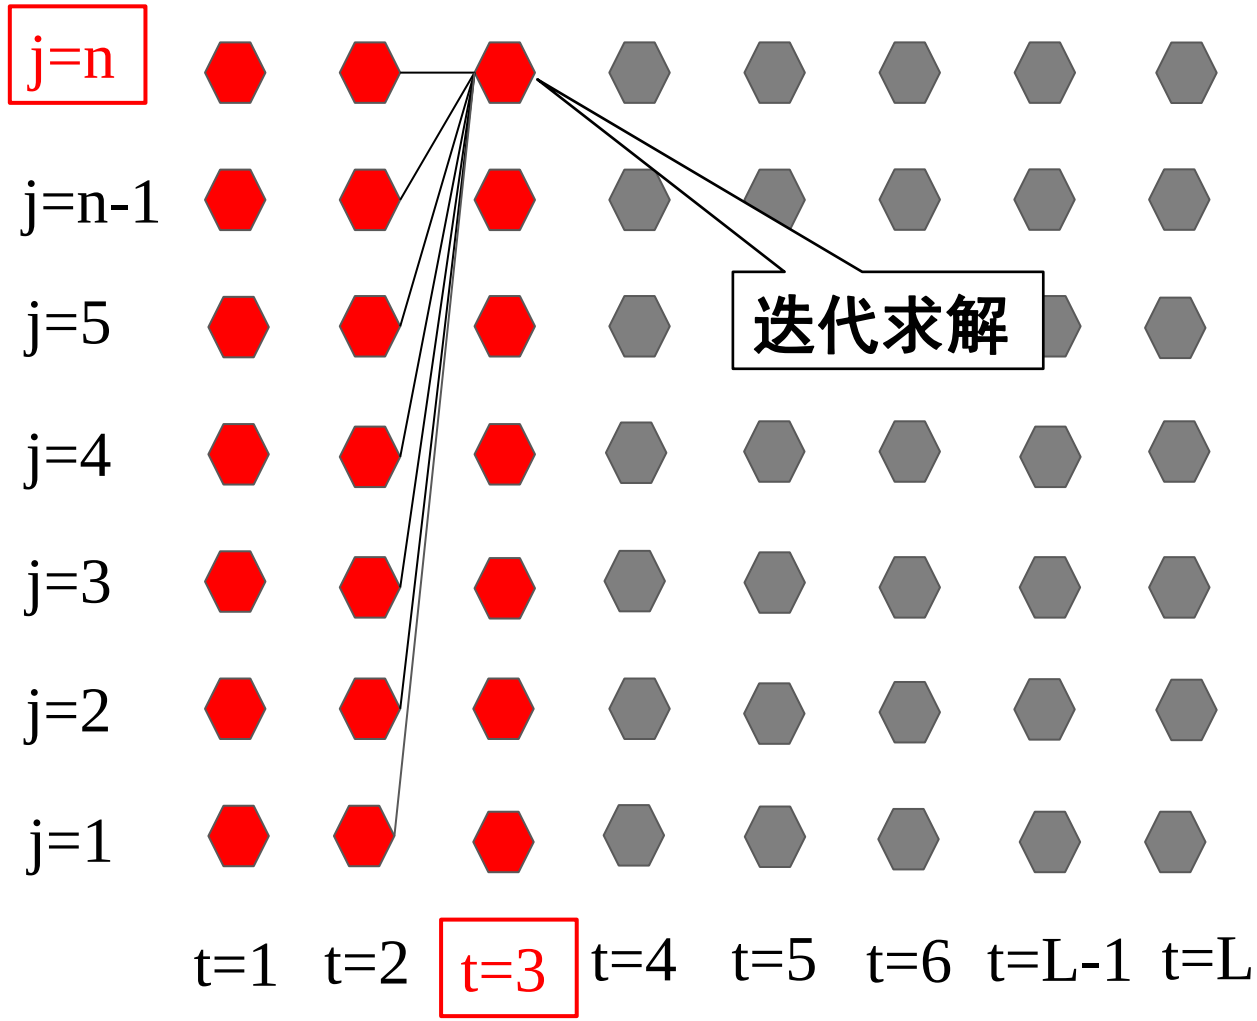
前向算法过程演示


j=n
j=n-1
j=5
j=4
j=3
j=2
j=1
t=1
t=2
t=3
t=4
t=5
t=6
t=L-1
t=L
迭代求解
$\alpha_{t+1}(n) = e_n(o_{t+1}) \sum_{i=1}^{n} \alpha_t(i) a_{in}$

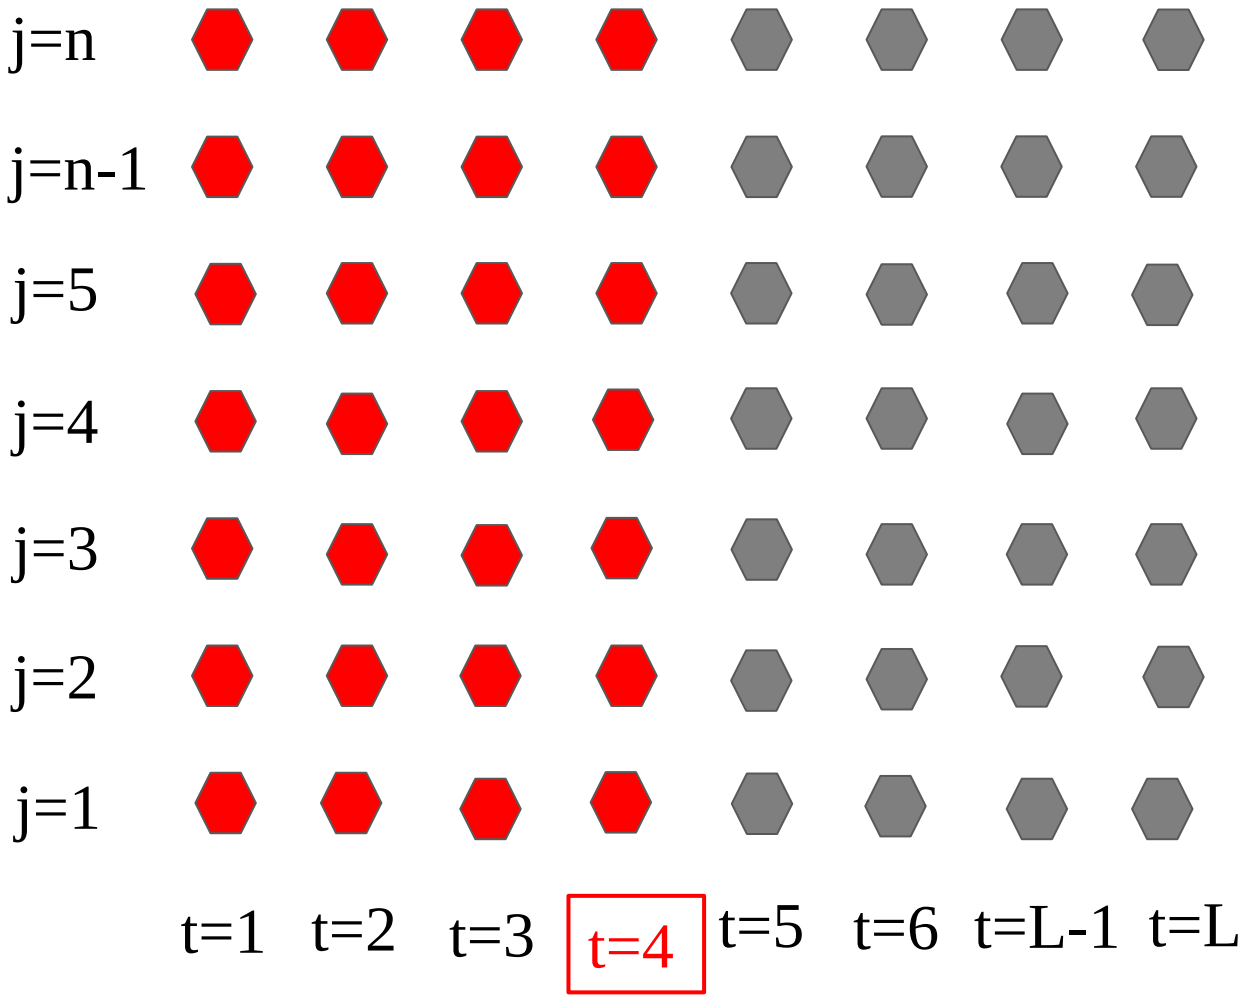
前向算法过程演示


j=n
j=n-1
j=5
j=4
j=3
j=2
j=1
t=1
t=2
t=3
t=4
t=5
t=6
t=L-1
t=L
迭代求解
$\alpha_{t+1}(1) = e_1(o_{t+1}) \sum_{i=1}^{n} \alpha_t(i) a_{i1}$

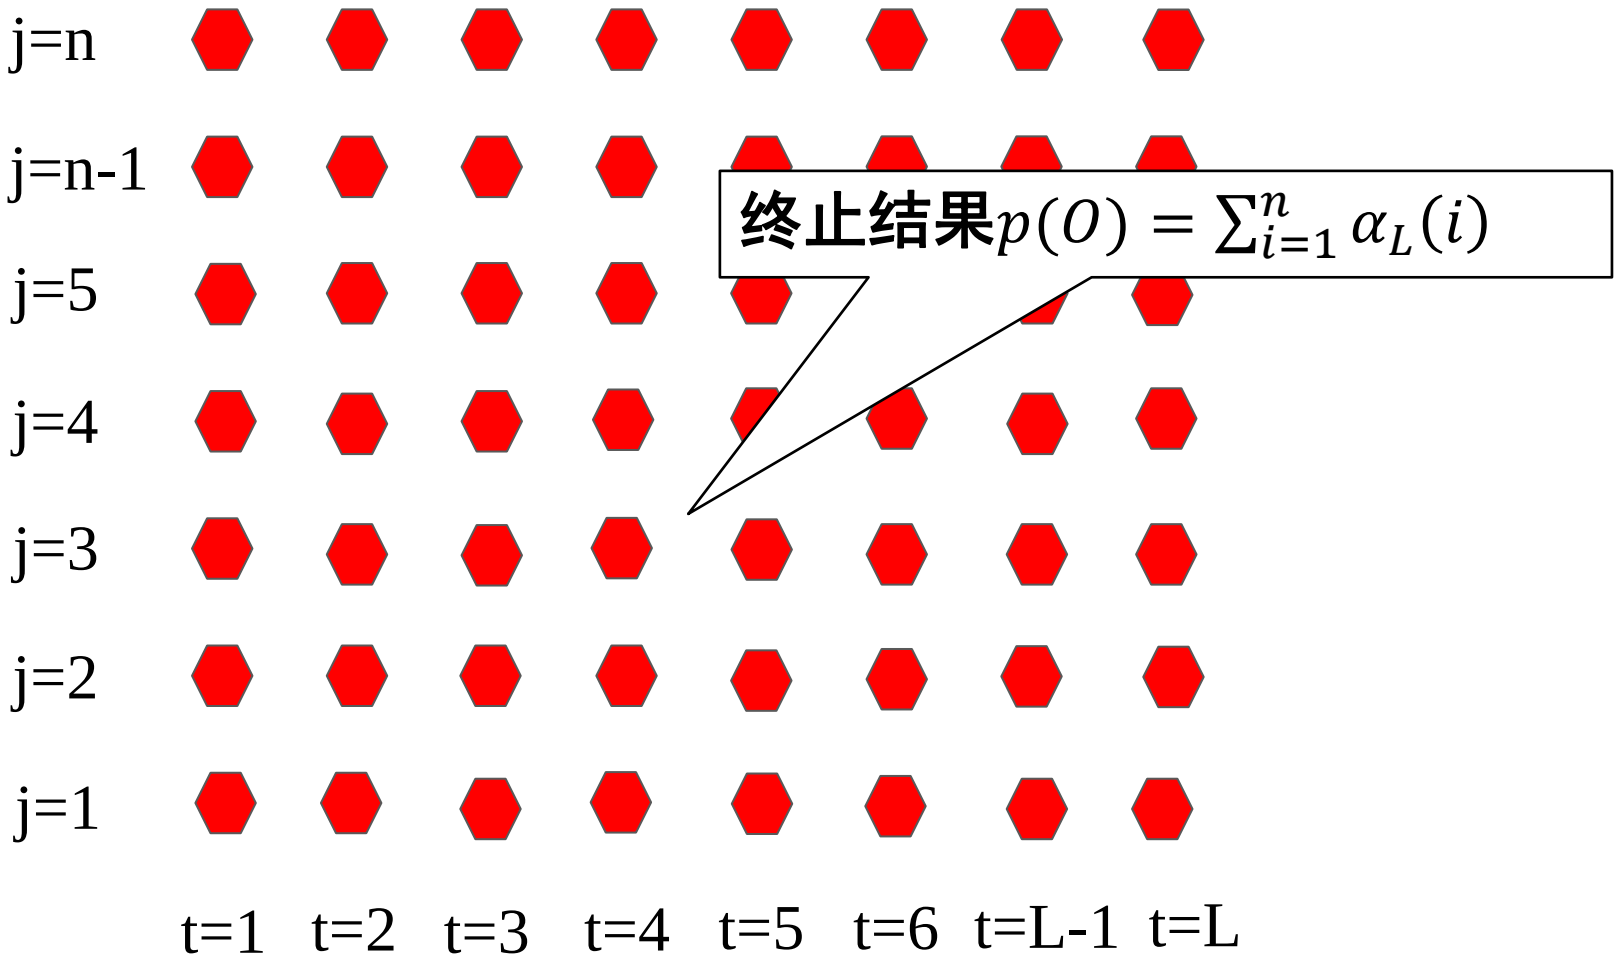
前向算法过程演示



前向算法过程演示



前向算法过程演示


j=n
j=n-1
j=5
j=4
j=3
j=2
j=1
t=1
t=2
t=3
t=4
t=5
t=6
t=L-1
t=L
终止结果$p(O)=\sum_{i=1}^{n}\alpha_L(i)$

7.6.2 HMM隐状态推断问题

– 根据模型参数与观测序列对端隐状态序列

– 给定观察序列O和HMM $\lambda = (\pi, A, B)$，计算与序列O相对应的最佳状态序列Q

– 所求的 Q 应当在某个准则下是 “ 最优 ” 的 , 因此也称 Q 为最优路径 , 解码问题即是确定最优路径的问题

解决方法：维特比算法

7.6.3 HMM模型学习问题

训练问题、参数估计问题

给定一系列观察序列样本从中确定产生这些序列的模型$\lambda = (\pi, A, B)$，以满足某种最优化准则，使得观察序列得概率$P(O|\lambda)$最大

- 希望利用数据学习HMM模型
  - 已知模型结构、观测取值范围$\boldsymbol{V}$和模型隐状态集$\boldsymbol{Q}$

$$v_t(j) = \max_{q_1 \cdots q_{t-1}} p(q_1 \cdots q_{t-1}, o_1 \cdots o_t, x_t = q_j | M)$$

  - 根据观测序列$\boldsymbol{O}$的样本，学习模型参数$\boldsymbol{A}$、$\boldsymbol{E}$和π

- 隐状态序列已知，最大似然估计

从训练数据中统计各种状态转移事件和各种状态下各观测值的发生频率，用它们作为对状态转移概率和发射概率的估计

$$\hat{a}_{ij} = \frac{\#T_{ij}}{\sum_{j'}^{n} \#T_{ij'}}$$

$$\hat{e}_{ik} = \frac{\#E_{ik}}{\sum_{k'}^{V} \#E_{ik'}}$$

$$\hat{\pi}_i = \frac{\#S_i}{S}$$

- 隐状态序列未知，EM算法

- 隐状态序列未知，EM算法

– 由于HMM中的状态序列是观察不到的（隐变量），以上的最大似然估计不可行，EM算法可用于含有隐变量的统计模型的最大似然估计

– EM算法是一个由交替进行的“期望(E过程)”和“极大似然估计(M过程)”两部分组成的迭代过程

– EM算法的每一次迭代过程必定单调地增加训练数据的对数似然值，于是迭代过程渐进地收敛于一个局部最优值

- EM算法步骤
  - E步骤：利用模型现有参数求隐变量取值的期望；
  - M步骤：利用当前对隐变量估计值对模型参数最大似然估计，更新模型

$$P(x_t = q_i, x_{t+1} = q_j, O|\widehat{M})$$

$$= p\left(o_{t+2} \cdots o_L \middle| o_1 \cdots o_{t+1}, x_t, x_{t+1}, \widehat{M}\right) p\left(o_1 \cdots o_{t+1}, x_t, x_{t+1} \middle| \widehat{M}\right)$$

$$= p\left(o_{t+2} \cdots o_L \middle| x_{t+1}, \widehat{M}\right) p\left(o_1 \cdots o_{t+1}, x_t, x_{t+1} \middle| \widehat{M}\right)$$

$$= p\left(o_1 \cdots o_t, x_t = q_i \middle| \widehat{M}\right) p\left(x_{t+1} = q_j \middle| x_t = q_i, \widehat{M}\right)$$

$$\cdot p\left(o_{t+1} \middle| x_{t+1} = q_j, \widehat{M}\right) p\left(o_{t+2} \ldots o_L \middle| x_{t+1} = q_j, \widehat{M}\right)$$

$$= \alpha_t(i) a_{ij} e_j(o_{t+1}) \beta_{t+1}(j)$$

- EM算法
  - 该算法也被称为前向后向算法
  - 整个观测序列的概率

$$p(O|\widehat{M}) = \sum_{i=1}^{n} \alpha_t(i)\beta_t(i)$$

  - E步骤

$$\hat{p}(x_t = q_i, x_{t+1} = q_j|O) = \frac{p(x_t = q_i, x_{t+1} = q_j, O)}{p(O)} = \frac{\alpha_t(i)a_{ij}e_j(o_{t+1})\beta_{t+1}(j)}{\sum_{i=1}^{n}\alpha_t(i)\beta_t(i)}$$

$$\hat{p}(x_t = q_j|O) = \frac{p(x_t = q_j, O)}{p(O)} = \frac{\alpha_t(j)\beta_t(j)}{\sum_{i=1}^{n}\alpha_t(i)\beta_t(i)}$$

– M步骤

$$\hat{a}_{ij} = \frac{\sum_{t=1}^{L} \hat{p}\left(x_t = q_i, x_{t+1} = q_j | O\right)}{\sum_{t=1}^{L} \left(\sum_{j'}^{n} \hat{p}\left(x_t = q_i, x_{t+1} = q_{j'} | O\right) \right)}$$

– 发射概率估计

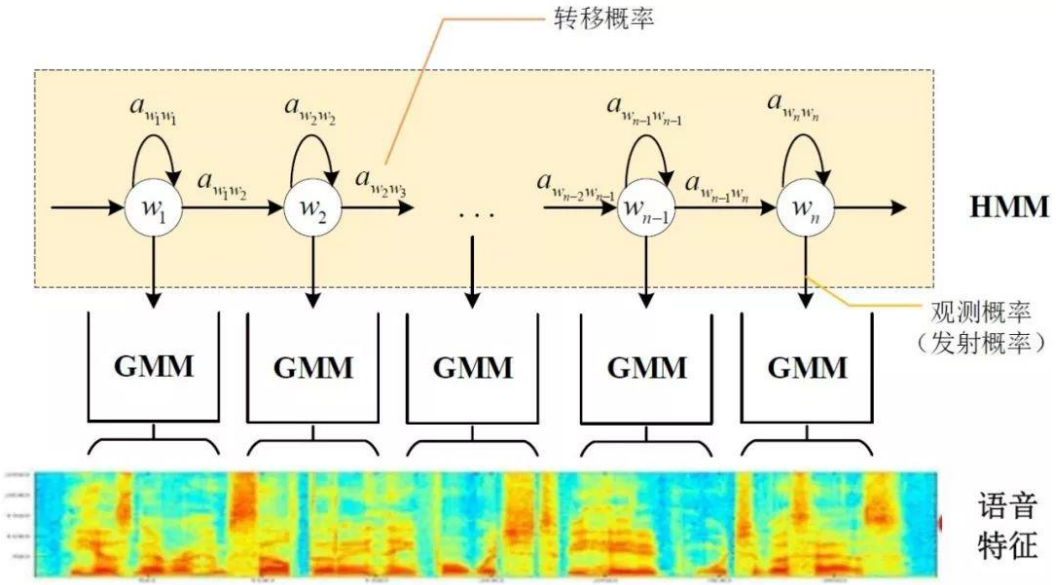
$$\hat{e}_{jk} = \frac{\sum_{t=1}^{L} \hat{p}\left(x_t = q_j | O\right) I(o_t = v_k)}{\sum_{t=1}^{L} \hat{p}\left(x_t = q_j | O\right)}$$

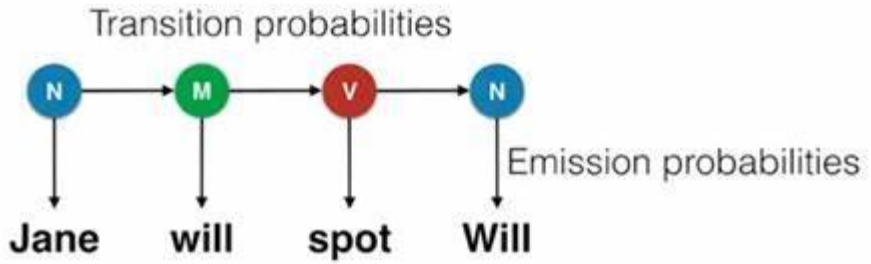
– 初始概率

$$\hat{\pi}_i = \hat{p}(x_1 = q_i | O)$$

- **HMM的应用**

– 语音识别
– 音字转换
– 词性标注（POS Tagging）
– 基因识别问题
  - 状态: 编码区域与非编码区域
  - 字符: ATCG
– 一般化：任何与线性序列相关的现象





词性标注

7.7 基于状态持续时间建模的HHM

在模式识别中，**基于状态持续时间建模的隐马尔可夫模型（HMM with explicit duration modeling）** 是对传统隐马尔可夫模型（HMM）的一种扩展，主要用于解决传统HMM无法直接建模状态持续时间分布的问题

传统隐马尔可夫模型的状态持续时间问题：

- 每个状态的持续时间隐含在状态转移概率中。
- HMM假设每个状态的持续时间服从**几何分布**，这是一种隐含的约束

问题：几何分布是**记忆性分布**，它倾向于让短持续时间出现更频繁，但在很多实际问题中（如**语音、手写识别**等），状态持续时间的分布往往**不是几何分布**

基于状态持续时间建模的隐马尔可夫模型

核心思想：

1.引入显式的持续时间分布：为每个状态定义一个明确的持续时间分布 $P_i(d)$，其中i是状态，d是持续时间，可以是任意分布（如高斯分布、泊松分布或非参数分布），取决于具体应用

2.解耦持续时间和状态转移：将状态的持续时间建模从转移概率中分离，使模型更灵活

优势：

1.更加灵活：可以通过显式建模的持续时间分布更准确地反映真实的状态持续时间特性

2.适应更多应用场景：适用于持续时间分布偏离几何分布的任务，比如语音信号处理（音素的持续时间）、行为分析等

实现方法：

1.分段式处理：在解码（如Viterbi算法）时，需要额外计算每个可能状态持续时间的概率，导致算法复杂度增加。

2.参数估计：通过 EM 算法对状态转移概率、持续时间分布等参数进行联合优化

7.8 使用神经网络训练马尔可夫模型

使用神经网络训练马尔可夫模型 是一种结合了传统概率模型（如隐马尔可夫模型）和深度学习能力的混合方法。这种方法主要用于解决隐马尔可夫模型（HMM）的一些限制（例如对状态转移和观测概率分布的建模能力不足）

常见方法：

- 神经网络替代HMM中的观测概率分布
- 神经网络替代状态转移概率分布
- 端到端的神经网络-HMM模型
- 使用神经网络改进序列生成和解码
- 隐变量模型与深度学习的结合：HMM与变分自编码器（VAE）

通过神经网络增强HMM的观测建模和转移建模能力，可以有效提高模型在**高维复杂序列数据**上的性能，同时**保持HMM的结构化优势**

7.9 马尔科夫随机场的讨论

马尔可夫随机场（Markov Random Field, MRF） 是一种广泛用于图像处理、自然语言处理和时间序列分析的**概率图模型**。它是对马尔可夫过程的推广，适合描述具有图结构的多变量随机变量之间的依赖关系

•MRF是一种无向图模型，用无向图表示随机变量之间的条件独立性。
•对于一个MRF，变量集$\boldsymbol{X} = \{X_1, X_1, \cdots, X_n\}$满足以下性质：

– **马尔可夫性**：每个节点的状态只与它的邻居相关，独立于其他不相邻的节点

$$P\left(X_i \middle| \boldsymbol{X} \setminus X_i\right) = P\left(X_i \middle| 邻居(X_i)\right)$$

– **联合概率分布**：通过图中的团（clique）上的势函数表示：

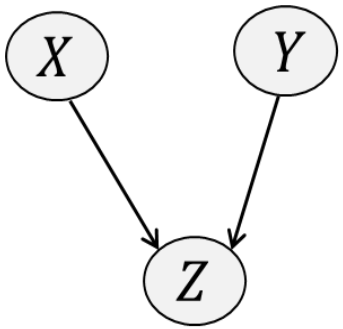
$$P(\boldsymbol{X}) = \frac{1}{\boldsymbol{Z}} \prod \phi_c(\boldsymbol{X_c})$$

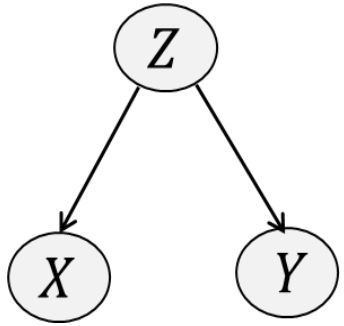
其中：

– $\phi_c(\boldsymbol{X_c})$是团势函数，描述团内变量的联合关系。
– $\boldsymbol{Z} = \sum_{\boldsymbol{X}} \prod_c \phi_c(\boldsymbol{X}_c)$是归一化分母，称为**配分函数**。

7.10 在贝叶斯网络上的条件独立性

- 贝叶斯网络任意三节点随机变量间的条件独立关系







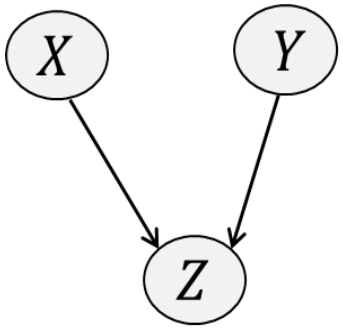
- 形式1：头对头
  - Z取值未知时

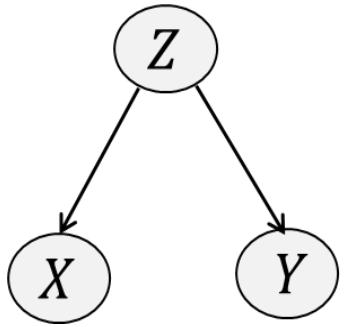
$$p(x,y)=\sum_{z'\in Z}p(x,y,z')$$

$$=\sum_{z'\in Z}p(x)p(y)p(z'|x,y)=p(x)p(y)\sum_{z'\in Z}p(z'|x,y)=p(x)p(y)$$

- 形式1：头对头
  - Z取值已知时

$$p(x,y|z) = p(x)p(y)p(z|x,y)/p(z)$$







- 形式2：尾对尾

$$p(x,y,z) = p(x|z)p(y|z)p(z)$$

  - Z取值已知时

$$p(x,y|z) = p(x,y,z)/p(z) = p(x|z)p(y|z)p(z)/p(z) = p(x|z)p(y|z)$$

- 形式2：尾对尾
  - Z取值未知时

$$p(x,y|z) = p(x,y,z)/p(z) = p(x|z)p(y|z)p(z)/p(z) = p(x|z)p(y|z)$$

$$p(y) = \sum_{z' \in Z} p(y|z')p(z')$$

$$p(z|y) = p(y|z)p(z)/p(y)$$

$$p(x|y) = \sum_{z' \in Z} p(x,z'|y) = \sum_{z' \in Z} p(x,z',y)/p(y) = \sum_{z' \in Z} p(x|z',y)\,p(z'|y)$$

$$= \sum_{z' \in Z} p(x|z')p(z'|y)$$

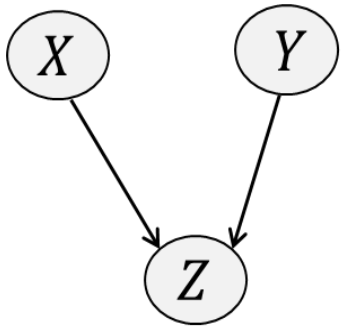
- 形式2：头对尾

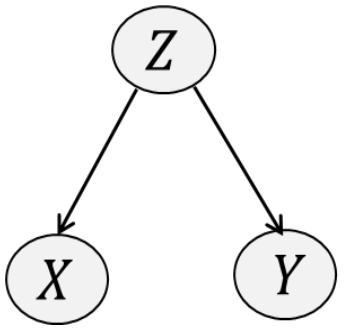
$$p(x,y,z) = p(x)p(z|x)p(y|z)$$

  - Z取值为z时

$$p(x,y|z) = \frac{p(x,y,z)}{p(z)} = \frac{p(x)p(z|x)p(y|z)}{p(z)}$$
$$= p(y|z)p(x,z)/p(z) = p(x|z)p(y|z)$$

- d-分离
  - （1）P包含$X \to Z \to Y$或者$Y \to Z \to X$，且节点Z属于集合E；
  - （2）P包含$X \leftarrow Z \to Y$，且节点Z属于集合E；
  - （3）P包含$X \to Z \leftarrow Y$，且Z和Z的后继节点不属于集合E。







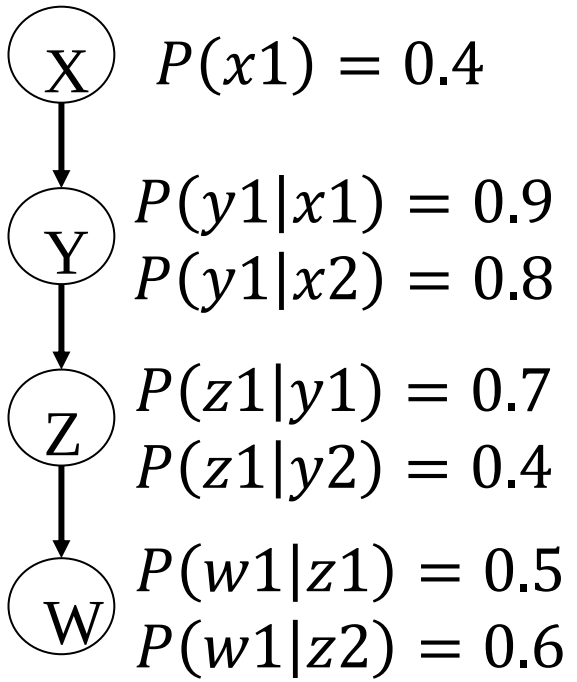
- 马尔可夫覆盖
  （1）对于网络中的一个节点t
  （2）存在节点集合使得在条件于该节点集合情况下
  （3）t与网络中的其它节点条件独立

- 不需要对所有节点联合概率进行计算
- 只需要找到需要计算的节点集合和它的马尔可夫覆盖

- 一个简单贝叶斯网络例子

已知右图，计算：$P(w1|x1)$、$P(x1|w1)$

- 计算过程：
- (1)
- P(y1|x1)=0.9
- P(z1|x1)=P(z1|y1,x1)P(y1|x1)+P(z1|y2,x1)P(y2|x1)
- =P(z1|y1)P(y1|x1)+P(z1|y2)P(y2|x1)
- =0.7*0.9+0.4*0.1=0.67
- P(w1|x1)=P(w1|z1,x1)P(z1|x1)+P(w1|z2,x1)P(z2|x1)
- =P(w1|z1)P(z1|x1)+P(w1|z2)P(z2|x1)
- =0.5*0.67+0.6*0.33=0.533
- 该计算利用向下概率传播及链式规则

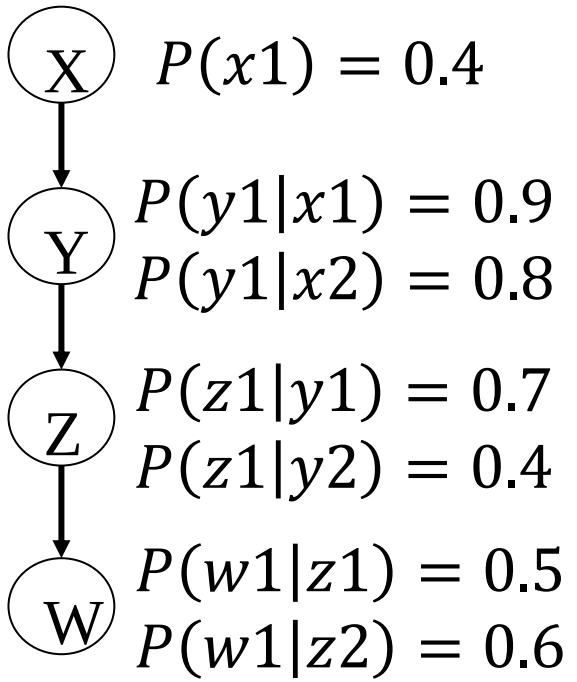


• 一个简单贝叶斯网络例子

计算：$P(w1|x1)$、$P(x1|w1)$

- 计算过程：
- (2)
- P(y1)=P(y1|x1)P(x1)+P(y1|x2)P(x2)=0.9*0.4+0.8*0.6=0.84
- P(z1)=P(z1|y1)P(y1)+P(z1|y2)P(y2)=0.7*0.84+0.4*0.16=0.652
- P(w1)=P(w1|z1)P(z1)+P(w1|z2)P(z2)=0.5*0.652+0.6*0.348=0.5348
- $P(z1|w1) = \frac{P(w1|z1)P(z1)}{P(w1)} = \frac{0.5*0.652}{0.5348} = 0.6096$
- P(w1|y1)=P(w1|z1)P(z1|y1)+P(w1|z2)P(z2|y1)
- =0.5*0.7+0.6*0.3=0.53
- P(w1|y2)=P(w1|z1)P(z1|y2)+P(w1|z2)P(z2|y2)
- =0.5*0.4+0.6*0.6=0.56
- P(w1|x1)=P(w1|y1)P(y1|x1)+P(w1|y2)P(y2|x1)
- =0.53*0.9+0.56*0.1=0.533
- $P(x1|w1) = \frac{P(w1|x1)P(x1)}{P(w1)} = \frac{0.533*0.4}{0.5348} = 0.3987$

- 该计算利用向上概率传播及贝叶斯定理



7.11 贝叶斯网络模型的学习

- 参数学习
  - 模型结构给定，训练数据

- 结构学习
  - 通过数据学习找到网络结构及概率分布参数

7.11.1 贝叶斯网络的参数学习

- 根据已知数据估计模型未知参数
  - 模型参数的后验概率密度为

$$p(\boldsymbol{\theta}|\boldsymbol{D}) = p(\boldsymbol{D}|\boldsymbol{\theta})p(\boldsymbol{\theta})/p(\boldsymbol{D})$$

$$\widehat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}} \left(\sum_{i=1}^{N} \log p(\boldsymbol{x}_i|\boldsymbol{\theta}) + \log p(\boldsymbol{\theta}) \right)$$

- 贝叶斯网络中分解概率密度函数
  - 条件概率分解

$$p(\boldsymbol{D}|\boldsymbol{\theta}) = \prod_{i=1}^{N} p(\boldsymbol{x}_i|\boldsymbol{\theta}) = \prod_{i=1}^{\boldsymbol{N}} \prod_{t=1}^{n} p\left(x_{i,t}\middle|\boldsymbol{x}_{i,\boldsymbol{pa}(t)}, \boldsymbol{\theta}_t\right)$$

$$= \prod_{t=1}^{\boldsymbol{n}} \left(\prod_{i=1}^{N} p\left(x_{i,t}\middle|\boldsymbol{x}_{i,\boldsymbol{pa}(\boldsymbol{t})}, \boldsymbol{\theta}_t\right) \right) = \prod_{t=1}^{\boldsymbol{n}} p(\boldsymbol{D}_t|\boldsymbol{\theta}_t)$$

  - 假设参数互相独立

$$p(\boldsymbol{\theta}) = \prod_{t=1}^{\boldsymbol{n}} p(\boldsymbol{\theta}_t)$$

- 贝叶斯网络中分解概率密度函数
  - 后验概率分解

$$\boldsymbol{p}(\boldsymbol{\theta}|\boldsymbol{D}) \sim \prod_{t=1}^{\boldsymbol{n}} p(\boldsymbol{D}_t|\boldsymbol{\theta}_t) p(\boldsymbol{\theta}_t)$$

- 以随机变量为离散取值、且满足多项式分布的情况为例
  - 节点t有K_t种可能的取值,用X_t来表示节点t的取值
  - X_t的条件概率分布

$$\boldsymbol{\theta}_{tc} = [\theta_{tc1}, \theta_{tc2}, \cdots, \theta_{tcK_t}]$$

$$\sum_{k=1}^{K_t} \theta_{tck} = 1$$

- 似然函数可表示为

$$N_{tck} = \sum_{i=1}^{N} I(X_{i,t} = k, \boldsymbol{X}_{i,\boldsymbol{pa}(t)} = c)$$

$$p(\boldsymbol{D}_t|\boldsymbol{\theta}_t) = \prod_{c=1}^{q_t} \prod_{k=1}^{K_t} \theta_{tck}^{N_{tck}} = \prod_{c=1}^{q_t} p(\boldsymbol{D}_{tc}|\boldsymbol{\theta}_{tc})$$

- 参数的后验分布为

$$p(\boldsymbol{\theta}_t|\boldsymbol{D}_t) \propto p(\boldsymbol{D}_t|\boldsymbol{\theta}_t)p(\boldsymbol{\theta}_t) = \prod_{c=1}^{q_t} p(\boldsymbol{D}_{tc}|\boldsymbol{\theta}_{tc})p(\boldsymbol{\theta}_{tc})$$

7.11.2 贝叶斯网络的结构学习

- 网络模型的评分函数

$$p(\boldsymbol{G}|\boldsymbol{D}) = p(\boldsymbol{D}|\boldsymbol{G})p(\boldsymbol{G})/p(\boldsymbol{D})$$

- 进一步简化为最大似然问题

$$G^* = \underset{\boldsymbol{G}}{\operatorname{argmax}}\, p(\boldsymbol{D}|\boldsymbol{G})$$

- 构造如下形式的打分函数

$$\text{Score}(D, G) = -\log(p(\boldsymbol{D} \mid \boldsymbol{G})) + \text{Penalty}(\boldsymbol{D}, \boldsymbol{G})$$

第一项为模型的负对数似然值，第二项为惩罚项

- 惩罚函数
  - BIC准则

$$\text{Penalty}(\boldsymbol{D},\boldsymbol{G}) = \frac{d}{2}\log N$$

  - AIC准则

$$\text{Penalty}(\boldsymbol{D},\boldsymbol{G}) = d$$

贝叶斯网络应用

- 医疗诊断
- 金融分析
- 计算机（微软Windows,Office）
- 军事（目标识别，多目标跟踪，战争身份识别等）
- 生物信息学（贝叶斯网络在基因连锁分析中应用）
- 编码学
- 分类聚类
- 时序数据和动态模型

7.12 监督学习尾声

- 系统性能的评估
- 理解如何组合各个设计阶段来构建分类系统
  - 医学成像实例研究（见教材p384）
- 半监督学习
  - 适当使用未标注的数据可以提高系统的性能

系统性能的评估

错误计数法：$\widehat{P_i} = \sum_{i=1}^{M} P(w_i)\frac{k_i}{N_i}$，其中$\widehat{P_i}$是总错误概率估计，$P(w_i)$是类别$w_i$出现的概率

混淆矩阵（Confusion Matrix）：混淆矩阵可以直观地展示模型的预测类别和实际类别之间的关系

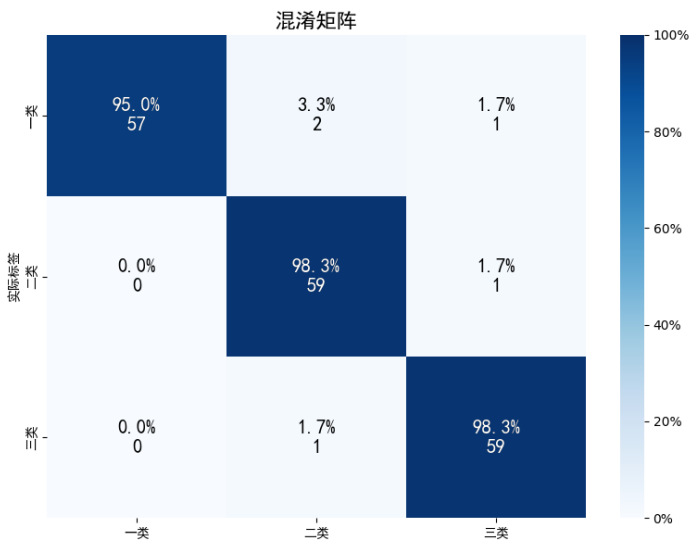
	实际正类	实际负类
预测正类	真正类（TP）	假正类（FP）
预测负类	假负类（FN）	真负类（TN）

$$准确率 = \frac{TP + TN}{TP + TN + FP + FN}$$

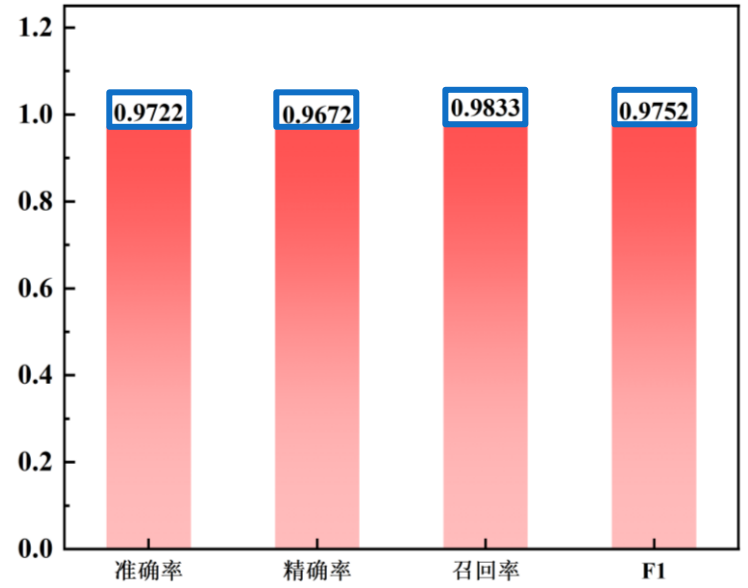
$$精确率 = \frac{TP}{TP + FP}$$

$$召回率 = \frac{TP}{TP + FN}$$

$$F1 = 2 \cdot \frac{精确率 \cdot 召回率}{精确率 + 召回率}$$



混淆矩阵



评价指标

半监督学习

在实际的机器学习应用中，无类标签样本易得，而有类标签样本因标注**成本高昂且耗时**往往稀缺。为此，人们提出半监督学习（Semi-Supervised Learning），通过结合大量无类标签样本与少量有类标签样本**共同训练**，以提升学习性能

半监督学习的假设：

- 聚类假设：如果两个点位于同一个聚类中，那么他们可能源自同一个类别
- 流形假设：数据分布在一个低维流形上，未标注数据可以帮助学习这个流形的结构
- 半监督假设（平滑假设）：如果两个样本在高维空间中彼此靠近，则它们的输出（标签）也应该相同
- 低密度分割假设:决策边界应位于数据分布的低密度区域，而不是高密度区域

半监督学习的方法：

- 生成模型
- 基于图的方法
- 传导支持向量机

7.13 讨论

- 基本思想：设法用模型刻画数据产生背后所遵循的规律
  - 模型只是人类用来理解和描述客观世界的工具
  - 我们并无法确知客观世界是按照我们的模型来运作的
  - 建立模型的工作，追求的就是用模型抓住数据背后最重要的规律
- 不基于模型的方法
  - 确定希望求解的判别函数形式
  - 通过训练数据确定判别函数中的参数
  - 从候选的判别函数集中选择特点的函数作为判别函数