模式识别
——模式识别与机器学习

刘文黎

liu_wenli@hust.edu.cn

土木与水利工程学院

第8章 集聚算法

本章主要内容

8.1 引言
8.2 邻近度
8.3 顺序算法：BSAS
8.4 层次算法
8.5 基于函数优化的方法：
模糊聚类算法
8.6 基于模型的聚类方法
8.7 混合模型的估计
8.8 动态聚类算法
8.9 自组织映射(SOM)神经网络
8.10 一致聚类方法
8.11 聚类有效性
8.12 讨论

8.1 引言

监督模式识别：

（已知）样本集 → 训练（学习，分类器设计）→ 识别（分类）

非监督模式识别：

（未知）样本集 → 非监督学习（聚类分析） → 后处理

根据：某种假设（对聚类应具有的性质的认识）

结果：聚类（clusters）

属中间结果（数学结果），需经解释赋予物理含义（后处理）

两大类方法
- 基于模型的方法
- 基于相似性度量的方法

8.2 邻近度

邻近度：两个对象之间的相似度和相异度

- 相似度（similarity）：衡量两个对象相似程度的数字度量，通常在0（不相似）和1（完全相似）之间
- 相异度（dissimilarity）：又称为距离，衡量两个对象差异程度的数值度量，对象越类似相异度越低。通常[0,1]之间取值

邻近度测量方法：

- 欧氏距离
- 曼哈顿距离
- 切比雪夫距离
- 闵可夫斯基距离
- 马氏距离
- 汉明距离

8.3 顺序算法：BSAS

顺序算法（sequential algorithms）是一种非常简单的聚类算法，大多数都至少将所有特征向量使用一次或几次，最后的结果依赖于向量参与算法的顺序。

BSAS伪代码：

- $m = 1 \quad /* \{聚类数量\} */$
- $C_m = \{x_1\}$
- $For\ i = 2\ to\ N$
  - 找C_k: $d(x_i, Ck) = min_{1 \le j \le m} d(x_i, Cj)$
  - $If\ (d(x_i, Ck) > \Theta)\ AND\ (m < q)\ then$
    - $m = m + 1$
    - $C_m = \{x_i\}$
  - $Else$
    - $C_k = Ck \cup \{x_i\}$
    - 如果需要，更新向量表达
  - $End\ \{if\}$
- $End\ \{for\}$

BSAS的核心思想：
由于要考虑每个新向量，根据向量到已有聚类的距离，将它分配到一个已有的聚类中，或者一个新生成的聚类中

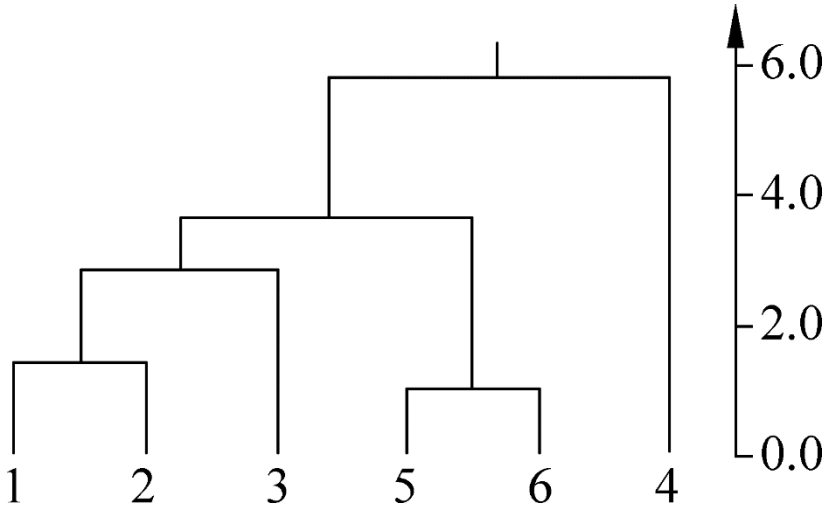
8.4 层次算法

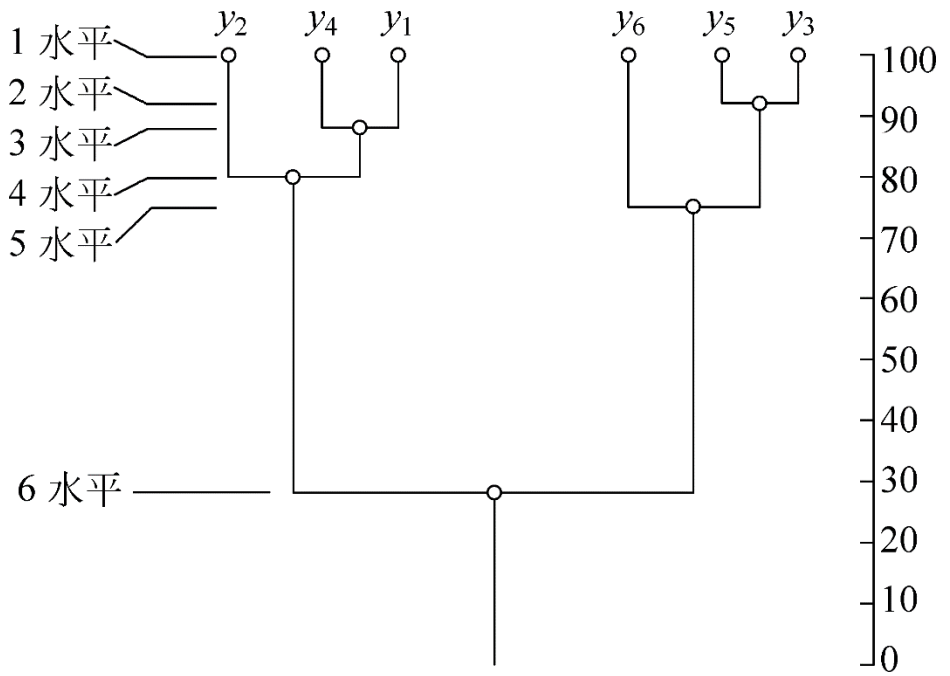
思想：

从各类只有一个样本点开始，逐级合并，每级只合并两类，直到最后所有样本都归到一类

Hierarchical tree —— dendrogram

聚类过程中逐级考查类间相似度，依此决定类别数





树枝长度：反映结点/树枝之间的相似度或距离

树枝位置：在不改变树的结构的情况下可以任意调整，调整方法需研究

距离/相似性度量：多种选择，如欧式距离、相关、City Block、…

距离（相似性度量）：

- 样本之间的度量
- 聚类之间的度量

两种聚类策略：

- bottom-up: agglomerative algorithm（合并算法，见教材P438）
- top-down: divisive algorithm（分裂算法，见教材P456）

算法（从底向上）：

（1）初始化，每个样本形成一类

（2）把相似性最大（距离最小）的两类合并

（3）重复（2），直到所有样本合并为两类

算法（从底向上）：K-means

常用的几种类间似性度量：

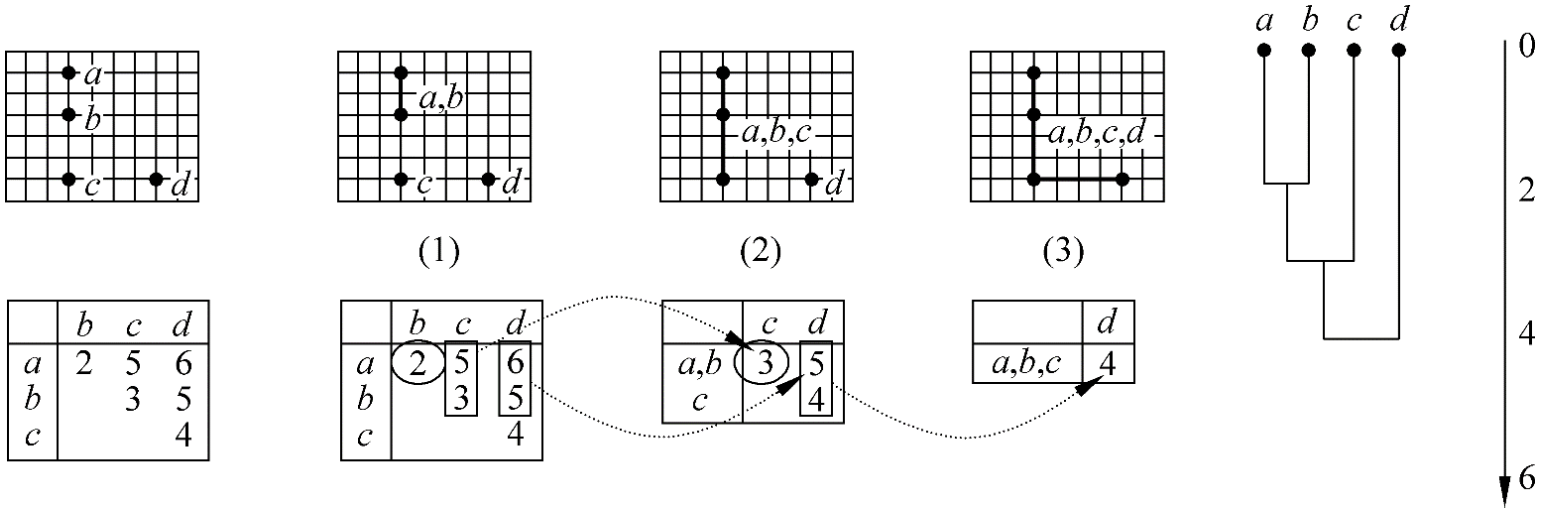
1. 最近距离（single-link） $\Delta(\Gamma_i, \Gamma_j) = \min_{\substack{y \in \Gamma_i \\ \tilde{y} \in \Gamma_j}} \delta(y, \tilde{y})$

2. 最远距离（complete-link） $\Delta(\Gamma_i, \Gamma_j) = \max_{\substack{y \in \Gamma_i \\ \tilde{y} \in \Gamma_j}} \delta(y, \tilde{y})$

3. 均值距离（average-link） $\Delta(\Gamma_i, \Gamma_j) = \delta(m_i, m_j)$

不同相似性度量对结果的影响

最近距离连接



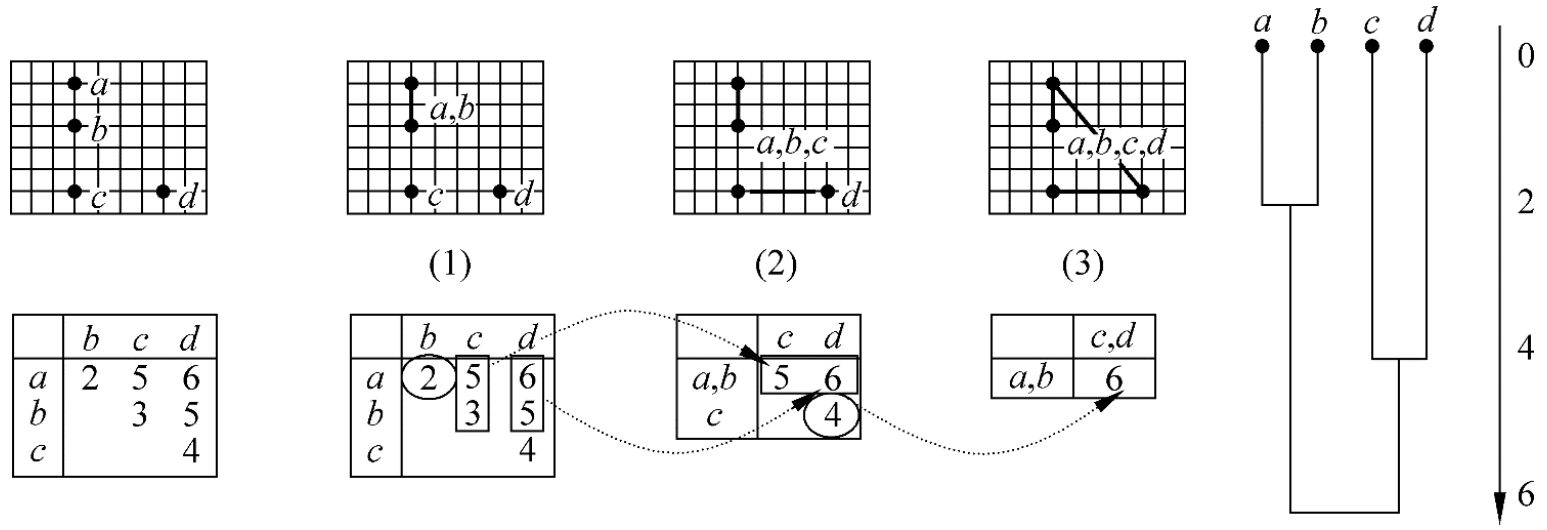
	b	c	d
a	2	5	6
b		3	5
c			4

	b	c	d
a	2	5	6
b		3	5
c			4

	c	d
a,b	3	5
c		4

	d
a,b,c	4

最远距离连接



	b	c	d
a	2	5	6
b		3	5
c			4

	b	c	d
a	2	5	6
b		3	5
c			4

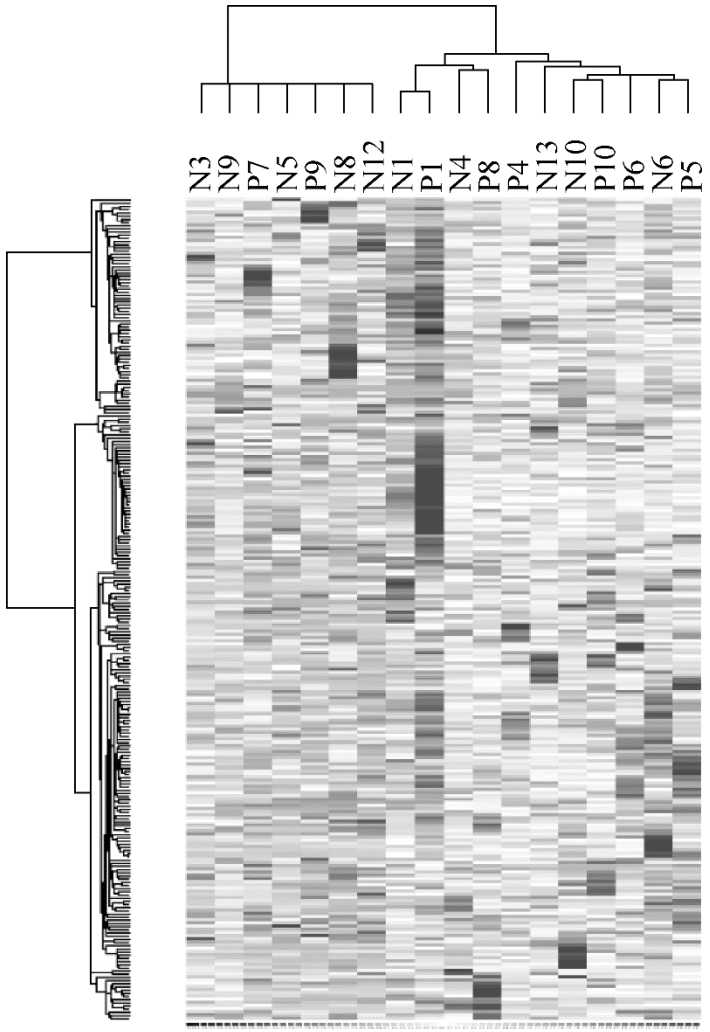
	c	d
a,b	5	6
c		4

	c,d
a,b	6

几点说明：

- 分级聚类是一种局部搜索，对样本中的噪声敏感
- 聚类数的画法不是唯一的。同一类中的两个分支可以左右互换而不改变聚类结果，但会改变树的外观和分析者的判断

例：基因表达数据的双向聚类（two-way clustering）



课堂习题

1. 【单选】在层次型聚类中（ C ）

A. 需要用户预先设定聚类的个数

B. 需要用户预先设定聚类个数的范围

C. 对于N个数据点，可生成1到N个簇

D. 对于N个数据点，可生成1到N/2个簇

课堂习题

2. 【单选】在层次型聚类中，两个点集之间的距离计算方法通常不包括（ C ）

A. 由点集间距离最近的一对点的距离决定

B. 由点集间距离最远的一对点的距离决定

C. 由点集间随机的一对点的距离决定

D. 由点集间所有点的平均距离决定

8.5 基于函数优化的方法：模糊聚类算法

8.5.1 模糊集的基本知识

L.A. Zadeh, Fuzzy sets, Intormation & Control, v.8, pp.338-353, 1965

确定集合（脆集合）：元素属于或者不属于集合

模糊集合：　元素以一定的程序属于某集合

——适于表达自然语言变量和常识性知识

几种叫法：模糊集、模糊逻辑、模糊数学、模糊系统、模糊技术、模糊方法

与其它技术相结合：模糊神经网络、模糊控制、模糊模式识别

隶属度函数$\mu_A(x)$: x属于集合A的程度

自变量：所有可能属于A的对象，空间$X = \{x\}$

值域：$[0, 1]$，$0 \le \mu_A(x) \le 1$

$$\mu_A(x) = 1 \Leftrightarrow x \in A$$
$$\mu_A(x) = 0 \Leftrightarrow x \notin A$$

模糊集合：一个定义在$X = \{x\}$上的隶属度函数就定义了一个模糊集合A，

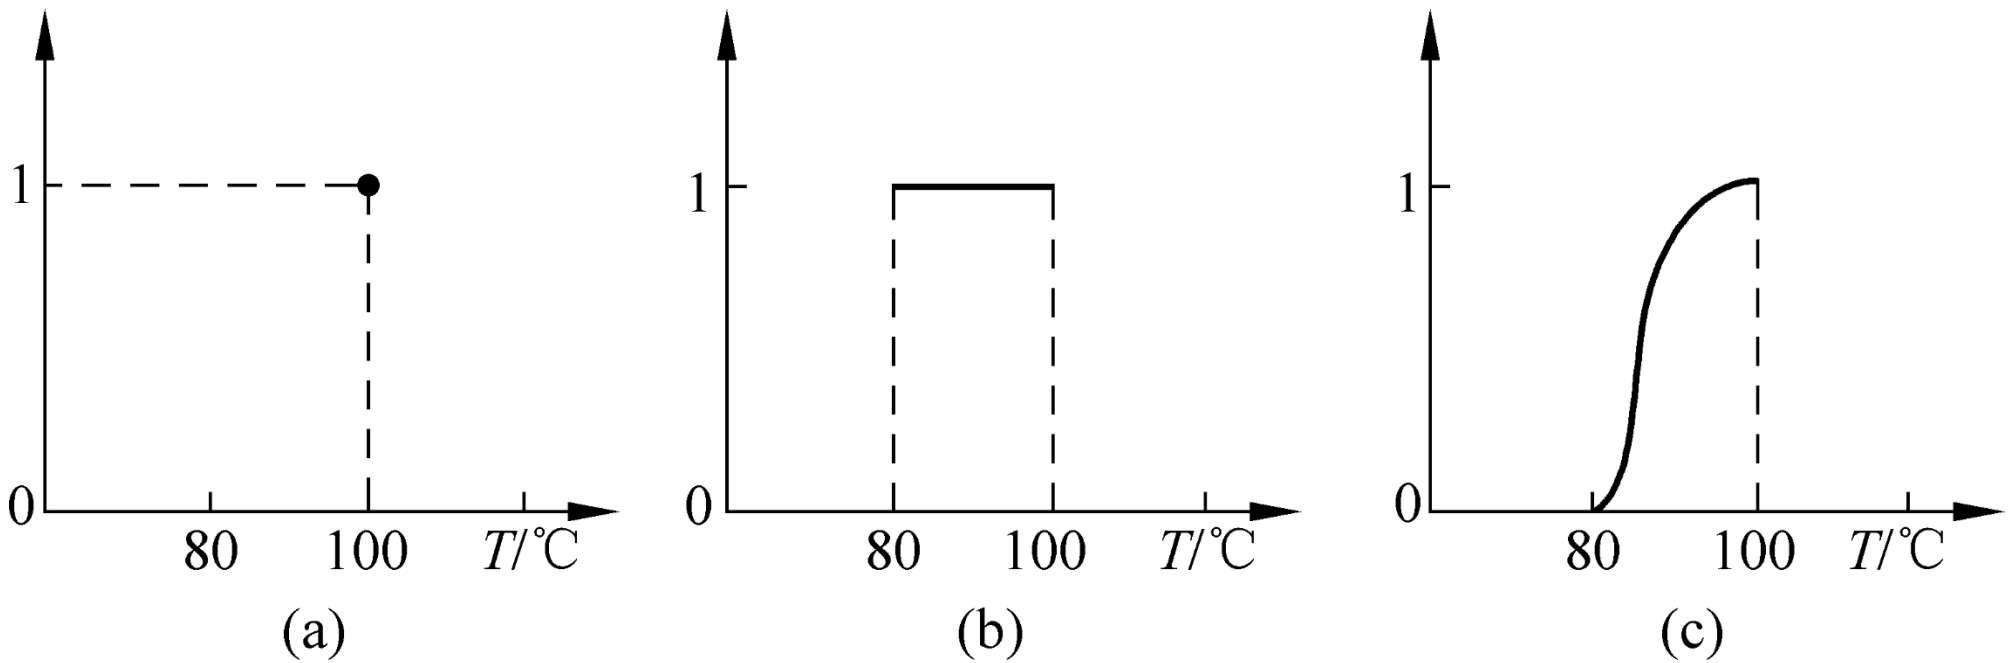
或称定义在空间$X = \{x\}$上的模糊子集，表示为：

$$A = \{(\mu_A(x_i), x_i)\} \text{ 或 } A = \bigcup_i \mu_i / x_i$$

模糊集A的支持集

$$S(A) = \{x, x \in X, \mu_A(x) > 0\}$$

例：“开水”概念的表达



8.5.2 C均值算法（K均值算法）

误差平方和准则

$$J_e = \sum_{i=1}^{c} \sum_{y \in \Gamma_i} \|y - m_i\|^2 = \sum_{i=1}^{c} J_i$$

其中 Γ_i是第i个聚类，$i = 1,2,\ldots,\mathrm{c}$，其中样本数为$N_i$

Γ_i中样本均值为

$$m_i = \frac{1}{N_i} \sum_{y \in \Gamma_i} y$$

直观理解：

J_e反映了用c个聚类中心代表c个样本子集所带来的总的误差平方和

J_e是样本集Υ与类别集Ω的函数

C均值算法的目标：最小化 ——最小方差划分

另一种角度来看C均值方法：

用c个码本来代表整个样本集，使这种表示带来的总体误差最小。

---- 向量量化Vector Quantisation

算法研究

设已有一个划分方案，考查Γ_k中的样本y，若把y移入Γ_j，此时Γ_k变成$\widetilde{\Gamma}_k$，此时Γ_j变成$\widetilde{\Gamma}_j$，有

$$\tilde{m}_k = m_k + \frac{1}{N_k - 1}[m_k - y]$$

$$\tilde{m}_j = m_j + \frac{1}{N_j + 1}[y - m_j]$$

$$\tilde{J}_k = J_k - \frac{N_k}{N_k - 1}\|y - m_k\|^2$$

$$\tilde{J}_j = J_j + \frac{N_j}{N_j + 1}\|y - m_j\|^2$$

若

$$\frac{N_j}{N_j + 1}\|y - m_j\|^2 < \frac{N_k}{N_k - 1}\|y - m_k\|^2$$

则把y从Γ_k移入Γ_j会使J_e减小

C均值算法

（1）初始划分c个聚类，$\Gamma_i,\ i = 1,2,\dots,\mathrm{c}$，计算$m_i,\ i = 1,2,\dots,\mathrm{c}$和$J_e$

（2）选样本y，设$y \in \Gamma_i$

（3）若$N_i = 1$，则转（2）；否则继续。

（4）计算ρ_j：

$$\rho_j = \frac{N_j}{N_j+1}\left\|y - m_j\right\|^2 \quad i \neq j$$

$$\rho_i = \frac{N_i}{N_i-1}\|y - m_i\|^2$$

（5）选ρ_j中的最小者，即若$\rho_k < \rho_j, \forall j$，则把y从$\Gamma_i$移到$\Gamma_k$中

（6）重新计算$m_i,\ i = 1,2,\dots,\mathrm{c}$和$J_e$

（7）若连续N次迭代J_e不改变，则停止；否则转（2）

初始划分：一般先选代表点，再进行初始分类

代表点选择方法：

1. 经验选择

2. 随机分成*c*类，选各类重心作为代表点

3. “密度”法：

　　计算每个样本的一定球形邻域内的样本数作为“密度”，选“密度”最大的样本点作为第一个代表点，在离它一定距离之外选最大“密度”点作为第二个代表点，…，依次类推。

4. 用前*c*个样本点作为代表点

5. 用*c-1*聚类求*c*个代表点：各类中心外加离它们最远的样本点，从1类开始

　　…

初始分类方法：

1. 最近距离法。离哪个代表点近就归入哪一类

2. 最近距离法归类，但每次都重新计算该类代表点

3. 直接划分初始分类：第一个样本自成一类，第二个样本若离它小于某距离阈值则归入此类，否则建新类，……

4. 将特征归一化，用样本各特征之和作为初始分类依据

$$SUM(i) = \sum_{j=1}^{D} y_{ij}\,, i = 1, \dots, N. \quad y_i \in R^D$$

$$MA = \max_i SUM(i),\ MI = \min_i SUM(i),\ k \underset{\text{取整}}{=} \frac{(c-1)}{MA - MI}[SUM(i) - MI] + 1$$

说明：

- 初始划分无一定之规，多为启发式方法
- C均值方法结果受初值影响，是局部最优解

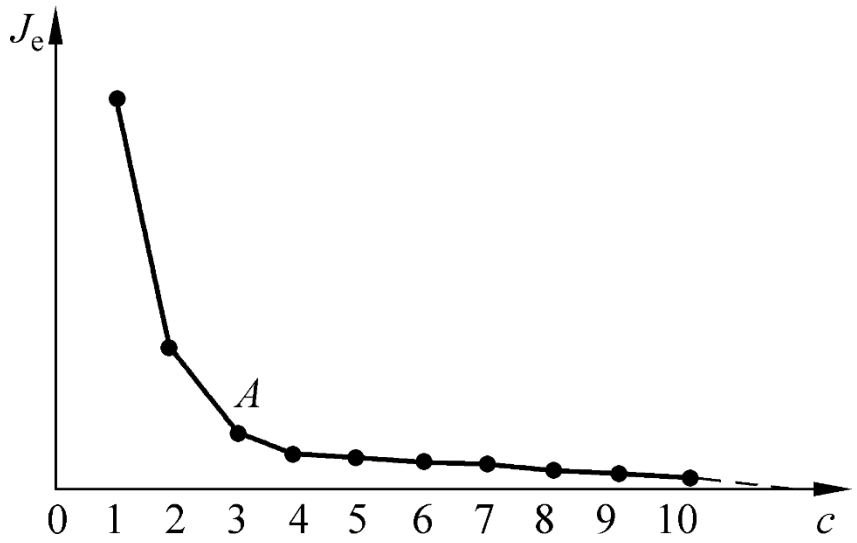
关于C均值方法的类别数c，多假定已知，由先验知识确定

- 一种实验确定方法：

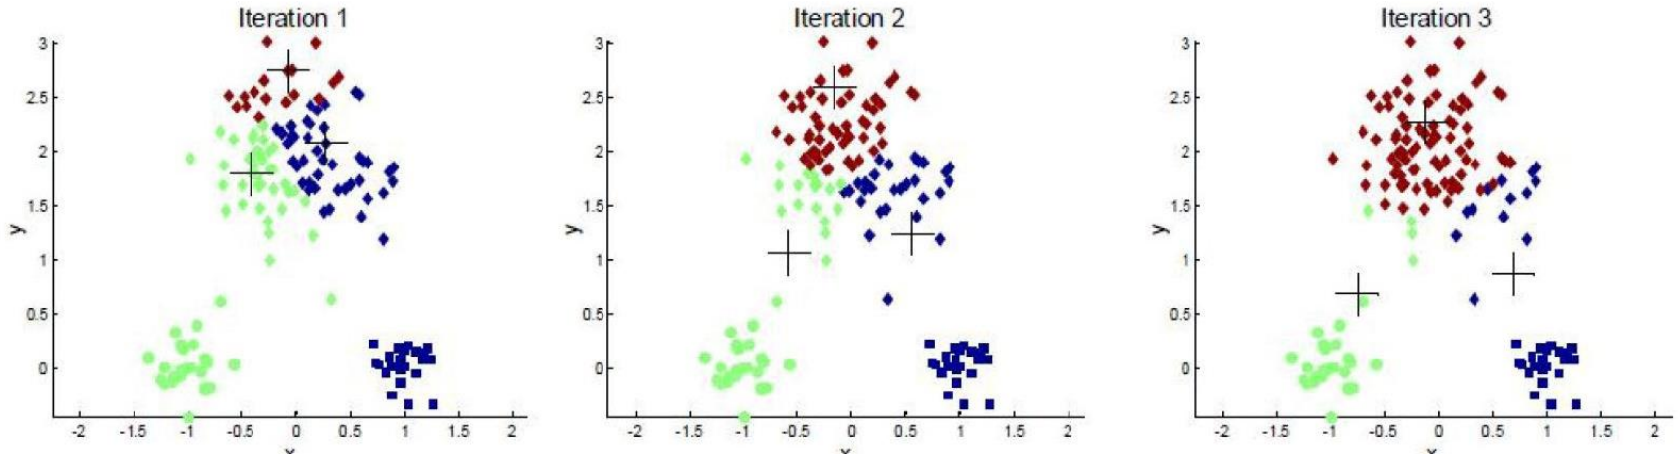
  对$c = 1,2,3,\cdots$聚类，求各自的$J_e(c)$。

  找到其中的拐点（图中$\hat{c} = 3$）

  （注：实际问题中并不一定有明确的拐点）

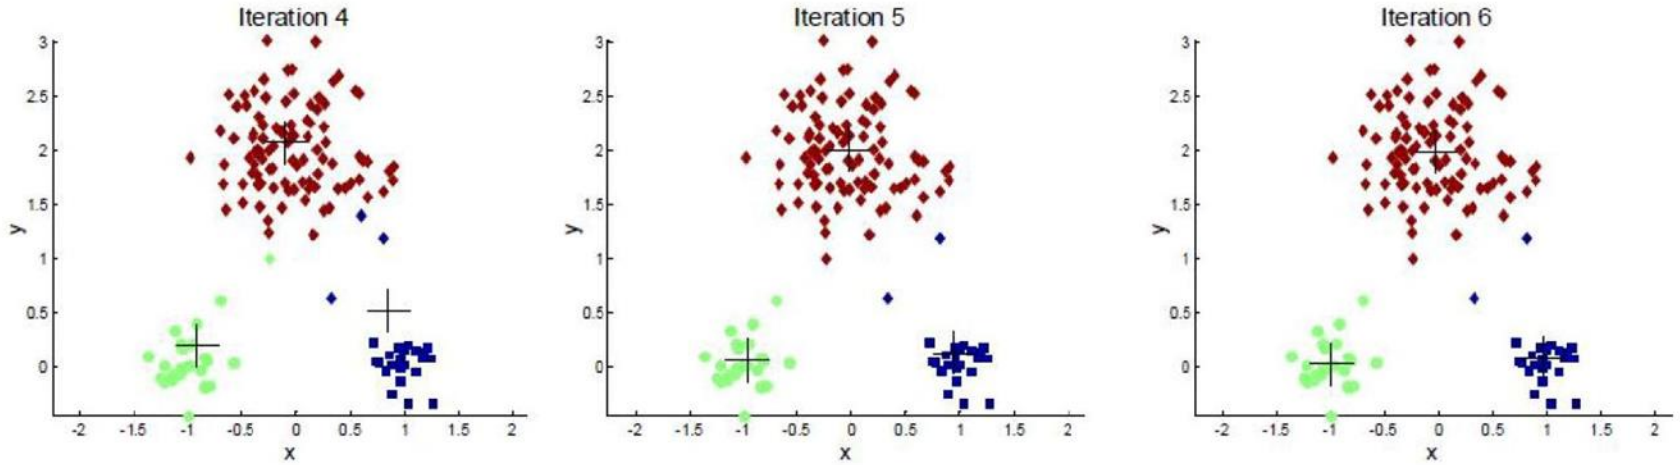


聚类问题（过程演示：初始中心的影响）



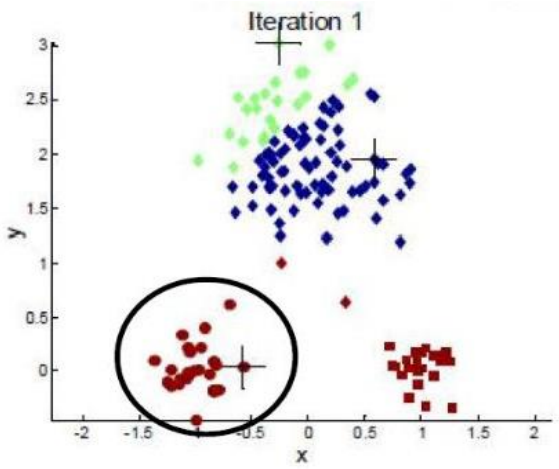
C=3
6次迭代后收敛

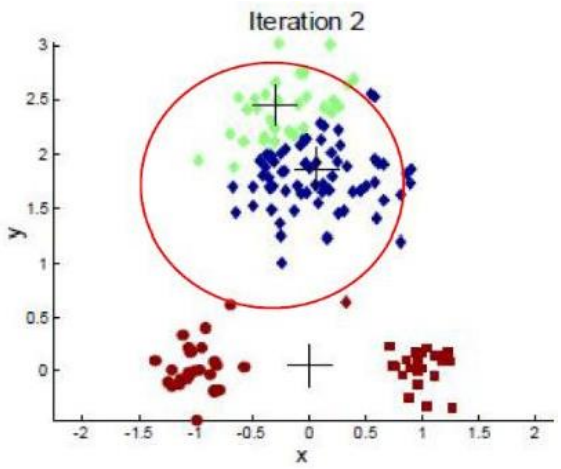
初始3个簇，生成点看似不好，聚类效果却不错。

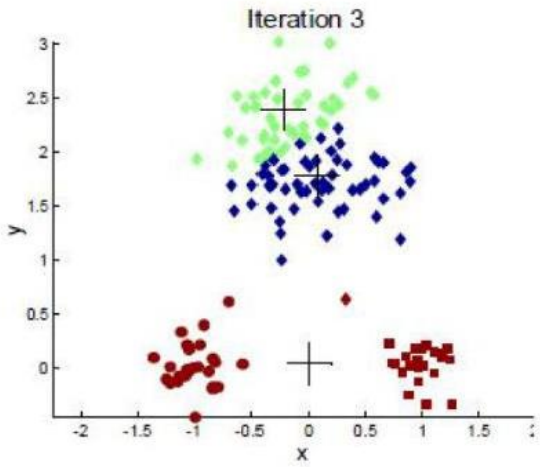


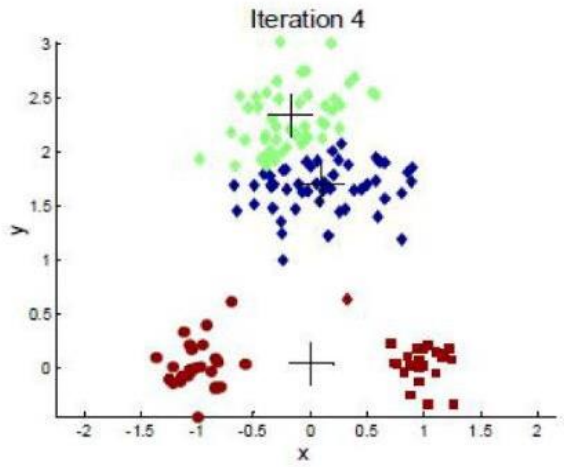
聚类问题（初始值不合适：不是最优解）

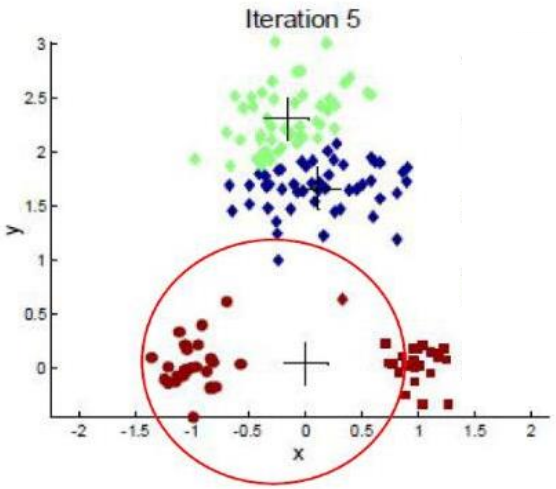
初始点位置
似乎不错







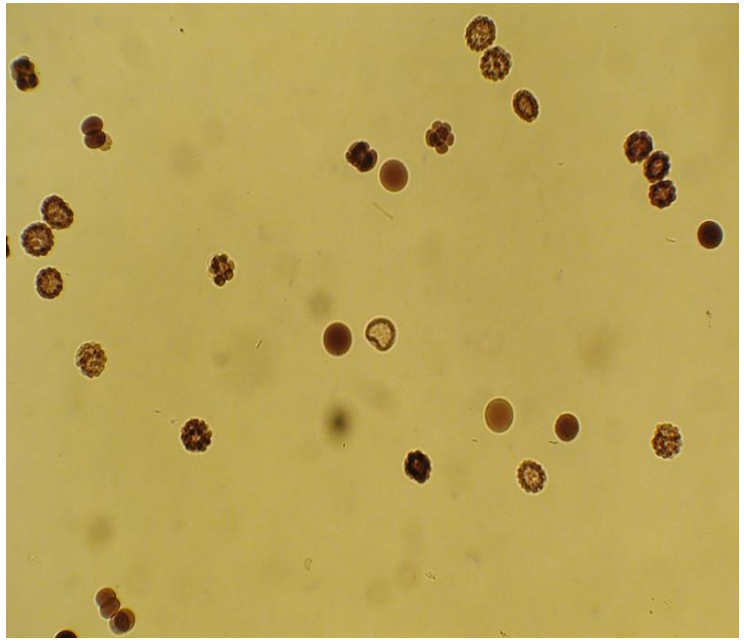


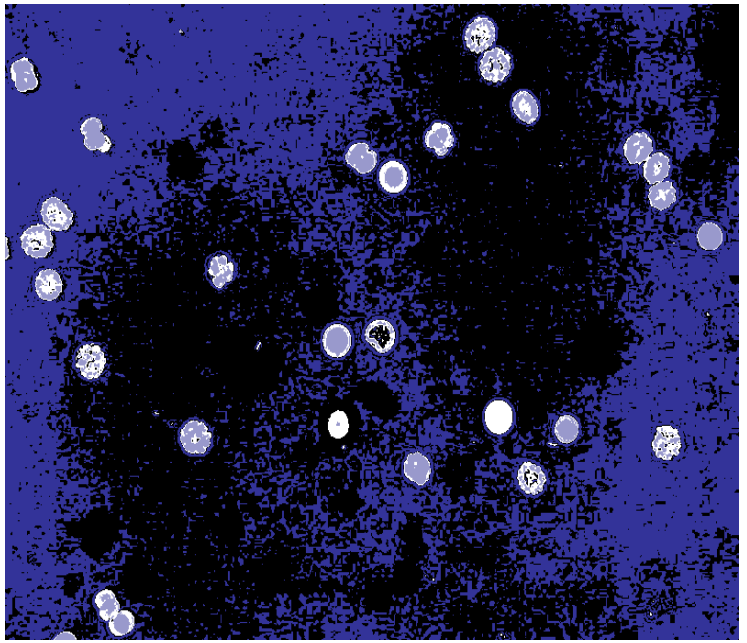


初始值敏感

一个大簇被分成绿蓝两个
两个分离的簇被认为是一个整体

C均值应用-彩色图像分割：



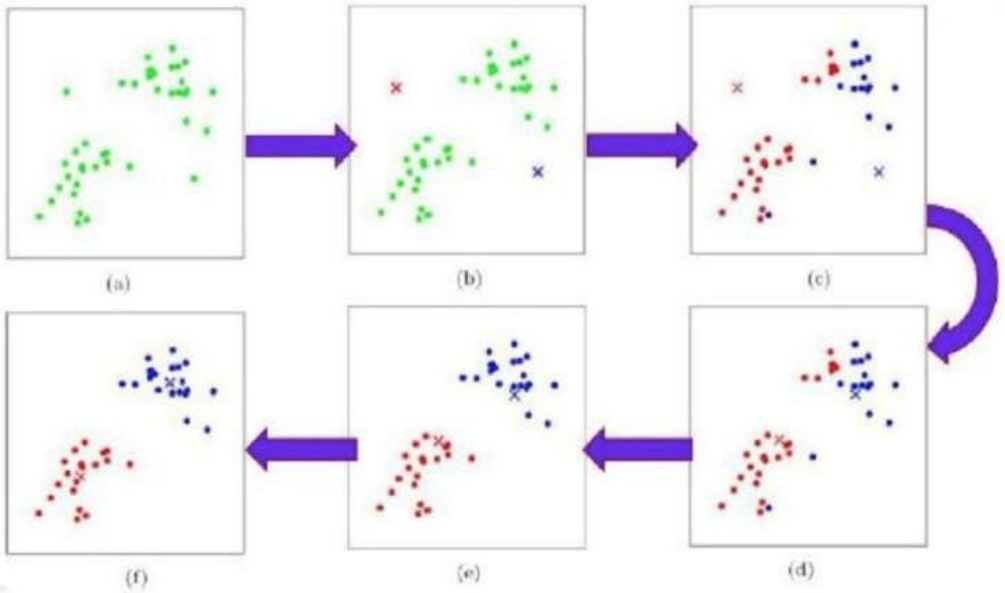


C均值聚类方法用于非监督模式识别的问题：

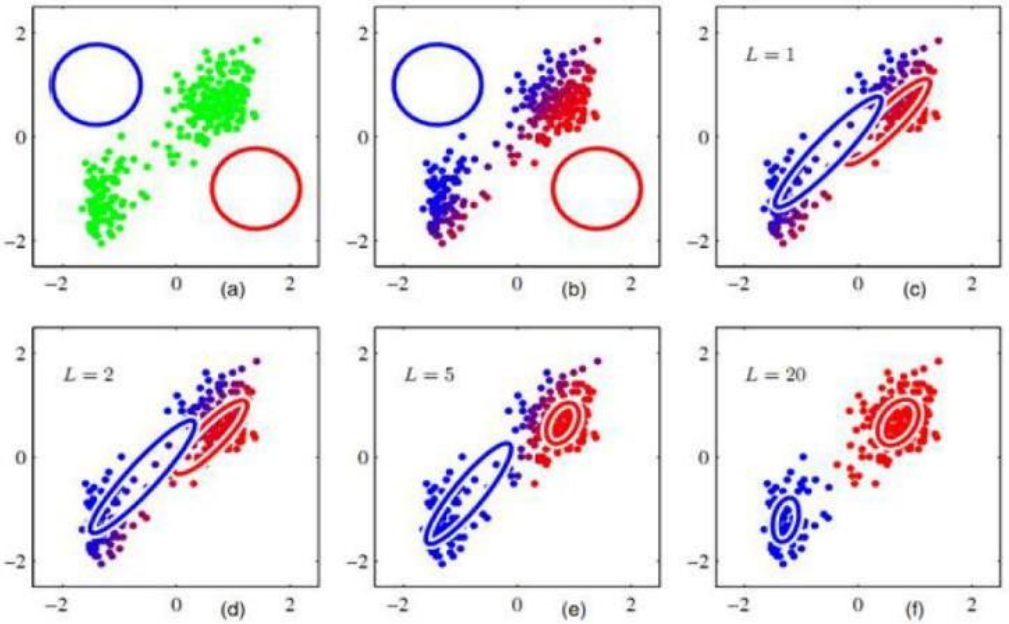
1. 要求类别数已知
2. 是最小方差划分，并不一定能反映内在分布
3. 与初始划分有关，不保证全局最优

C-means和混合正态分布模型

C-means



混合正态分布模型



混合高斯和C-means很相似，相似点在于两者的分类受初始值影响；两者可能限于局部最优解。

混合正态分布计算复杂度高于C-means。

课堂习题

1. 【单选】由于C均值聚类是一个迭代过程，我们需要设置其迭代终止条件。下面哪句话正确描述了K均值聚类的迭代终止条件（ B ）

A. 已经形成了C个聚类集合，或者已经达到了迭代次数上限

B. 已经达到了迭代次数上限,或者前后两次迭代中聚类质心基本保持不变

C. 已经达到了迭代次数上限,或者每个待聚类样本分别归属唯一一个聚类集合

D. 已经形成了C个聚类集合，或者每个待聚类样本分别归属唯一一个聚类集合

课堂习题

2. 【单选】我们可以从最小化每个类簇的方差这一视角来解释K均值聚类的结果，下面对这一视角描述不正确的是（ D ）

A. 每个簇类的方差累加起来最小

B. 每个样本数据分别归属于与其距离最近的聚类质心所在聚类集合

C. 最终聚类结果中每个聚类集合中所包含数据呈现出来差异性最小

D. 每个簇类的质心累加起来最小

课堂习题

3. 【单选】K-Means算法中的初始中心点（ D ）

A. 可随意设置

B. 必须在每个族的真实中心点的附近

C. 必须足够分散

D. 直接影响算法的收敛结果

课堂习题

4. 【单选】关于K-Means算法的表述正确的是（ C ）

A. 对数据分布没有特殊的要求

B. 能较好处理噪点和离群点

C. 对初始中心点较为敏感

D. 计算复杂度较高

8.5.3 模糊C均值算法

模糊C均值，要求 $\sum_{j=1}^{c}\mu_j(x_i)=1\,,i=1,\ldots,n$

求解：

令$\partial J_f/\partial m_j=0$ 和 $\partial J_f/\partial \mu_j(x_i)=0$，可得

$$m_j=\frac{\sum_{i=1}^{n}\left[\mu_j(x_i)\right]^b x_i}{\sum_{i=1}^{n}\left[\mu_j(x_i)\right]^b},\quad j=1,\cdots,c$$

$$\mu_j(x_i)=\frac{\left(1/\left\|x_i-m_j\right\|^2\right)^{1/(b-1)}}{\sum_{k=1}^{c}(1/\|x_i-m_k\|^2)^{1/(b-1)}},\qquad j=1,\cdots,c,\quad i=1,\cdots,n$$

模糊C均值算法（FCM）：

① 设定聚类数目c和常数b

② 初始化各聚类中心$m_j, j = 1, \ldots, c$（可参考上两节中的方法）

③ 重复下面的运算，直到各$\mu_j(x_i)$稳定

（1） 用当前的m_j计算$\mu_j(x_i)$

（2）用当前的$\mu_j(x_i)$计算m_j

④ 如需要，可对所有模糊聚类去模糊化

8.5.4 改进的模糊C均值算法（AFC）

模糊C均值算法的一个缺点：

由于$\sum_{j=1}^{c}\mu_j(x_i)=1$，故对某些野值（本应属于各类程度都很小），隶属度可能较大。

改进：放松归一化条件为$\sum_{j=1}^{c}\sum_{i=1}^{n}\mu_j(x_i)=n$

于是

$$m_j=\frac{\sum_{i=1}^{n}[\mu_j(x_i)]^b x_i}{\sum_{i=1}^{n}[\mu_j(x_i)]^b},\quad j=1,\cdots,c\text{（不变）}$$

$$\mu_j(x_i)=\frac{n\left(1/\|x_i-m_j\|^2\right)^{1/(b-1)}}{\sum_{k=1}^{c}\sum_{l=1}^{n}(1/\|x_l-m_k\|^2)^{1/(b-1)}},\quad j=1,\cdots,c,\quad i=1,\cdots,n$$

改进的模糊C均值算法步骤与模糊C均值相同

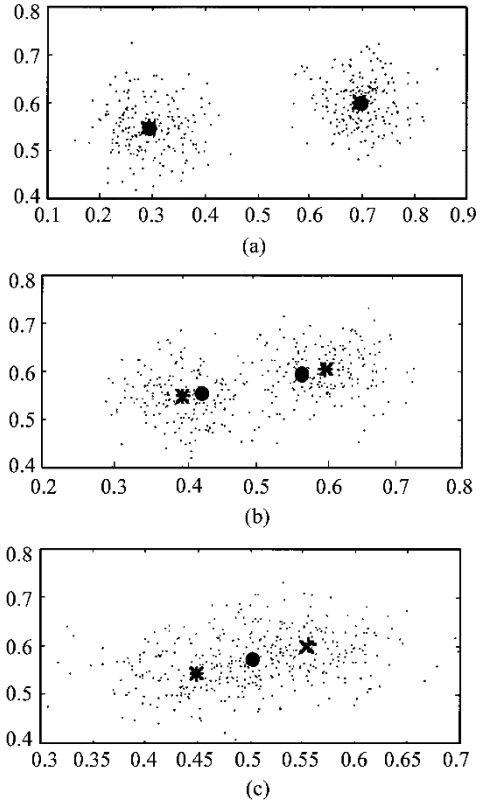
注意:

改进的模糊C均值算法所得到的$\mu_j(x_i)$可能大于1，不是严格意义下的隶属度函数。必要时可做归一化

特点：

- 改进的模糊C均值算法有更好的鲁棒，且对给定的聚类数目不十分敏感
- 但有时可能会出现一个类中只包含一个样本的情况，可通过在距离计算中引入非线性使之不会小于某值来改进
- 改进的模糊C均值和C均值一样，依赖于初值

实验效果举例

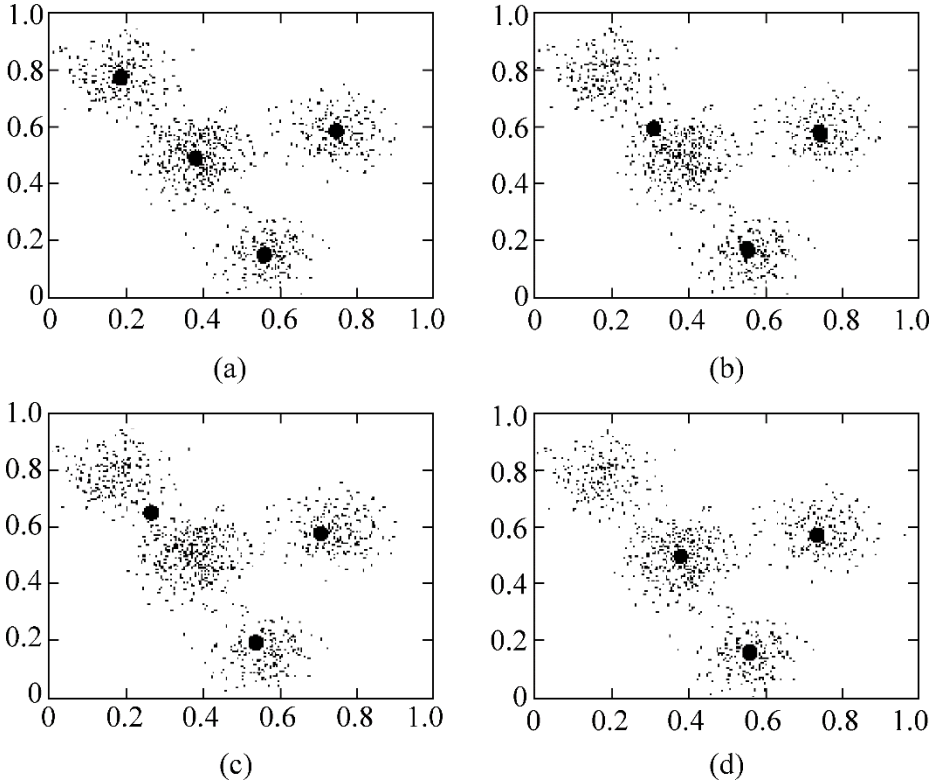


例一：类别重迭及类别不明显情况

+：C均值

×：模糊C均值

·：改进的模糊C均值

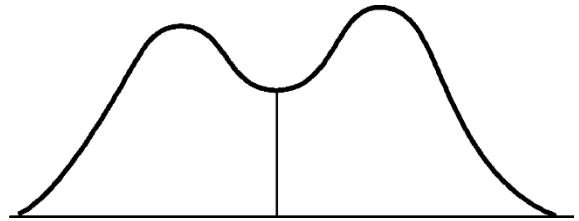


例二：给定类别数与实际类别数不一致的情况

8.6 基于模型的聚类方法：单峰子集分离法

基本假设：

每个聚类的样本分布是单峰的，根据总体分布中的单峰来划分子集



- 投影方法

基本思路：

把样本按照某种准则投影到某个一维坐标上，在这一维度上估计样本的概率密度，在其中寻找单峰并进行聚类划分

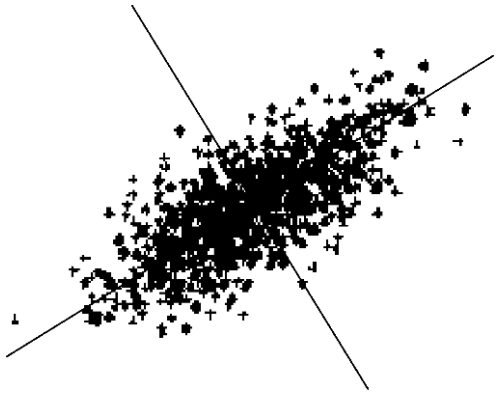
（如果这一维上只有一个峰，则寻找下一个投影方向）

投影方向：

使方差最大的方向，即协方差阵本征值最大的本征向量方向

算法步骤：

(1) 主成分分析：计算所有样本 $\{x\}$ 的协方差矩阵的最大本征值对应的本征向量 u_j, 把样本投影到 u_j 上



(2) 估计投影后样本 $v_j = u_j^T x$ 的概率密度函数 $P(v_j)$

（用直方图方法或其它方法）

(3) 求 $P(v_j)$ 中的极小点（波谷）

在这些极小点上作垂直于 u_j 的超平面作为分类超平面，得到子集划分

(4) 如果 $P(v_j)$ 上没有这种极小点

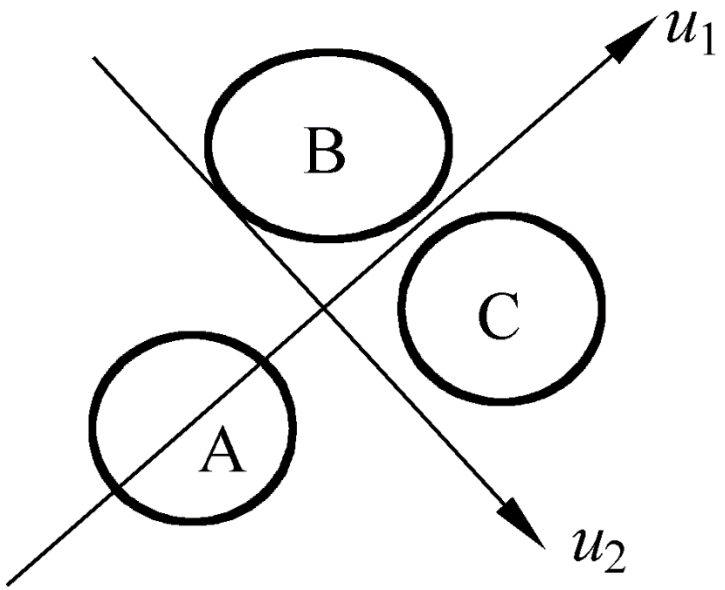
则用下一个本征值对应的本征向量作为投影方向，重复（2）～（3）

(5) 对划分出的每一个子集重复上述过程，直到不能再分（所有方向上都是单峰）

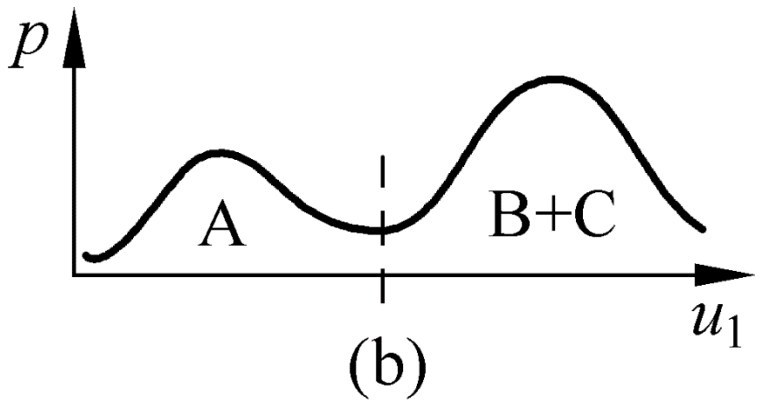
问题：

如何选择投影方向？　　---方差最大的准则有时并不一定最有利于聚类

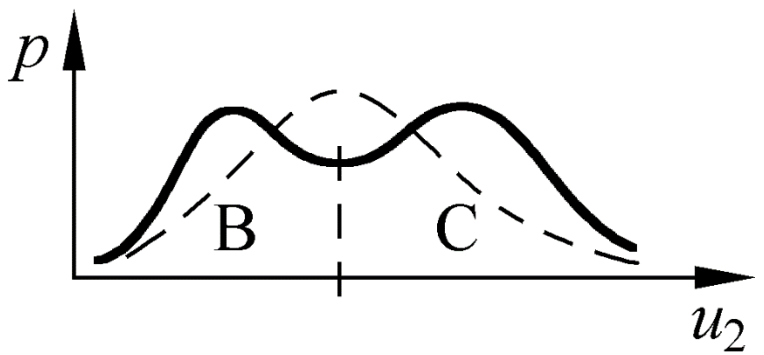
有效的聚类：



(a)

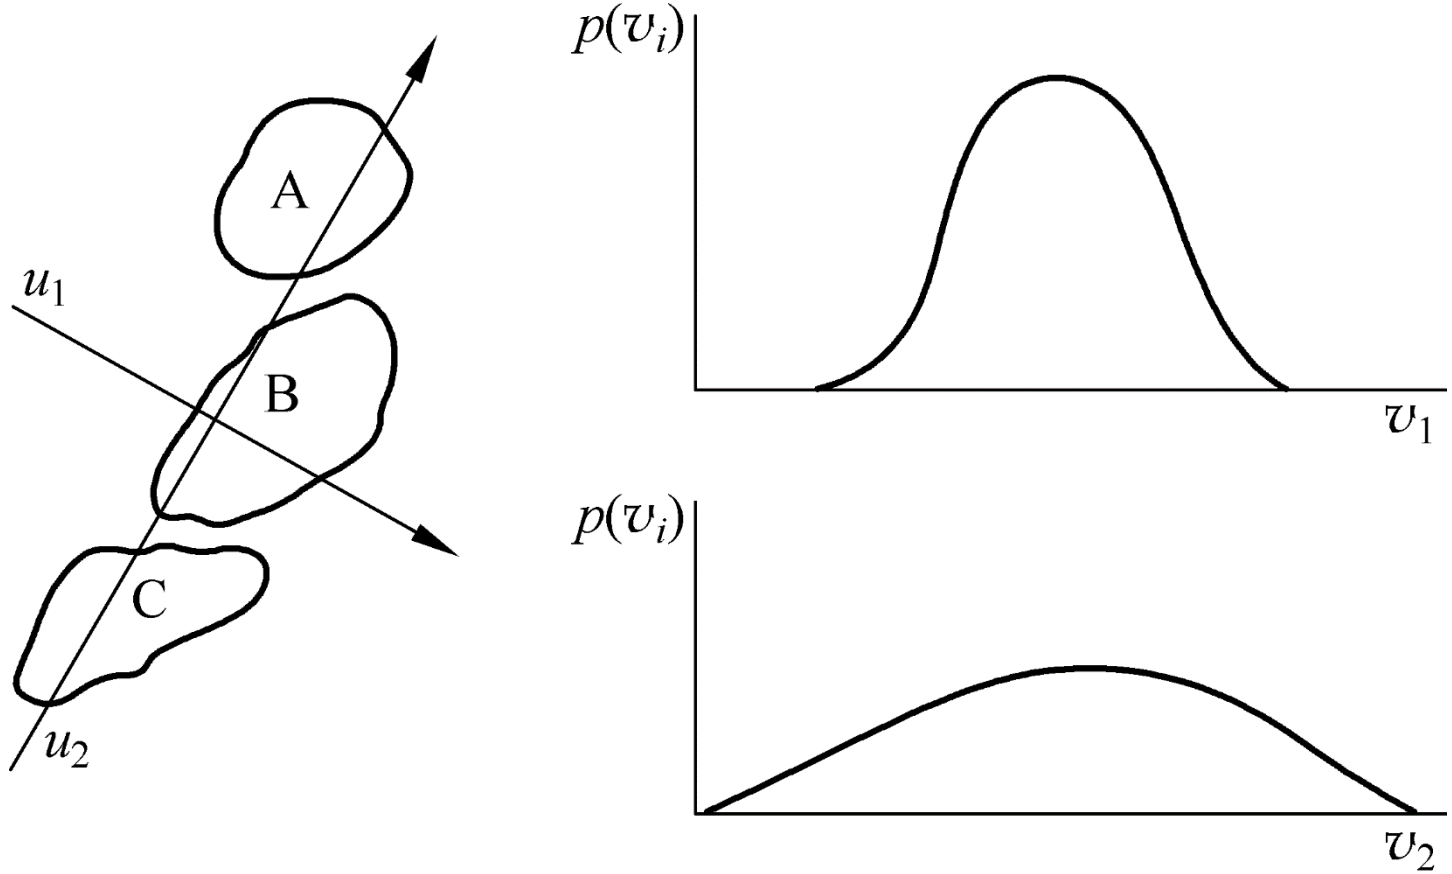


(b)



(c)

失败的聚类：



8.7 混合模型的估计：非监督参数估计

定义：

非监督参数估计指样本类别未知，但各类条件概率密度函数的形式已知，根据所有样本估计各类密度函数中的参数。

- 本节只介绍非监督最大似然估计的思路

8.7.1混合密度的最大似然估计

（一） 假设条件

1. 样本集 $X = \{x_1, \ldots, x_N\}$ 中的样本属于c 个类别，但不知各样本属哪类。
2. 类先验概率 $P(\omega_i), i = 1, \ldots, c$ 已知
3. 类条件概率密度形式已知 $P(x \mid \omega_i, \theta_i), i = 1, \ldots, c$
4. 未知是仅是 c 个参数向量 $\theta_1, \theta_2, \ldots, \theta_c$ 的值

   所有未知参数组成的向量记为 $\theta = [\theta_1, \theta_1, \ldots, \theta_c]^T$

（二） 似然函数

混合密度：$p(x|\theta)=\sum_{i=1}^{c}p(x|\omega_i,\theta_i)P(\omega_i)$

分量密度：类条件密度$p(x|\omega_i,\theta_i)$

混合参数：先验概率 $P(\omega_i)$（有时也可未知，一起参与估计）

设样本集x中的样本是从混合密度为$p(x|\theta)$ 的总体中独立抽取的，即满足独立同分布条件，θ确定但未知，则

似然函数： $l(\theta)=p(X|\theta)=\prod_{i=1}^{N}p(\,x_i|\theta)$

对数似然函数： $H(\theta)=ln[l(\theta)]=\sum_{i=1}^{N}\ln p(\omega_i|\theta_i)$

最大似然估计$\hat{\theta}$就是使 $l(\theta)$ 或 $H(\theta)$ 取最大的 θ 值

（三）可识别性问题

求出$\hat{\theta}$，就得到了$\hat{\theta}_1, \ldots, \hat{\theta}_c$，即从混合密度函数中恢复出了分量密度函数。

可能吗？什么条件下可能？

可识别性定义：

若对$\theta \neq \theta'$，对混合分布中每个x都有 $p(x|\theta) \neq p(x|\theta')$，则密度$p(x|\theta)$是可识别的

- 大部分常见连续随机变量的分布密度函数都是可识别的
- 离散随机变量的混合概率函数则往往是不可识别的

（四）计算问题

对于可识别的似然函数，如何求最大似然估计？

思路同监督情况，即如果$p(x|\theta)$对θ可微，则令

$$\nabla_\theta H(\theta) = 0$$

得一系列方程组，它们是最大似然估计的必要条件，若存在唯一极值则就是解。

$$\nabla_{\theta_i} H(\theta) = \sum_{k=1}^{N} \frac{1}{p(x_k|\theta)} \nabla_{\theta_i} \left[\sum_{j=1}^{c} p\left(x_k \middle| \omega_j, \theta_j\right) P(\omega_j) \right]$$

$$= \sum_{k=1}^{N} \frac{1}{p(x_k|\theta)} \nabla_{\theta_i} [p(x_k|\omega_i, \theta_i) P(\omega_i)] \quad (\text{设}\theta_i, \theta_j \text{独立})$$

$$= \sum_{k=1}^{N} \frac{1}{p(x_k|\theta)} \nabla_{\theta_i} \ln p(x_k|\omega_i, \theta_i)$$

其中后验概率 $\mathrm{P}(\omega_i|x_k,\theta_i)=\frac{p(x_k|\omega_i,\theta_i)P(\omega_i)}{p(x_k|\theta)}$

有微分方程组：

$$\nabla_{\theta_i}H\left(\hat{\theta}\right)=0,i=1,2,\ldots,c$$

另，若$P(\omega_i)$也未知，则可引入限制条件:

$$P(\omega_i)>0,i=1,2,\ldots,c$$

$$\sum_{i=1}^{c}P(\omega_i)=1$$

可用 Lagrange 法求条件极值问题，定义 Lagrange 函数:

$$H'=H+\lambda\left[\sum_{i=1}^{c}P(\omega_i)-1\right]$$

可得：

$$\hat{P}(\omega_i) = \frac{1}{N}\sum_{k=1}^{N} \hat{P}\left(\omega_i \middle| x_k, \hat{\theta}_i\right), i = 1,2,\dots,\mathrm{c}$$

$$\sum_{k=1}^{N} \hat{P}\left(\omega_i \middle| x_k, \hat{\theta}_i\right) \nabla_{\theta_i} \ln p\left(x_k \middle| \omega_i, \hat{\theta}_i\right) = 0, i = 1,2,\dots,\mathrm{c}$$

其中 $\hat{P}\left(\omega_i \middle| x_k, \hat{\theta}_i\right) = \frac{p\left(x_k \middle| \omega_i, \hat{\theta}_i\right)\hat{P}(\omega_i)}{\sum_{j=1}^{c} p\left(x_k \middle| \omega_i, \hat{\theta}_i\right)\hat{P}(\omega_i)}, i = 1,2,\dots,\mathrm{c}$

原则上可以从上述微分方程组中求解出最大似然估计$\hat{\theta}$和$\hat{P}(\omega_i)$

但实际上多数问题中只能采用某种迭代方法求解

8.7.2 混合正态分布的参数估计

混合高斯模型（mixture of Gaussian models）：

混合模型中的各个分布都是多维正态分布，即

$$p(x|\omega_i,\theta_i)\sim N(\mu_i,\Sigma_i)$$

主要有三种情况：（“？”表示未知，“✓”表示已知）

情况	μ_i	Σ_i	$P(\omega_i)$	c
1	?	✓	✓	✓
2	?	?	?	✓
3	?	?	?	?

其中第3种情况无法用最大似然法求解

（一） 情况1：均值向量μ_i未知，其他参数已知

由上节知最大似然估计满足方程组

$$\sum_{k=1}^{N} \hat{P}(\omega_i|x_k,\hat{\theta}_i)\nabla_{\theta_i} ln\, p\,(x_k|\omega_i,\hat{\theta}_i) = 0, i = 1,\dots,c$$

代入正态分布公式，可得

$$\sum_{k=1}^{N} P(\omega_i|x_k,\hat{\mu}_i)\ \ \Sigma_i^{-1}(x_k - \hat{\mu}_i) = 0$$

即

$$\hat{\mu}_i = \frac{\sum_{k=1}^{N} P(\omega_i|x_k, \hat{\mu}_i) x_k}{\sum_{k=1}^{N} P(\omega_i|x_k, \hat{\mu}_i)}$$

样本的加权平均，物理意义明确

可惜权值中包含未知参数

其中

$$\hat{P}(\omega_i|x_k, \hat{\mu}_i) = \frac{p(x_k|\omega_i, \hat{\mu}_i) P(\omega_i)}{\sum_{j=1}^{c} p(x_k|\omega_j, \hat{\mu}_j) P(\omega_j)}$$

迭代法求解：

用某种方法得到一个较好的初值$\hat{\mu}_i\,(0)$，然后用下式迭代：

$$\hat{\mu}_i(j+1)=\frac{\sum_{k=1}^{N}P(\omega_i|x_k,\hat{\mu}_i(j))x_k}{\sum_{k=1}^{N}P(\omega_i|x_k,\hat{\mu}_i(j))}$$

—— 梯度法，可能不是全局最优解，受初值影响大

（二） 情况2：类别数目c已知，其他参数均未知

思路与（一）类似，将有关分布公式代入上小节方程即可，只是公式复杂一些，也可得到物理意义明确的方程式，但一般也只能用迭代法求解

回顾：

基于模型的方法：　1. 估计概率密度函数 —— 困难

2. 寻找密度函数中的单峰

需要较多样本或先验知识，在非监督学习中不易满足

基于相似性度量的聚类方法：

考查样本之间的相似性，根据相似性把样本集划分为若干子集，使某种表示聚类质量的准则函数最优

相似性度量：以某种距离定义

直观理解：同一类的样本的特征向量应是相互靠近的

——前提：特征选取合理，能反映所感兴趣的关系

8.8 动态聚类算法

动态聚类方法

多次迭代，逐步调整类别划分，最终使某准则达到最优

三个要点：

① 选某种距离作为样本相似性度量

② 定义某个准则函数，用于评价聚类质量

③ 初始分类方法及迭代算法

8.8.1 ISODATA方法

ISODATA:

- iterative self-organizing data analysis techniques（迭代自组织数据分析技术）

特点：

① 成批样本修正，把所有样本调整完后才重新计算均值

② 可进行类别合并与分裂

算法步骤：

① 初始化，聚类数c, 中心$m_i,\ i = 1,2,\ldots,\mathrm{c}$（不一定等于期望聚类数$k$）

② 把所有样本分到距离最近的类中，$\Gamma_i,\ i = 1,2,\ldots,\mathrm{c}$

③ 若某个类Γ_i中样本数过少（$N_j < \theta_N$），则去掉这一类（合入其他类），置$c = c - 1$

④ 重新计算均值$m_j = \frac{1}{N_j}\sum_{y\in\Gamma_j} y\,, y = 1,\ldots,c$

⑤ 计算第j类样本与其中心的平均距离

$$\bar{\delta}_j = \frac{1}{N_j}\sum_{y\in\Gamma_j}\left\|y - m_j\right\|,\ j = 1,\ldots,c$$

和总平均距离$\bar{\delta} = \frac{1}{N}\sum_{j=1}^{c} N_j\bar{\delta}_j$

⑥ 若是最后一次迭代（由参数I确定），则程序停止；

若$c \le k/2$，则转⑦（分裂）；

若$c \ge 2k$，或是偶数次迭代，则转⑧（合并）

⑦ （分裂）

7-1 对每个类，求各维标准偏差$\sigma_j = \left[\sigma_{j1}, \sigma_{j2}, \cdots, \sigma_{jd}\right]^T$

$$\sigma_{ji} = \sqrt{\frac{1}{N_j}\sum_{y_k \in \Gamma_j}\left(y_{ki} - m_{ji}\right)^2}, \quad j = 1, \ldots, c, \quad i = 1, \ldots, d$$

7-2 对每个类，求出标准偏差最大的分量σ_{jmax}， $j = 1, \ldots, c$

7-3 若对σ_{jmax}， $j = 1, \ldots, c$存在$\sigma_{jmax} > \theta_s$（标准偏差参数）

且$\bar{\delta}_j > \bar{\delta},$， $N_j > 2(\theta_N + 1)$，或$c \le k/2$

则Γ_j分裂为两类，中心分别为m_j^+和m_j^-，置$c = c + 1$

$$m_j^+ = m_j + \gamma_j, \quad m_j^- = m_j - \gamma_j$$

其中$\gamma_j = k\sigma_{jmax}$， $0 < k \le 1$

⑧ （合并）

8-1 计算各类中心之间的距离算

$$\delta_{ij} = \|m_i - m_j\|，\ i,j = 1,\cdots,c，\ i \neq j$$

8-2　比较δ_{ij}与θ_c(合并参数)，对小于θ_c者排序

$$\delta_{i_1 j_1} < \delta_{i_2 j_2} < \cdots < \delta_{i_l j_l}$$

8-3　从最小的$\delta_{i_l j_l}$开始，把每个$\delta_{i_l j_l}$对应的m_{i_l}和m_{j_l}合并：

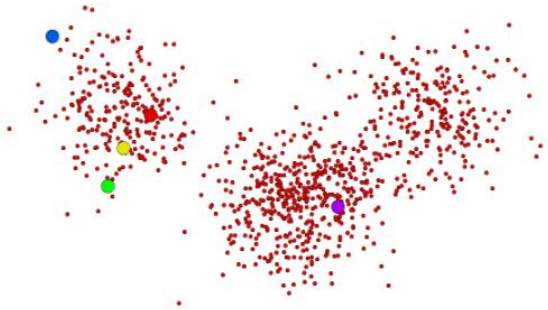
$$m_l = \frac{1}{N_{i_l} + N_{j_l}} \left[N_{i_l} m_{i_l} + N_{j_l} m_{j_l} \right]$$

并置$c = c - 1$。每次迭代中避免同一类被合并两次

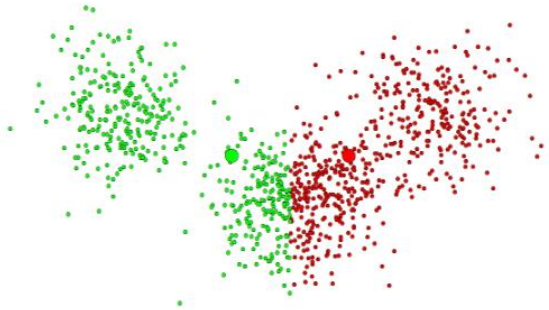
⑨ 若是最后一次迭代，则终止；

否则迭代次数加1，转②　（必要时可调整算法参数）

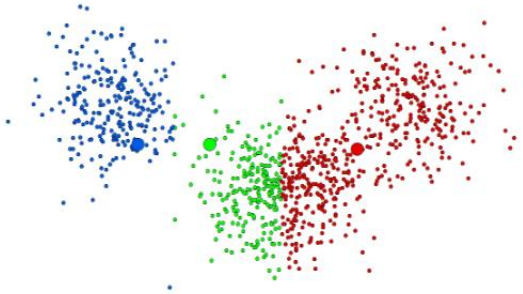
用ISODATA聚类过程的迭代图



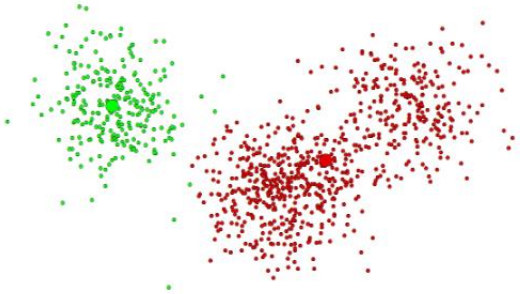
初始状态



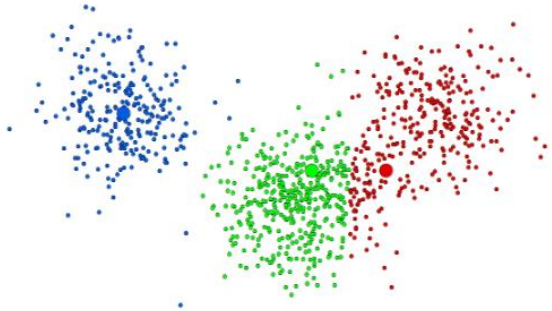
第1次迭代



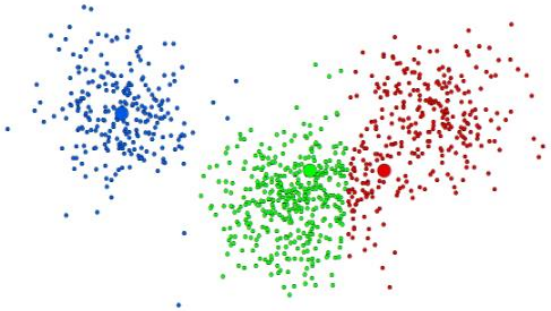
第2次迭代



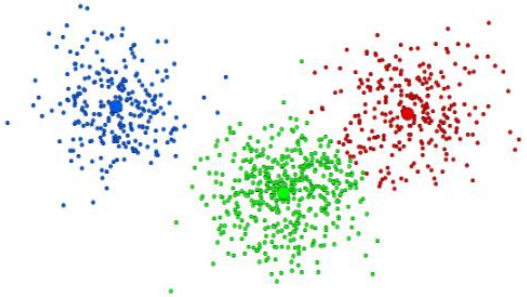
第3次迭代



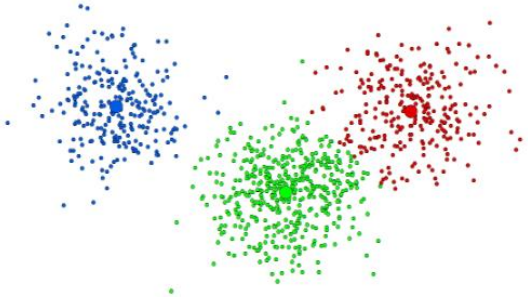
第4次迭代



第5次迭代



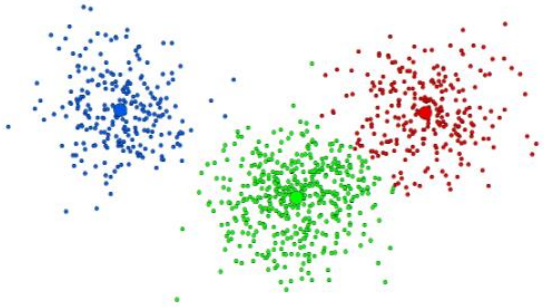
第6次迭代



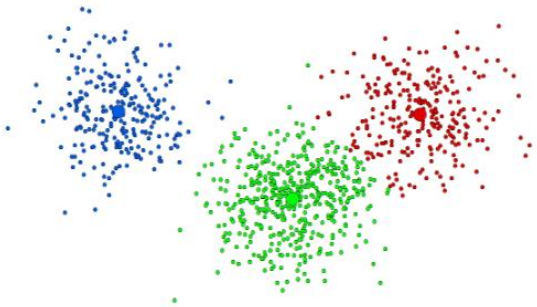
第7次迭代



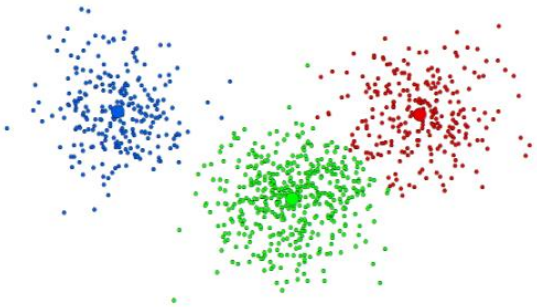
第8次迭代



第9次迭代



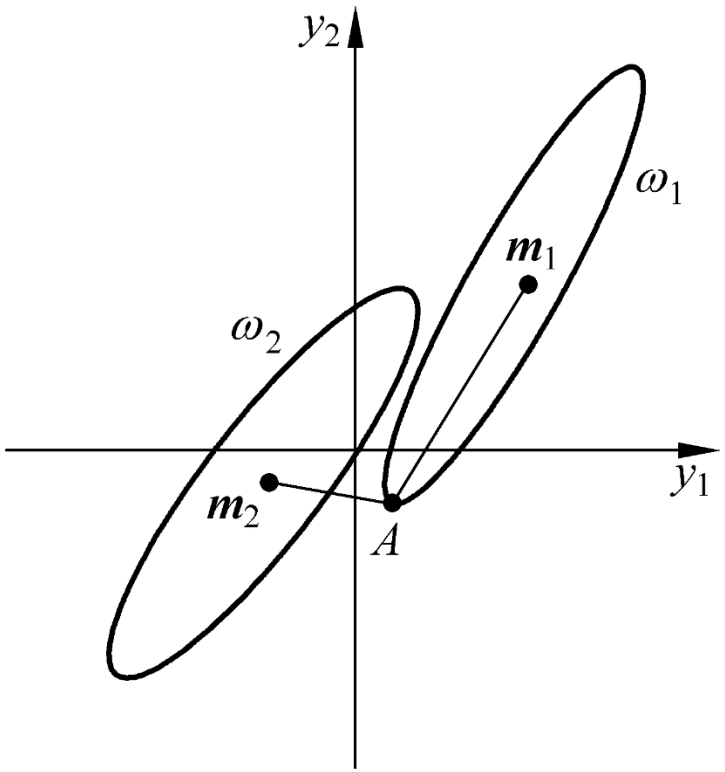
第10次迭代



第11次迭代

8.8.2 基于核的动态聚类算法

- C均值方法的缺点：
  - 用均值代表类，只适用于近似球状分布的类
- 改进：
  - 用核$K_j = k(y, V_j)$来代表一个类Γ_i，V_j是参数集
  - 核K 可以是一个函数、一个点集或某种分类模型
  - 定义样本y到类Γ_i（核k_j）之间的相似性度量$\Delta(y, k_j)$



准则函数

$$J_k = \sum_{i=1}^{c} \sum_{y \in \Gamma_j} \Delta(y, k_j)$$

算法

① 初始划分，得到初始核$k_j,\ j = 1, \ldots, c$

② 按以下规则把各样本分类：

若$\Delta(y, k_j) = \min_{k=1,\cdots,c} \Delta(y, k_k)$，则$y \in \Gamma_j$

③ 更新$k_j,\ j = 1, \ldots, c$，若k_j不变，则总之；否则转②

C均值可看作k_j为m_j，Δ为欧氏距离下的特例

两种核函数举例

1. 正态核函数：

$$k_k(y, V_j) = \frac{1}{(2\pi)^{d/2}\left|\widehat{\sum}_j\right|^{1/2}} exp\left\{-\frac{1}{2}(y - m_j)^T \widehat{\sum}_j^{-1}(y - m_j)\right\}$$

$$V_j = \{m_j, \hat{\Sigma}_j\}$$

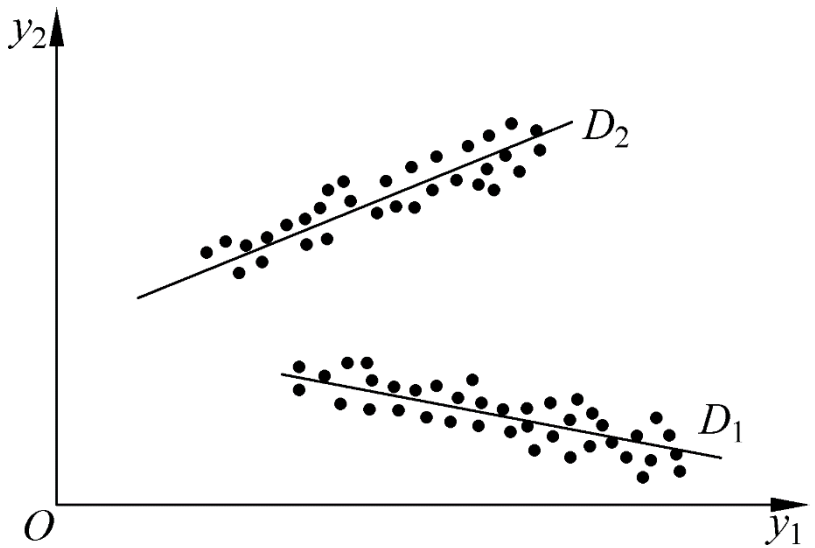
$$\Delta(y, k_j) = \frac{1}{2}(y - m_j)^T \widehat{\sum}_j^{-1}(y - m_j) + \frac{1}{2} log\left|\widehat{\sum}_j\right|$$

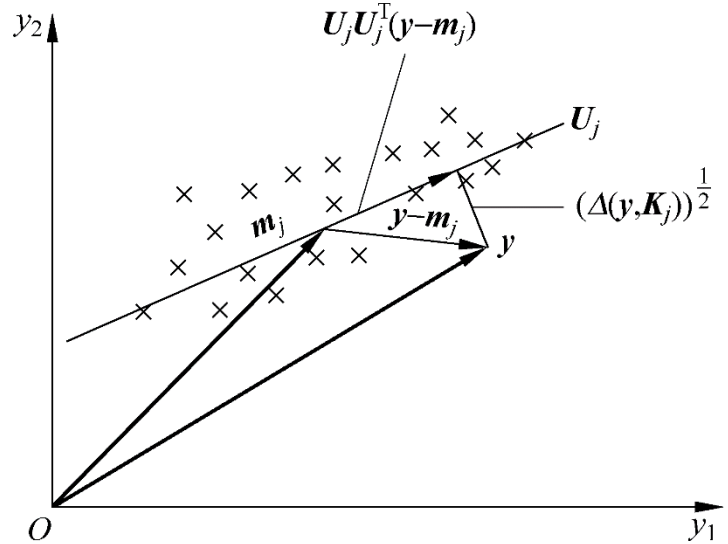
2. 主轴核函数：

用KL变换得到样本子集的主轴方向作为核：$k(y, V_j) = U_j^T y$

$U_j^T = \left[u_1, u_2, \cdots, u_{d_j}\right]$是$\hat{\sum}_j$的$d_j$个最大本征值的本征向量系统。

$$\Delta(y, k_j) = \left[(y - m_j) - U_j U_j^T (y - m_j)\right]^T \left[(y - m_j) - U_j U_j^T (y - m_j)\right]$$

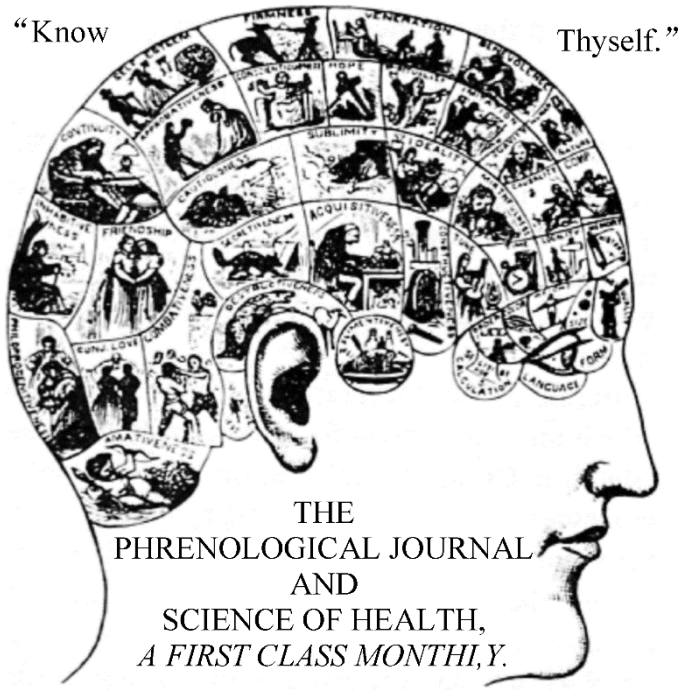


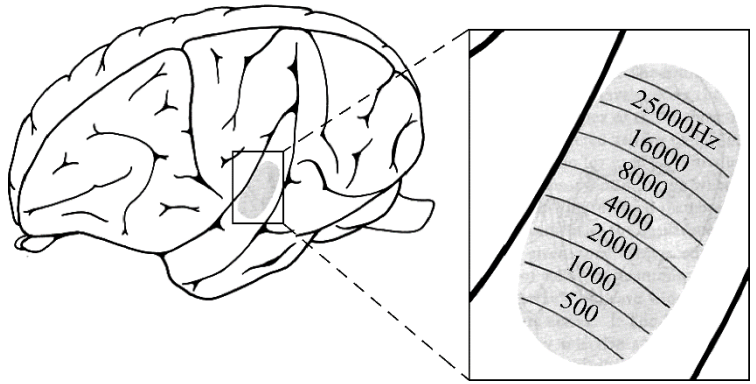


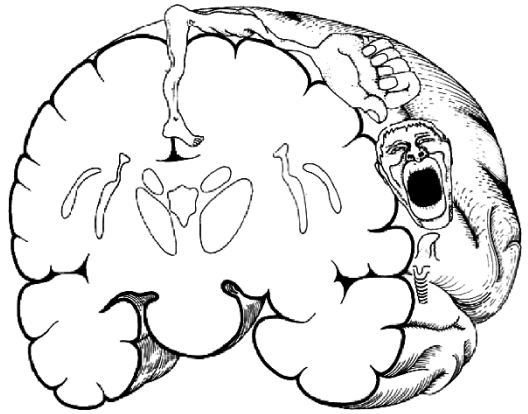
8.9 自组织映射（SOM）神经网络

自组织映射Self-Organizing Map，亦称SOFM。 Kohonen提出（1980s）

神经系统的自组织功能

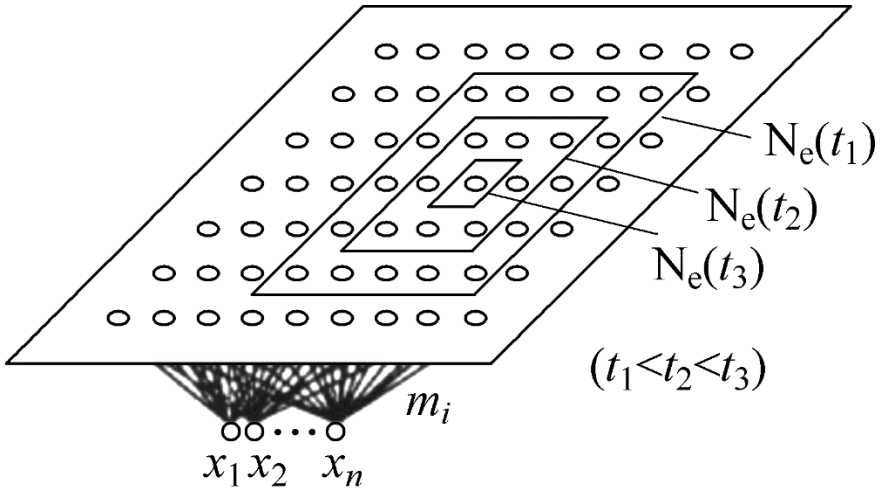






8.9.1 SOM网络结构

- 神经元呈平面分布(或其它空间分布)
- 输入向量的每一维连接到每个结点
- 结点间依分布位置关系而有相互作用



(b) 矩形邻域作用示意

神经元计算特性：　向量匹配，与输入向量最佳匹配者称winner

(计算距离或内积)　　(最大响应)

8.9.2 SOM学习算法和自组织特性

SOM算法：

① 权值初始化（小随机数，不能相等）

② 在t时刻 ，加入一个输入样本 （从样本集中选择或抽取，有时须调整顺序）

③ 寻找最佳匹配点 （winner）

如用欧氏距离匹配，则c： $\|x(t)-m_c(t)\|=\min\limits_{i\in A}\{\|x(t)-m_i(t)\|\}$

④ 权值竞争学习：

$$m_i(t+1)=m_i(t)+\alpha(t)h_{ci}(t)d[x(t),m_i(t)],\forall i\in A$$

其中$\alpha(t)$为步长，$h_{ci}(t)$为结点i与c之间的近邻函数值。

$d[\cdot,\cdot]$为误差函数，通常可采用欧氏距离，

如采用矩形领域，则

$$m_i(t+1)=\begin{cases} m_i(t)+\alpha(t)[x(t)-m_i(t)] & i\in N_c(t). \\ m_i(t) & i\notin N_c(t). \end{cases} \quad \forall i\in A$$

$N_c(t)$是结点c的矩形领域中的结点集合

⑤ 更新步长$\alpha(t)$和领域$N_c(t)$，如达到终止条件（如迭代次数）则终止，否则置$t=t+1$，转②

($\alpha(t)$和$N_c(t)$一般应随t增大而减小和缩小)

SOM特性：

经过适当训练后，结点对输入的响应表现出一定的规律性，这些规律性反映了输入样本集内部的一些特性（样本分布密度及样本间拓扑关系）。

名词解释：

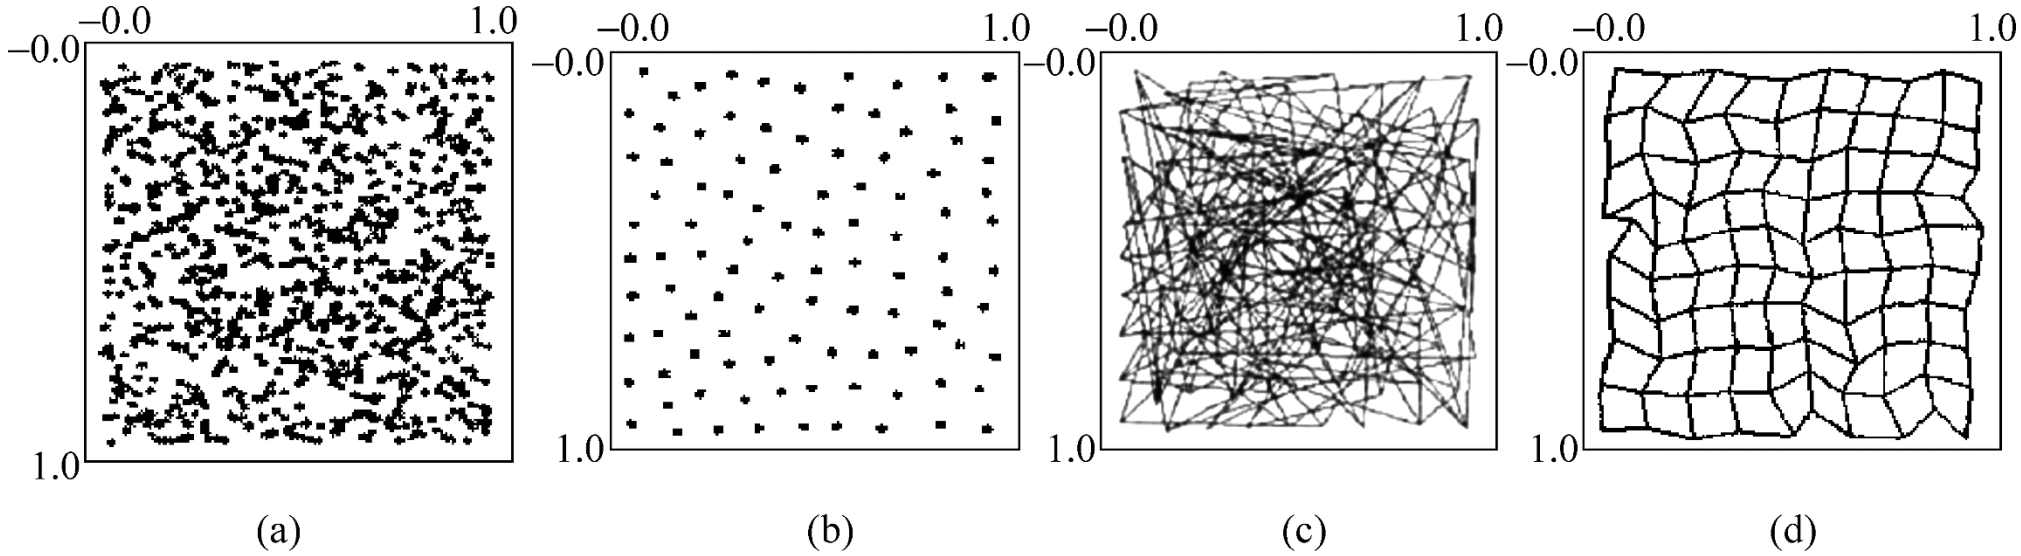
- 象：随着不断学习，对于某个输入向量，对应的winner结点逐步趋于固定，这个结点称作该样本的象
- 原象：若向量$\boldsymbol{x}$的象为结点i，则称$\boldsymbol{x}$为i的一个原象
- 象密度：同一结点上原象的数目，即有多少样本映射到该结点
- 象密度图：按结点位置把象密度（的相对值）画到一张图上

自组织特性：

在经过充分的学习之后，对用于学习的样本集

- 每个样本有且只有一个象（固定映射到某一结点），但一个结点可能有多个原象（也可能没有）
- 在原空间中距离相近的样本趋于映射到相同或相近的象
- 结点象密度与其原象附近原空间中的样本密度有某种单调关系

如果取消SOM中邻域作用，则SOM等价于C均值方法，或者向量量化



当引入邻域相互作用后，出现自组织现象

8.9.3 SOM用于模式识别的做法

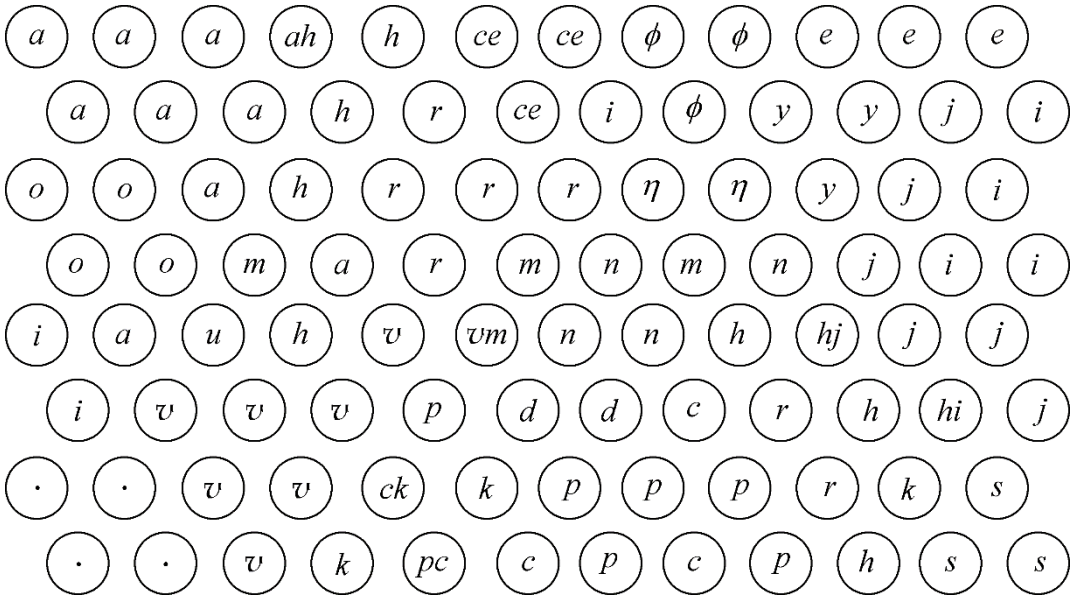
Kohonen芬兰语语音识别

① 用一批（有代表性）的样本训练SOM，（自学习）使之出现自组织特性，

（形成对输入空间的映射）

② 用一批类别已知的样本（可以与训练样本集相同）去标定在SOM上的象，完成对各结点的分类

③ 输入待识别样本，计算其象结点位置，根据象的类别标号确定样本的类别



思路类似于先作向量量化（聚类），用较少的代表点（子类）代表原样本空间，把这些代表点进行分类。 —— LVQ（学习向量量化）

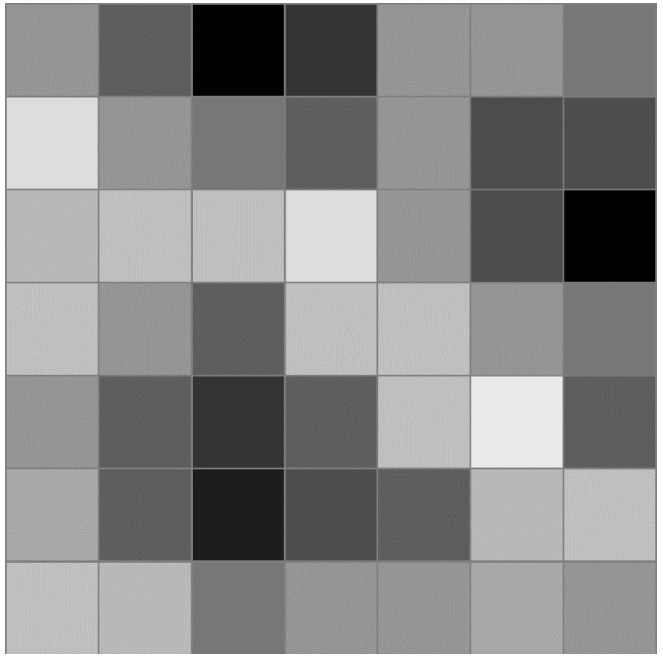
与普通向量量化（C均值聚类）的不同：

- 所得到的代表点本身是有序的，且保持了所代表的子集在原空间中的相对关系

- SOM用于非监督模式识别

  自组织学习过程本身就是一个非监督学习过程

- SOMA(自组织分析)



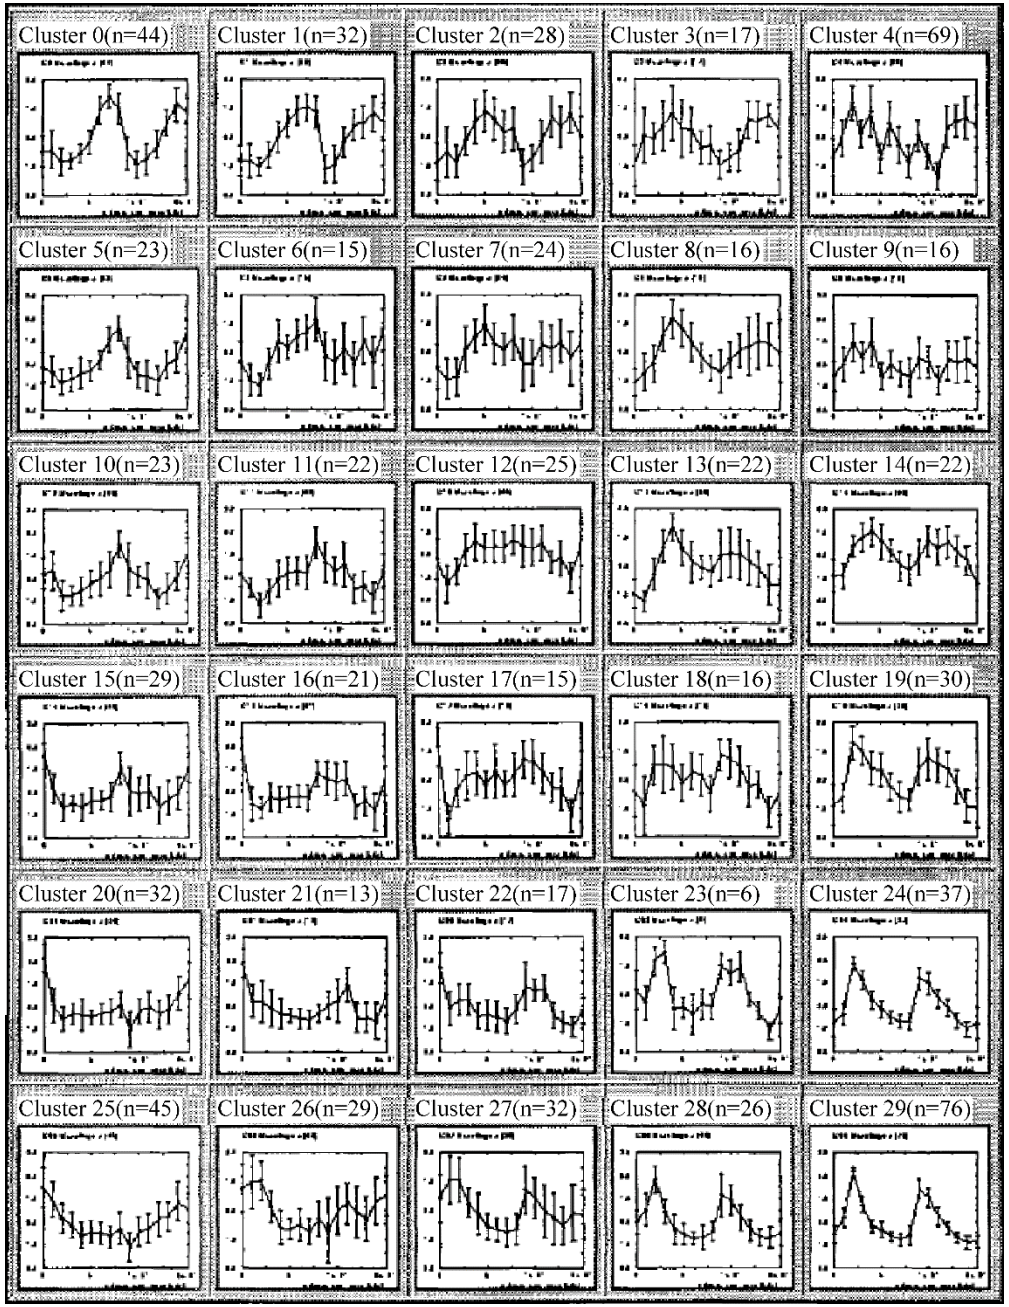
基本思路：

- 用未知样本集训练SOM
- 计算象密度图
- 根据象密度图划分聚类(把结点代表的小聚类合并)

特点：

- 对数据分布形状少依赖性
- 可反映真实存在的聚类数目
- 尤其适合人机合作分析(高维数据的有效二维显示)
- 数学上待研究的问题多：　象密度与样本分布密度之间的关系？
  拓扑保持特性？
  如何在SOM平面上聚类？

SOM应用举例


Cluster 0(n=44)
Cluster 1(n=32)
Cluster 2(n=28)
Cluster 3(n=17)
Cluster 4(n=69)
Cluster 5(n=23)
Cluster 6(n=15)
Cluster 7(n=24)
Cluster 8(n=16)
Cluster 9(n=16)
Cluster 10(n=23)
Cluster 11(n=22)
Cluster 12(n=25)
Cluster 13(n=22)
Cluster 14(n=22)
Cluster 15(n=29)
Cluster 16(n=21)
Cluster 17(n=15)
Cluster 18(n=16)
Cluster 19(n=30)
Cluster 20(n=32)
Cluster 21(n=13)
Cluster 22(n=17)
Cluster 23(n=6)
Cluster 24(n=37)
Cluster 25(n=45)
Cluster 26(n=29)
Cluster 27(n=32)
Cluster 28(n=26)
Cluster 29(n=76)

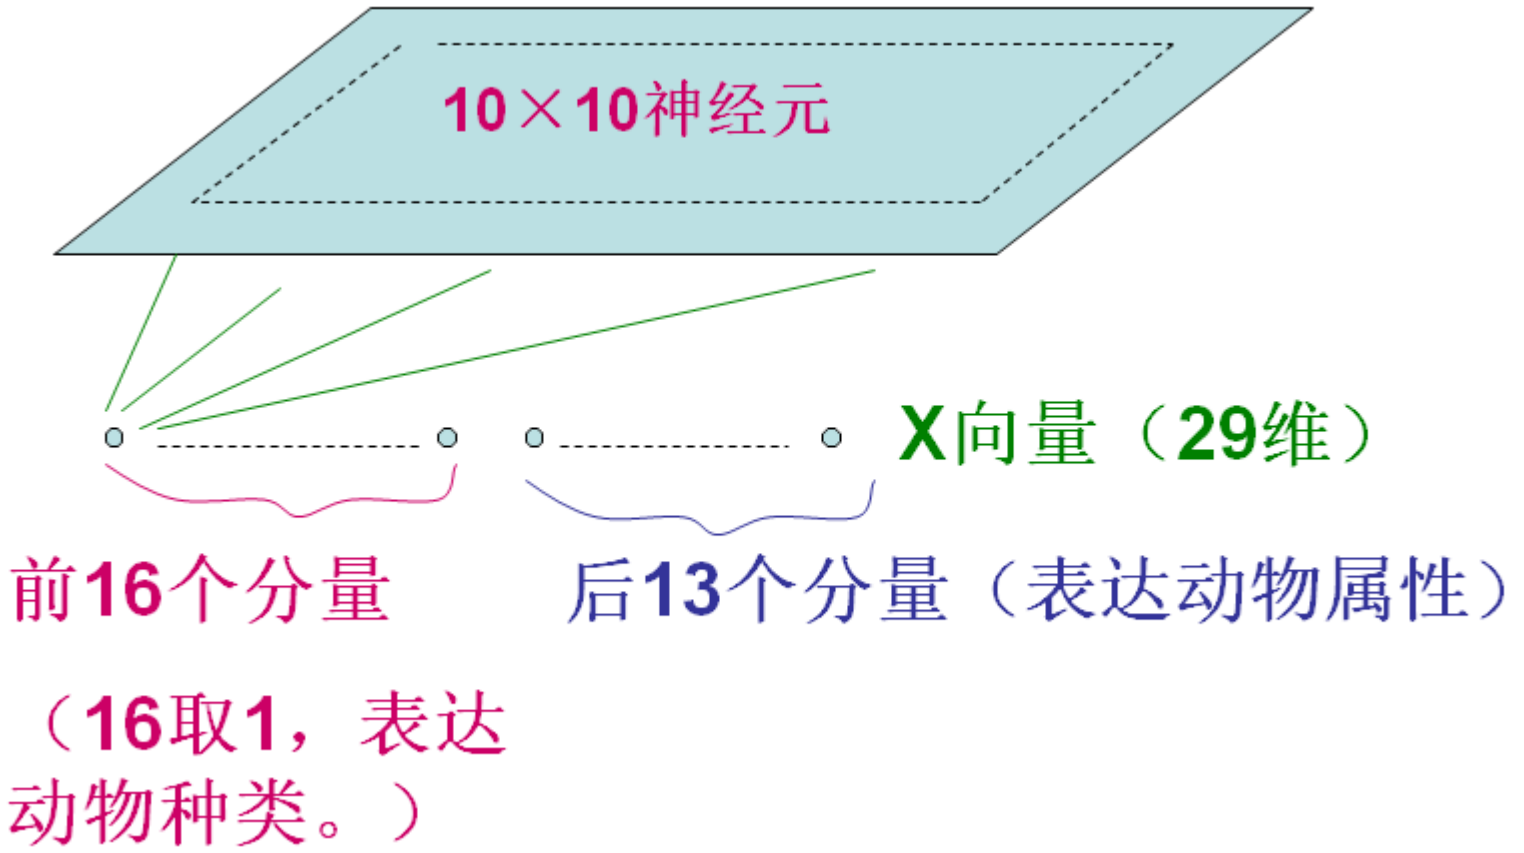
SOM应用举例

1989年Kohonen给出一个SOM网的著名应用实例，即把不同的动物按其属性映射到二维输出平面上，使属性相似的动物在SOM网输出平面上的位置也相近。训练集选了16种动物，每种动物用一个29维向量来表示。前16个分量构成符号向量（不同的动物进行16取1编码），后13个分量构成属性向量，描述动物的13种属性的有或无（用1或0表示）。

动物 / 属性	鸽子	母鸡	鸭	鹅	猫头鹰	隼	鹰	狐狸	狗	狼	猫	虎	狮	马	斑马	牛
小	1	1	1	1	1	1	0	0	0	0	1	0	0	0	0	0
中	0	0	0	0	0	0	1	1	1	1	0	0	0	0	0	0
大	0	0	0	0	0	0	0	0	0	0	0	1	1	1	1	1
2只腿	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0
4只腿	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1
毛	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1
蹄	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	1
鬃毛	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	0
羽毛	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0
猎	0	0	0	0	1	1	1	1	0	1	1	1	1	0	0	0
跑	0	0	0	0	0	0	0	0	1	1	0	1	1	1	1	0
飞	1	0	0	1	1	1	1	0	0	0	0	0	0	0	0	0
泳	0	0	1	1	0	0	0	0	0	0	0	0	0	0	0	0

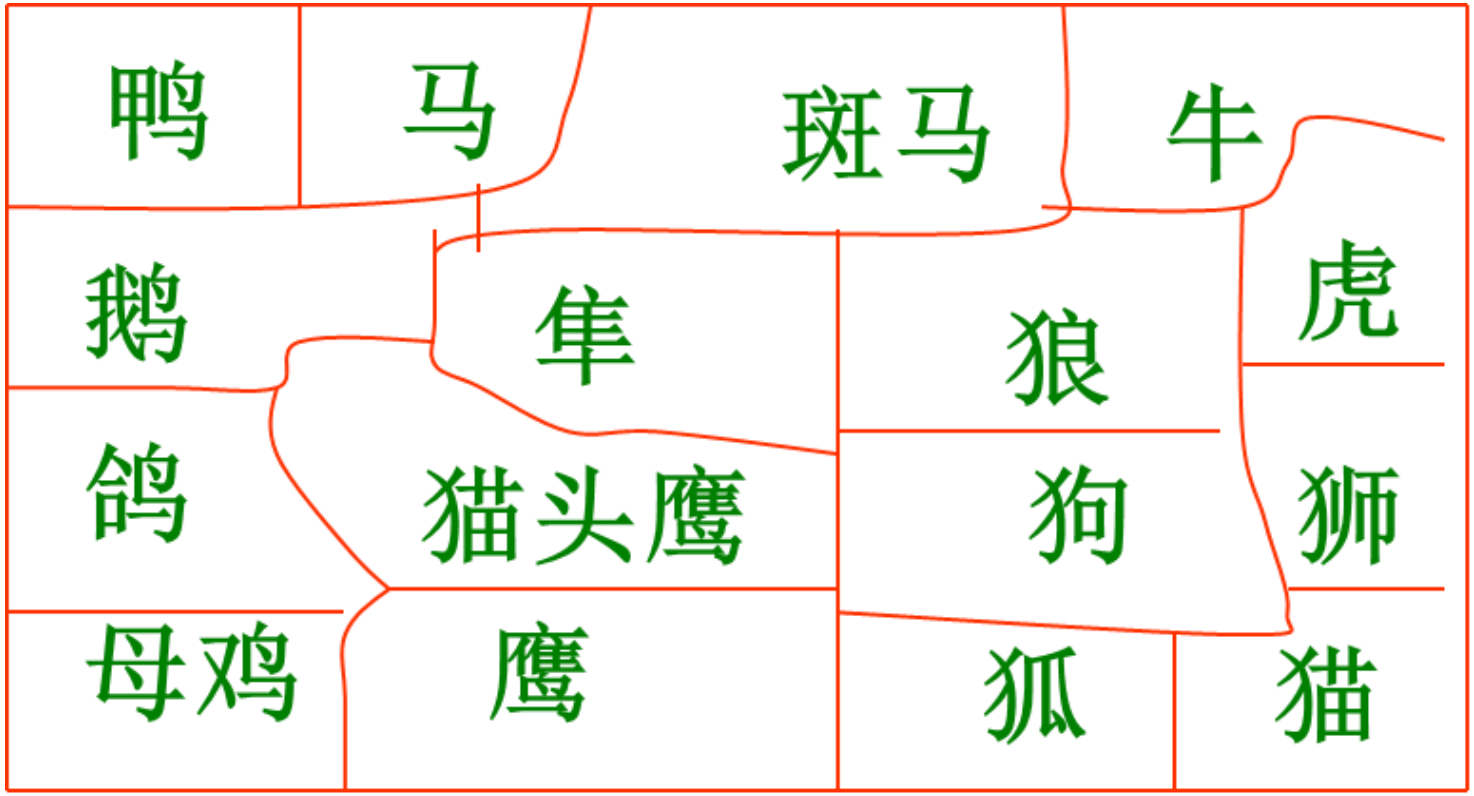
SOM应用举例

1989年Kohonen给出一个SOM网的著名应用实例，即把不同的动物按其属性映射到二维输出平面上，使属性相似的动物在SOM网输出平面上的位置也相近。训练集选了16种动物，每种动物用一个29维向量来表示。前16个分量构成符号向量（不同的动物进行16取1编码），后13个分量构成属性向量，描述动物的13种属性的有或无（用1或0表示）。



SOM应用举例

SOM网输出平面上有10×10个神经元，16个动物模式轮番输入训练，最后输出平面呈现16种动物属性特征映射，属性相似的挨在一起，实现了特征的有序分布。（实现这个图只需要判断每个神经元的模式和哪个样本最近）



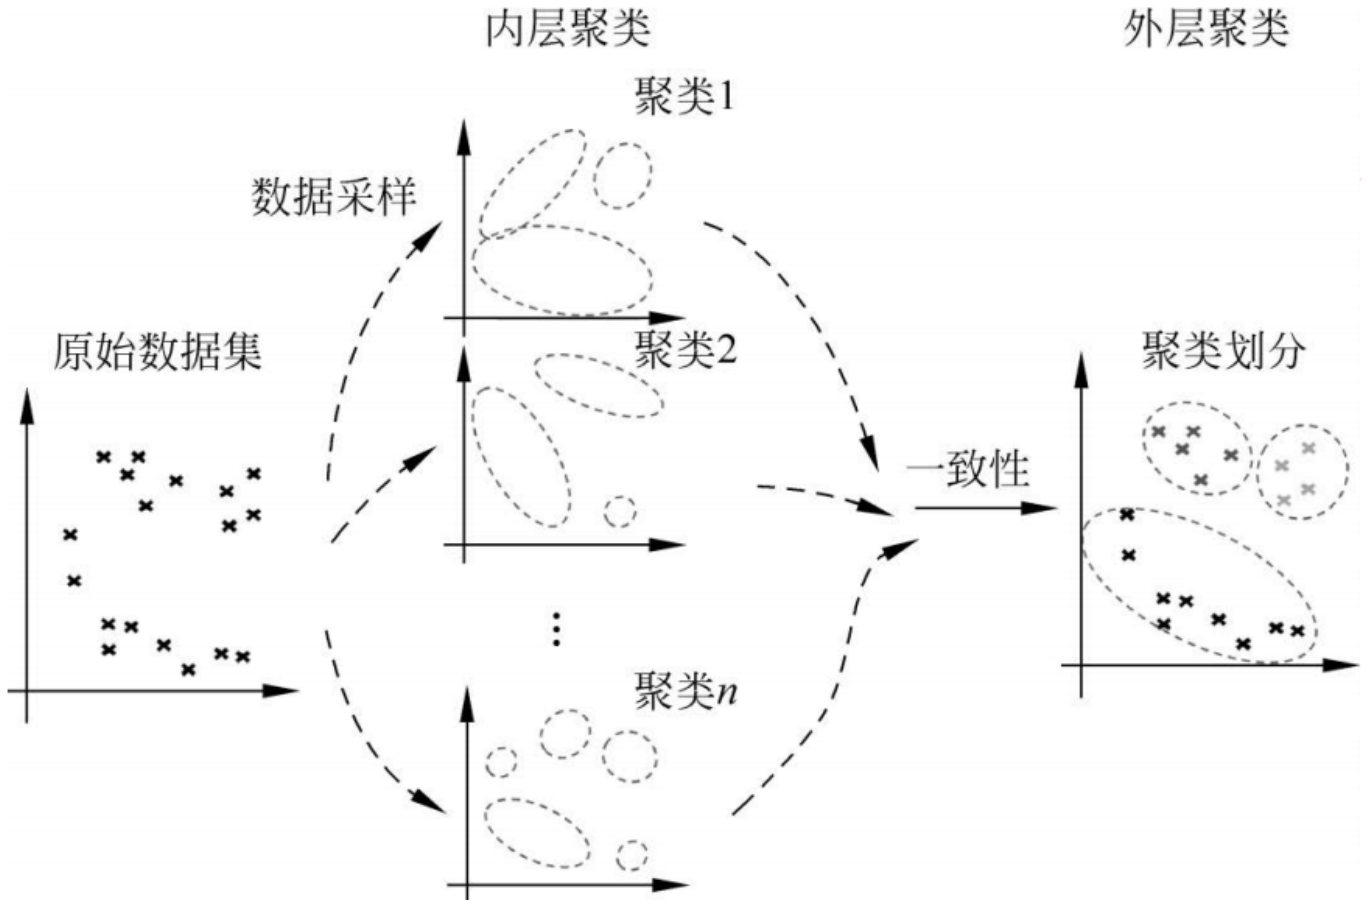
从高维空间样本向低维空间的映射，SOM网的输出层相当于低维特征空间。

将高维空间的样本在保持拓扑结构不变的条件下投影到低维的空间，在这方面SOM网具有明显的优势。无论输入样本空间是多少维，其模式都可以在SOM网输出层的某个区域得到相应。SOM网经过训练以后，在高维空间输入相近的样本，其输出相应的位置也相近。

8.10 一致聚类方法

基本思路：

通过不同的数据抽样和不同方法进行多次聚类，再对结果进行合并，将在大多数结果中一致的结果作为最终的聚类划分依据



原始数据集：$D = \{x_1, x_2, \ldots, x_N\}$

数据子集： $D^{(1)}, \ldots, D^{(S)}$　　(S次采样)

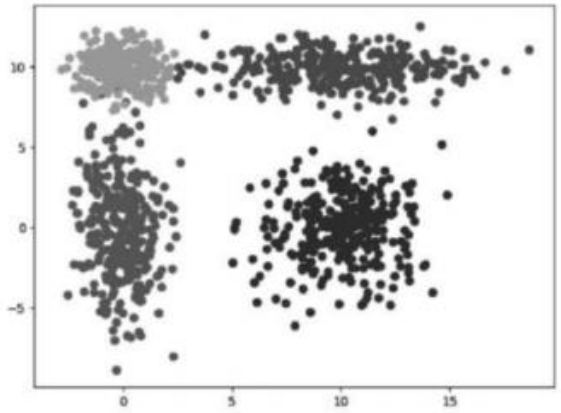
连接矩阵$M_{(s)}^{(K)}$：表示在$D^{(S)}$上将数据聚类为K类时，样本i和样本j处于同一个类中，则$M_{(s)}^{(K)}(i,j) = 1$；否则$M_{(s)}^{(K)}(i,j) = 0$

聚类数为K时的整体一致性矩阵$M^{(K)}$:

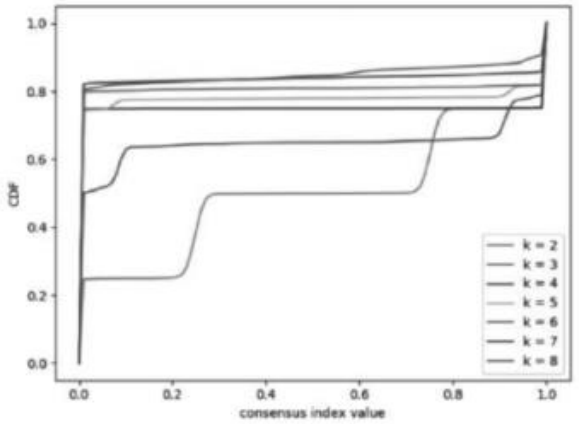
$$M^{(K)}(i,j) = \frac{\sum_s M_{(s)}^{(K)}(i,j)}{\sum_s I_s(i,j)}$$

其中$I_{(s)}$为指示矩阵，但样本i和j都出现在数据集$D^{(S)}$中时， $I_s(i,j) = 1$

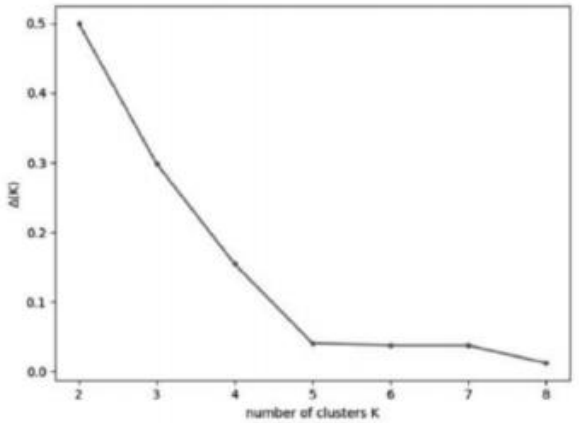
一致性矩阵$M^{(K)}$是对称矩阵，可以可视化观察聚类结果的稳定性



(a) 仿真数据
k=2



(b) CDF曲线
k=4



(c) Δ(K)随K的变化
k=8



(d) $M^{(K)}$矩阵的可视化分析

关于外层聚类结果

定义新的距离度量矩阵$Dist^{(K)} = \left(1 - M^{(K)}\right)$，在此距离矩阵进行聚类，得到最终的聚类结果

关于类别数K

定义CDF函数：

$$\mathrm{CDF}^{(K)}(t) = \frac{\sum_{i<j} I\left\{M^{(K)} \leq t\right\}}{N(N-1)/2}$$

若一致性高，则CDF的取值在t靠近0和1附近变化较大，中间平稳。

若一致性差，则CDF的取值随着t增大缓慢上升。

比较CDF函数曲线的线下面积AUC来确定聚类数K

$$A(K) = \sum_{i=2}^{N(N-1)/2} [x_i - x_{i-1}] CDF^{(K)}(x_i)$$

其中$\{x_1, x_2, \ldots, x_{\frac{1}{2}N(N-1)}\}$是对$M^{(K)}$元素取值从小到大的排序

定义

$$\Delta(K) = \begin{cases} A(K), & K = 2 \\ \dfrac{A(K+1) - \hat{A}^{(K)}}{\hat{A}^{(K)}}, & K > 2 \end{cases}$$

其中$\hat{A}^{(K)} = \max_{k \in \{2,\ldots,K\}} A(k)$

取$\Delta(K)$趋近稳定前一时刻的K

算法伪代码：

输入：

样本集 $D = \{x_1, x_2, \ldots, x_N\}$

可能的聚类类别数集合 $C = \{c_1, c_2, \ldots, c_{max}\}$

样本重采样策略函数 Resample( )

内层聚类算法 Cluster_i( )

外层聚类算法 Cluster_o( )

数据集重采样次数S

过程：

for $K \in C$ *do*

$M \leftarrow \emptyset$ # 初始化连接矩阵为空

for $s = 1,2,\ldots,S$ *do*

$D^{(s)} \leftarrow Resample(D)$ # 获得重采样数据集

$M_{(s)}^{(K)} \leftarrow Cluster_i\left(D^{(s)}, K\right)$ # 在重采样数据集上的聚类划分

$M^{(K)} \leftarrow M^{(K)} \cup M_{(s)}^{(K)}$ # 将$M_{(s)}^{(K)}$记录存储到$M^{(K)}$

end

$M^{(K)} \leftarrow$ 通过 $M^{(K)} = \left\{M_{(1)}^{(K)}, M_{(2)}^{(K)}, \ldots, M_{(s)}^{(K)}\right\}$计算一致矩阵$M^{(K)}$

end

通过对$\{M^{(2)}, M^{(3)}, \ldots, M^{(c_{max})}\}$的计算分析得到最优的聚类数取值$\hat{K}$

构建距离矩阵$\left(1 - M^{\hat{K}}\right)$，通过外层聚类算法Cluster_o$\left(1 - M^{\hat{K}}\right)$将数据集合D划分到各聚类中

输出：

聚类数$\hat{K}$以及聚类簇划分结果

8.11 聚类有效性

内部有效指标：

内部有效指标主要基于数据集的集合结构信息从紧致性、分离性、连通性和重叠度等方面对聚类划分进行评价。

（1）邓恩（Dunn）指标：

$$DVI = \frac{\min\limits_{0<m\neq n<K}\left\{\min\limits_{\forall x\in\Omega}\{\|x_i - x_j\|\}\right\}}{\max\limits_{0<m<K}\max\limits_{0<n<K}\{\|x_i - x_j\|\}}$$

Dunn 指标计算任意两个簇元素的最短距离(类间)除以任意簇中的最大距离(类内)。DVI越大意味着类间距离越大，同时类内距离越小。缺点:对离散点的聚类测评很高、对环状分布测评效果差。

（2）轮廓系数 (Silhouette Coefficient)：

轮廓系数是用于评估聚类质量的一个度量指标，它综合考虑了数据点与同簇内其他点的紧密度（凝聚度）以及与最近簇的分离度

（3）戴维森堡丁指数 (Davies-Bouldin Index)：

戴维森堡丁指数 (DBI) 用于评估聚类的紧密度和分离度。它通过计算簇之间的相似性来量化聚类结果的好坏。DBI的值越小，表示聚类效果越好，因为簇的分离度高且簇内的点紧密

外内部有效指标：

（1）标准互信息NMI（Normalized Mutual Information）：

用于衡量两个数据集（如聚类结果和真实标签）之间的相似度的指标。它来源于信息论，衡量的是两个变量之间共享的信息量。

（2） F-measure指标：

F-measure（或F1-score）是聚类评估中常用的综合性指标，它结合了准确率（precision）和召回率（recall）来衡量聚类效果

（3）Rand指数：

Rand指数 是一种用于比较两个聚类结果的相似性的指标。它考虑了数据点对的不同可能关系，并计算真实标签和聚类结果的一致性

（4）Jaccard指数：

Jaccard指数 是衡量两个集合相似性的指标，通常用于衡量两个聚类结果之间的相似度

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|}$$

8.12 讨论

- 样本特征各分量的尺度比例会影响聚类结果
- 非监督学习结果的解释

